

# Analisis Sentimen Multi-Class pada Sosial Media menggunakan metode *Long Short-Term Memory* (LSTM)

Yuliya Astari<sup>#1</sup>, Afiyati<sup>\*2</sup>, Saddam Wahib Rozaqi<sup>#3</sup>

<sup>#\*</sup>Teknik Informatika, Ilmu Komputer, Universitas Mercu Buana

Jl. Raya Meruya Selatan, Kembangan, Jakarta, 11650

<sup>1</sup>41516120007@student.mercubuana.ac.id

<sup>2</sup>afiyati.reno@mercubuana.ac.id

<sup>3</sup>41516120084@student.mercubuana.ac.id

**Abstrak**—Perkembangan teknologi khususnya dalam internet dan media sosial dapat menjadikan subjek penelitian yang sangat penting dalam memperoleh informasi, karena banyaknya jumlah informasi di dalam sebuah teks yang terdapat pada sosial media. Dalam beberapa tahun terakhir, telah terjadi peningkatan penelitian terhadap analisis sentimen pada teks ulasan maupun cuitan agar dapat mengetahui polaritas yang dihasilkan dari sosial media. Masih sedikit penelitian yang menerapkan metode deep learning dengan algoritma *Long Short-Term Memory* (LSTM) untuk menganalisa sentimen multiclass pada teks berbahasa Indonesia. Penelitian ini bertujuan untuk menganalisa emosi bersifat positif maupun negatif pada teks sosial media menggunakan pendekatan klasifikasi informasi yang ada pada teks dan membaginya menjadi 8 kelas yang berbeda dengan menggunakan metode LSTM. Dataset langsung diambil dan dikumpulkan dari tulisan pengguna pada media sosial. Dalam pengujian metodel LSTM ini dihasilkan perhitungan dari nilai akurasi, exactness, review, f-measure. Pada hasil pengolahan metode LSTM menunjukan cukup baik dengan uji coba sebanyak 5 kali dengan nilai akurasi tertinggi 91,9% dan nilai rata-rata dari multiclass mendapatkan hasil 89,45%.

**Kata kunci** — analisa sentimen, teks, klasifikasi, *Long Short-Term Memory*, sosial media, multiclass

## I. PENDAHULUAN

Pada era digital seperti ini kebanyakan orang melakukan kegiatan komunikasi melalui media sosial [1]. Para pengguna media sosial dapat menuliskan opini, pendapat atau pengungkapan perasaan yang biasanya diungkapkan secara verbal [2]. Penelitian tersebut juga menyatakan bahwa setiap tulisan atau kicauan seseorang pada media sosial seringkali juga berisi tentang informasi ataupun kondisi emosi seseorang dalam menulis sebuah cuitan [3]. Bahkan ketika seseorang yang tidak secara khusus menuliskan tentang status emosi pribadi mereka, tetap saja tulisan pada media sosial dapat mencerminkan suasana hati penulis. Dengan demikian setiap

postingan dapat dianggap sebagai tempat menyalurkan suasana hati atau emosi yang instan [2].


Penelitian ini memfokuskan perhatian pada setiap sentimen, perasaan atau emosi. Sentimen bisa digambarkan sebagai emosi, keputusan, pendapat atau ide-ide sebagai sumber informasi utama. Informasi berupa teks ini digunakan untuk menganalisa konsep ekspresi sentimen dan menghitung klasifikasinya [3]. Untuk mengetahui sifat emosi itu sendiri diperlukan sebuah metode pada machine learning yang dapat digunakan untuk mendeteksi ataupun klasifikasi sentiment [4]. Pada prinsipnya analisis sentimen merupakan bagian dari Natural Language Processing (NLP) dan Machine Learning [5]. Cara kerjanya adalah dengan melakukan klasifikasi terhadap kata positif, negatif dan netral. Sebuah penelitian telah menganalisa pendapat seseorang, jenis sentimen, evaluasi, penilaian, sikap, dan emosi terhadap entitas produk, jasa, organisasi, individu, masalah, peristiwa atau suatu topik [3].

Sebelumnya ada banyak penelitian mengenai analisis sentimen juga sudah pernah dilakukan yaitu untuk melakukan review novel menggunakan metode *Long Short-Term Memory* (LSTM). Berdasarkan hasil pengujian yang dilakukan memperlihatkan bahwa metode LSTM memiliki hasil akurasi 72.85%, presisi 73%, recall 72%, dan f-measure 72%. Penelitian tersebut membandingkan LSTM dengan hasil akurasi dari metode Naïve Bayes dengan nilai akurasi 67.88%, presisi 69%, recall 68%, dan f-measure 68%. Penelitian ini menunjukkan performansi metode LSTM lebih baik daripada metode Naïve Bayes [6]. Pada penelitian selanjutnya yaitu melakukan klasifikasi teks multilebel pada artikel berita menggunakan metodel *Long Short-Term Memory* (LSTM), mendapatkan hasil akurasi tertinggi model kelima dengan 95,38% sedangkan nilai rata-rata presisi, recall, dan F1-score 95% [7]. dan yang terakhir penelitian yang terkait adalah Multiclass deteksi beban kerja mental menggunakan *Long Short-Term Memory* dengan mendapatkan akurasi rata-rata convolutional neural network (CNN) and LSTM 87,45% dan 89,31% masing-masing [8].

Oleh karena itu penulis melakukan penelitian untuk menganalisa emosi yang ditimbulkan dalam bentuk positif maupun negatif pada penggunaan sosial media, dengan pendekatan klasifikasi data ke dalam 8 kelas yang berbeda. Dengan menggunakan metode *Long Short-Term Memory*, dan implementasi dengan menganalisis akurasi klasifikasi dan presisi. Pengolahan data menggunakan bahasa pemrograman Python. Penelitian ini diharapkan dapat menjadikan penelitian lanjutan untuk membantu bidang ilmu psikologi dengan membuat aplikasi antar muka yang menganalisa emosi dari setiap kalimat pengguna pada media sosial.

## II. METODOLOGI PENELITIAN

Penelitian ini dilakukan dengan mengumpulkan sumber bacaan dari penelitian-penelitian lain dengan urutan pekerjaan dapat dilihat pada Gambar 1.




Gambar.1 Proses Metodologi Penelitian

### A. Studi Kasus

Pada penelitian ini mengambil studi kasus yang bersumber dari bidang ilmu komputer yang mengambil metode yang akan digunakan dan bidang ilmu psikologi untuk mengetahui emosi yang ada pada data tulisan pengguna sosial media. Penelitian-penelitian yang dikumpulkan adalah penelitian yang memfokuskan pada klasifikasi sentimen emosi positif dan negatif serta mengklasifikasikan data tulisan pengguna sosial media ke dalam 8 kelas sentimen yang berbeda, dan menghasilkan model dari metode *Long Short-Term Memory* (LSTM) yang paling optimal.


### B. Analisa Data

Dari data tulisan sosial media yang dapat dikumpulkan berjumlah total 400 tulisan yang selanjutnya data tulisan ini diberikan pelabelan secara manual dengan pembagian berisi 200 kelas positif dan 200 kelas negatif dapat dilihat pada Gambar 2. Jumlah data yang sama ini diharapkan tidak memberikan masalah pada keseimbangan jumlah data.



Gambar.2 Diagram Batang Jumlah Data

Selanjutnya data positif dan negatif kemudian akan diklasifikasikan menjadi 8 kelas kategori yaitu: (1) Kelas positif *courage* (keberanian), *acceptance* (penerimaan), *love* (cinta) dan *peace* (kedamaian); (2) Kalas negatif *pride* (kebanggaan), *anger* (amarah), *desire* (hasrat) dan *fear* (ketakutan). Jumlah kelas emosi yang terdiri dari 8 kelas dapat dilihat perbandingan jumlah datanya pada Gambar 3. Jumlah data kelas emosi yang tidak sama ini tidak akan memberikan masalah pada keseimbangan jumlah data karena pada penelitian ini hanya ditujukan untuk menemukan akurasi sentimen yang ada pada dataset yang ada.



Gambar.3 Diagram Batang Jumlah Emosi

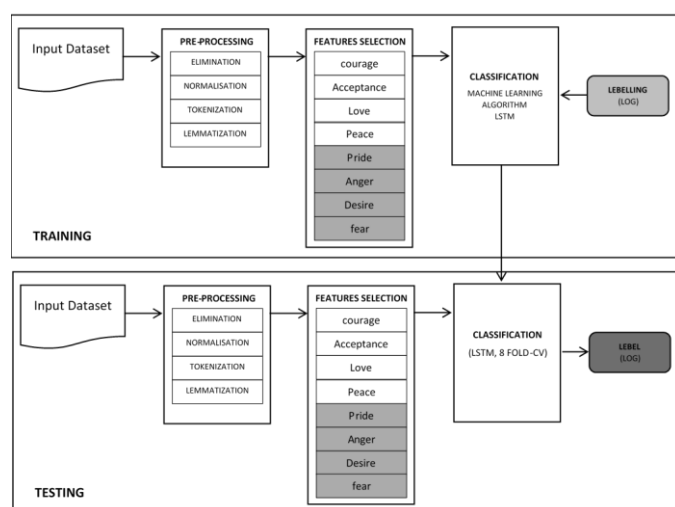
Pada Tabel 1 dapat dilihat contoh data tulisan dari media sosial yang telah diberi label kelas positif maupun negatif.

TABEL I  
DATASET CUITAN SOSIALMEDIA

No.	Teks	Kategori	Emosi
1.	Perdebatan sengit dalam hati, antara mempertahankan EGO The Wachter, dan nalar, seperti saling tarik dan saling menguasai.	acceptance (penerimaan)	Positif
2.	Ikut kuliah transendensi semalam ikut kena tepuk, kerasa sakit dan klepek2, ,	acceptance (penerimaan)	Positif
3.	Spiderman aja berani jualan pete. Laku pula. Ahhh. . kreatif itu memang harus out the box atau create the new bo	courage (keberanian)	Positif
...	...	...	...
400.	Saya pernah nggak di rumah, temen2 main ke rumah, ditemani anak kecil yang mirip saya, bahkan sebaju2 yang saya pakai hari itu mirip	fear (ketakutan)	Negatif

### C. Perancangan

Pekerjaan yang dilakukan pada penelitian ini adalah klasifikasi multi emosi dengan menggunakan metode LSTM. Gambar 4 menunjukkan diagram tahapan-tahapan perancangan penelitian untuk mengklasifikasi data yang telah dikumpulkan.



Gambar.4 Diagram Perancangan Penelitian

### III. IMPLEMENTASI

Penelitian ini menggunakan bahasa pemrograman Python untuk mengolah data, dengan mengikuti tahapan-tahapan berikut ini.

#### A. Pelabelan Data

Didalam klasifikasi hal yang utama yang harus dilakukan adalah pelabelan pada data yang benar dan akurat. Pada penelitian ini dilakukan pelabelan secara manual untuk 8 kelas yang berbeda-beda.

#### B. Data Pre-Processing

Data pre-processing adalah sebuah tahapan yang sangat penting dimana dalam melakukan proses klasifikasi data teks. Tujuan dilakukannya *data pre-processing* yaitu untuk menghilangkan *noise* atau data yang tidak dibutuhkan seperti emoji, url, angka dan untuk menyeragamkan bentuk data kata sehingga data kata dapat menjadi lebih bersih sebelum diolah pada proses selanjutnya [9].

Dari data yang didapatkan masih banyak ditemukan kata-kata yang tidak berstruktur sehingga dibutuhkan pemerosesan atau pembersihan data yang dilakukan mencakup tahapan-tahapan sebagai berikut:

- (1) mengubah semua huruf kapital menjadi huruf kecil;
- (2) menghapus data yang tergendakan;
- (3) menghilangkan symbol, angka, string ASCII, dan tanda baca seperti [ “TM “, “© “, “SM “ ];
- (4) memproses tranformasi untuk membentuk normalisasi satu kata atau proses *lemmatization*;
- (5) tokenisasi membentuk kata-kata, frase atau elemen bermakna lainnya.

#### C. Feature Selection

*Highlight Selection* atau *Feature Reduction* sebuah tahapan yang umum dilakukan pada preprocessing, bertujuan dapat memilih *include* yang sangat berpengaruh dan mengesampingkan sebuah garis besar yang tidak berpengaruh dalam melakukan suatu pemodelan atau penganalisaan suatu informasi.

#### D. Long Short-Term Memory (LSTM)

*Long Short-Term Memory* (LSTM) diperkenalkan pertamakali pada tahun 1997 yang dikenalkan oleh Hochreiter dan Schmidhuber [10]. LSTM adalah sebuah jenis dari Recurrent Neural Network (RNN). LSTM sendiri dapat menemukan lapisan tersembunyi dari setiap sel dan dirancang untuk menyimpan informasi sel sebelumnya. Metode LSTM digunakan dengan cara mengklasifikasi data secara jangka panjang dengan menyimpan pada sel memori.

Hingga penelitian ini telah dilakukan banyak dilakukan oleh para peneliti agar dapat mengembangkan Metode LSTM [11], pada metode LSTM sendiri memiliki empat komponen utama yaitu : *Input Gate* , koneksi berulang, *forget gate* dan *output gate* [12].

Berikut ini tahapan awal dalam membangun model LSTM adalah dengan mengidentifikasi suatu informasi yang tidak diperlukan lagi dan akan dihilangkah dari sebuah sel informasi. Pada proses dalam mengidentifikasi dan mengecualikan suatu

sel informasi ini diputuskan oleh fungsi *sigmoid*, yang mengambil suatu output dari model LSTM ( $h_{t-1}$ ) pada waktu berikut ( $t-1$ ) dan pada input ( $X_t$ ) memiliki waktu  $t$ . Selain itu, fungsi *sigmoid* menentukan bagian mana dari output lama yang harus dihilangkan. Fungsi itu disebut dengan *Forget gate* di mana  $f_t$  adalah *vector* dengan nilai mulai dari 0 hingga 1, sesuai dengan setiap angka dalam keadaan sel ( $C_{t-1}$ ) [12].

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Pada tahapan,  $\sigma$  berfungsi dalam *sigmoid*. Pada suatu lapisan *sigmoid* ini akan menghasilkan angka antara 0 dan 1, yang menggambarkan seberapa banyak setiap komponen harus dilewati. Pada nilai 0 mengartikan sebagai tidak ada suatu informasi yang akan diteruskan dan pada nilai 1 mengartikan semua informasi akan diteruskan [12], jika keluarannya 1 maka 1 sebagai semua data yang akan disimpan dan kebalikannya pada keluaran 0 maka semua data akan dibuang [11]. Rumus sebagai berikut :

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (1.1)$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (1.2)$$

$$O_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (1.3)$$

Pada *input gate* memiliki dua gates yang akan dilaksanakan, pertama akan ditentukan nilai yang akan diperbaharui dengan menggunakan sebuah fungsi aktivasi *sigmoid* [11]. Selanjutnya mengatur sebuah nilai dari input untuk diperbarui pada *cell state*, dapat dihitung dengan persamaan (1.1). *Forget gate* mengatur informasi mana yang akan dihapus dari *cell state*, dapat dihitung dengan persamaan (1.2) dan output gate mengatur nilai yang akan dihasilkan output sesuai dengan input dan memori pada *cell state*, dapat dihitung dengan persamaan (1.3).

Dimana  $i_t$  adalah sebuah *input gate*,  $f_t$  adalah sebuah fungsi *forget gate*, dan  $o_t$  adalah sebuah *output gate*.  $\sigma$  adalah fungsi *sigmoid*,  $W$  dan  $b$  adalah matriks bobot dan bias, masing-masing dari keadaan sel. ( $h_{t-1}$ ) merupakan *concealed state* yaitu memori pada jaringan yang terdapat di *cell state* yang merupakan nilai output sebelum orde ke  $t$  dan  $x_t$  merupakan input pada orde ke  $t$ .

$$N_t = \tanh \cdot (W_n \cdot [h_{t-1}, x_t] + b_n) \quad (1.4)$$

$$C_t = C_{t-1} \cdot f_t + N_t \cdot i_t \quad (1.5)$$

Fungsi  $\tanh$  dalam persamaan (1.4) memberikan suatu bobot pada nilai-nilai yang dilewati, memutuskan suatu tingkat kepentingannya (-1 ke 1). Dua nilai dikalikan untuk memperbarui status sel baru. Memori baru ini kemudian ditambahkan ke memori lama ( $C_{t-1}$ ) yang menghasilkan ( $C_t$ ). Parameter ( $C_{t-1}$ ) dan ( $C_t$ ) adalah keadaan sel pada waktu ( $t-1$ ) dan ( $t$ ), sedangkan  $W$  dan  $b$  adalah matriks bobot serta bias, masing-masing, dari keadaan sel.

$$h_t = O_t \cdot \tanh(C_t) \quad (1.6)$$

Pada tahapan terakhir terlihat pada persamaan di rumus (1.6) nilai output ( $h_t$ ) yang didasarkan pada sel output ( $O_t$ ) merupakan versi yang difilter. Pada awal lapisan *sigmoid* memutuskan bagian sel mana yang membuatnya menjadi output. Setelah itu pada output dari gerbang *sigmoid* ( $O_t$ ) dikalikan dengan nilai-nilai baru yang dibuat pada lapisan *tanh* dari keadaan sel ( $C_t$ ), dengan nilai berkisar antara -1 dan 1 [12].

#### E. Hasil Pembahasan

Hasil uji pada klasifikasi sentimen dari model yang digunakan, telah diukur nilai akurasi, presisi, recall, dan f-measure dari metode LSTM. Dari jumlah data yang digunakan sebanyak 400 data, yang telah diberikan pelabelan manual dan menghasilkan 200 data sentiment positif dan 200 data sentiment negatif. Pada data pelatihan yang digunakan adalah 80% dari total data, yang diproses dengan algoritma *k-fold*. Sementara 20% dari total data digunakan sebagai data pengujian.

Uji klasifikasi dilakukan dengan membandingkan setiap teks tulisan pada sosial media yang telah dilabeli secara manual dengan hasil perhitungan pada metode LSTM. Semakin besar jumlah tulisan yang sesuai dengan label yang diberikan secara manual diawal, semakin tinggi nilai akurasi, presisi, recall, dan f-measure yang diperoleh. Tabel II memperlihatkan hasil klasifikasi menggunakan metode LSTM.

TABEL II  
HASIL UJI TERNARY

Model	Train Acc	Train Loss	Val Acc	Val Loss	Epoch
LSTM	<b>0.9849</b>	<b>0.0896</b>	<b>0.6600</b>	<b>0.6928</b>	<b>20</b>
	0.9950	0.0095	0.6550	0.9949	40
	1.0000	0.0039	0.6600	0.8360	60
	1.0000	0.0016	0.6300	0.2596	80
	1.0000	0.0010	0.6600	1.1996	100

TABEL III  
CONFUSION MATRIX TERNARY

Fold Pertama				
Kelas	Precision	Recall	F1-Score	Support
Negatif	0.62	0.76	0.68	96
Positif	0.72	0.57	0.63	104
Fold Kedua				
Kelas	Precision	Recall	F1-Score	Support
Negatif	0.62	0.72	0.67	96
Positif	0.70	0.60	0.64	104
Fold Ketiga				
Kelas	Precision	Recall	F1-Score	Support
Negatif	0.63	0.69	0.66	96
Positif	0.69	0.63	0.63	104
Fold Keempat				
Kelas	Precision	Recall	F1-Score	Support
Negatif	0.59	0.74	0.66	96
Positif	0.69	0.53	0.60	104

Fold Kelima				
Kelas	Precision	Recall	F1-Score	Support
Negatif	0.62	0.73	0.67	96
Positif	0.70	0.60	0.65	104

Setelah melakukan lima kali uji coba, maka akurasi yang dihasilkan dapat dilihat pada Tabel III. Dengan mengubah *epoch* yang berbeda-beda, terlihat hasil akurasi yang paling baik pada data training 98% dan testing 66% dengan melakukan sebanyak 20 kali *epoch*.

TABEL IV  
HASIL UJI COBA MULTICLASS

Model	Train Acc	Train Loss	Val Acc	Val Loss	Epoch
LSTM	0.5729	1.3887	0.2400	2.0309	20
	<b>0.9196</b>	<b>0.5163</b>	<b>0.2550</b>	<b>2.1675</b>	<b>40</b>
	0.9950	0.1345	0.2400	2.6501	60
	0.9900	0.0440	0.2450	2.5974	80
	0.9950	0.0284	0.2150	2.6929	100

TABEL V  
CONFUSION MATRIX MULTICLASS

Kelas	Precision	Recall	F1-Score	Support
Desire (hasrat)	0.32	0.30	0.31	43
acceptance (Penerimaan)	0.42	0.15	0.22	33
courage (keberanian)	0.17	0.07	0.10	14
peace (kedamaian)	0.17	0.10	0.12	31
fear (ketakutan)	0.14	0.11	0.12	19
pride (kebanggaan)	0.00	0.00	0.00	10
anger (amarah)	0.20	0.03	0.06	30
love (cinta)	0.50	0.05	0.09	20

Hasil klasifikasi 8 kelas dapat dilihat pada Tabel IV dimana diperoleh nilai akurasi untuk data training 91,9% dan data testing 25,50% dengan melakukan sebanyak 40 kali *epoch*. Sedangkan untuk 8 kelas multi matrix diperoleh hasil yang dapat dilihat pada Tabel V. Klasifikasi 8 kelas terlihat nilai presisi untuk emosi *acceptance* sebesar 42% dan nilai recall tertinggi pada emosi *desire* yaitu 30% dan nilai F-score tertinggi diperoleh pada emosi *desire* yaitu 31%. Dengan menggunakan jumlah masing-masing data yang diterangkan pada bagian column terakhir atau dicolumn *support* ini dapat memperjelas bagian pada setiap elemen jumlah data.

#### IV. KESIMPULAN

Penelitian analisis sentimen dimana data diklasifikasikan ke dalam 8 kelas yang berbeda telah dilakukan. Hasil yang diperoleh menunjukkan beberapa potensi akurasi pada data ternary dengan nilai akurasi yang baik pada data training 98% dan data testing 66%, dengan melakukan sebanyak 20 kali *epoch*. Sedangkan untuk hasil akurasi ujicoba multiclass dengan 8 label yang berbeda menghasilkan data training dengan nilai 91,9% dan data testing dengan nilai akurasi 25,5%, dengan melakukan sebanyak 40 kali *epoch*, ini memberikan hasil bahwa penelitian ini mendapat nilai rata-rata akurasi dari multiclass 89,45%.

#### REFERENSI

- [1] R. Habibi, D. B. Setyohadi, and E. Wati, "Analisis Sentimen Pada Twitter Mahasiswa Menggunakan Metode Backpropagation," *J. Inform.*, vol. 12, no. 1, pp. 103–109, 2016, doi: 10.21460/inf.2016.121.462.
- [2] F. R. Hartono, Y. A. Sari, and P. P. Adikara, "Pembangkitan Aturan Pengenalan Emosi Pada Twitter Menggunakan Metode Fuzzy-C Means," *J. Pengemb. Teknol. Inf. dan Ilmu Komput.*, vol. 2, no. 10, pp. 3258–3264, 2018.
- [3] Y. Cahyono, "Analisis Sentiment pada Sosial Media Twitter Menggunakan Naïve Bayes Classifier dengan Feature Selection Particle Swarm Optimization dan Term Frequency," *J. Inform. Univ. Pamulang*, vol. 2, no. 1, p. 14, 2017, doi: 10.32493/informatika.v2i1.1500.
- [4] M. Suhasini and S. Badugu, "Two Step Approach for Emotion Detection on Twitter Data," *Int. J. Comput. Appl.*, vol. 179, no. 53, pp. 12–19, 2018, doi: 10.5120/ijca2018917350.
- [5] R. Abidin, E. Sedyono, and S. Y. joko Prasetyo, "Analisis Data Status Di Facebook Untuk Merekomendasikan Produk Makanan Ringan Menggunakan Tf-Idf Dan Document Weighting," *Simetris J. Tek. Mesin, Elektro dan Ilmu Komput.*, vol. 9, no. 2, pp. 977–984, 2018, doi: 10.24176/simet.v9i2.2518.
- [6] M. A. Nurrohmat and A. SN, "Sentiment Analysis of Novel Review Using Long Short-Term Memory Method," *IJCCS (Indonesian J. Comput. Cybern. Syst.)*, vol. 13, no. 3, p. 209, 2019, doi: 10.22146/ijccs.41236.
- [7] W. K. Sari, D. P. Rini, R. F. Malik, and I. S. B. Azhar, "Klasifikasi Teks Multilabel pada Artikel Berita Menggunakan Long Short-Term Memory dengan Word2Vec," vol. 1, no. 10, pp. 276–285, 2017.
- [8] U. Asgher *et al.*, "Enhanced Accuracy for Multiclass Mental Workload Detection Using Long Short-Term Memory for Brain-Computer Interface," *Front. Neurosci.*, vol. 14, no. June, pp. 1–19, 2020, doi: 10.3389/fnins.2020.00584.
- [9] M. A. Fatmawati, "Klasifikasi Keluhan Menggunakan Metode Support Vector Machine (SVM) (Studi Kasus : Akun Facebook Group iRaise Helpdesk)," *J. CoreIT*, vol. 3, no. 1, pp. 24–30, 2017, doi: 10.1007/s00766-002-0156-7.
- [10] L. Wiranda and M. Sadikin, "Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma," *J. Nas. Pendidik. Tek. Inform.*, vol. 8, no. 3, pp. 184–196, 2019.
- [11] M. Wildan, P. Aldi, and A. Aditsania, "Analisis dan Implementasi Long Short Term Memory Neural Network untuk Prediksi Harga Bitcoin," *e-Proceeding Eng.*, vol. 5, no. 2, pp. 3548–3555, 2018.
- [12] D. Li and J. Qian, "Text sentiment analysis based on long short-term memory," in *2016 1st IEEE International Conference on Computer Communication and the Internet, ICCCI 2016*, 2016, pp. 471–475, doi: 10.1109/CCCI.2016.7778967.