

Optimais *Deep Learning* untuk Prediksi Data Saham Di Era Pandemi Covid-19

Adhitio Satyo Bayangkari Karno ^{a,1,*}, Widi Hastomo ^{b,2}, Ervina Nisfiani ^{b,3}, Saeful Lukman ^{b,4}

^a Universitas Gunadarma, Jl. Margonda 100 Jawa Barat, Depok, Indonesia

^b Institut Teknologi dan Bisnis Ahmad Dahlan, Jl. Ciputat Raya, Tangerang Selatan, Indonesia

^b Magister Teknologi Informasi STMIK Jakarta STI&K, Jl. Radio Dalam, Jakarta, Indonesia

^b STMIK Jakarta STI&K, Jl. Radio Dalam, Jakarta, Indonesia

¹ Adh1t10.2@gmail.com; ² Widie.has@gmail.com; ³ ervinanisfiani@gmail.com; ⁴ fulman2021@gmail.com

* Penulis Koresponden

INFO ARTIKEL

Histori Artikel

Pengajuan 30-juni-2020

Diperbaiki 10-juni-2020

Diterima 28-juli-2020

Kata Kunci

Covid-19

Epoch

GRU

LSTM

RMSE

ABSTRAK (10PT)

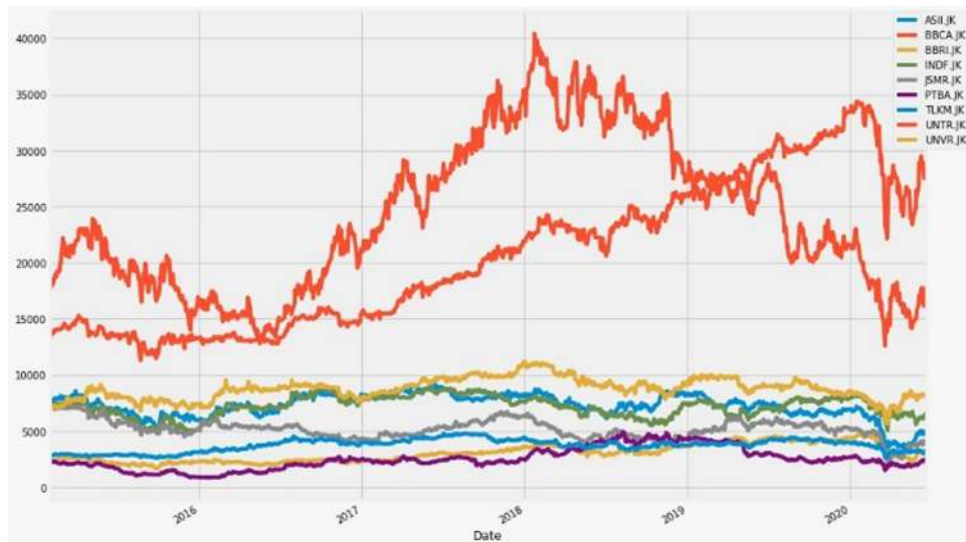
Penelitian ini bertujuan untuk menentukan nilai *epoch* yang dipergunakan dalam parameter *Deep Learning* (LSTM dan GRU) untuk menghasilkan tingkat akurasi tinggi, masih menjadi permasalahan sampai saat ini. Adanya Grafik *rmse* versus nilai *epoch* memberikan informasi penting untuk memperoleh nilai *epoch* dengan cepat dan tepat tanpa harus melakukan *try-error*. Untuk memprediksi saham bank di Indonesia (sumber data: *finance.yahoo.com*) dengan jumlah data dan kualitas yang baik, menunjukan bahwa GRU memberikan hasil lebih baik (*rmse* dan *epoch* lebih kecil) dibandingkan dengan LSTM. Dengan menggunakan nilai korelasi data antar bank, dapat diketahui sekelompok bank yang mempunyai hubungan kuat serta tingkat resiko pengembalian setiap bank.

Ini adalah artikel akses terbuka di bawah lisensi [CC-BY-SA](https://creativecommons.org/licenses/by-sa/4.0/).



1. Pendahuluan

Pasar saham merupakan salah satu komponen penting yang membentuk ekonomi suatu negara, melalui *Initial Public Offering* (IPO) suatu perusahaan dapat meningkatkan hal yang substansial untuk mengembangkan bisnis, hal ini merupakan sebuah peluang besar bagi investor untuk membeli saham baru dan menjadi pemegang saham agar mendapat manfaat ekstra dari *capital gain* dan *dividen*. Jika investor saham dapat memprediksikan tren harga saham dengan benar, ia akan mendapat *value* yang cukup besar. Namun, pasar saham saat ini tidak stabil [1], terlebih lagi dengan adanya pandemi covid-19 [2]. Dampak dari pandemi sangat mempengaruhi kinerja saham pada sektor perbankan [3],[4] dan secara *year to date* saham *blue chips* juga sangat tertekan serta mengalami *bearish*, hal ini terlihat pada grafik 1. Saham BBRI sejak awal tahun 2020 sempat mengalami penurunan sebesar 50,7% [5] lebih rendah dibandingkan indeks harga saham gabungan (IHSG), sementara *year to date* IHSG sempat mencapai 34,83% [6].



Gambar 1. Fluktuasi Saham *Blue Chip* dalam 5 Tahun Terakhir
(Sumber: Yahoo Finance)

Beberapa faktor yang memberikan dampak pada pasar saham misalnya, pandemi [7]–[9], terkait isu politik [10],[11] kebijakan pemerintah [12],[13],[14], kinerja perusahaan [10],[11], kurs rupiah terhadap dolar [17]–[19], inflasi [20]–[22] dan kejadian tak terduga lainnya secara cepat mempengaruhi harga saham bisa positif atau negatif. Akibatnya, probabilitas sangat kecil dalam memprediksi harga saham dan arahnya (kenaikan, penurunan) secara akurat, sebagai gantinya investor hanya memperkirakan tren jangka pendek yang akan datang [1]. Sebelum memutuskan untuk membeli saham, investor melakukan analisis laporan pendapatan dan pembayaran triwulanan perusahaan, memperhatikan berita penting untuk menghindari pembelian berlebihan atau saham yang berisiko tinggi.

Dalam dekade terakhir ini penelitian menggunakan mesin belajar sudah banyak dilakukan [23]–[32], namun dalam kondisi pandemi [33]–[35] seperti sekarang, dengan harga minyak dunia [36],[37] yang fluktuatif dan kondisi ekonomi [37],[38], memberikan tantangan untuk memprediksi data saham *blue chip*, karena peristiwa tak terduga sangat rentan terhadap harga saham secara cepat. Kemampuan investor terbatas untuk menganalisa secara menyeluruh volume data yang sangat besar, dalam hal ini dibutuhkan sebuah algoritma atau model yang cocok untuk membantu pengambil keputusan para investor. Karena kategori data transaksi saham merupakan data time series, maka hal ini memungkinkan menggunakan mesin belajar untuk memprediksinya [40],[41]. Karakteristik dari mesin belajar adalah mampu mengolah data yang jumlahnya besar, salah satunya yaitu saham *blue chip*.

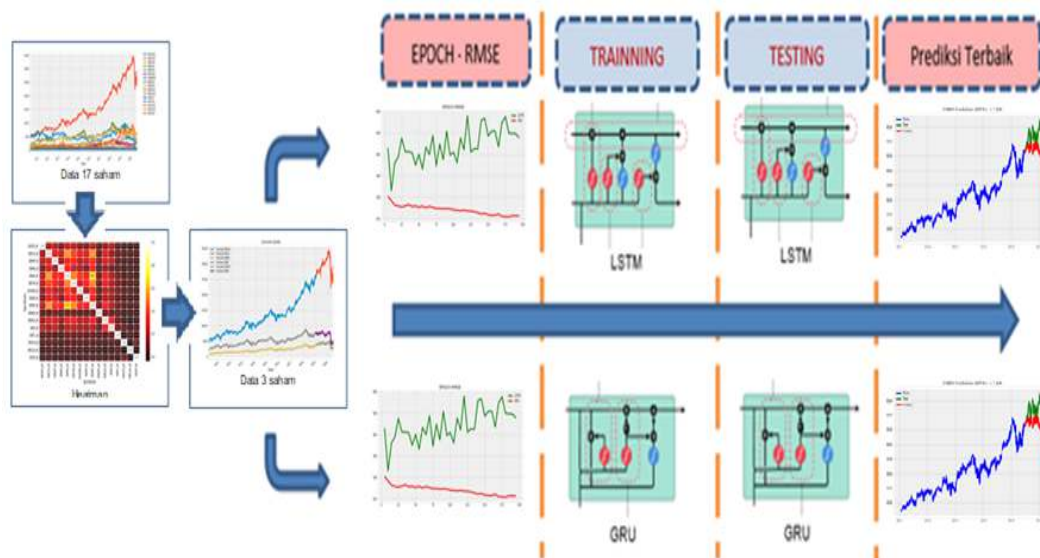
Penelitian ini akan melakukan beberapa hal; (a) mencari keterhubungan antar data saham bank di Indonesia, (b) membuat grafik epoch vs rmse dari setiap data saham bank yang dipilih, (c) serta menguji dua metode DL yaitu LSTM dan GRU untuk memprediksi saham bank di Indonesia (BBRI.JK, BBKA.JK, BMRI.JK ,). Dari data 17 saham bank di Indonesia akan dipilih tiga data untuk proses selanjutnya. Pemilihan tiga data ini berdasarkan keterhubungan data masing-masing bank, dengan melihat nilai korelasi tertinggi (r mendekati 1). Hasil perhitungan korelasi ditampilkan secara visual (*matrik heat map*), warna dan nilai numerik di *matrik heat map* menunjukkan tingkat keterhubungan antara 2 data. Data 3 bank dengan korelasi kuat adalah Bank Rakyat Indonesia (BBRI), Bank Mandiri (BMRI) dan Bank Central Asia (BBKA).

Dengan membuat kode program iteratif menggunakan input tiga data saham yang telah dipilih sebelumnya, dihasilkan tiga grafik yang menunjukkan karakteristik *rmse vs epoch*. Dari grafik ini dapat ditentukan berapa nilai *epoch* yang akan dijadikan parameter di LSTM dan GRU sehingga hasil dengan akurasi tinggi akan dengan cepat diperoleh tanpa melalui tahap coba salah (*try error*). Dari grafik *rmse* dan *epoch* juga dapat dilihat kemampuan LSTM dan GRU dengan arsitektur tertentu dan jumlah data besar seperti data saham bank. *Epoch* besar tentu akan memerlukan waktu proses lebih besar dan *epoch* kecil waktu proses lebih cepat. Dari hasil yang diharapkan adalah nilai *epoch* kecil (waktu proses cepat) dengan nilai *rmse* yang minim (akurasi tinggi). Dengan menggunakan nilai *epoch* yang tepat, hasil dengan akurasi yang baik dapat diketahui secara numeris melalui nilai *rmse* dan juga dapat dilihat secara visual grafik yang memperlihatkan historis data training, data testing dan data prediksi.

Semua kode program yang dibuat dalam penelitian ini menggunakan *python* sebagai bahasa pemrogramannya. *Python* sebagai bahasa pemrograman *open source*, menjadikan bahasa ini cepat berkembang dengan banyak paket dan *library* yang memudahkan dalam pemrograman ML. Beberapa *library python* diantaranya seperti: *numpy* yang memudahkan manipulasi dalam bentuk matrik dan vektor, *pandas* memudahkan dalam hal yang berhubungan dengan tabel, *matplotlib* untuk menampilkan data dalam bentuk grafik, *seaborn* untuk menampilkan berbagai bentuk matrik heatmap hasil korelasi data dan juga *tensorflow* dan *keras* yang sangat membantu pemrograman yang berhubungan dengan mesin *learning*.

2. Metode penelitian

Alur Penelitian secara garis besar dapat digambarkan sebagai berikut:



Gambar 2. Skenario Penelitian LSTM – GRU

2.1 Data Mentah

Gambar 3 menunjukkan data saham bank di Indonesia, sumber "*finance.yahoo.com*" mulai dari 1 Februari 2010 sampai dengan 14 Juni 2020 (tiap saham berisi 2.578 baris). Dataset ini terdiri dari 6 fitur data kolom, yaitu *High*, *Low*, *Open*, *Close*, *Volume*, *Adj Close*. Dari 6 fitur dipilih fitur *Close* yang akan dipergunakan sebagai dataset untuk proses berikutnya. Terdapat 17 data saham bank di Indonesia yang dipergunakan dalam penelitian ini yaitu: 'BBNI.JK', 'BBRI.JK', 'BBCA.JK', 'BMRI.JK', 'BBTN.JK', 'BNII.JK', 'BTPN.JK', 'INPC.JK', 'MAYA.JK', 'NISP.JK', 'MEGA.JK', 'BBKP.JK', 'BDMN.JK', 'BNBA.JK', 'BNGA.JK', 'BJBR.JK', 'AGRO.JK'.

```
In [5]: display(dataset.shape)
display(dataset.head(3))
display(dataset.tail(3))
```


(2578, 17)

Symbols	AGRO.JK	BBCA.JK	BBKP.JK	BBNI.JK	BBRI.JK	BBTN.JK	BDMN.JK	BJBR.JK	BMRI.JK	BNBA.JK	BNGA.JK	BNIL.JK
2010-02-01	112.915001	4850.0	365.883002	1829.640015	755.0	1009.369995	4515.259768	NaN	2298.469971	151.0	717.070984	283.875000
2010-02-02	113.825996	4775.0	365.883002	1829.640015	755.0	990.146973	4588.089644	NaN	2286.179932	148.0	726.893982	283.875000
2010-02-03	120.199997	4775.0	370.790004	1810.680054	755.0	1047.829956	4685.189941	NaN	2298.469971	148.0	726.893982	288.606995

Symbols	AGRO.JK	BBCA.JK	BBKP.JK	BBNI.JK	BBRI.JK	BBTN.JK	BDMN.JK	BJBR.JK	BMRI.JK	BNBA.JK	BNGA.JK	BNIL.JK	BTPN.JK	INPC.JK	M
2020-06-10	128.0	29000.0	165.0	4520.0	3030.0	1090.0	2860.0	790.0	4910.0	290.0	740.0	161.0	2150.0	52.0	
2020-06-11	125.0	28400.0	169.0	4210.0	2970.0	1025.0	2770.0	775.0	4690.0	288.0	720.0	162.0	2120.0	50.0	
2020-06-12	121.0	28350.0	206.0	4470.0	3030.0	1125.0	2730.0	785.0	4890.0	292.0	725.0	159.0	2120.0	50.0	

Gambar 3. Data Sahm Bank di Indonesia


Gambar 4 menunjukkan grafik dari fitur *Close* data 17 saham bank di Indonesia. Terlihat perbedaan yang sangat signifikan, harga penutupan saham Bank BCA (BBCA.JK) berada di posisi teratas dari seluruh saham bank di

Gambar 4. Fitur *Close* dari 17 Saham Bank di Indonesia


Dengan mengukur tingkat risiko pengambalian saham, ditampilkan di gambar 5 yang menunjukkan bahwa BCA berada di posisi tingkat risiko yang sangat kecil, sedangkan NISP, BNI dan MAYA masuk dalam kelompok berisiko besar.

2.2 Pemilihan Dataset

Agar menghasilkan penelitian yang dapat dibandingkan, maka akan dipergunakan 3 data saham bank. Pemilihan berdasarkan nilai korelasi yang tinggi antar 2 bank, yang menunjukkan hubungan kuat antar bank.



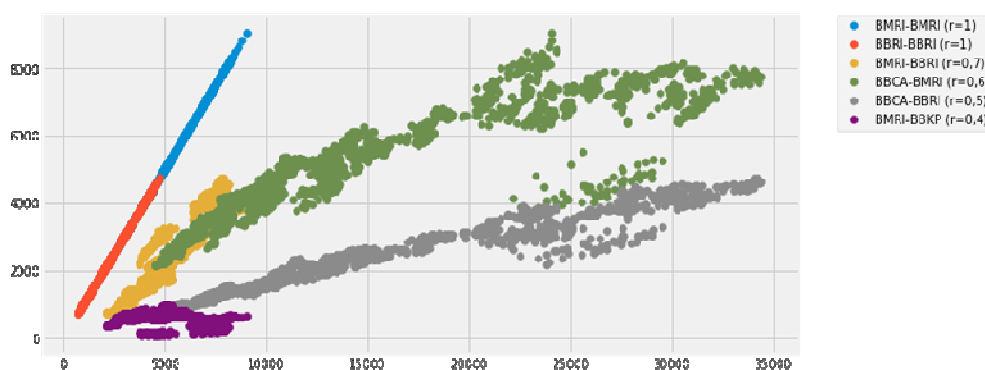
Gambar 5. Sebaran Tingkat Resiko 17 Saham Bank




Gambar 6. Matrik Korelasi 17 Saham Bank

Berdasarkan data yang ada. Hasil korelasi ditampilkan dalam bentuk visual matrik heatmap yang mudah dilihat berdasarkan tingkatan warna dan numerik yang tercantum di matrik heatmap tersebut (gambar 6). Dari matrik heatmap terlihat 3 saham bank dengan korelasi tinggi yaitu Bank Central Asia, Bank Rakyat Indonesia, dan Bank Mandiri. Sebaran 3 data saham bank ini juga dapat dilihat dengan jelas secara visual di gambar 7.

Dari 3 data saham bank tersebut, dilakukan pemisahan data untuk pelatihan sekitar 70% - 80% (2.212 data) dan sisanya untuk proses pengujian (366 data). Grafik tiga data saham terlihat di gambar 8.



Gambar 7. Scatering Tiga Data Saham bank



Gambar 8. Tiga Saham bank dengan Korelasi Kuat

2.3 Karakteristik *Epoch*

Untuk mengetahui nilai *epoch* yang tepat dipergunakan sebagai parameter LSTM dan GRU, maka akan lebih baik mengetahui karakteristik *epoch* sesuai dengan jumlah data dan desain LSTM dan GRU. Desain LSTM yang digunakan terdiri dari 1 input layer, 3 *hidden layer*, tiap *layer* terdiri dari 50 *node* dan 1 *dense layer* dengan 1 *node*. Nilai *dropout* = 0,2. GRU terdiri dari 4 layer (50 *node* tiap *layer*) dan 1 *dense layer* dengan 1 *node*. Nilai *dropout* = 0,2.

Dengan membuat program iterasi, diperoleh 3 grafik *epoch* versus *rmse* (gambar 12). Semakin besar nilai *epoch* tidak selalu menjadikan mesin lebih pintar, dan juga sebaliknya untuk *epoch* yang kecil tidak berarti mesin menjadi kurang pandai. Untuk data dengan jumlah

besar seperti data saham ini, GRU menunjukkan kemampuan lebih baik dibandingkan dengan LSTM.

3. Hasil dan Analisis

- Korelasi

Dengan menggunakan paket *library seaborn* di *python*, hasil perhitungann korelasi dapat ditunjukkan di matrik *heatmap* dalam bentuk numerik dan tingkatan warna.

$$r_{x,y} = \frac{n(\sum X_i Y_i) - (\sum X_i)(\sum Y_i)}{\sqrt{(n(\sum X_i^2) - (\sum X_i)^2)(n(\sum Y_i^2) - (\sum Y_i)^2)}} \quad (1)$$

Dimana:

$\sum X_i$ = Jumlah Data X_i

$\sum Y$ = Jumlah dari Y

$\sum X_i Y$ = Jumlah dari $X_i Y$

$\sum X_i^2$ = Jumlah dari X_i^2

- Rumus Korelasi *Pearson* [42]

Hasil numerik korelasi berupa bilangan dengan rentang -1 dan 1, dimana nilai ± 1 menunjukkan hubungan yang kuat, dan nilai 0 menunjukkan hubungan yang rendah antara dua data.

- RMSE dan MSE

Tingkat akurasi ditujukan selain secara visual dalam bentuk grafik juga dalam bentuk kuantitatif dengan mengukur nilai RMSE (*Root Mean Square Error*) dan MSE (*Mean Square Error*). Secara garis besar nilai RMSE dipahami untuk mengetahui seberapa jauh nilai kesalahan dari suatu model terhadap garis regresi linier [43]. RMSE berhubungan dengan variasi sebaran frekuensi (*frequency distribution*) dari besar kesalahan yang diperoleh, tapi tidak dengan variasi kesalahan. Sedangkan MSE merupakan kuadrat nilai dari RMSE. Jadi dapat dilihat bahwa RMSE mampu meredam perubahan kesalahan yang besar, sebaliknya MSE mampu melihat perubahan kesalahan yang kecil.

Dalam mesin *learning* biasanya MSE dipergunakan untuk mengukur kesalahan untuk setiap 1 *epoch*, dan RMSE mengukur kesalahan dalam sejumlah *epoch* tertentu.

- Rumus RMSE dan MSE

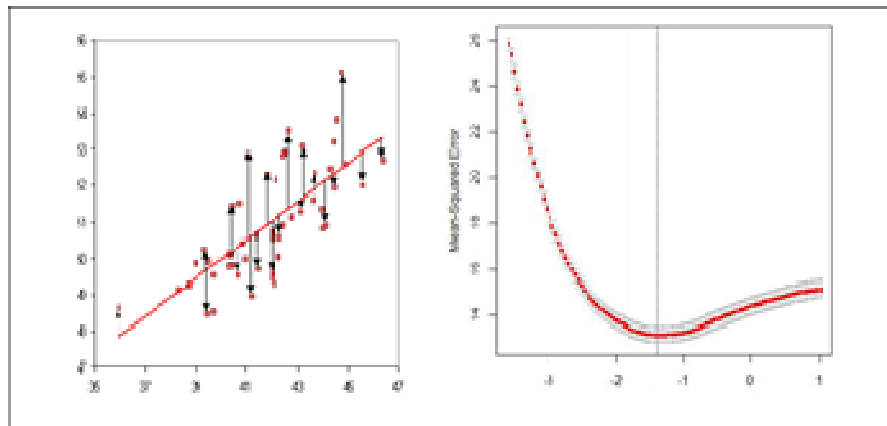
$$RMSE = \sqrt{\sum_{i=1}^n \frac{(y_i - \hat{y}_i)^2}{n}} \quad \text{dan} \quad MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Keterangan:

$\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n$ = Nilai yang diprediksi

y_1, y_2, \dots, y_n = Nilai yang diamati

n = Jumlah data yang diamati




Gambar 10. RMSE dan MSE [46]

- LSTM – GRU

Dengan terus bertambahnya jumlah *layer* dan *node* yang ada dalam suatu jaringan *neural network*, membuat suatu klasifikasi tersendiri dari mesin learning yang dinamakan *Deep Learning* (DL), seperti halnya 2 metode ML yang dipergunakan dalam penelitian ini (LSTM dan GRU).

Model mesin learning LSTM dirancang untuk mengatasi kekurangan yang ada di model sebelumnya yaitu RNN (*Recurrent Neural Network*). Masalah *vanishing gradient* yang ada di RNN disebabkan karena ketidak mampuan untuk mengatasi informasi yang panjang [44]. Berbeda dengan RNN, LSTM berbentuk sel dengan rangkaian *gate* (4 *gate*) yang cukup rumit. Dengan jumlah *gate* yang banyak dan kerumitan jaringan di LSTM tentunya juga akan berpengaruh terhadap durasi proses pengolahan data. Untuk itu maka dikembangkan lagi suatu model yaitu GRU. GRU berupa sel yang berisi hanya 2 *gate* dengan rangkaian yang lebih sederhana dibandingkan dengan LSTM. Kemampuan GRU lebih baik dari LSTM terutama untuk dataset yang jumlahnya sedikit [45].

Gambar 11. RNN, LSTM, GRU
(Sumber: Phi, Michael [47])

Formula LSTM:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

Formula GRU:

$$\tilde{s} = \sigma(x_t U^s + s_{t-1} W^s)$$

$$r = \sigma(x_t U^r + s_{t-1} W^r)$$

$$h = \tanh(x_t U^h + (s_{t-1} \circ r) W^h)$$

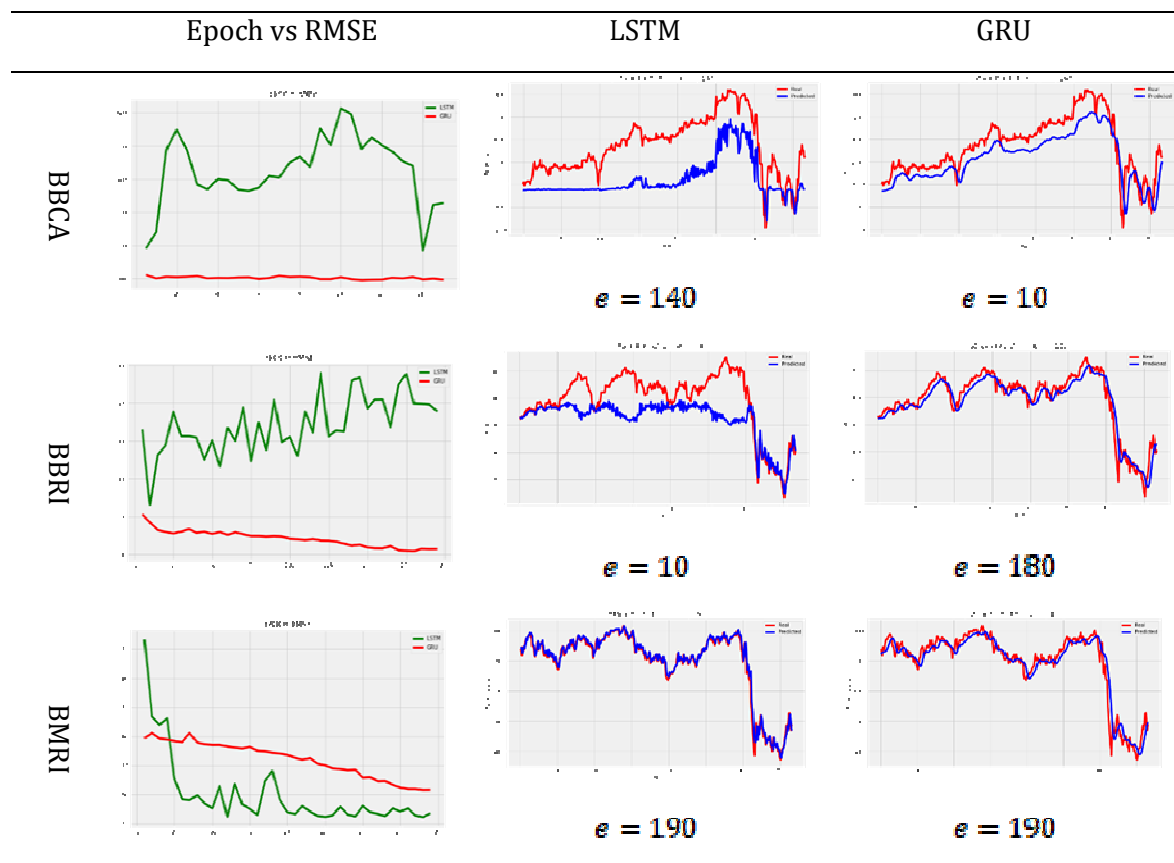
$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

$$S_t = (1-\alpha) o h + \alpha o s_{t-1}$$

$$O_t = \sigma(W_O \cdot [h_{t-1}, x_t] + b_O)$$

$$h_t = O_t * \tanh(C_t)$$

Dari gambar Grafik Epoch vs RMSE 3 negara, dipilih nilai epoch yang akan dipergunakan untuk LSTM dan GRU untuk negara Indonesia masing-masing 140 dan 10, Bangladesh adalah 10 dan 180, dan South Africa adalah 190 dan 190. Grafik output dengan nilai epoch dari 3 negara dapat dilihat pada gambar 12 di bawah ini.



Gambar 12. Grafik Output Tiga Saham Bank

4. Conclusion

1. Dari hasil korelasi 17 data saham bank di Indonesia, terdapat 3 saham bank yang mempunyai reputasi bagus dan korelasi yang tinggi, yaitu : Bank Central Asia, Bank Rakyat Indonesia, dan Bank Mandiri.
2. Karakteristik *epoch* sangat membantu dalam hal ketepatan menentukan nilai *epoch* tanpa harus melakukan proses coba salah (try error).
3. Dengan menggunakan data dengan jumlah besar seperti data saham bank yang dipergunakan dalam penelitian ini. Menunjukkan dari 3 data tersebut bahwa GRU mempunyai kemampuan yang jauh lebih baik dibandingkan LSTM.
4. Untuk lebih mengetahui karakteristik *epoch*, masih perlu dilakukan penelitian dengan kombinasi arsitektur mesin, jumlah dan jenis data yang berbeda. Dengan harapan dengan diketahuinya parameter yang tepat, dapat lebih mengoptimalkan kecepatan dan kemampuan DL dalam hal ini LSTM dan GRU.

5. Hasil dari penelitian ini dapat membantu investor sebagai *second opinion* untuk mengambil keputusan dalam investasi pada saham *blue chips* khususnya BBKA, BBRI dan BMRI hal ini juga diperkuat dari kinerja perusahaan yang terus meningkat, saham paling likuid di pasar modal dan mencetak net profit margin yang cukup besar pada tahun 2019 dari ketiga saham tersebut.
6. Disaat pandemi seperti sekarang ini, investor agar lebih berhati-hati dalam berinvestasi, semakin tinggi dampak pandemi, semakin berisiko pula harga saham dipasaran, walaupun kategori saham *blue chips*.

References

- [1] T. Berger and R. Gençay, "Short-run wavelet-based covariance regimes for applied portfolio management," *J. Forecast.*, no. August 2019, pp. 642–660, 2020.
- [2] A. Abbas *et al.*, "Inovbiz of COVID-19 : Evidence from Indonesia," vol. 8, pp. 72–76, 2020.
- [3] R. Baldwin and B. W. di Mauro, *Mitigating the COVID Economic Crisis: Act Fast and Do Whatever It Takes*. 2020.
- [4] M. A. Ruiz Estrada, E. Koutronas, and M. Lee, "Stagpression: The Economic and Financial Impact of COVID-19 Pandemic," *SSRN Electron. J.*, 2020.
- [5] Akhmad Suryahadi, "Saham perbankan blue chips berguguran, saatnya untuk beli?," 2020. [Online]. Available: <https://investasi.kontan.co.id/news/saham-perbankan-blue-chips-berguguran-saatnya-untuk-beli>. [Accessed: 22-Jun-2020].
- [6] Lona Olivia and Merdy Pasaribu, "Asing Jual Saham, IHSG Anjlok 5,2%," 2020. [Online]. Available: <https://www.beritasatu.com/ekonomi/610631-asing-jual-saham-ihsg-anjlok-52>. [Accessed: 24-Jun-2020].
- [7] M. Personal and R. Archive, "Direct and Indirect Effects of COVID-19 Pandemic on Implied Stock Market Volatility : Evidence from Panel Data Analysis," no. 100020, 2020.
- [8] N. Fernandes, "Economic effects of coronavirus outbreak (COVID-19) on the world economy Nuno Fernandes Full Professor of Finance IESE Business School Spain," *SSRN Electron. Journal, ISSN 1556-5068, Elsevier BV*, pp. 0–29, 2020.
- [9] L. Elliott, "Spillover of COVID-19: Impact on the Global Economy," *SSRN Electron. J.*, no. 99850, 2020.
- [10] T. I. Eldomiaty, M. Anwar, N. Magdy, and M. N. Hakam, "Robust examination of political structural breaks and abnormal stock returns in Egypt," *Futur. Bus. J.*, vol. 6, no. 1, 2020.
- [11] T. Huang, F. Wu, J. Yu, and B. Zhang, "Investor protection and the value impact of stock liquidity," *J. Int. Bus. Stud.*, vol. 51, no. 1, pp. 72–94, 2020.
- [12] C.-Y. C. L. L. Jonathan A. Cook, "Wind Turbine Shutdowns and Upgrades in Denmark: Timing Decisions and the Impact of Government Policy," *Energy J.*, vol. 41, 2020.
- [13] S. Bevan and A. Rasmussen, "When Does Government Listen to the Public? Voluntary Associations and Dynamic Agenda Representation in the United States," *Policy Stud. J.*, vol. 48, no. 1, pp. 111–132, 2020.
- [14] S. Cao, Jian & Chen, Xihui & Zhang, Xuemei & Gao, Yanchen & Zhang, Xueping & Kumar, "Overview of remanufacturing industry in China: Government policies, enterprise, and public awareness," *J. Clean. Prod.*, 2019.

- [15] N. Yasmin and C. A. Utama, "The impact of Busy Directors on Firm Performance in Manufacturing Companies on the Indonesia Stock Exchange," vol. 144, no. 33, pp. 283–286, 2020.
- [16] A. I. Keskin, B. Dincer, and C. Dincer, "Exploring the impact of sustainability on corporate financial performance using discriminant analysis," *Sustain.*, vol. 12, no. 6, 2020.
- [17] Z. Azhar, H. S. Putra, and D. Saputra, "Effect of Macroeconomic Factors on the Composite Stock Price Index Using the Vector Auto Regression (VAR) Method," vol. 124, no. January 2010, pp. 288–294, 2020.
- [18] D. Mashudi, M. A. Ibrahim, and F. Ilahi, "The Effect of Macroeconomic Variables on Sharia Stock Prices in the Jakarta Islamic Index," vol. 409, no. SoRes 2019, pp. 324–327, 2020.
- [19] O. Y. Utama and S. Puryandani, "The Effect of BI Rate , USD to IDR Exchange Rates , and Gold Price on Stock Returns Listed in the SRI KEHATI Index," vol. 11, no. 36, pp. 38–46, 2020.
- [20] N. A. Asab and A. Al-Tarawneh, "Inflation thresholds and stock market development: Evidence of the nonlinear nexus from an emerging economy," *Int. J. Financ. Res.*, vol. 11, no. 1, pp. 447–461, 2020.
- [21] H. Alqaralleh, "Stock return-inflation nexus; revisited evidence based on nonlinear ARDL," *J. Appl. Econ.*, vol. 23, no. 1, pp. 66–74, 2020.
- [22] A. Shabbir, S. Kousar, and S. A. Batool, "Impact of gold and oil prices on the stock market in Pakistan," *J. Econ. Financ. Adm. Sci.*, vol. ahead-of-print, no. ahead-of-print, 2020.
- [23] X. Fu, S. Zhang, J. Chen, T. Ouyang, and J. Wu, "A Sentiment-Aware Trading Volume Prediction Model for P2P Market Using LSTM," *IEEE Access*, vol. 7, pp. 81934–81944, 2019.
- [24] S. Borovkova and I. Tsiamas, "An ensemble of LSTM neural networks for high-frequency stock market classification," *J. Forecast.*, vol. 38, no. 6, pp. 600–619, 2019.
- [25] M. Sridevi, S. Aishwarya, A. Nidheesha, and D. Bokadia, "Application of LSTM, GRU & ICA for Stock Price Prediction," vol. 2, no. January, pp. 83–93, 2019.
- [26] J. Z. G. Hiew, X. Huang, H. Mou, D. Li, Q. Wu, and Y. Xu, "BERT-based Financial Sentiment Index and LSTM-based Stock Return Predictability," no. 2005, 2019.
- [27] D. Karmiani, R. Kazi, A. Nambisan, A. Shah, and V. Kamble, "Comparison of Predictive Algorithms: Backpropagation, SVM, LSTM and Kalman Filter for Stock Market," *Proc. - 2019 Amity Int. Conf. Artif. Intell. AICAI 2019*, pp. 228–234, 2019.
- [28] D. Lien Minh, A. Sadeghi-Niaraki, H. D. Huy, K. Min, and H. Moon, "Deep learning approach for short-term stock trends prediction based on two-stream gated recurrent unit network," *IEEE Access*, vol. 6, pp. 55392–55404, 2018.
- [29] J. Eapen, D. Bein, and A. Verma, "Novel deep learning model with CNN and bi-directional LSTM for improved stock market index prediction," *2019 IEEE 9th Annu. Comput. Commun. Work. Conf. CCWC 2019*, pp. 264–270, 2019.
- [30] D. B. and Z. I. A. Site, "Stock Market Forecasting Using Machine Learning Models," *Innov. Intell. Syst. Appl. Conf. (ASYU), Izmir, Turkey*, pp. 1–6, 2019.
- [31] Z. W. and B. Z. Y. Liu, "Application of Regularized GRU-LSTM Model in Stock Price Prediction," *IEEE 5th Int. Conf. Comput. Commun. (ICCC), Chengdu, China*, pp. 1886–

1890, 2019.

- [32] W. H. Zhan X., Li Y., Li R., Gu X., Habimana O., "Stock Price Prediction Using Time Convolution Long Short-Term Memory Network," *Knowl. Sci. Eng. Manag. KSEM 2018*, vol. 11061, pp. 461–468, 2018.
- [33] L. Altinoglu, "The Origins of Aggregate Fluctuations in a Credit Network Economy," *Financ. Econ. Discuss. Ser.*, vol. 2018, no. 031, 2018.
- [34] M. Irandoust, "The causality between house prices and stock prices: evidence from seven European countries," *Int. J. Hous. Mark. Anal.*, 2020.
- [35] P. Abmuth, "Stock price related financial fragility and growth patterns," *The Open-Access, Open-Assessment E-Journal*, vol. 14, no. 2020–10, pp. 1–34, 2020.
- [36] N. Vlastakis, A. Triantafyllou, and N. Kellard, "Oil price uncertainty as a predictor of stock market volatility," no. 54, pp. 1–49, 2020.
- [37] A. P. Ha Nguyen, Huong Nguyen, "Oil Price Declines Could Hurt U.S. Financial Markets: The Role of Oil Price Level," *IAEE Energy J.*, 2020.
- [38] N. J. Gormsen and R. S. J. Koijen, "Coronavirus: Impact on Stock Prices and Growth Expectations," *SSRN Electron. J.*, pp. 1–27, 2020.
- [39] S. D. Thanh, N. P. Canh, and M. Maiti, "Asymmetric effects of unanticipated monetary shocks on stock prices: Emerging market evidence," *Econ. Anal. Policy*, vol. 65, no. March 2020, pp. 40–55, 2020.
- [40] W. Hastomo and A. Satyo, "Long Short Term Memory Machine Learning Untuk Memprediksi Akurasi Nilai Tukar IDR Terhadap USD," vol. 3, 2019.
- [41] Adhitio Satyo Bayangkari Karno, "Prediksi Data Time Series Saham Bank BRI Dengan Mesin Belajar LSTM (Long ShortTerm Memory)," vol. 1, no. 1, pp. 1–8, 2020.
- [42] K. Pearson, "Notes on Regression and Inheritance in the Case of Two Parents Proceedings of the Royal Society of London," vol. 58, pp. 240–242, 1895.
- [43] L. J. Tashman, "Out-of-sample tests of forecasting accuracy: an analysis and review," *Int. J. Forecast. Elsevier*, vol. 16, no. 4, pp. 437–450, 2000.
- [44] S. Hochreiter and J. Uergen Schmidhuber, "Long Short Term Memory," *Neural Comput.*, vol. 9, no. 8, p. 17351780, 1997.
- [45] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, "Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling," pp. 1–9, 2014.
- [46] P. Waldmann, G. Mészáros, B. Gredler, C. Fuerst, and J. Sölkner, "Evaluation of the lasso and the elastic net in genome-wide association studies," *Front. Genet.*, vol. 4, no. DEC, 2013.
- [47] "Illustrated guide to lstms and gru step by step explanation," *Medium*, 2019. [Online]. Available: <https://towardsdatascience.com/illustrated-guide-to-lstms-and-gru-s-a-step-by-step-explanation-44e9eb8>. [Accessed: 06-Jun-2020].



Adhitio Satyo Bayangkari Karno menempuh S1 Jurusan Fisika FMIPA Universitas Indonesia pada tahun 1992 melanjutkan studi S2 Magister Teknologi Informasi Universitas Indonesia tahun 2010, aktif mengajar di Universitas Indonesia, Universitas Gunadarma, Universitas Multimedia Nusantara, STMIK Jakarta. Minat penelitian Machine learning, Expert systems

Alamat Email: Adh1t10.2@gmail.com



Widi Hastomo, menempuh pendidikan S1 di STMIK Jakarta jurusan Sistem Informasi tahun 2006, melanjutkan studi Master di Universitas Trisakti jurusan Magister Manajemen tahun 2009, melanjutkan studi Master di STMIK Jakarta jurusan Magister Teknologi Informasi tahun 2019. Aktif mengajar di ITB Ahmad Dahlan Jakarta, STMIK Jakarta dan Universitas Terbuka. Minat penelitian machine learning, gesture recognition.

Alamat Email: Widie.has@gmail.com



Ervina Nisfiani menempuh pendidikan S1 Sistem Informasi di STMIK Jakarta, melanjutkan studi S2 Magister Teknologi Infomasi STMIK Jakarta tahun 2019. Aktif bekerja di salah satu Perusahaan Swasta di Jakarta. Minat penelitian pada Machine learning, Expert Systems.

Alamat Email: ervinanispiani@gmail.com



Saeful Lukman menyelesaikan S1 Manajemen Informasi di STMIK Jakarta, melanjutkan studi S2 Magister Teknik Infomasi di Universitas Gunadarma, saat ini aktif mengajar di STMIK Jakarta dan Universitas Gunadarma. Minat penelitian pada machine learning, Expert Systems.

Alamat Email: fulman2012@gmail.com