

**PRAKIRA SUHU UDARA RATA-RATA KOTA- KOTA BESAR
DUNIA MENGGUNAKAN METODE
*LONG SHORT-TERM MEMORY***

SKRIPSI

WENDY WINATA

141402093



**PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
2018**

**PRAKIRA SUHU UDARA RATA-RATA KOTA- KOTA BESAR
DUNIA MENGGUNAKAN METODE
*LONG SHORT-TERM MEMORY***

SKRIPSI

**Diajukan untuk melengkapi dan memenuhi syarat memperoleh ijazah
Sarjana Teknologi Informasi**

WENDY WINATA

141402093



**PROGRAM STUDI TEKNOLOGI INFORMASI
FAKULTAS ILMU KOMPUTER DAN TEKNOLOGI INFORMASI
UNIVERSITAS SUMATERA UTARA
2018**

PERSETUJUAN

Judul : PRAKIRA SUHU UDARA RATA-RATA KOTA-KOTA BESAR DUNIA MENGGUNAKAN METODE LONG SHORT TERM MEMORY

Kategori : SKRIPSI

Nama : WENDY WINATA

Nomor Induk Mahasiswa : 141402093


Program Studi : S1 TEKNOLOGI INFORMASI

Fakultas : ILMU KOMPUTER DAN TEKNOLOGI INFORMASI

UNIVERSITAS SUMATERA UTARA

Komisi Pembimbing :

Pembimbing 2



Ulfi Andayani, S.Kom, M.Kom
NIP. 198604192015042004

Pembimbing 1

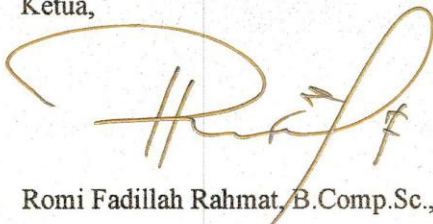


Baihaqi Siregar, S.SI, M.IT
NIP. 198603032010121004

Diketahui/disetujui oleh

Program Studi S1 Teknologi Informasi

Ketua,



Romi Fadillah Rahmat, B.Comp.Sc., M.Sc.
NIP 198603032010121004

PERNYATAAN

PRAKIRA SUHU UDARA RATA-RATA KOTA-KOTA BESAR DUNIA MENGUNAKAN METODE LONG SHORT-TERM MEMORY

SKRIPSI

Saya mengakui bahwa skripsi ini adalah hasil karya saya sendiri, kecuali beberapa kutipan dan ringkasan yang masing-masing telah disebutkan sumbernya.

Medan, 24 Juli 2018

WENDY WINATA
141402093

UCAPAN TERIMA KASIH

Puji dan syukur penulis sampaikan kehadiran Tuhan Yang Maha Esa yang telah memberikan rahmat dan restu-Nya sehingga penulis dapat menyelesaikan skripsi ini sebagai syarat untuk memperoleh gelar Sarjana Komputer, Program Studi S1 Teknologi Informasi Universitas Sumatera Utara.

Skripsi ini penulis persembahkan kepada kedua orangtua penulis, Bapak Efendi Sariman, S.E., serta Ibu penulis Meri yang telah membesarkan dan membimbing penulis dengan sabar dan penuh cinta.

Penulis menyadari bahwa penelitian ini tidak akan terwujud tanpa bantuan banyak pihak. Dengan kerendah hati, penulis ucapkan terima kasih kepada:

1. Bapak Prof. Dr. Opm Salim Sitompul, M.Sc. selaku Dekan Fakultas Ilmu Komputer dan Teknologi Informasi Universitas Sumatera Utara.
2. Ketua dan Sekretaris Program Studi S1 Teknologi Informasi, Bapak Romi Fadillah Rahmat, B.Comp. Sc, M.Sc. dan Ibu Sarah Purnamawati, S.T., M.Sc.
3. Bapak Baihaqi Siregar, S.Si, M.IT selaku Dosen Pembimbing pertama dan ibu Ulfi Andayani, S.Kom, M.Kom selaku Dosen Pembimbing kedua yang telah membimbing penulis dalam penelitian serta penulisan skripsi ini.
4. Ibu Dr. Erna Budhiarti Nababan, M.IT selaku Dosen Pembimbing pertama dan Ibu Sarah Purnamawati, ST., M.Sc. selaku Dosen Pembimbing kedua yang telah memberikan saran serta kritik yang bermanfaat dalam penulisan skripsi ini.
5. Seluruh dosen serta staf pegawai di lingkungan Program Studi Teknologi Informasi dan Fasilkom-TI USU, yang telah membantu proses administrasi selama masa perkuliahan.
6. Keluarga besar penulis yang tidak dapat penulis ucapkan satu persatu namanya.
7. Kepada teman dekat penulis Jacinda Fransisca yang selalu memberikan dukungan dan motivasi kepada penulis.

8. Kepada seluruh teman-teman angkatan 2014 dan ICP USU yang telah bersama-sama penulis melewati perkuliahan pada program studi S1 Teknologi Informasi, serta teman-teman mahasiswa Teknologi Informasi lainnya.

ABSTRAK

Pemantauan suhu udara rata-rata berdasarkan letak geografis lokasi di muka bumi merupakan salah satu faktor penentu terjadi atau tidaknya perubahan iklim global. Dengan adanya perubahan iklim dapat menyebabkan dampak bagi perencanaan dalam berbagai bidang. Perencanaan pada berbagai bidang seperti pertanian, penerbangan, pembangunan, dan bidang yang berhubungan dengan suhu membutuhkan prakiraan sebab akan mempengaruhi seberapa besar tingkat kesuksesan perencanaan tersebut. Prakira adalah melakukan peramalan tentang suatu peristiwa berdasarkan hasil perhitungan rasional atau ketepatan analisis data. Prakiraan adalah hasil dari prakira. Dalam penelitian ini, penulis akan melakukan prakira suhu udara rata-rata kota-kota besar dunia. Data yang digunakan adalah data suhu udara rata-rata kota-kota dunia tahun 1963 sampai dengan 2013. Pada penelitian ini akurasi yang didapatkan untuk prakira data suhu udara rata-rata kota-kota besar dunia dengan metode *Long Short Term Memory* (LSTM) adalah 91,848416%. Penentuan akurasi ini didasari dengan perhitungan *error rate* dengan menggunakan 3 metode, yaitu: RMSE, MAPE, dan *correlation*. Berdasarkan prakiraan data suhu udara rata-rata 100 kota besar dunia yang didapatkan dengan metode LSTM, diperoleh RMSE adalah 1,881693. Hasil MAPE yang diperoleh adalah 8,151584%. Hasil *correlation* yang diperoleh adalah 0,872803. Nilai RMSE dan MAPE yang rendah, serta akurasi yang baik dan nilai *correlation* yang menunjukkan keterkaitan antara data historis suhu udara rata-rata dengan data prakiraan suhu udara rata-rata, maka metode LSTM terbukti sesuai dalam memprakirakan data suhu udara rata-rata.

Kata Kunci: Suhu udara, *LSTM*, dan prakira

FORECASTING AVERAGE AIR TEMPERATURE BASED ON MAJOR CITIES USING LONG SHORT TERM MEMORY

ABSTRACT

The average air temperature monitoring based on the geographical location of the earth is one of the determinants of global climate change. Global climate change can cause impacts for planning in various fields. Planning in areas such as agriculture, aviation, construction, and other areas that has relation with temperature requires forecasting because forecasting will affect how successful the planning is. Forecasting is to forecast about an event based on the results of rational calculation or accuracy of data analysis. In this research, the authors will forecast the average air temperature of major cities of the world using historical data. The historical data are the average air temperature from 1963 to 2013. In this research the accuracy obtained for the forecast average air temperature data of major cities in the world with Long Short Term Memory (LSTM) method is 91.848416%. The accuracy calculation is based on the calculation of error rate using 3 methods: RMSE, MAPE, and correlation. Based on the estimation of average air temperature data of 100 major cities of the world obtained by LSTM method, RMSE is 1.881693. MAPE result is 8,151584%. The correlation result is 0.872803. Low RMSE and MAPE values, as well as good accuracy and correlation values shows that the relation between historical data of average air temperature and forecast average air temperature data, the LSTM method has been proven appropriate in forecasting the average air temperature data.

Keywords: Average Air temperature, LSTM, dan forecasting.

DAFTAR ISI

	Hal.
PERSETUJUAN	ii
PERNYATAAN	iii
UCAPAN TERIMA KASIH.....	iv
ABSTRAK	v
ABSTRACT.....	vi
DAFTAR ISI.....	vii
DAFTAR TABEL.....	ix
DAFTAR GAMBAR	x
BAB 1 PENDAHULUAN	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	2
1.3. Tujuan Penelitian	2
1.4. Batasan Masalah	3
1.5. Manfaat Penelitian	3
1.6. Metodologi Penelitian	3
1.7. Sistematika Penulisan	4
BAB 2 LANDASAN TEORI.....	6
2.1. Prakira	6
2.2. Data historis	6
2.3. RNN	6
2.4. LSTM	7
2.5. Interpolation	14
2.6. MinMax Scaller.....	15
2.7. Penentuan error dan akurasi prakira.....	16
2.8. Penelitian terdahulu.....	17
BAB 3 ANALISA DAN PERANCANGAN	21
3.1. Data yang digunakan.....	21
3.2. Arsitektur Umum	22
3.3. Preprocessing data.....	23
3.3.1. Data Selection	23

3.3.2. Data <i>Cleaning</i>	23
3.3.3. Normalisasi	24
3.4. Prakiraan	25
BAB 4 IMPLEMENTASI DAN PEMBAHASAN	34
4.1. Implementasi Sistem	34
4.1.1. Prakira metode LSTM dengan variasi <i>epoch</i>	35
4.1.2. Prakira metode LSTM dengan <i>batch size</i>	38
4.2. Pembahasan	51
BAB 5 KESIMPULAN DAN SARAN	56
5.1. Kesimpulan	56
5.2. Saran.....	56
DAFTAR PUSTAKA	57

DAFTAR TABEL

	Hal.
Tabel 2.1. Penelitian Terdahulu	17
Tabel 3.1. Data suhu udara rata-rata Kota Medan dari Kaggle.....	21
Tabel 3.2. Proses data <i>cleaning</i> mengisi <i>missing value</i>	24
Tabel 3.3. Contoh normalisasi data suhu udara rata-rata Kota Medan	25
Tabel 3.4. Data suhu udara rata-rata Kota Medan pada tahun 1996.....	26
Tabel 3.5. Hasil perhitungan suhu udara rata-rata Kota Medan tahun 1996 dengan metode LSTM	32
Tabel 4.1. Hasil prakiraan metode LSTM dengan variasi <i>epoch</i> Kota Medan.....	35
Tabel 4.2. Hasil prakiraan metode LSTM dengan variasi <i>epoch</i> Kota Tokyo.....	36
Tabel 4.3. Hasil prakiraan metode LSTM dengan variasi <i>epoch</i> Kota New York	37
Tabel 4.4. Hasil prakiraan metode LSTM dengan variasi <i>batch size</i> Kota Medan.....	39
Tabel 4.5. Hasil prakiraan metode LSTM dengan variasi <i>batch size</i> Kota Tokyo	40
Tabel 4.6. Hasil prakiraan metode LSTM dengan variasi <i>batch size</i> Kota New York	41
Tabel 4.7. Tabel parameter <i>training</i> yang digunakan pada penelitian ini.....	42
Tabel 4.8. Tabel prakiraan data suhu udara rata-rata 100 Kota besar dunia.....	42
Tabel 4.9. Tabel rata -rata RMSE, MAPE, <i>accuracy</i> , dan <i>correlation</i> prakiraan.....	45
Tabel 4.10. Tabel grafik perbandingan suhu udara rata-rata aktual dengan prakiraan	45
Tabel 4.11. Tabel grafik suhu udara rata-rata historis dan prakiraan	47
Tabel 4.12. Tabel akurasi perbandingan antara data aktual dengan data prakira Kota Medan	49

DAFTAR GAMBAR

	Hal.
Gambar 2.1. <i>Recurrent Neural Network looping</i>	6
Gambar 2.2. Pengirimman informasi masa lalu pada RNN.....	7
Gambar 2.3. Perulangan model dengan satu <i>layer</i> tunggal pada RNN.....	7
Gambar 2.4. Perulangan model dengan empat <i>layer</i> pada LSTM.....	8
Gambar 2.5. <i>Cell state</i> pada LSTM	9
Gambar 2.6. Sigmoid <i>layer</i> pada LSTM.....	9
Gambar 2.7. Langkah pertama metode LSTM “ <i>forget gate layer</i> ”	10
Gambar 2.8. Langkah kedua metode LSTM “ <i>input gate layer</i> dan <i>tanh layer</i> ”	11
Gambar 2.9. Langkah ketiga metode LSTM “membuat <i>cell state</i> baru”	13
Gambar 2.10. Langkah keempat metode LSTM “menentukan <i>output</i> ”	13
Gambar 3.1. Arsitektur umum	22
Gambar 4.1. Box plot Kota Medan dengan variasi <i>epoch</i>	36
Gambar 4.2. Box plot Kota Tokyo dengan variasi <i>epoch</i>	37
Gambar 4.3. Box plot Kota New York dengan variasi <i>epoch</i>	38
Gambar 4.4. Box plot Kota Medan dengan variasi <i>batch size</i>	39
Gambar 4.5. Box plot Kota Tokyo dengan variasi <i>batch size</i>	40
Gambar 4.6. Box plot Kota New York dengan variasi <i>batch size</i>	41
Gambar 4.7. Header <i>website</i>	52
Gambar 4.8. Tentang <i>website</i>	53
Gambar 4.9. Memilih Kota yang akan ditampilkan grafik data historisnya	53
Gambar 4.10. Grafik data historis suhu udara Kota Medan.....	54
Gambar 4.11. Peta dunia dengan 100 Kota sebagai titik atau legenda	54
Gambar 4.12. Tampilan grafik prakiraan suhu udara di Kota Medan	55

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perbedaan dingin panasnya suatu tempat dengan tempat lain disebabkan oleh adanya perbedaan suhu udara pada tempat – tempat tersebut. Suhu adalah ukuran kuantitatif terhadap temperatur yang diukur dengan termometer (KBBI, n.d.). Suhu udara merupakan pengukuran suhu yang berada di suatu tempat pada waktu tertentu. Pemantauan suhu udara rata-rata berdasarkan letak geografis lokasi di muka bumi merupakan salah satu faktor penentu terjadi atau tidaknya perubahan iklim global. Dengan adanya perubahan iklim dapat menyebabkan dampak bagi beberapa bidang. Dalam bidang pertanian suhu udara adalah salah satu faktor penting dalam proses pertumbuhan tanaman. Dalam bidang kesehatan, suhu udara yang tidak stabil juga dapat menyebabkan timbulnya penyakit. Dalam bidang penerbangan, perubahan suhu udara juga berpengaruh terhadap jadwal penerbangan pesawat. Oleh karena itu, diperlukan teknik prakira yang digunakan untuk prakiraan suhu udara di masa depan dari data suhu sebelumnya.

Prakiraan suhu udara akan dipakai sebagai perencanaan penjadwalan dalam berbagai bidang. Salah satu contohnya, dalam bidang pertanian petani dapat mengetahui kapan akan bercocok tanam dan tumbuhan apa yang akan ditanam untuk suhu udara tersebut. Dibutuhkan teknik prakira yang memiliki prakiraan yang akurat. Teknik prakira *time series* model merupakan teknik prakira yang sering digunakan dalam berbagai bidang. Teknik prakira *time series* model didasarkan pada data-data yang berurutan yang berjarak mingguan, bulanan, tahunan, dll. Dalam metode *time series* terdapat beberapa model tradisional seperti *Moving Average (MA)*, *Autoregressive (AR)*, *Exponential Smoothing (ESM)*. Akan tetapi, model tradisional ini tingkat akurasi masih kurang dari sempurna (Rahmadayanti et al., 2015). Penelitian yang dilakukan oleh Zheng et al. (2017) memiliki hasil yang menunjukkan bahwa metode prakira

berbasis *Long Short Term Memory* (LSTM) dapat mengungguli metode prakira tradisional dalam masalah prakira beban listrik. Hasil *Root Mean Square Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) metode LSTM adalah yang terendah jika dibandingkan dengan metode lain (0.0702 & 0.0535). Pada penelitian yang dilakukan oleh Azzouni & Pujolle (2017) menunjukkan bahwa LSTM sangat sesuai dalam prediksi lalu lintas matriks. Prakiraan pada penelitian ini menunjukkan akurasi tinggi dengan waktu yang singkat (kira-kira 60 detik untuk satu lapisan tersembunyi dari 300 *node*). Pada penelitian yang dilakukan oleh Adianshar (2014) menunjukkan bahwa hasil dari identifikasi tulisan Jepang huruf Katakana menggunakan metode *Recurrent Neural Network* terbukti cukup berhasil dengan tingkat akurasi sebesar 86,1952%. Semakin banyaknya data tingkat akurasi prakiraan model LSTM dari RNN semakin tinggi lain halnya dengan model tradisional sebelumnya (Brownlee, 2017).

Oleh karena itu, berdasarkan beberapa penelitian terdahulu pada penelitian ini menggunakan metode LSTM untuk memprakirakan suhu udara rata-rata kota-kota besar dunia.

1.2 Rumusan Masalah

Pemantauan suhu udara rata-rata berdasarkan letak geografis lokasi di muka bumi merupakan salah satu faktor penentu terjadi atau tidaknya perubahan iklim global. Dengan adanya perubahan iklim dapat menyebabkan dampak bagi perencanaan dalam berbagai bidang. Perencanaan pada berbagai bidang seperti pertanian, penerbangan, dan pembangunan membutuhkan prakiraan sebab akan mempengaruhi seberapa besar tingkat kesuksesan perencanaan tersebut. Oleh karena itu, diperlukan sebuah pendekatan yang mampu untuk memprakirakan suhu udara rata-rata di masa mendatang berdasarkan data historis suhu udara rata-rata sebelumnya.

1.3 Tujuan Penelitian

Tujuan penelitian ini adalah prakiraan terhadap suhu udara rata-rata kota-kota besar dunia menggunakan metode *Long Short Term Memory*. Dengan adanya prakiraan suhu udara, memberikan dampak positif terhadap beberapa bidang diantaranya agribisnis, konstruksi, marketing produk, dan bidang lain yang berhubungan dengan suhu.

1.4 Batasan Masalah

Untuk membatasi cakupan permasalahan yang akan dibahas dalam studi ini, penulis membuat batasan:

1. Penelitian ini hanya menggunakan data suhu udara dari 100 kota besar dunia. Kota yang dimaksud berdasarkan kota yang tersedia pada data Suhu *Kaggle*.
2. Tipe suhu yang diproses adalah *celcius*.
3. Data suhu yang digunakan pada penelitian ini yaitu data suhu dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 2013 (50 tahun) dengan interval per bulan.
4. *Output* prakiraan adalah 5(lima) tahun mendatang dengan interval per bulan yaitu dari bulan September tahun 2013 sampai dengan bulan Agustus tahun 2018.

1.5 Manfaat Penelitian

Manfaat yang diperoleh dari penelitian ini adalah:

1. Mengetahui cara prakira dengan metode *Long Short Term Memory* (LSTM) berbasis *Recurrent Neural Network* (RNN).
2. Menjadi referensi dalam pengembangan di bidang prakiraan suhu udara.
3. Memprakirakan suhu beberapa kota besar pada beberapa negara di dunia.

1.6 Metodologi Penelitian

Tahapan- tahapan yang akan dilakukan dalam pelaksanaan penelitian ini adalah sebagai berikut:

1. Studi Literatur

Pada tahap ini penulis mengumpulkan dan mempelajari materi-materi yang berhubungan dengan penelitian. Referensi berasal dari jurnal, buku, skripsi, informasi dari internet, dan referensi lainnya yang berhubungan dengan prakira, metode LSTM, dan pemograman Python.

2. Analisis Permasalahan

Pada tahap ini penulis melakukan analisis terhadap studi literatur yang sebelumnya telah dikumpulkan untuk mendapatkan pemahaman mengenai metode LSTM dalam menyelesaikan masalah prakira.

3. Implementasi

Pada tahap ini dilakukan proses implementasi metode LSTM dalam aplikasi komputer menggunakan pemograman Python.

4. Pengujian

Pada tahap ini dilakukan pengujian prakiraan yang telah dibuat guna memastikan prakira telah berjalan sesuai dengan yang diharapkan.

5. Dokumentasi dan penyusunan laporan

Pada tahap ini dilakukan dokumentasi hasil analisis dari penelitian metode LSTM untuk menyelesaikan masalah prakira.

1.7 Sistematika Penulisan

Sistematika penulisan dari skripsi ini terdiri data lima bagian utama sebagai berikut:

Bab 1: Pendahuluan

Pada bab pendahuluan ini, berisi latar belakang, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

Bab 2: Landasan Teori

Pada bab ini berisi teori-teori yang digunakan untuk memahami permasalahan yang dibahas pada penelitian ini. Pada bab ini dijelaskan tentang prakira metode LSTM untuk memprakirakan suhu udara rata-rata beberapa kota dunia berdasarkan data beberapa tahun sebelumnya.

Bab 3: Analisa dan Perancangan

Pada bab ini menjelaskan analisis dan penerapan metode LSTM untuk melakukan prakira suhu udara rata-rata pada beberapa tahun yang akan datang. Bab ini juga membahas arsitektur umum, hingga proses prakira metode LSTM dengan menggunakan pemograman Python.

Bab 4: Implementasi dan Pembahasan

Pada bab ini menjelaskan pembahasan tentang implementasi dari analisis dan perancangan yang telah disusun pada Bab 3 dan pembahasan guna memastikan prakiraan telah sesuai dengan yang diharapkan.

Bab 5: Kesimpulan dan Saran

Pada bab ini berisi tentang kesimpulan hasil penelitian dan saran-saran yang berkaitan dengan penelitian selanjutnya.

BAB 2

LANDASAN TEORI

2.1. Prakira


Prakira adalah melakukan peramalan tentang suatu peristiwa berdasarkan hasil perhitungan rasional atau ketepatan analisis data (KBBI, n.d.-a). Prakiraan adalah hasil dari prakira (KBBI, n.d.-b).

2.2. Data historis

Data historis adalah data yang sudah tersimpan sebelumnya.(KBBI, n.d.) Data historis dapat digunakan untuk memprakirakan data-data kedepannya.


2.3. RNN

Recurrent neural network adalah bagian dari neural network yang memproses sejumlah data yang bersambung (*sequential data*). Secara umum, manusia tidak membuat keputusan dari awal setiap saat. Manusia selalu memperhitungkan informasi masa lalu dalam membuat keputusan. Seperti halnya manusia, *Recurrent Neural Network* juga memperhitungkan informasi masa lalu dalam membuat keputusannya. *Recurrent Neural Network* menyimpan informasi dari masa lalu dengan melakukan *looping* dalam arsitekturnya seperti yang terlihat dalam gambar 2.1, yang secara otomatis membuat informasi dari masa lalu tetap tersimpan.



Gambar 2.1. Recurrent Neural Network Looping (Olah, 2015)


Pada gambar 2.1, terlihat X_t sebagai *input*, H_t sebagai *output* dan terdapat alur *loop* yang memungkinkan informasi masa lalu dapat dikirim dari satu tahap ke tahap lainnya seperti yang terlihat pada gambar 2.2.



Gambar 2.2. Pengiriman informasi masa lalu pada *Recurrent Neural Network*
Looping (Olah, 2015)

2.4. LSTM

Long Short Term Memory (LSTM) adalah salah satu metode dari *Recurrent Neural Network* (RNN). *LSTM* menangani masalah ketergantungan jangka panjang pada RNN. Pada RNN perulangan model hanya menggunakan satu *layer* tunggal yang sederhana, yaitu *layer* tanh seperti pada gambar 2.3. *Layer* tanh bertujuan membuat *input* menjadi angka dengan *range* -1 sampai dengan 1. X_{t-1} adalah *input* sebelumnya, h_{t-1} adalah *output* sebelumnya yang akan dimasukkan sebagai *input* bersamaan dengan *input* baru. H_{t+1} adalah *output* setelah orde t dan X_{t+1} adalah *input* setelah orde t .



Gambar 2.3. Perulangan model dengan satu layer tunggal pada RNN (Olah, 2015)

Persamaan tanh diuraikan pada persamaan 2.1.

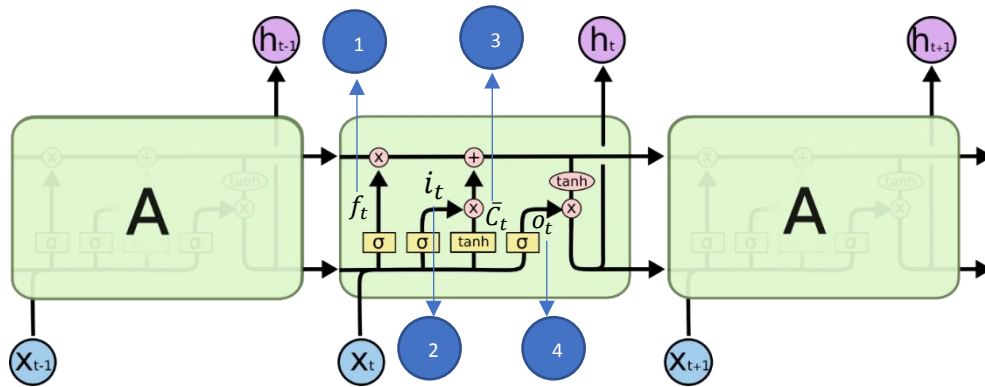
$$\tanh(x) = 2\sigma(2x) - 1 \quad (2.1)$$

Dimana:

σ = fungsi aktivasi sigmoid

x = data *input*

Sedangkan, *LSTM* memiliki empat *layer*, yaitu *forget gate* (1), *input gate* (2), *new cell state candidate* (3), dan *ouput gate* (4) pada perulangan modelnya seperti pada gambar 2.4.



Gambar 2.4. Perulangan model dengan empat layer pada *LSTM* (Olah, 2015)

Persamaan metode *LSTM* menurut Hochreiter & Schmidhber (1997) diuraikan pada persamaan 2.2.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.2)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$


$$\bar{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$C_t = f_t * C_{t-1} + i_t * \bar{C}_t$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

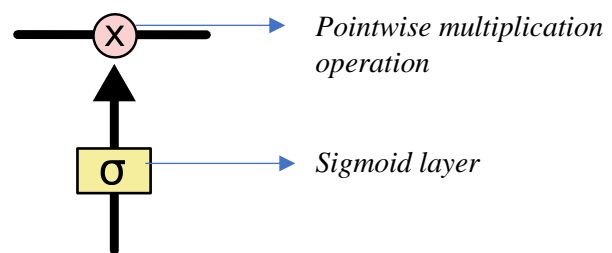
$$h_t = o_t * \tanh(C_t)$$

Kunci utama pada *LSTM* adalah *cell state*. *Cell state* adalah garis horizontal yang menghubungkan semua *output layer* pada *LSTM* seperti terlihat pada gambar 2.5.



Gambar 2.5. Cell state pada LSTM (Olah, 2015)

LSTM memiliki kemampuan untuk menambah dan menghapus informasi dari *cell state*. Kemampuan ini disebut dengan *gates*. *Gates* sebagai pengatur apakah informasi akan diteruskan atau diberhentikan. *Gates* terdiri dari *layer* sigmoid dan *pointwise multiplication operation* seperti yang terlihat pada gambar 2.6.



Gambar 2.6. Sigmoid layer pada LSTM (Olah, 2015)

Output dari *layer* sigmoid adalah antara angka 1 sampai dengan 0 yang menunjukkan apakah informasi tersebut akan diteruskan atau diberhentikan. Angka 0 menunjukkan bahwa tidak ada informasi yang akan diteruskan, sedangkan angka 1 menunjukkan bahwa semua informasi akan diteruskan. Persamaan sigmoid diuraikan pada persamaan 2.3.

$$\sigma(x) = 1/(1 + e^{-x}) \quad (2.3)$$

Dimana:


x = data *input*

e = konstanta matematika (2,71828 18284 59045 23536 02874 71352)

LSTM memiliki 3 jenis *gates* diantaranya adalah *forget gate*, *input gate*, dan *output gate*. *Forget gate* adalah *gate* yang memutuskan informasi mana yang akan dihapus dari *cell*. *Input gate* adalah *gate* yang memutuskan nilai dari *input* untuk di diperbarui pada *state* memori. *Output gate* adalah *gate* yang memutuskan apa yang akan dihasilkan *output* sesuai dengan *input* dan memori pada *cell*.

Langkah - langkah panduan jalannya metode LSTM:

Langkah pertama adalah LSTM memutuskan informasi apa yang akan dihapus dari *cell state*. Keputusan ini dibuat oleh *layer* sigmoid yang bernama “*layer forget gate*”. *Layer forget gate* akan memproses h_{t-1} dan x_t sebagai *input*, dan menghasilkan *output* berupa angka 0 sampai dengan 1 pada *cell state* C_{t-1} seperti yang terlihat pada gambar 2.7.



Gambar 2.7. Langkah pertama metode *LSTM* “*layer forget gate*” (Olah, 2015)

Persamaan *forget gate* diuraikan pada persamaan 2.4

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (2.4)$$

Dimana:

f_t = *forget gate*

σ = fungsi sigmoid

W_f = nilai *weight* untuk *forget gate*

h_{t-1} = nilai *output* sebelum orde ke t

x_t = nilai *input* pada orde ke t

b_f = nilai bias pada *forget gate*

Nilai *weight* diuraikan pada persamaan 2.5.

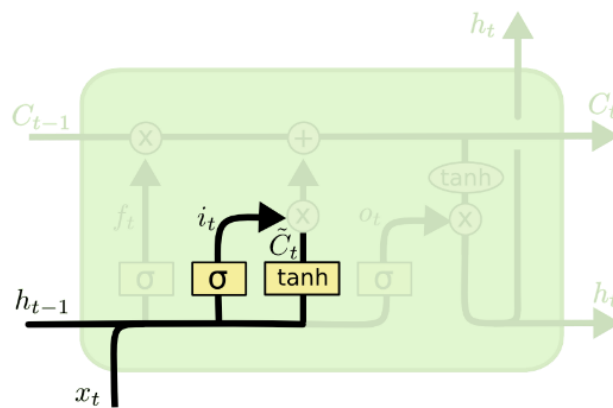
$$W = (-\frac{1}{\sqrt{d}}, \frac{1}{\sqrt{d}}) \quad (2.5)$$

Dimana:

W = *weight*

d = jumlah data

Langkah kedua adalah memutuskan informasi apa yang akan disimpan di *cell state*. Untuk langkah ini terdapat dua bagian. Bagian pertama, *layer sigmoid* yang bernama “*input gate layer*” memutuskan nilai mana yang akan diperbarui. Selanjutnya, *tanh layer* membuat satu kandidat dengan nilai baru, \tilde{C}_t , yang dapat ditambahkan ke *cell state*. Tahap selanjutnya adalah *output* dari *layer input gate* dan *layer tanh* akan digabungkan untuk memperbarui *cell state*. Langkah kedua digambarkan pada gambar 2.8.



Gambar 2.8. Langkah kedua metode LSTM “layer input gate & layer tanh”

(Olah, 2015)

Persamaan *input gate* diuraikan pada persamaan 2.6.

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2.6)$$

Dimana:

i_t = *input gate*

σ = fungsi sigmoid

W_i = nilai *weight* untuk *input gate*

h_{t-1} = nilai *output* sebelum orde ke t
 x_t = nilai *input* pada orde ke t
 b_i = nilai bias pada *input gate*

Persamaan kandidat baru diuraikan pada persamaan 2.7.

$$\bar{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (2.7)$$

Dimana:

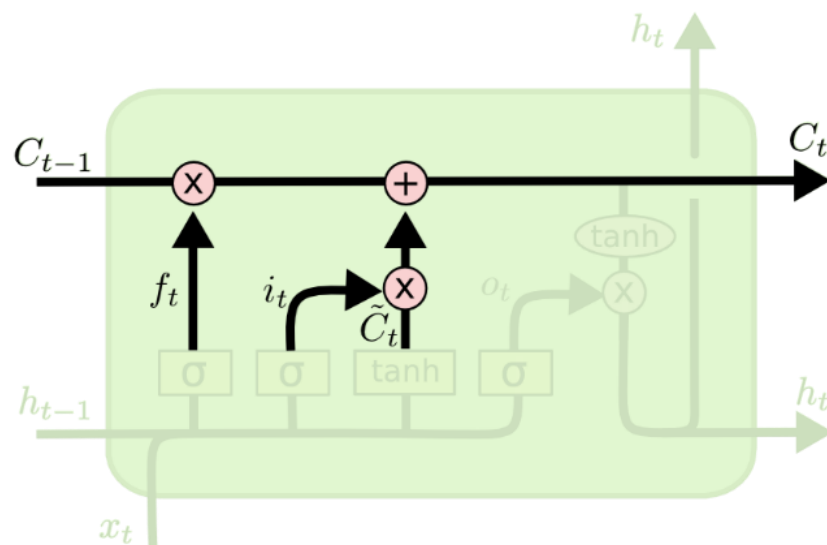
\bar{C}_t = nilai baru yang dapat ditambahkan ke *cell state*
 \tanh = fungsi tanh
 W_C = nilai *weight* untuk *cell state*
 h_{t-1} = nilai *output* sebelum orde ke t
 x_t = nilai *input* pada orde ke t
 b_f = nilai bias untuk *cell state*

Langkah ketiga adalah memperbarui *cell state* yang lama, C_{t-1} , menjadi *cell state* baru, C_t seperti digambarkan pada gambar 2.9. Dengan mengkalikan *state* lama dengan f_t , untuk menghapus informasi yang sudah ditentukan sebelumnya pada langkah *layer forget gate*. Selanjutnya, ditambahkan dengan $i_t * \bar{C}_t$, yang merupakan nilai baru dan digunakan untuk memperbarui *state*. Persamaan *cell state* diuraikan pada persamaan 2.8.

$$C_t = f_t * C_{t-1} + i_t * \bar{C}_t \quad (2.8)$$


Dimana:

C_t = *Cell state*
 f_t = *forget gate*
 C_{t-1} = *Cell state* sebelum orde ke t
 i_t = *input gate*
 \bar{C}_t = nilai baru yang dapat ditambahkan ke *cell state*



Gambar 2.9. Langkah ketiga metode *LSTM* “membuat *cell state* baru” (Olah, 2015)

Langkah keempat adalah langkah terakhir dalam metode *LSTM* yang bertujuan untuk memutuskan hasil *output* digambarkan pada gambar 2.10. *Output* harus sesuai dengan *cell state* yang telah diproses terlebih dahulu. Pertama *layer* sigmoid memutuskan bagian dari *cell state* yang menjadi *output*. Selanjutnya, *output* dari *cell state* dimasukkan kedalam *layer* tanh (untuk mengganti nilai menjadi diantara -1 dan 1) dan dikalikan dengan sigmoid *gate*, agar *output* yang dihasilkan sesuai dengan apa yang kita putuskan sebelumnya.



Gambar 2.10. Langkah keempat metode *LSTM* “menentukan *output*” (Olah, 2015)

Persamaan *output gate* diuraikan pada persamaan 2.9.

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (2.9)$$

Dimana:

o_t = *output gate*

σ = fungsi sigmoid

W_o = nilai *weight* untuk *output gate*

h_{t-1} = nilai *output* sebelum orde ke t

x_t = nilai *input* pada orde ke t

b_o = nilai bias pada *output gate*

Persamaan nilai *output* orde t diuraikan pada persamaan 2.10.

$$h_t = o_t * \tanh(C_t) \quad (2.10)$$

Dimana:

h_t = nilai *output* orde t

o_t = *output gate*

\tanh = fungsi tanh

C_t = *Cell state*

2.5. Interpolation

Interpolation adalah metode yang digunakan untuk menghasilkan data baru dengan data sebelum dan data sesudah dari data yang akan diisi. *Interpolation* sesuai untuk mengisi *missing value* pada data yang berkelanjutan.

Persamaan *interpolation* diuraikan pada persamaan 2.11.

$$y = y_a + (y_b - y_a) \frac{x - x_a}{x_b - x_a} \text{ di koordinat } (x, y)$$

$$\frac{y - y_a}{y_b - y_a} = \frac{x - x_a}{x_b - x_a} \quad (2.11)$$

Dimana:

y = orde data yang akan di*interpolation*

y_a = orde data sebelum data yang akan di*interpolation*

y_b = orde data sesudah data yang akan di*interpolation*

x = data hasil *interpolation*

x_a = data orde sebelum data yang akan di*interpolation*

x_b = data orde sesudah data yang akan di*interpolation*

2.6. MinMax Scaller

MinMax Scaller adalah salah satu metode normalisasi dengan menyederhanakan data menjadi data dengan nilai diantara jangkauan tertentu agar nilai data tidak terlalu besar ketika diproses.

Persamaan *minmax scaller* diuraikan pada persamaan 2.12.

$$y = (x - \min) / (\max - \min) \quad (2.12)$$

Dimana:

Y = nilai setelah dinormalisasi

X = nilai *input*

\min = nilai minimum dari keseluruhan data

\max = nilai maksimum dari keseluruhan data

2.7. Penentuan *error* dan akurasi prakira

Penentuan *error* prakira metode LSTM pada penelitian ini menggunakan *Root Mean Square Error* (RMSE), *Mean Absolute Percentage Error* (MAPE), dan *correlation*. RMSE adalah penentuan *error* dengan menghitung *standar deviation* (std) dari titik-titik data prediksi yang menjauhi garis regresi (data aktual). Persamaan RMSE menurut Barnston (1992) diuraikan pada persamaan 2.13.

$$RMSE_{f0} = \left[\sum_{i=1}^N (z_{fi} - z_{oi})^2 / N \right]^{1/2} \quad (2.13)$$

Dimana:

$\sum_{i=1}^N ()$ = Penjumlahan dari 1 sampai dengan n

z_{fi} = nilai prediksi

z_{oi} = nilai aktual

N = jumlah data

Penentuan nilai akurasi pada penelitian ini menggunakan *Mean Absolute Percentage Error* (MAPE) dengan tujuan mengetahui persen *error* dan untuk mendapatkan nilai akurasinya digunakan $100 - \text{MAPE}$.

Persamaan akurasi diuraikan pada persamaan 2.14.

$$MAPE = \left\{ \frac{1}{n} \sum_{i=1}^n \frac{|\text{nilai prakira} - \text{nilai aktual}|}{\text{nilai aktual}} \right\} * 100 \quad (2.14)$$

Dimana:

n = Jumlah data

prakira = nilai data prakiraan

nilai aktual = nilai data sebenarnya

Penentuan keterkaitan data aktual dan data prakiraan pada penelitian ini menggunakan *correlation*. *Output correlation* adalah angka dalam jangkauan -1 sampai dengan 1. Hasil 1 pada *correlation* menunjukkan adanya peningkatan secara positif. Hasil -1 pada *correlation* menunjukkan adanya peningkatan secara negatif. Sedangkan, hasil 0 pada *correlation* menunjukkan tidak adanya keterkaitan atau hubungan antara kedua data.

Persamaan *correlation* diuraikan pada persamaan 2.15.

$$r = \frac{n(\sum xy) - (\sum x)(\sum y)}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}} \quad (2.14)$$

Dimana:

n = Jumlah data

x = Data pertama (aktual)

y = Data kedua (prakiraan)

2.8. Penelitian terdahulu

Beberapa penelitian telah dilakukan untuk memprakirakan data dengan metode LSTM. Salah satunya adalah penelitian yang dilakukan Zheng et al. (2017) memiliki hasil yang menunjukkan bahwa metode prakira berbasis LSTM dapat mengungguli metode prakira tradisional dalam masalah prakira beban listrik. Hasil *Root Mean Square Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) metode LSTM adalah yang terendah jika dibandingkan dengan metode lain (0.0702 & 0.0535).

Pada penelitian yang dilakukan oleh Azzouni & Pujolle (2017) menunjukkan bahwa LSTM sangat sesuai dalam prediksi lalu lintas matriks. Prakiraan pada penelitian ini menunjukkan akurasi tinggi dengan waktu yang singkat (kira-kira 60 detik untuk satu lapisan tersembunyi dari 300 *node*). Beberapa penelitian terdahulu yang terkait dengan penelitian ini diuraikan pada tabel 2.1.

Tabel 2.1. Penelitian Terdahulu

No	Peneliti & Tahun	Keterangan Hasil
1	Zheng et al., 2017	Dalam penelitian ini hasil percobaan menunjukkan bahwa metode prakira berbasis LSTM dapat mengungguli metode prakira tradisional dalam masalah prakira beban listrik. Hasil RMSE dan MAPE metode LSTM adalah yang terendah dari metode lain (0.0702 & 0.0535)

Tabel 2.1. Penelitian Terdahulu (lanjutan)

No	Peneliti &Tahun	Keterangan Hasil
2	Kong et al., 2017	Dalam penelitian ini, kerangka LSTM yang diusulkan mencapai kinerja prakira terbaik di dataset. Hasil: MAPE 8,9% merupakan yang terendah jika disbanding dengan metode lain
3	Alahi et al., 2016	Dalam penelitian ini secara kualitatif menunjukkan bahwa Social-LSTM berhasil memprediksi berbagai hal yang tidak linier seperti sikap yang timbul dari interaksi sosial, seperti sekelompok individu yang bergerak bersama.
4	Samin et al., 2010	Dalam penelitian ini, hasil menunjukkan pemodelan bilangan sunspot sangat bagus dan dapat kita katakan bahwa model ini sebenarnya bisa digunakan untuk prakiraan angka sunspot untuk tahun-tahun mendatang.

Tabel 2.1. Penelitian Terdahulu (lanjutan)

No	Peneliti & Tahun	Keterangan Hasil
5	Toqu�e et al., 2016	Hasil yang didapat dari penelitian ini adalah: LSTM yang menggunakan data kereta bawah tanah dan bus benar-benar memperbaiki semua kinerja prediksi kumpulan data dibandingkan dengan kalender, VAR, dan LSTM yang hanya menggunakan model informasi kereta bawah tanah.
6	Abdelhadi Azzouni & Guy Pujolle, 2017	LSTM sangat sesuai dalam prediksi lalu lintas matriks. Prakiraan pada penelitian ini menunjukkan akurasi tinggi dengan waktu yang singkat (kira-kira 60 detik untuk satu lapisan tersembunyi dari 300 node).

Tabel 2.1. Penelitian Terdahulu (lanjutan)

No	Peneliti & Tahun	Keterangan Hasil
7	Asklany et al., 2011	Akurasi prakiraan pada penelitian ini menunjukkan bahwa metode fuzzy inference systems cocok untuk data yang sedikit.
8	Ammar Adianshar, 2014	Hasil dari identifikasi tulisan Jepang huruf Katakana menggunakan metode <i>Recurrent Neural Network</i> terbukti cukup berhasil dengan tingkat akurasi sebesar 86,1952%

BAB 3

ANALISA DAN PERANCANGAN

3.1 Data yang digunakan

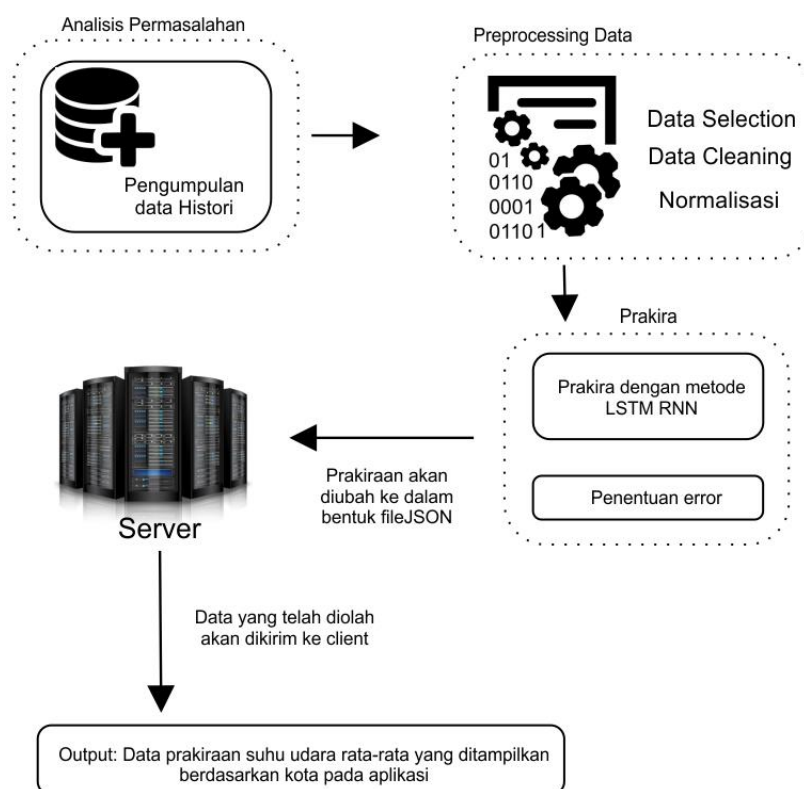
Data yang digunakan adalah data suhu udara rata-rata kota-kota besar dunia dari tahun 1743 sampai dengan 2013 per bulan yang berasal dari situs Kaggle. Kaggle adalah sebuah situs yang mengumpulkan data dari berbagai pihak. Seperti contoh, data suhu udara rata-rata berasal dari Berkeley Earth. Berkeley Earth adalah organisasi nonprofit yang dibangun dengan tujuan untuk mengatasi potensi bias dalam catatan permukaan tanah. Data suhu udara rata-rata Kota Medan dari situs Kaggle diuraikan pada tabel 3.1.

Tabel 3.1. Data suhu udara rata-rata Kota Medan dari Kaggle.

Date	<i>Average Temperature</i>	<i>Average Temperature Uncertainty</i>	City	Country	Latitude	Longitude
1743-11-01	25.121	Nan	Medan	Indonesia	98.84E	4.02N
1743-12-01	Nan	Nan	Medan	Indonesia	98.84E	4.02N
1744-01-01	Nan	Nan	Medan	Indonesia	98.84E	4.02N
.
.
.
2013-07-01	28.17	0.193	Medan	Indonesia	98.84E	4.02N
2013-08-01	27.98	0.298	Medan	Indonesia	98.84E	4.02N
2013-09-01	Nan	Nan	Medan	Indonesia	98.84E	4.02N

3.2 Arsitektur Umum

Arsitektur umum penelitian dalam proses prakira suhu udara rata-rata beberapa kota besar dunia ditunjukkan dalam gambar 3.1 dan gambar 3.2. Tahap pertama yang dilakukan adalah analisis permasalahan dengan mengumpulkan data historis suhu udara rata-rata beberapa kota besar dunia, kemudian dilanjutkan dengan tahap *preprocessing* data serta prakira dengan metode LSTM. Dalam metode LSTM terdapat empat *layer* utama yang memproses *input* data suhu udara rata-rata, yaitu *forget gate*, *input gate*, *output gate*, dan *cell state*. Prakiraan yang didapatkan melalui metode LSTM akan diubah ke dalam bentuk json dan dikirim ke *web server*. *Web server* akan mengolah data tersebut dan menampilkan data yang sudah diolah kepada *client*.



Gambar 3.1 Arsitektur Umum

3.3.Data preprocessing

Data *preprocessing* terdiri dari 3 tahapan, yaitu:

3.3.1. Data Selection

Data yang dipakai adalah data dari bulan Agustus tahun 1963 sampai dengan bulan Agustus 2013 (50 tahun) dengan interval per bulan. Data suhu udara rata-rata dikelompokkan berdasarkan kota- kota besar di dunia. Jumlah kota yang digunakan dalam penelitian ini adalah 100 kota besar dunia. Penelitian ini menggunakan *field* tanggal, suhu udara rata-rata, kota, negara, koordinat x (*longtitude*), dan koordinat y (*latitude*).

3.3.2 Data Cleaning

Data cleaning dengan menghapus *file* NaN dan mengisi *missing value* dengan fungsi *interpolation*. File NaN pada akhir baris suatu kota akan dihapus dengan tujuan membuat data lebih relevan satu sama lain. Fungsi *interpolation* disini menggunakan *linear interpolation* atau biasa disebut *lerp*, karena data yang digunakan adalah data tunggal. Pemilihan fungsi *interpolation* didasari dari data yang akan digunakan dalam penelitian. Karena data suhu udara rata- rata sesuai dengan yang diisi fungsi *interpolation* dalam mengisi *missing value*.

Contoh pengisian *missing value* dengan *interpolation* diuraikan pada persamaan 3.1.

$$y = y_a + (y_b - y_a) \frac{x - x_a}{x_b - x_a} \text{ di koordinat}(x, y) \quad (3.1)$$

$$\frac{y - y_a}{y_b - y_a} = \frac{x - x_a}{x_b - x_a}$$

$$\frac{2 - 1}{3 - 1} = \frac{x - 25.139}{26.053 - 25.139}$$

$$\frac{1}{2} = \frac{x - 25.139}{0.914}$$

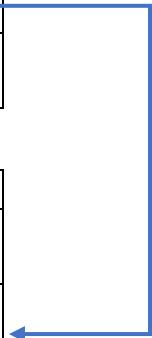
$$x = 25,596$$

Contoh pengisian *missing value* diilustrasikan pada tabel 3.2.

Tabel 3.2 Proses data *cleaning* mengisi *missing value*

dt	AverageTemperature	City
1970-01-01	25.139	Medan
1970-02-01		Medan
1970-03-01	26.053	Medan

dt	AverageTemperature	City
1970-01-01	25.139	Medan
1970-02-01	25.596	Medan
1970-03-01	26.053	Medan



3.3.3 Normalisasi

Normalisasi adalah mengubah skala data dari data asli menjadi data dengan jangkauan nilai antara 0 sampai dengan 1. Normalisasi digunakan dalam data *preprocessing* agar data tidak terlalu besar saat di *training*. Normalisasi dalam penelitian ini menggunakan *MixMaxscaller*.

Persamaan normalisasi menggunakan *MixMaxscaller* diuraikan pada persamaan 3.2.

$$y = (x - \min) / (\max - \min) \quad (3.2)$$

$$y = (24.810 - 24.810) / (26.457 - 24.810)$$

$$y = 0$$

$$y = (25.365 - 24.810) / (26.457 - 24.810)$$

$$y = 0.337$$

$$y = (26.006 - 24.810) / (26.457 - 24.810)$$

$$y = 0,726$$

$$y = (26.457 - 24.810) / (26.457 - 24.810)$$

$$y = 1$$

Normalisasi menggunakan *Min-Max scaller* diilustrasikan pada tabel 3.3.

Tabel 3.3. Contoh normalisasi data suhu udara rata-rata kota Medan

dt	<i>AverageTemperature</i> (sebelum normalisasi)	<i>AverageTempertature</i> (sesudah normalisasi)	<i>City</i>
1895-01-01	24.810	0	Medan
1895-02-01	25.365	0.337	Medan
1895-03-01	26.006	0.726	Medan
1895-04-01	26.457	1	Medan

3.4 Prakiraan

Prakiraan dengan metode LSTM dimulai dengan memasukkan *input* dan *output* sebelumnya ke dalam *forget layer*. *Forget layer* berfungsi menghasilkan *output* berupa angka 0 atau 1 pada *cell state*. Angka 0 berarti *input* akan dilupakan dan sebaliknya angka 1 berarti *input* akan dilanjutkan. Selanjutnya, pada *input gate layer* akan ditentukan data mana yang akan diperbarui dan pada *tanh layer* akan membuat satu nilai kandidat baru. *Output* dari *input gate layer* dan *tanh layer* akan digabungkan ke dalam *cell state*. Selanjutnya, *cell state* lama akan diperbarui dengan *cell state* baru. Langkah terakhir adalah *layer sigmoid* memutuskan bagian dari *cell state* yang menjadi *output*. Selanjutnya, *output* dari *cell state* dimasukkan ke dalam *layer tanh* (untuk mengganti nilai menjadi diantara -1 dan 1) dan dikalikan dengan *gate sigmoid*, agar *output* yang dihasilkan sesuai dengan apa yang kita putuskan sebelumnya. Contoh perhitungan prakiraan suhu udara rata-rata menggunakan metode LSTM menggunakan data suhu udara rata-rata kota Medan pada tahun 1996 dengan interval per bulan (12 bulan) yang dipaparkan pada tabel 3.4. Data suhu udara rata-rata dinormalisasi terlebih dahulu dengan mengubah nilai data tersebut menjadi data dengan *range* (0,1).

Tabel 3.4. Data suhu udara rata-rata kota medan pada tahun 1996

Tanggal	Suhu udara rata-rata	Normalisasi
1996-01-01	25,759	0
1996-02-01	26,059	0,1267
1996-03-01	27,314	0,6569
1996-04-01	27,263	0,6239
1996-05-01	28,126	1
1996-06-01	28,083	0,9818
1996-07-01	27,939	0,9209
1996-08-01	27,330	0,6637
1996-09-01	27,315	0,6574
1996-10-01	26,418	0,2784
1996-11-01	26,559	0,3379
1996-12-01	25,792	0,0139

Nilai *Weight* akan dinisialisasikan dengan jangkauan dari $(-0,289, 0,289)$.

$$W = (-\frac{1}{\sqrt{d}}, \frac{1}{\sqrt{d}})$$

$$W = (-\frac{1}{\sqrt{12}}, \frac{1}{\sqrt{12}})$$

$$W = (-0,289, 0,289)$$

Perhitungan bulan 1:

Dengan:

$$\text{Suhu} = 0$$

$$\text{Weight} = 0,285$$

$$\text{Bias forget, bias input, bias Ct, bias output} = 1, 0,5, 0, 0,1$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$= \text{sigmoid}(0,285 * 0 + 0,285 * 0 + 1)$$

$$= \text{sigmoid}(1)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1 / (1 + 2,718^{-1})$$

$$= 1 / (1 + 0,3679)$$

$$= 0,731$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$= \text{sigmoid}(0,285 * 0 + 0,285 * 0 + 0,5)$$

$$= \text{sigmoid}(0,5)$$

$$= \sigma(x) = 1 / (1 + e^{-x})$$

$$= 1 / (1 + 2,718^{-0,5})$$

$$= 1 / (1 + 0,6065)$$

$$= 0,6225$$

$$\bar{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$= \tanh(0,285 * 0 + 0,285 * 0 + 0)$$

$$= \tanh(0)$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= \sigma(2x) = 1 / (1 + e^{-2x})$$

$$= 1 / (1 + 2,718^0)$$

$$= 1 / (1 + 1)$$

$$= 0,5$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= 2 * 0,5 - 1$$

$$= 0$$

$$C_t = f_t * C_{t-1} + i_t * \bar{C}_t$$

$$= 0,731 * 0 + 0,6225 * 0$$

$$= 0$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$= \text{sigmoid}(0,285 * 0 + 0,285 * 0 + 0,1)$$

$$= \text{sigmoid}(0,1)$$

$$= \sigma(x) = 1 / (1 + e^{-x})$$

$$= 1 / (1 + 2,718^{-0,1})$$

$$= 1 / (1 + 0,9048)$$

$$= 0,5249$$

$$h_t = o_t * \tanh(C_t)$$

$$= 0,5249 * \tanh(0)$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= \sigma(2x) = 1/(1 + e^{-2x})$$

$$= 1/(1 + 2,718^0)$$

$$= 1/(1+1)$$

$$= 0,5$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= 2*0,5 - 1$$

$$= 0$$

$$h_t = 0,5249 * 0$$

$$= 0$$

Hasil yang didapatkan dari bulan 1:

$$H_t = 0$$

$$C_t = 0$$

Perhitungan bulan 2:

Dengan:

$$\text{Suhu} = 0,1267$$

$$\text{Weight} = 0,285$$

$$\text{Bias forget, bias input, bias } C_t, \text{ bias output} = 1, 0,5, 0, 0,1$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$= \text{sigmoid}(0,285 * 0 + 0,285 * 0,1267 + 1)$$

$$= \text{sigmoid}(1,0361)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1/(1 + 2,718^{-1})$$

$$= 1/(1 + 0,3548)$$

$$= 0,7381$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$= \text{sigmoid}(0,285 * 0 + 0,285 * 0,1267 + 0,5)$$

$$= \text{sigmoid}(0,5361)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1/(1 + 2,718^{-0,5})$$

$$= 1/(1 + 0,585)$$

$$= 0,6309$$

$$\bar{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$= \tanh(0,285 * 0 + 0,285 * 0,1267 + 0)$$

$$= \tanh(0,03611)$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= \sigma(2x) = 1/(1 + e^{-2x})$$

$$= 1/(1 + 2,718^{-0,07222})$$

$$= 1/(1 + 0,9303)$$

$$= 0,5181$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= 2 * 0,5181 - 1$$

$$= 0,0362$$

$$C_t = f_t * C_{t-1} + i_t * \bar{C}_t$$

$$= 0,7381 * 0 + 0,6309 * 0,0362$$

$$= 0,02284$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$= \text{sigmoid}(0,285 * 0 + 0,285 * 0,1267 + 0,1)$$

$$= \text{sigmoid}(0,1361)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1/(1 + 2,718^{-0,1361})$$

$$= 1/(1 + 0,8727)$$

$$= 0,53399$$

$$h_t = o_t * \tanh(C_t)$$

$$= 0,53399 * \tanh(0,02284)$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= \sigma(2x) = 1/(1 + e^{-2x})$$

$$= 1/(1 + 2,718^{-0,04568})$$

$$= 1/(1 + 0,9553)$$

$$= 0,5114$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= 2 * 0,5114 - 1$$

$$= 0,0228$$

$$h_t = 0,53399 * 0,0228$$

$$= 0,012175$$

Hasil yang didapatkan dari bulan 2:

$$H_t = 0,012175$$

$$C_t = 0,02284$$

Perhitungan bulan 3:

Dengan:

$$\text{Suhu} = 0,6569$$

$$\text{Weight} = 0,285$$

$$\text{Bias forget, bias input, bias } C_t, \text{ bias output} = 1, 0,5, 0, 0,1$$

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$= \text{sigmoid}(0,285 * 0,012175 + 0,285 * 0,6569 + 1)$$

$$= \text{sigmoid}(1,19067)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1/(1 + 2,718^{-1})$$

$$= 1/(1 + 0,30402)$$

$$= 0,76686$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$= \text{sigmoid}(0,285 * 0,012175 + 0,285 * 0,6569 + 0,5)$$

$$= \text{sigmoid}(0,69067)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1/(1 + 2,718^{-0,69067})$$

$$= 1/(1 + 0,50124)$$

$$= 0,66612$$

$$\bar{C}_t = \tanh(W_c \cdot [h_{t-1}, x_t] + b_c)$$

$$= \tanh(0,285 * 0,012175 + 0,285 * 0,6569 + 0)$$

$$= \tanh(0,19067)$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= \sigma(2x) = 1/(1 + e^{-2x})$$

$$= 1/(1 + 2,718^{-0,38134})$$

$$= 1/(1 + 0,68294)$$

$$= 0,5942$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= 2 * 0,5942 - 1$$

$$= 0,1884$$

$$C_t = f_t * C_{t-1} + i_t * \bar{C}_t$$

$$= 0,76686 * 0,02284 + 0,66612 * 0,1884$$

$$= 0,143012$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$= \text{sigmoid}(0,285 * 0,012175 + 0,285 * 0,6569 + 0,1)$$

$$= \text{sigmoid}(0,29067)$$

$$= \sigma(x) = 1/(1 + e^{-x})$$

$$= 1/(1 + 2,718^{-0,29067})$$

$$= 1/(1 + 0,7478)$$

$$= 0,5721$$

$$h_t = o_t * \tanh(C_t)$$

$$= 0,5721 * \tanh(0,143012)$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= \sigma(2x) = 1/(1 + e^{-2x})$$

$$= 1/(1 + 2,718^{-0,286024})$$

$$= 1/(1 + 0,7512)$$

$$= 0,57104$$

$$\tanh(x) = 2\sigma(2x) - 1$$

$$= 2 * 0,57104 - 1$$

$$= 0,14208$$

$$ht = 0,5721 * 0,14208$$

$$= 0,08128$$

Hasil yang didapatkan dari bulan 3:

$$H_t = 0,08128$$

$$C_t = 0,143012$$

Perhitungan akan dilanjutkan sampai dengan bulan 12 dan diperoleh hasil seperti data yang diuraikan pada tabel 3.5.

Tabel 3.5 Hasil perhitungan suhu udara rata-rata Kota medan tahun 1996 dengan metode LSTM

Tanggal	Suhu udara rata-rata	Normalisasi	ht	Ct
1996-01-01	25,759	0	0	0
1996-02-01	26,059	0,1267	0,012175	0,02284
1996-03-01	27,314	0,6569	0,08128	0,143012
1996-04-01	27,263	0,6239	0,11068	0,19504
1996-05-01	28,126	1	0,21143	0,3663
1996-06-01	28,083	0,9818	0,22292	0,39633
1996-07-01	27,939	0,9209	0,294596	0,53221
1996-08-01	27,330	0,6637	0,3173	0,598155
1996-09-01	27,315	0,6574	0,3406	0,65351
1996-10-01	26,418	0,2782	0,3115	0,61523
1996-11-01	26,559	0,3379	0,30365	0,5928
1996-12-01	25,792	0,0139	0,2537	0,501624

$$0,2537 = \frac{x - 25,759}{28,126 - 25,759}$$

$$0,2537 = \frac{x - 25,759}{2,367}$$

$$x = 26,36$$

$$MAPE = \left\{ \frac{1}{1} \sum_{i=1}^1 \frac{|26.36 - 26.254|}{26.254} \right\} * 100$$

$$MAPE = \left\{ \frac{1}{1} \sum_{i=1}^1 \frac{|0.106|}{26.254} \right\} * 100$$

$$MAPE = 0.4037$$

Berdasarkan tabel 3.5 maka diperoleh *output* bulan 12 adalah 0,2537 yang dimana adalah prakiraan suhu udara rata-rata bulan 1 tahun 1997. Setelah dilakukan denormalisasi pada *output* bulan 12, maka didapat prakiraan suhu udara rata-rata bulan 1 tahun 1997 adalah 26,36. MAPE yang didapatkan adalah 0,4037 dan akurasi yang didapatkan adalah 99,5963%. Pada Bab 4, akan ditampilkan hasil prakira menggunakan metode LSTM dengan data suhu udara rata-rata 100 kota besar dunia dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 2013 sebagai *input*.

BAB 4

IMPLEMENTASI DAN PEMBAHASAN

4.1. Implementasi Sistem

Pada penelitian ini implementasi sistem dimulai dari data *preprocessing*. Data historis suhu udara rata-rata kota-kota besar dunia diambil dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 2013 (50 tahun) untuk memprakirakan data kedepannya. Jumlah kota yang akan diprakirakan adalah 100 kota-kota besar dunia. *Data cleaning* pada penelitian ini terdapat dua tahap yaitu tahap pertama menghapus *missing value* data pada akhir data kota tersebut. Tahap selanjutnya adalah mengisi *missing value* yang berada diantara dua angka dengan *interpolation*.

Data yang sudah *preprocessing* dibagi per kota dengan tujuan memudahkan proses prakira. Data suhu udara rata-rata dibagi menjadi 70% dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 1998 akan di *training* dan 30% dari bulan September tahun 1998 sampai dengan bulan Agustus tahun 2013 akan dijadikan *testing*. Setelah terbukti perbandingan hasil prakira training dengan testing memiliki akurasi yang tinggi, maka akan dilanjutkan prakira dengan menggunakan seluruh data dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 2013 untuk memprakirakan suhu udara rata-rata dari bulan September tahun 2013 sampai dengan bulan Agustus tahun 2018.

Terdapat 2 parameter yang mempengaruhi hasil prakira metode LSTM pada penelitian ini, yaitu:

1. *Epoch* adalah jumlah training yang dilakukan.
2. *Batch size* mengatur seberapa sering *weight* pada *network* diperbarui.

Pada penelitian ini, menggunakan grafik *box plot* untuk menentukan parameter yang memberikan *error rate* paling rendah. Terdapat 3 kota besar yang dijadikan

sebagai pedoman menentukan parameter *epoch* dan *batch size*. Penentuan kota sebagai pedoman didasarkan dari suhu kota yang bervariasi.

4.1.1. Prakira metode LSTM dengan variasi *epoch*

Epoch yang akan digunakan pada penelitian ini adalah 10, 50, 100, 500, dan 1000.

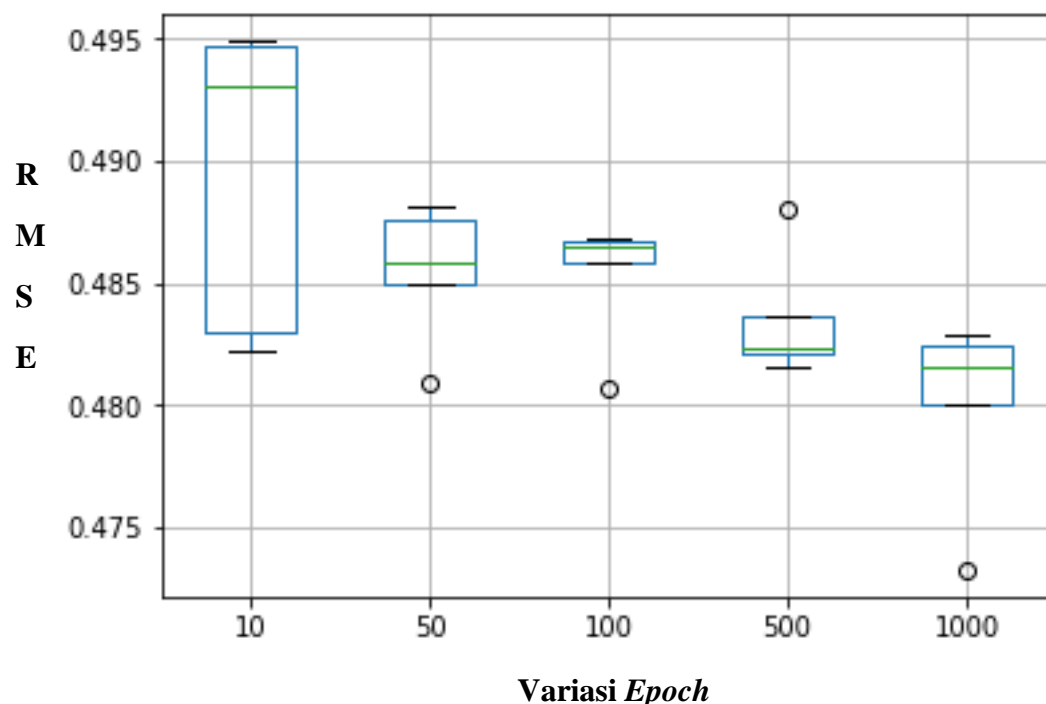
Training akan diulang 5 kali untuk mendapatkan hasil perbandingan yang akurat.

Hasil prakiraan suhu udara rata-rata Kota Medan dengan variasi *epoch* diuraikan pada tabel 4.1.

Tabel 4.1 Hasil prakiraan metode LSTM dengan variasi *epoch* Kota Medan

Jumlah epoch	10	50	100	500	1000
Count	5.000000	5.000000	5.000000	5.000000	5.000000
Mean	0.489579	0.485475	0.485306	0.483543	0.480018
Std	0.006404	0.002892	0.002602	0.002654	0.003946
Min	0.482239	0.480852	0.480696	0.481544	0.473242
25%	0.482992	0.484919	0.485872	0.482086	0.479992
50%	0.493037	0.485867	0.486453	0.482338	0.481537
75%	0.494719	0.487593	0.486722	0.483663	0.482450
Max	0.494906	0.488144	0.486788	0.488082	0.482870

Hasil prakiraan suhu udara rata-rata Kota Medan dengan variasi *epoch* digambarkan pada gambar 4.1.



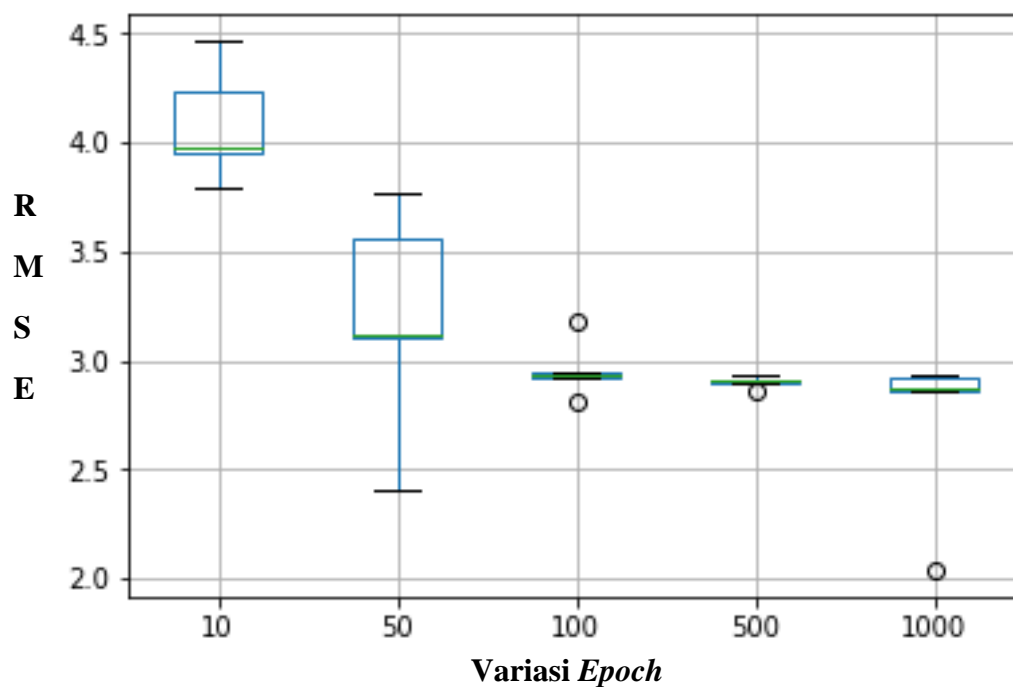
Gambar 4.1. Boxplot Kota Medan dengan variasi *epoch*

Hasil prakiraan suhu udara rata-rata Kota Tokyo dengan variasi *epoch* diuraikan pada tabel 4.2.

Tabel 4.2. Hasil prakiraan metode LSTM dengan variasi *epoch* Kota Tokyo

Jumlah epoch	10	50	100	500	1000
Count	5.000000	5.000000	5.000000	5.000000	5.000000
Mean	4.084557	3.191054	2.957776	2.903066	2.725975
Std	0.264082	0.523352	0.133660	0.025719	0.384973
Min	3.793039	2.307586	2.815688	2.861813	2.039200
25%	3.956206	3.099450	2.919057	2.897758	2.865389
50%	3.976773	3.119459	2.929918	2.912115	2.874545
75%	4.232898	3.563990	2.945434	2.913742	2.917281
Max	4.463869	3.764787	3.178782	2.929900	2.933460

Hasil prakiraan suhu udara rata-rata Kota Tokyo dengan variasi *epoch* digambarkan pada gambar 4.2.




Gambar 4.2. *Boxplot* Kota Tokyo dengan variasi *epoch*

Hasil prakiraan suhu udara rata-rata Kota New York dengan variasi *epoch* diuraikan pada tabel 4.3.

Tabel 4.3. Hasil prakiraan metode LSTM dengan variasi *epoch* Kota New York

Jumlah epoch	10	50	100	500	1000
Count	5.000000	5.000000	5.000000	5.000000	5.000000
Mean	4.516314	3.841753	3.401338	2.754364	2.962297
Std	0.139132	0.138861	0.437941	0.262208	0.424545
Min	4.366823	3.728384	2.765120	2.568225	2.544533
25%	4.386922	3.732275	3.190690	2.579556	2.566181
50%	4.526396	3.776505	3.523999	2.616951	2.899936
75%	4.618218	3.928641	3.620713	2.820866	3.370973
Max	4.683212	4.042962	3.906169	3.186222	3.429861

Hasil prakiraan suhu udara rata-rata Kota New York dengan variasi *epoch* digambarkan pada gambar 4.3.



Gambar 4.3. Boxplot Kota New York dengan variasi *epoch*

Berdasarkan prakiraan data suhu udara rata-rata Kota Medan pada tabel 4.1 dan gambar 4.1, data suhu udara rata-rata Kota Tokyo pada tabel 4.2 dan gambar 4.2, dan data suhu udara rata-rata Kota New York pada tabel 4.3 dan gambar 4.3 dapat disimpulkan bahwa *training* data suhu udara rata-rata dengan *epoch* 1000 mendapat *error rate* terendah jika dibandingkan dengan yang lain.

4.1.2. Prakira metode LSTM dengan variasi *batch size*


Batch size yang akan digunakan pada penelitian ini adalah 1, 2, dan 4. *Training* akan diulang 5 kali untuk mendapatkan hasil perbandingan yang akurat.

Hasil prakiraan suhu udara rata-rata Kota Medan dengan variasi *batch size* diuraikan pada tabel 4.4.

Tabel 4.4 Hasil prakiraan metode LSTM dengan variasi *batch size* Kota Medan

Jumlah batch size	1	2	4
Count	3.000000	3.000000	3.000000
Mean	0.474684	0.479448	0.481416
Std	0.005794	0.002478	0.000844
Min	0.468230	0.477262	0.480751
25%	0.472307	0.478102	0.480941
50%	0.476384	0.478942	0.481132
75%	0.477910	0.480541	0.481749
Max	0.479437	0.482140	0.482366

Hasil prakiraan suhu udara rata-rata Kota Medan dengan variasi *batch size* digambarkan pada gambar 4.4.




Gambar 4.4. Boxplot Kota Medan dengan variasi *batch size*

Hasil prakiraan suhu udara rata-rata Kota Tokyo dengan variasi *batch size* diuraikan pada tabel 4.5

Tabel 4.5 Hasil prakiraan metode LSTM dengan variasi *batch size* Kota Tokyo

Jumlah batch size	1	2	4
Count	3.000000	3.000000	3.000000
Mean	3.399299	2.862194	2.613450
Std	0.888280	0.000458	0.369530
Min	2.885664	2.861935	2.189157
25%	2.886451	2.861935	2.487790
50%	2.887238	2.862370	2.786424
75%	3.656117	2.862370	2.825596
Max	4.424996	2.862712	2.864769

Hasil prakiraan suhu udara rata-rata Kota Tokyo dengan variasi *batch size* digambarkan pada gambar 4.5.



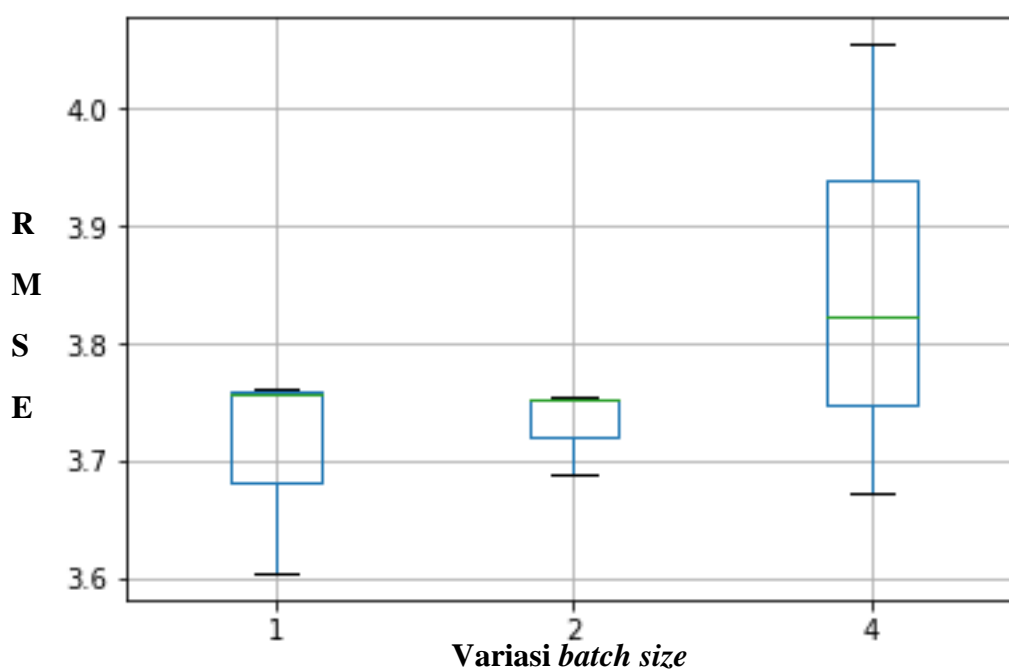
Gambar 4.5. Boxplot Kota Tokyo dengan variasi *batch size*

Hasil prakiraan suhu udara rata-rata Kota New York dengan variasi *batch size* diuraikan pada tabel 4.6.

Tabel 4.6 Hasil prakiraan metode LSTM dengan variasi *batch size* Kota

New York			
Jumlah batch size	1	2	4
Count	3.000000	3.000000	3.000000
Mean	3.707964	3.731567	3.850672
Std	0.089622	0.037914	0.192233
Min	3.604493	3.687801	3.673833
25%	3.681345	3.720156	3.748369
50%	3.758198	3.752511	3.822905
75%	3.759700	3.753450	3.939092
Max	3.761202	3.754388	4.055279

Hasil prakiraan suhu udara rata-rata Kota New York dengan variasi *batch size* digambarkan pada gambar 4.6.



Gambar 4.6. Boxplot Kota New York dengan variasi *batch size*

Berdasarkan prakiraan data suhu udara rata-rata Kota Medan pada tabel 4.4 dan gambar 4.4, prakiraan data suhu udara rata-rata Kota Tokyo pada tabel 4.5 dan gambar 4.5, dan prakiraan data suhu udara rata-rata Kota New York pada tabel 4.6 dan gambar 4.6 dapat disimpulkan bahwa *training* data suhu udara rata-rata dengan *batch size* 4 mendapat *error rate* rendah jika dibandingkan dengan yang lain.

Berdasarkan grafik *box plot* pada Kota Medan, Tokyo, dan New York dengan variasi *epoch* dan *batch size*, maka didapat kesimpulan parameter yang digunakan pada penelitian ini diuraikan pada tabel 4.7.

Tabel 4.7. Tabel parameter training yang digunakan pada penelitian ini.

<i>Epoch</i>	<i>Batch size</i>
1000	4

Hasil prakiraan data suhu udara rata-rata 100 kota besar dunia dari bulan Agustus tahun 1998 sampai dengan bulan Agustus tahun 2013 menggunakan metode LSTM diuraikan pada tabel 4.8.

Tabel 4.8. Tabel prakiraan data suhu udara rata-rata 100 kota besar dunia.

No	City	Country	RMSE	MAPE	Accuracy	Correlation
0	Salvador	Brazil	0.6046	1.8795%	98.1205%	0.8866
1	Tokyo	Japan	1.9567			0.9702
2	Seoul	South Korea	2.623			0.9812
3	Mexico	Mexico	1.1754	5.8612%	94.1388%	0.8753
4	Bombay	India	1.1875	3.5593%	96.4407%	0.7136
5	Delhi	India	2.7357	9.5211%	90.4789%	0.9185
6	New York	United States	2.6327			0.9588
7	Jakarta	Indonesia	0.4203	1.2574%	98.7425%	0.6115
8	Sao Paulo	Brazil	1.6762	6.7179%	93.282%	0.7640
9	Manila	Philippines	0.9448	2.6989%	97.3011%	0.7583
10	Los Angeles	Chile	1.4277	9.3113%	90.6887%	0.91301
11	Shanghai	China	2,0509	14.5583%	85.4417%	0.96901
12	Ha_Noi	Vietnam	2.2082	8.34%	91.66%	0.9131
13	Cairo	Egypt	1.4035	5.2038%	94.796%	0.97225
14	Calcutta	India	2.1099	6.2717%	93.7283%	0.8969
15	Guangzhou	China	2.6486	10.1589%	89.8411%	0.90938
16	Moscow	Russia	4.6627			0.9005
17	Surabaya	Indonesia	0.5800	1.7261%	98.2739%	0.5792
18	Dhaka	Bangladesh	1.9184	5.9589%	94.0411%	0.8921
19	Istanbul	Turkey	2.2215	17.1145%	82.8854%	0.94714
20	Rio de Janeiro	Brazil	1.2057	3.7075	96.2925%	0.7809

Tabel 4.8. Tabel prakiraan data suhu udara rata-rata 100 kota besar dunia. (lanjutan)

No	City	Country	RMSE	MAPE	Accuracy	Correlation
21	Lahore	Pakistan	2.2123	9.3185%	90.6815%	0.9472
22	Shenzhen	Hong Kong	2.0306	8.5109%	91.4891%	0.9316
23	Lagos	Nigeria	0.6207	1.9088%	98.0912%	0.6485
24	Paris	France	2.6578	39.7159%	60.2840%	0.8886
25	Chicago	United States	3.6018			0.90236
26	Chongqing	China	2.3633	13.2566%	86.7434%	0.9485
27	Nagoya	Japan	2.1819	17.1952%	82.805%	0.96519
28	Wuhan	China	2.5788	15.9725%	84.0274%	0.9643
29	Lima	Peru	0.8057	3.7602%	96.2398%	0.95298
30	Bogota	Colombia	0.5083	1.9784%	98.0216%	0.6602
31	Kinshasa	Congo	0.7471	2.5534%	97.4466%	0.74005
32	Washington	United States	2.6399			0.95579
33	Tianjin	China	2.328			0.9779
34	Madras	India	0.9755	2.7198%	97.2802%	0.94
35	Dar Es Salaam	Tanzania	0.5474	1.6173%	98.3827%	0.9406
36	Bangalore	India	1.0606	3.1495%	96.8505%	0.8533
37	Kanpur	India	2.7482	8.9755%	91.0245%	0.9292
38	Johannesburg	South Africa	2.0434	10.8946%	89.1054%	0.9030
39	San Francisco	United States	1.7915	10.0603%	89.9397%	0.9133
40	Essen	Germany	2.8654			0.8966
41	Chaozhou	China	1.9014	7.3795%	92.6205%	0.9412
42	Taipei	Taiwan	1.4882	5.2616%	94.7384%	0.9397
43	Ho Chi Minh City	Vietnam	0.7393	2.1099%	97.8901%	0.7293
44	Baghdad	Iraq	2.0928	9.1042%	90.8958%	0.9767
45	Dallas	United States	2.7227	15.5086%	84.4914%	0.9434
46	Madrid	Spain	2.9019			0.9127
47	Philadelphia	United States	3.2335			0.9345
48	Santiago	Chile	1.6642			0.9458
49	Belo Horizonte	Brazil	1.2333	4.5434%	95.4566%	0.7775
50	Toronto	Canada	3.2669			0.9429
51	Ahmadabad	India	2.2831	6.7175%	93.2825%	0.8857
52	Houston	United States	2.2702	10.2656%	89.7344%	0.9363
53	Detroit	United States	2.5638			0.9644
54	Boston	United States	2.5079			0.9635
55	Atlanta	United States	2.6109	19.4563%	80.5437%	0.94141
56	Khartoum	Sudan	2.3236	6.0649%	93.9351%	0.8447
57	Chengdu	China	1.5127	24.111%	75.889%	0.9751
58	Miami	United States	1.8761	6.05275%	93.947%	0.8931
59	Kuala Lumpur	Malaysia	0.4621	1.319%	98.681%	0.5929

Tabel 4.8. Tabel prakiraan data suhu udara rata-rata 100 kota besar dunia. (lanjutan)

No	City	Country	RMSE	MAPE	Accuracy	Correlation
60	Shenyang	China	2.0915			0.98586
61	Riyadh	Saudi Arabia	1.879	6.8441%	93.1559%	0.97322
62	Caracas	Venezuela	0.588	1.85%	98.15%	0.7639
63	Rangoon	Burma	1.2353	3.442%	96.558%	0.7865
64	Xian	China	2.342			0.96988
65	Saint Petersburg	Russia	3.8189			0.9032
66	Samarinda	Indonesia	0.3738	1.1004%	98.8996%	0.44761
67	Singapore	Singapore	0.4947	1.425%	98.575%	0.6268
68	Guadalajara	Mexico	1.3929	4.84%	95.16%	0.8334
69	Ismailia	Egypt	1.0780	4.2424%	95.7576%	0.9746
70	Tungi	Bangladesh	1.8416	5.6089%	94.3911%	0.8902
71	Sydney	Australia	1.2309	5.3779%	94.6221%	0.8235
72	Phoenix	United States	2.368	10.676%	89.324%	0.9559
73	Algiers	Algeria	2.2301	12.0865%	87.9135%	0.9565
74	Harbin	China	3.8795	35.244%	64.756%	0.9706
75	Yogyakarta	Indonesia	0.5854	1.7978%	98.202%	0.6174
76	Berlin	Germany	3.2689			0.8953
77	Porto Alegre	Brazil	2.0333	9.2158%	90.7842%	0.8680
78	Barcelona	Spain	1.8639	9.2086%	90.7914%	0.9373
79	Milan	Italy	2.6961			0.92571
80	Nanjing	China	2.1079	25.7366%	74.2634%	0.9711
81	Monterrey	Mexico	2.351	9.6012%	90.3988%	0.9227
82	Port Moresby	Papua New Guinea	0.5768	1.8396%	98.1604%	0.7831
83	Surat	India	2.1292	6.3885%	93.6115%	0.8719
84	Hangzhou	China	3.0972	22.9219%	77.0781%	0.9445
85	Casablanca	Morocco	1.9879	9.3113%	90.6887%	0.94695
86	Seattle	United States	2.0661			0.9289
87	Ankara	Turkey	3.5599			0.9271
88	Melbourne	Australia	1.7818	9.7064%	90.2936%	0.9044
89	Recife	Brazil	0.4882	1.4254%	98.5746%	0.9147
90	Semarang	Indonesia	0.5626	1.6951%	98.3049%	0.6477
91	Aleppo	Syria	2.0725	12.2739%	87.7261%	0.9732
92	Athens	Greece	2.7091	14.3079%	85.6921%	0.9281
93	Montreal	Canada	3.0597			0.9625
94	Bangkok	Thailand	1.1723	3.127%	96.873%	0.7229
95	Palembang	Indonesia	0.4545	1.337%	98.663%	0.5878
96	Medan	Indonesia	0.4763	1.411%	98.589%	0.7746
97	Bucharest	Romania	2.7441			0.95539
98	Bandung	Indonesia	0.4809	1.5418%	98.4582%	0.5266
99	Yokosuka	Japan	1.6427	8.76%	91.24%	0.9693

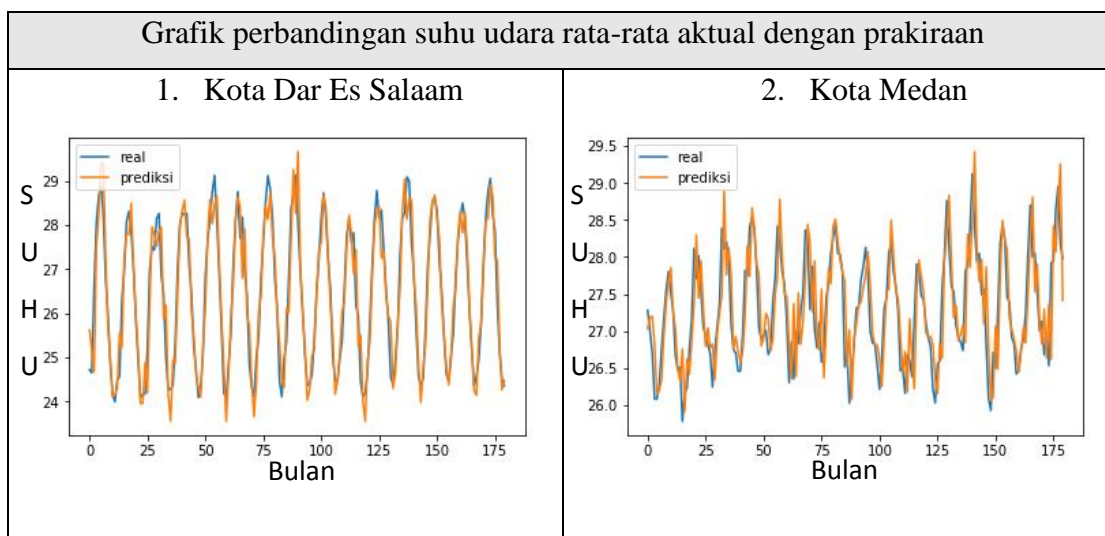
Berdasarkan tabel 4.8. didapat kesimpulan rata-rata *RMSE*, *MAPE*, dan akurasi untuk prakira suhu udara rata-rata 100 kota besar dunia dari bulan September tahun 1998 sampai dengan bulan Agustus tahun 2013 diuraikan pada tabel 4.9. Prakira ini dilakukan dengan tujuan agar membuktikan akurasi prakiraan sebelum melakukan prakira kedepannya, yaitu dari bulan September tahun 2013 sampai dengan bulan Agustus tahun 2018. Nilai *Correlation* diperoleh dari perbandingan data historis suhu udara rata-rata dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 2013 (50 tahun) dengan data suhu udara rata-rata prakira dari bulan September tahun 2013 sampai dengan bulan Agustus tahun 2018. Nilai rata-rata *correlation* suhu udara rata-rata 100 kota dunia yang diuraikan pada tabel 4.9 membuktikan bahwa adanya keterkaitan antara data historis suhu udara rata-rata dengan data prakiraan suhu udara rata-rata.

Tabel 4.9. Tabel rata-rata *RMSE*, *MAPE*, *Accuracy*, dan *Correlation* prakiraan.

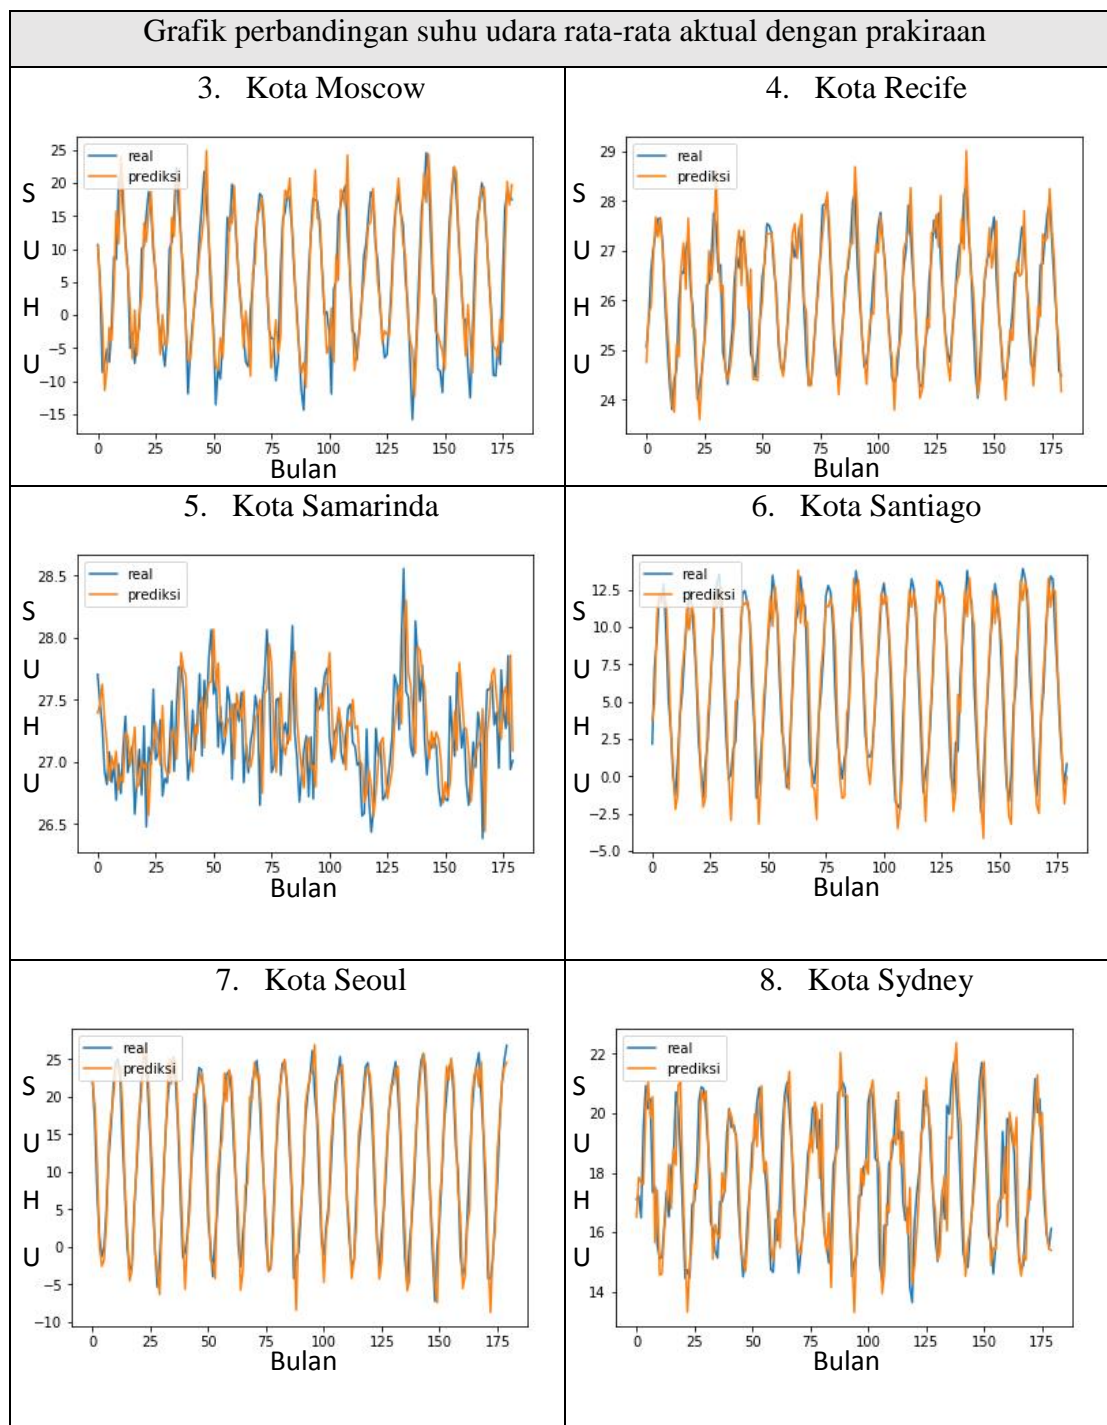
<i>RMSE</i>	<i>MAPE</i>	<i>Accuracy</i>	<i>Correlation</i>
1,881693	8,151584%	91,848416%	0,872803

Grafik perbandingan data aktual suhu udara rata-rata dari bulan September tahun 1998 sampai dengan bulan Agustus tahun 2013 dengan data prakiraan suhu udara rata-rata dari bulan September tahun 1998 sampai dengan bulan Agustus tahun 2013 akan ditampilkan 10 kota besar sebagai contoh digambarkan pada tabel 4.10.

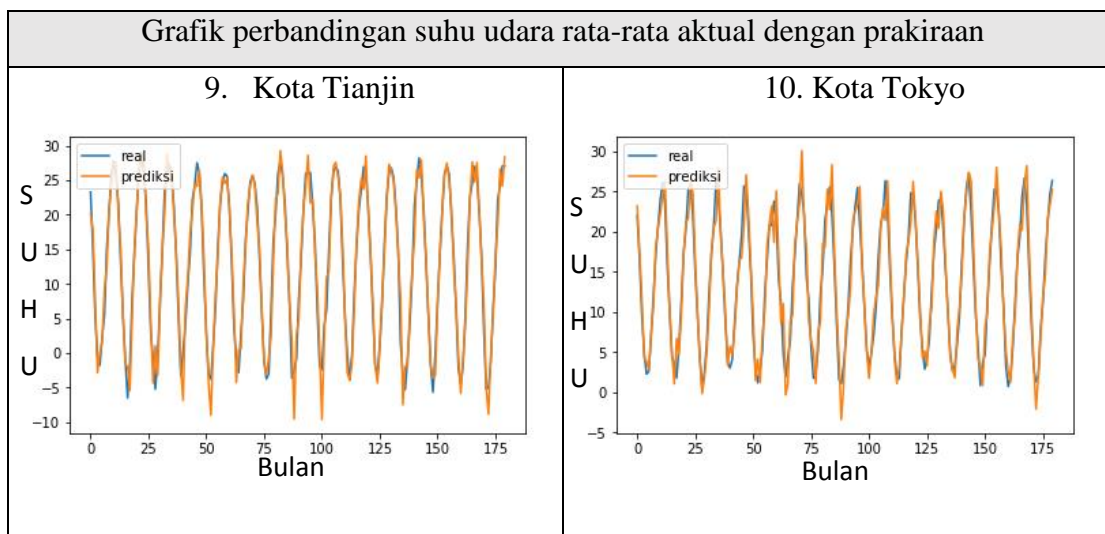
Tabel 4.10. Tabel grafik perbandingan suhu udara rata- rata aktual dengan prakiraan



Tabel 4.10. Tabel grafik perbandingan suhu udara rata- rata aktual dengan prakiraan (lanjutan)




Tabel 4.10. Tabel grafik perbandingan suhu udara rata- rata aktual dengan prakiraan (lanjutan)



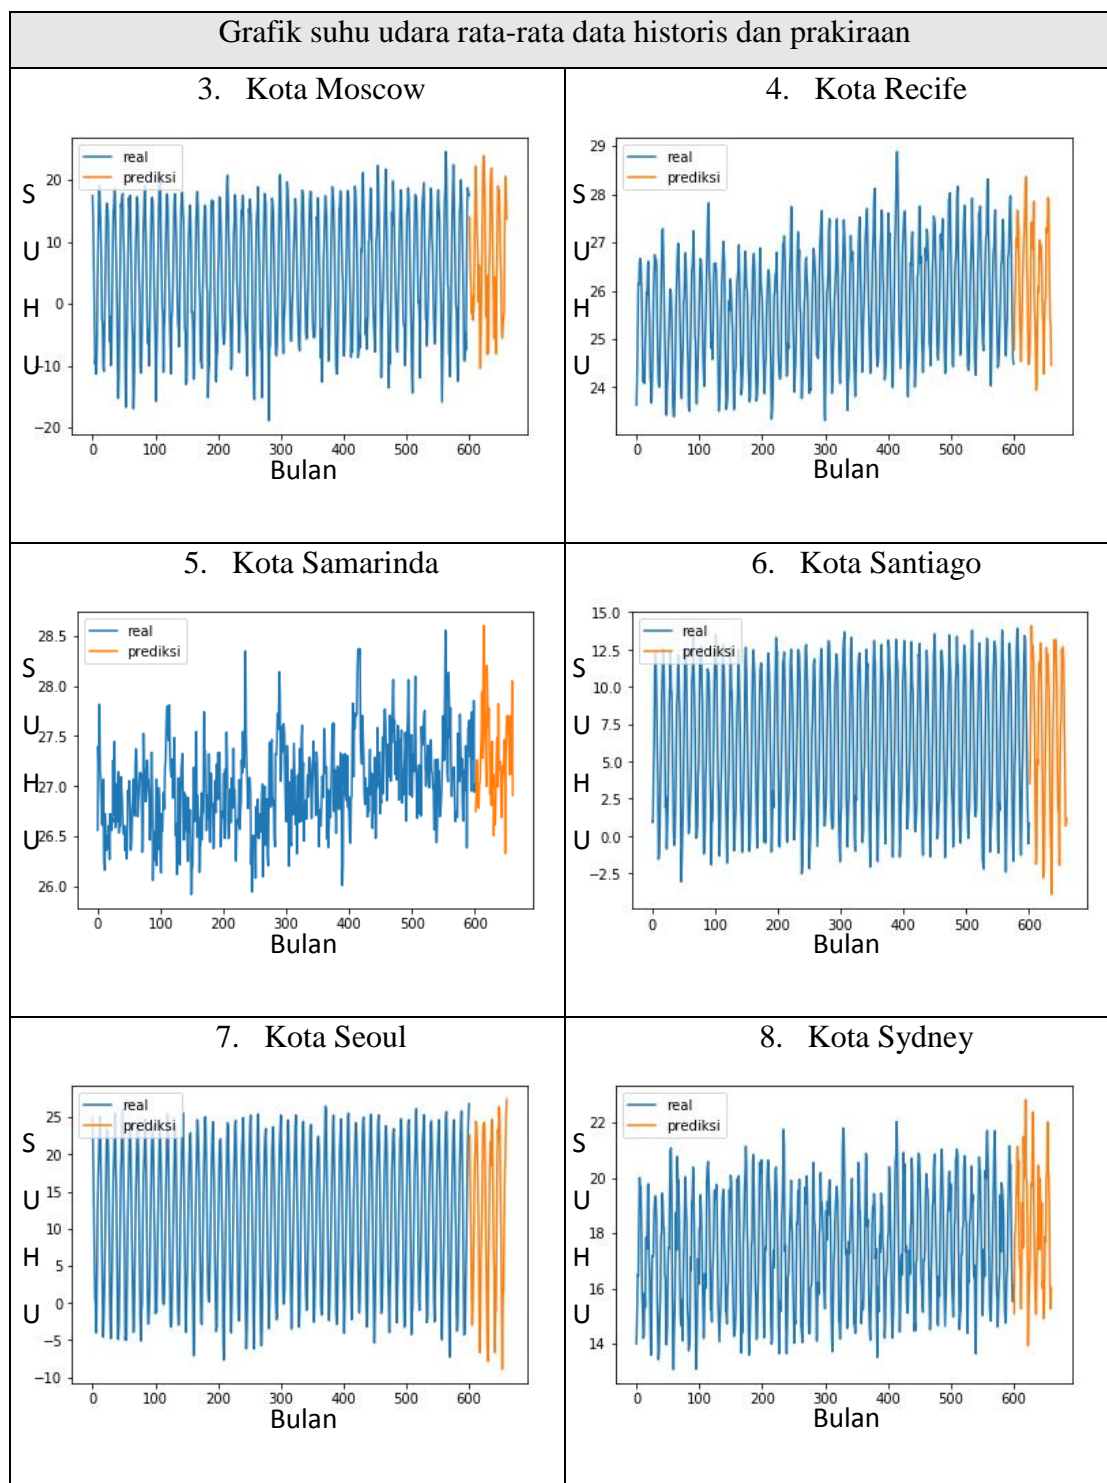
Tabel 4.10 membuktikan nilai RMSE, MAPE , dan akurasi yang diuraikan pada tabel 4.8. Salah satu contoh perbandingan data suhu udara rata-rata aktual dan prakira adalah pada kota Medan bulan ke-180 (bulan Agustus tahun 2013) data aktualnya adalah 27.98 dan data prakiranya adalah 27.3, maka akurasi yang didapatkan adalah 97,57%.

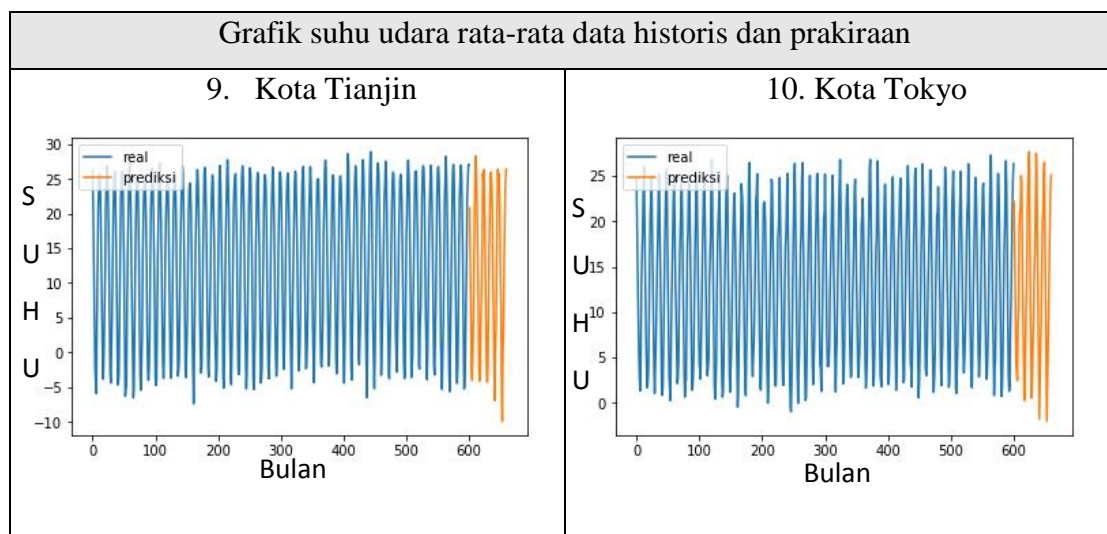
Grafik suhu udara rata- rata data historis dari bulan Agustus tahun 1963 sampai dengan bulan Agustus tahun 2013 dan data prakiraan dari bulan September tahun 2013 sampai dengan bulan Agustus tahun 2018 akan ditampilkan 10 kota besar sebagai contoh digambarkan pada tabel 4.11 dengan tujuan menampilkan *correlation* antara data suhu udara rata-rata historis dengan data suhu udara rata-rata prakiraan.

Tabel 4.11. Tabel grafik suhu udara rata- rata data historis dan prakiraan



Tabel 4.11. Tabel grafik suhu udara rata-rata data historis dan prakiraan (lanjutan)



Tabel 4.11. Tabel grafik suhu udara rata- rata data historis dan prakiraan (lanjutan)

Perbandingan prakira suhu udara rata-rata Kota Medan dari tahun 2013 bulan September sampai dengan tahun 2018 bulan Juni dengan data aktual suhu udara rata-rata Kota Medan yang bersumber dari data online BMKG diuraikan pada tabel 4.12 sebagai pengujian akurasi prakira yang didapatkan pada tabel 4.8 dan pembuktian nilai *correlation* yang diuraikan pada tabel 4.9 dan digambarkan pada tabel 4.11.

Tabel 4.12. Tabel akurasi perbandingan antara data aktual dengan data prakira Kota Medan

Tanggal	Data aktual suhu udara rata-rata	Data Prakiraan suhu udara rata-rata	Akurasi
2013-09-01	27,312	27,227	99,689%
2013-10-01	26,932	26,86	99,732%
2013-11-01	27,187	26,697	98,199%
2013-12-01	26,381	26,661	98,948%
2014-01-01	26,45806452	25,856	97,724%
2014-02-01	27,25535714	26,434	96,986%
2014-03-01	27,96393443	26,675	95,391%
2014-04-01	28,06166667	26,52	94,506%
2014-05-01	28,14677419	28,003	99,489%
2014-06-01	29,11333333	27,92	95,901%
2014-07-01	28,92258065	28,745	99,386%
2014-08-01	27,3	27,869	97,958%

Tabel 4.12. Tabel akurasi perbandingan antara data aktual dengan data prakira Kota Medan (lanjutan)

Tanggal	Data aktual suhu udara rata-rata	Data Prakiraan suhu udara rata- rata	Akurasi
2014-09-01	27,326	27,102	99,18%
2014-10-01	27,42	27,497	99,719%
2014-11-01	27,313	27,08	99,147%
2014-12-01	26,627	26,859	99,136%
2015-01-01	26,5	26,614	99,572%
2015-02-01	26,5	26,838	98,741%
2015-03-01	27,5	28,154	97,677%
2015-04-01	27,2	27,939	97,355%
2015-05-01	28	28,46	98,384%
2015-06-01	28,3	29,589	95,644%
2015-07-01	28	28,263	99,069%
2015-08-01	27,6	27,713	99,592%
2015-09-01	27,7	27,632	99,755%
2015-10-01	27	27,139	99,488%
2015-11-01	26,8	27,557	97,253%
2015-12-01	27,2	26,863	98,761%
2016-01-01	28,088	25,879	92,135%
2016-02-01	27,486	26,148	95,132%
2016-03-01	28,919	26,953	93,202%
2016-04-01	29,333	26,555	90,529%
2016-05-01	28,609	27,551	96,302%
2016-06-01	28,462	28,325	99,519%
2016-07-01	27,984	28,331	98,775%
2016-08-01	28,429	28,8	98,712%
2016-09-01	27,864	26,936	96,669%
2016-10-01	27,485	27,188	98,919%
2016-11-01	27,259	26,89	98,646%
2016-12-01	27,244	26,78	98,297%
2017-01-01	26,284	26,932	97,594%

Tabel 4.12. Tabel akurasi perbandingan antara data aktual dengan data prakira Kota Medan (lanjutan)

Tanggal	Data aktual suhu udara rata-rata	Data Prakiraan suhu udara rata-rata	Akurasi
2017-02-01	26,604	27,225	97,719%
2017-03-01	27,5	27,695	99,296%
2017-04-01	26,857	27,767	96,723%
2017-05-01	27,467	28,215	97,349%
2017-06-01	28,321	28,325	99,986%
2017-07-01	28,586	28,18	98,579%
2017-08-01	27,687	27,815	99,539%
2017-09-01	27,511	27,377	99,513%
2017-10-01	27,2	27,584	98,608%
2017-11-01	26,987	27,085	99,638%
2017-12-01	27,14	26,831	98,861%
2018-01-01	26,694	26,576	99,558%
2018-02-01	27,713	27,126	97,882%
2018-03-01	28,019	26,95	96,185%
2018-04-01	28,027	27,815	99,244%
2018-05-01	27,916	27,968	99,814%
2018-06-01	28,087	28,9	97,187%

Berdasarkan tabel 4.12., rata-rata akurasi perbandingan prakira suhu udara rata-rata Kota Medan dari bulan September tahun 2013 sampai dengan bulan Juni tahun 2018 dengan data aktual suhu udara rata-rata kota medan yang bersumber dari data online BMKG adalah 97,97%. Prakiraan suhu udara rata-rata untuk bulan Juli dan bulan Agustus 2018 tidak bisa dibandingkan, karena pada saat penelitian masih dalam pertengahan bulan Juli.

4.2. Pembahasan

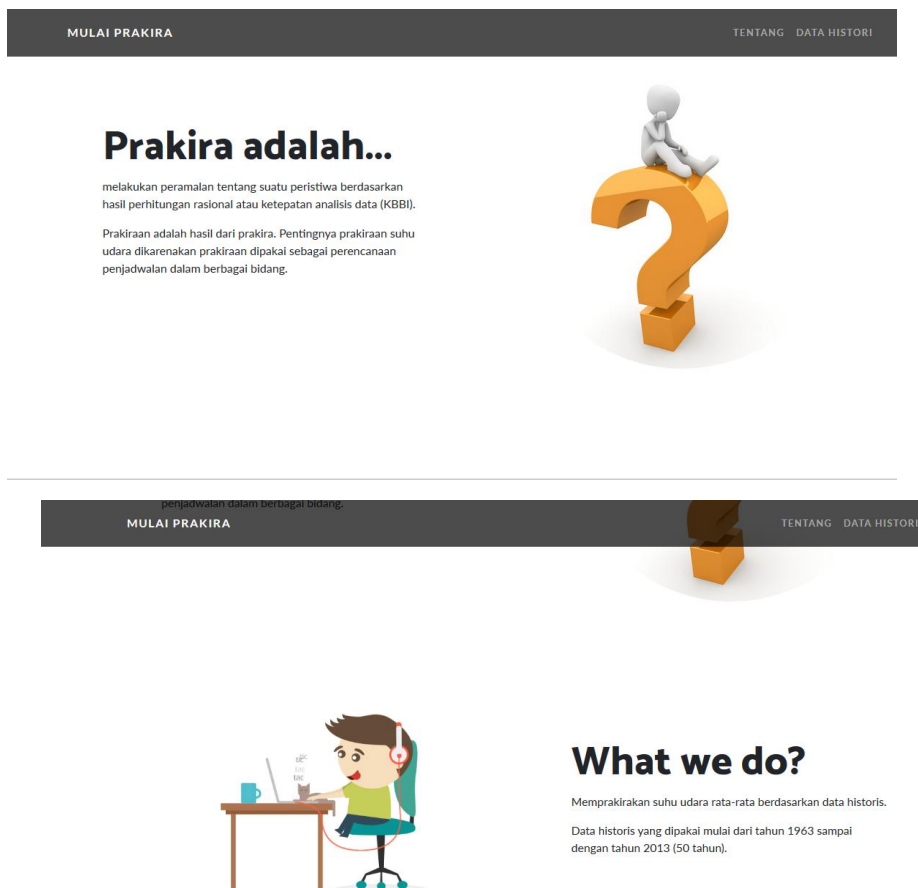
Prakiraan suhu udara rata-rata 100 kota besar dunia diubah ke dalam format json dan dikirim ke *web server*. Data diolah oleh *web server* dan ditampilkan ke dalam bentuk *website* untuk memudahkan *user* dalam melihat data. Pada *website* dibagi ke dalam

beberapa bagian. Bagian pertama adalah bagian *header*, pada bagian ini terdapat 3 navigasi *bar* dan 1 *button* seperti terlihat pada gambar 4.7. Navigasi *bar* pertama adalah mulai prakira, navigasi *bar* ini merujuk ke *header website*. Navigasi *bar* kedua adalah tentang, navigasi *bar* ini merujuk ke bagian yang menjelaskan informasi dari *website* ini. Navigasi *bar* ketiga adalah data historis, navigasi *bar* ini merujuk ke grafik data historis suhu udara rata-rata 100 kota besar dunia. *Button* merujuk ke peta dunia yang berisikan 100 kota sebagai legenda atau titik yang disusun berdasarkan koordinat *longitude* dan *latitude*.



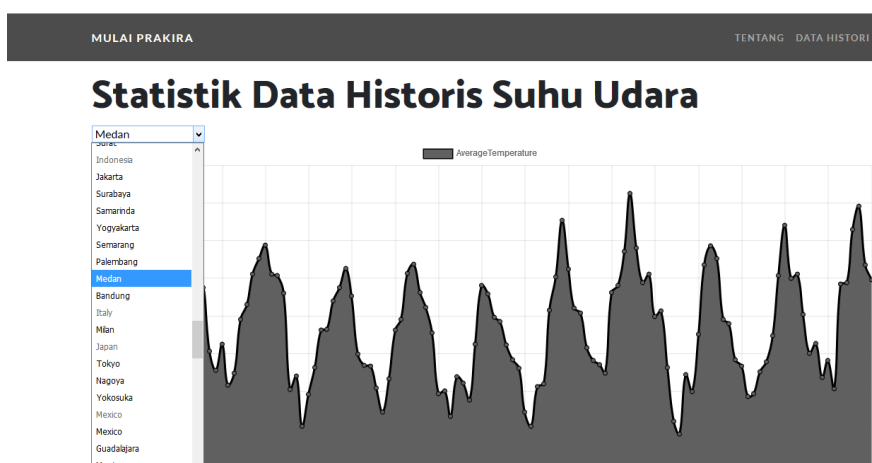
Gambar 4.7. Header website

Bagian kedua adalah informasi tentang *website*, apa yang akan dibahas dan apa yang akan ditampilkan seperti terlihat pada gambar 4.8.



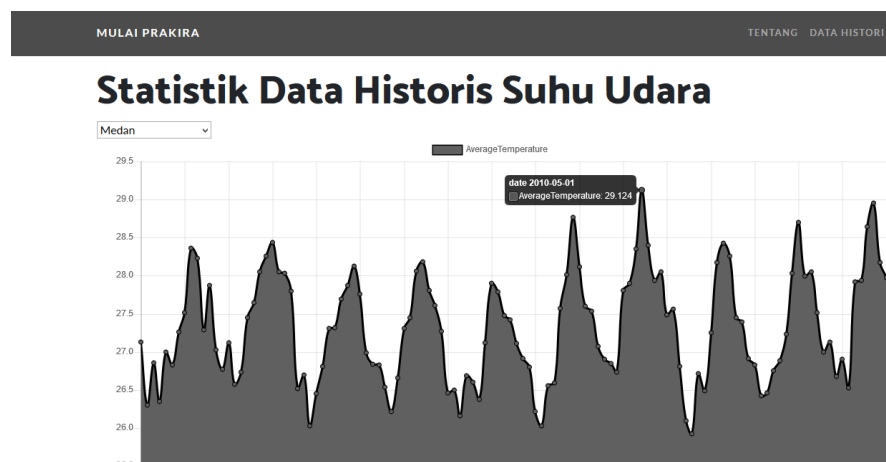
Gambar 4.8. Tentang *website*

Bagian ketiga adalah bagian yang menampilkan grafik data historis suhu udara rata-rata 100 kota besar dunia. Data ditampilkan dalam bentuk grafik dan dibagi berdasarkan kota dan negara agar memudahkan *user* untuk memilih grafik yang akan ditampilkan. Bagian ketiga ditampilkan pada gambar 4.9 dan 4.10.



Gambar 4.9. Memilih kota yang akan ditampilkan grafik data historisnya

Grafik data historis setelah memilih kota yang akan ditampilkan digambarkan pada gambar 4.10.



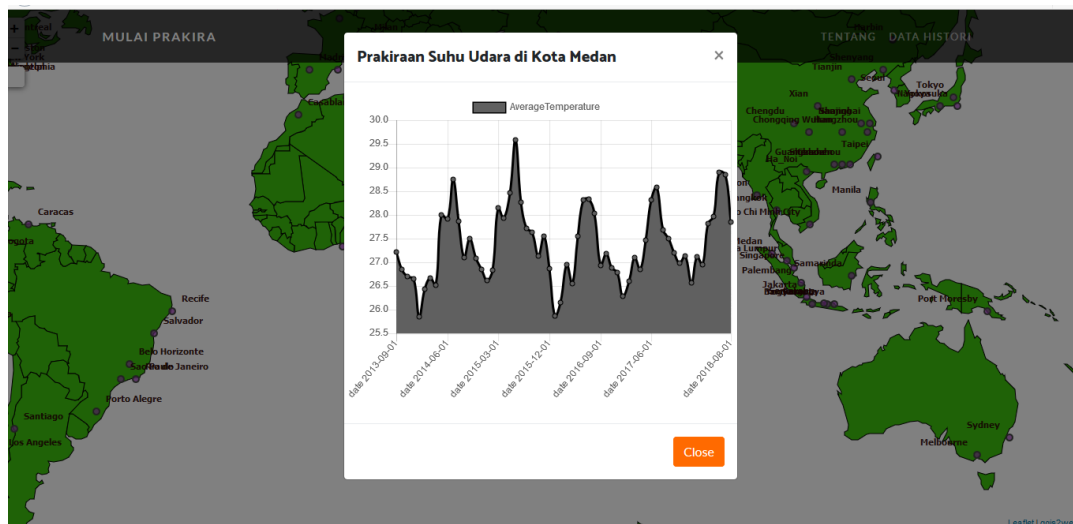
Gambar 4.10. Grafik data historis suhu udara Kota Medan

Bagian keempat adalah bagian yang menampilkan peta dunia dengan 100 kota sebagai legenda atau titik seperti terlihat pada gambar 4.11. Jika mengarahkan *mouse* mendekati legenda atau titik tersebut akan ditampilkan informasi berupa nama kota yang kita arahkan dan nama negara kota tersebut terletak.



Gambar 4.11. Peta dunia dengan 100 kota sebagai titik atau legenda

Untuk menampilkan data prakiraan metode LSTM yang sudah diubah ke dalam format json, dengan cara mengklik kota yang ingin ditampilkan dan data suhu udara rata-rata kota yang diklik akan digambarkan seperti pada gambar 4.12.



Gambar 4.12. Tampilan grafik prakiraan suhu udara di Kota Medan

BAB 5

KESIMPULAN DAN SARAN

5.1 Kesimpulan

1. Pada penelitian ini akurasi yang didapatkan untuk prakira data suhu udara rata-rata kota-kota besar dunia dengan metode *Long Short Term Memory* (LSTM) adalah 91,848416%. Penentuan akurasi ini didasari dengan perhitungan *error rate* dengan menggunakan 3 metode, yaitu: RMSE, MAPE, dan *correlation*. Berdasarkan prakiraan data suhu udara rata-rata 100 kota besar dunia yang didapatkan dengan metode LSTM, diperoleh RMSE adalah 1,881693. Hasil MAPE yang diperoleh adalah 8,151584%. Hasil *correlation* yang diperoleh adalah 0,872803. Nilai RMSE dan MAPE yang rendah, serta akurasi yang baik dan nilai *correlation* yang menunjukkan keterkaitan antara data historis suhu udara rata-rata dengan data prakiraan suhu udara rata-rata, maka metode LSTM terbukti sesuai dalam memprakirakan data suhu udara rata-rata.

2. Akurasi yang rendah seperti pada Kota Harbin dan Kota Paris dikarenakan perubahan suhu udara rata-rata yang jauh jangkauannya dan tidak stabil dari satu bulan ke bulan lain.

3. MAPE tidak bisa digunakan pada kota yang kemungkinan memiliki suhu 0 derajat celcius dikarenakan nilai MAPE akan menjadi tidak terdefinisi jika dibagi dengan 0 pada saat perhitungan.

5.2 Saran

Pada penelitian selanjutnya, diharapkan dapat diterapkan metode LSTM pada prakira cuaca. Perencanaan suatu bidang akan lebih akurat jika menggunakan prakira yang memiliki parameter lebih dari satu tidak sekedar suhu. Pada cuaca terdapat lebih dari satu parameter yang mempengaruhi, yaitu kelembaban, angin, suhu, dan lain sebagainya.

DAFTAR PUSTAKA

- Azzouni, A., & Pujolle, G. (2017). A Long Short-Term Memory Recurrent Neural Network Framework for Network Traffic Matrix Prediction. Retrieved from <http://arxiv.org/abs/1705.05690> (12 Oktober 2017).
- Adianshar. 2014. Penerapan *Recurrent Neural Network* Dalam Identifikasi Tulisan Tangan Huruf Jepang Jenis Katakana. Skripsi. Universitas Sumatera Utara.
- Brownlee, J. (2017). *Long Short-Term Memory Networks With Python Develop Sequence Prediction Models With Deep Learning*.
- Rahmadayanti, R., Susilo, B., & Puspitaningrum, D. (2015). Perbandingan Keakuratan Metode *Autoregressive Integrated Moving Average (ARIMA)* dan *Exponential Smoothing* pada peramalan penjualan semen di PT. Sinar Abadi. *Jurnal Rekursif*, 3(1), 23–36.
- Zheng, J., Xu, C., Zhang, Z., & Li, X. (2017). Electric Load Forecasting in Smart Grid Using Long-Short-Term-Memory based Recurrent Neural Network Electric Load Forecasting in Smart Grid Using Long-Short-Term-Memory based Recurrent Neural Network. *2017 51st Annual Conference on Information Sciences and Systems (CISS)*, (January), 1–6.
- Kong, W., Dong, Z. Y., Jia, Y., Hill, D. J., Xu, Y., & Zhang, Y. (2017). Short-Term Residential Load Forecasting based on LSTM Recurrent Neural Network. *IEEE Transactions on Smart Grid*, 3053(c), 1–11.
- Olah, C. (2015). Understanding LSTM Networks. Retrieved from <http://colah.github.io/posts/2015-08-Understanding-LSTMs/> (13 Oktober 2017).
- Samin, R. E., Kasmani, R. M., Khamis, A., & Isa, S. (2010). Forecasting Sunspot Numbers with Recurrent Neural Networks (RNN) Using “Sunspot Neural Forecaster” System. *2010 Second International Conference on Advances in Computing, Control, and Telecommunication Technologies*, 10–14.

- Toqué, F., Côme, E., Mahrsi, M. K. El, & Oukhellou, L. (2016). Forecasting dynamic public transport origin-destination matrices with long-short term memory recurrent neural networks. *IEEE Conference on Intelligent Transportation Systems, Proceedings, ITSC*, 1071–1076.
- Alahi, A., Goel, K., Ramanathan, V., Robicquet, A., Fei-Fei, L., & Savarese, S. (2016). Social LSTM: Human Trajectory Prediction in Crowded Spaces. *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 961–971.
- Askany, S. A., Elhelow, K., Youssef, I. K., & Abd El-wahab, M. (2011). Rainfall events prediction using rule-based fuzzy inference system. *Atmospheric Research*, 101(1–2), 228–236.
- Barnston, A. G. (1992). Correspondence among the Correlation, RMSE, and Heidke Forecast Verification Measures; Refinement of the Heidke Score. *Climate Analysis Center*, 7, 699–709.
- Hochreiter, S., & Schmidhber, J. (1997). Long Short-term Memory. *Neural Computation*, (December 1997).
- KBBI. (n.d.). Arti kata data historis. Retrieved from https://kbbi.web.id/data_historis (11 Mei 2018).
- KBBI. (n.d.). Arti kata prakira. Retrieved from <https://kbbi.web.id/prakira> (6 Januari 2018).
- KBBI. (n.d.). Arti kata prakiraan. Retrieved from <https://kbbi.web.id/prakiraan> (6 Januari 2018).
- KBBI. (n.d.). Arti kata suhu. Retrieved from <https://kbbi.web.id/suhu> (6 Januari 2018).