

**OPTIMALISASI DEEP LEARNING METHOD DENGAN
LONG SHORT-TERM MEMORY DALAM
MEMPROYEKSI CURAH HUJAN**

SKRIPSI

*Untuk Memenuhi Salah Satu Syarat
Memperoleh Gelar Sarjana Komputer*

**Program Studi : Teknik Informatika
Jenjang Pendidikan : Strata 1 (S1)**



OLEH:

**EDO SULAIMAN
NIM. 18101152630092**

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PUTRA INDONESIA “YPTK” PADANG

2022

LEMBAR PERNYATAAN

Saya yang bertanda tangan dibawah ini :

Nama : EDO SULAIMAN

No. BP : 18101152630092

Jurusan : Teknik Informatika

Fakultas : Ilmu Komputer

Menyatakan Bahwa :

1. Sesungguhnya skripsi yang saya susun ini merupakan hasil karya tulis saya sendiri. Adapun bagian-bagian tertentu dalam skripsi yang saya peroleh dari hasil karya tulis orang lain, telah saya tuliskan sumbernya dengan jelas, sesuai dengan kaidah penulisan ilmiah.
2. Jika dalam pembuatan skripsi secara keseluruhan ternyata terbukti dibuatkan oleh orang lain, maka saya bersedia menerima sanksi yang diberikan oleh akademik, berupa pembatalan skripsi dan mengulang penelitian serta mengajukan judul baru.

Demikianlah surat pernyataan ini saya buat dengan sesungguhnya tanpa ada paksaan dari pihak manapun.

Padang, Juli 2022

EDO SULAIMAN
18101152630092

LEMBAR PENGESAHAN SKRIPSI

OPTIMALISASI DEEP LEARNING METHOD DENGAN LONG SHORT-TERM MEMORY DALAM MEMPROYEKSI CURAH HUJAN

Yang Dipersiapkan dan Disusun Oleh

EDO SULAIMAN

18101152630092

Telah Memenuhi Persyaratan Untuk Dipertahankan di Depan Dewan Pengaji

Pada Ujian Komprehensif

Padang, Juli 2022

Pembimbing I

Pembimbing II

(Dr. Ir. H. Sumijan, M.Sc)
NIP: 196605071994031004

(Musli Yanto, S.Kom, M.Kom)
NIDN: 1007078901

LEMBAR PENGESAHAN PENGUJI SIDANG SKRIPSI

OPTIMALISASI DEEP LEARNING METHOD DENGAN LONG SHORT-TERM MEMORY DALAM MEMPROYEKSI CURAH HUJAN

Yang dipersiapkan dan disusun oleh

EDO SULAIMAN
18101152630092

PROGRAM STUDI TEKNIK INFORMATIKA

**Skripsi ini telah dinyatakan LULUS oleh
Penguji Materi Pada Sidang Skripsi Program Studi Strata 1 Ilmu Komputer
Program Studi Teknik Informatika
Universitas Putra Indonesia "YPTK" Padang
Pada Hari/Tgl :/.../...../.....**

TIM PENGUJI :

- 1.**
- 2.**

Padang,

**Mengetahui
Dekan Fakultas Ilmu Komputer
Universitas Putra Indonesia "YPTK" Padang**

**(Dr. Yuhandri, S.Kom, M.Kom)
NIDN : 1015057301**

LEMBAR PENGESAHAN LULUS SIDANG SKRIPSI

OPTIMALISASI DEEP LEARNING METHOD DENGAN LONG SHORT-TERM MEMORY DALAM MEMPROYEKSI CURAH HUJAN

Yang dipersiapkan dan disusun oleh

**EDO SULAIMAN
18101152630092**

Yang Telah dipertahankan di depan Dewan Pengaji
Pada tanggal :
Dan dinyatakan telah lulus
memenuhi syarat

Pembimbing I

Pembimbing II

**(Dr. Ir. H. Sumijan, M.Sc)
NIP: 196605071994031004**

**(Musli Yanto, S.Kom, M.Kom)
NIDN: 1007078901**

**Padang,
Dekan Fakultas Ilmu Komputer
Universitas Putra Indonesia “YPTK” Padang**

**(Dr. Yuhandri, S.Kom, M.Kom)
NIDN : 1015057301**

ABSTRACT

Nowadays data is support for quick decision-making in various aspects including making predictions regarding accurate rainfall information where the commonly used modeling still has shortcomings such as the use of the number of parameters, mathematical assumptions, and the formulation of equations that tend to be complicated, therefore in the form a system to produce a prediction model that is close to optimal accuracy that is more efficient. deep learning can be applied to predict an event to make decisions such as predicting the rainfall of an area, one of which is the Pariaman Padang. One of the deep learning methods that are suitable for use on sequential data types is Long Short-Term Memory (LSTM). This study applies the deep learning LSTM method with 50 epochs 1 layer, the data used is 9:1, where 90% is training data and 10% is test data, the data range used in the calculation starts from October 16, 2004, to December 14, 2004, where 54 rows of data are used as training data, while the last 4 data lines are used as a comparison of the prediction results of the LSTM method, as well as the measurement of MSE values. The results showed that the MSE value from the evaluation of the model that was trained for 50 epochs got an MSE value of 0.03 for the prediction results of testing data for the next 4 days. The implementation of the LSTM method into the system makes it easier to make comparisons and future predictions compared to doing mathematical calculations manually, this convenience provides benefits so that the process of predicting rainfall in the Padang Pariaman area can be done more easily, quickly, and efficiently.

Keywords : Deep Learning, BMKG, Climatology, Rainfall, Long Short-Term Memory.

ABSTRAK

Dewasa ini data merupakan penunjang pengambilan keputusan secara cepat dalam berbagai aspek termasuk melakukan prediksi mengenai informasi curah hujan yang akurat di mana pemodelan yang biasa di gunakan masih memiliki kekurangan seperti penggunaan jumlah parameter, asumsi matematis, dan rumusan persamaan yang cenderung rumit, maka dari itu di bentuk suatu sistem untuk menghasilkan sebuah model prediksi yang mendekati keakuratan optimal yang lebih efisien. *deep learning* dapat diterapkan untuk memprediksi suatu peristiwa untuk mengambil keputusan seperti memprediksi curah hujan suatu area salah satunya padang pariaman. Salah satu metode deep learning yang cocok digunakan pada tipe data sekuensial adalah *Long Short-Term Memory (LSTM)*. Penelitian ini menerapkan *deep learning* metode LSTM dengan 50 *epoch* 1 *layer*, data yang di gunakan berbanding 9:1 dimana 90% sebagai data training dan 10% sebagai data uji, rentang data yang digunakan dalam perhitungan di mulai dari tanggal 16 Oktober 2004 sampai 14 Desember 2004 dimana 54 baris data digunakan sebagai data training, sedangkan data 4 baris terakhir digunakan sebagai perbandingan hasil prediksi metode LSTM, serta pengukuran nilai MSE. Hasil penelitian menunjukkan bahwa nilai MSE hasil evaluasi dari model yang di latih selama 50 *epoch* mendapat nilai MSE sebesar 0.03 untuk hasil prediksi data testing 4 hari kedepan. Implementasi metode LSTM ke dalam sistem mempermudah dalam melakukan perbandingan dan prediksi yang akan datang di bandingkan melakukan perhitungan matematis secara manual, kemudahan tersebut memberikan manfaat agar proses prediksi curah hujan daerah padang pariaman dapat di lakukan lebih mudah, cepat, dan efisien.

Kata Kunci : *Deep Learning, BMKG, Klimatologi, Curah Hujan, Long Short-Term Memory.*

KATA PENGANTAR



Syukur Alhamdulillah, berkat rahmat Allah SWT yang telah memberikan segala karunia-Nya sehingga penulis dapat menyelesaikan skripsi ini dengan baik dan tepat waktu. Dan tidak lupa shalawat dan salam kepada Nabi Besar Muhammad SAW yang telah berjasa besar dengan membuka jalan dalam perkembangan ilmu pengetahuan seperti sekarang ini.

Adapun judul dari skripsi ini adalah "**OPTIMALISASI DEEP LEARNING METHOD DENGAN LONG SHORT-TERM MEMORY DALAM MEMPROYEKSI CURAH HUJAN**".

Pada kesempatan ini penulis ingin menyampaikan ucapan terimakasih yang setulusnya kepada pihak yang telah membantu dalam penulisan skripsi ini, terutama kepada :

1. Ketua Yayasan **Dr. Hj. Zerni Melmusi, MM, Ak, CA**, selaku Ketua Perguruan Tinggi Komputer "YPTK" Padang
2. Bapak **Prof. Dr. H. Sarjon Defit, S.Kom, M.Sc**, selaku Rektor Universitas Putra Indonesia "YPTK" Padang.
3. Bapak **Dr. Yuhandri, S.Kom, M.Kom**, selaku Dekan Fakultas Ilmu Komputer Universitas Putra Indonesia "YPTK" Padang.

4. Bapak **Eka Praja Wiyata Mandala, S.Kom, M.Kom**, selaku Ketua Jurusan Teknik Informatika Fakultas Ilmu Komputer Universitas Putra Indonesia “YPTK” Padang.
5. Bapak **Dr. Ir. H. Sumijan, M. Sc**, selaku Dosen pembimbing I yang telah banyak memberikan pengetahuan dan arahan kepada penulis.
6. Bapak **Musli Yanto, S.Kom, M.Kom**, selaku Dosen pembimbing II yang telah banyak memberikan pengetahuan dan arahan kepada penulis.
7. Seluruh Keluarga Universitas Putra Indonesia “YPTK” yang telah banyak membantu dalam pemberian data-data yang diperlukan.
8. Seluruh Bapak dan Ibu Dosen yang telah mendidik dan mengajar penulis berbagai disiplin ilmu di fakultas ilmu komputer.
9. Segenap karyawan dan karyawati di lingkungan Universitas Putra Indonesia “YPTK” Padang yang telah memberikan jasanya dalam penanganan administrasi akademik.

Penulis menyadari dalam penulisan skripsi ini, hasilnya masih jauh dari sempurna. Untuk itu penulis sangat mengharapkan saran-saran dan kritikan yang bersifat membangun. Akhir kata penulis berharap semoga skripsi ini dapat memberikan manfaat bagi penulis dan bagi pembaca pada umumnya.

Padang, Juli 2022

Penulis

DAFTAR ISI

LEMBAR PERNYATAAN	II
LEMBAR PERSETUJUAN PEMBIMBING	III
LEMBAR PENGESAHAN.....	V
LEMBAR PENGESAHAN PENGUJI SIDANG SKRIPSI.....	IV
ABSTRACT.....	VI
ABSTRAK.....	VII
KATA PENGANTAR	VIII
DAFTAR ISI.....	X
DAFTAR GAMBAR	XVII
DAFTAR TABEL.....	XXI
BAB I PENDAHULUAN	1
1.1. LATAR BELAKANG	1
1.2. PERUMUSAN MASALAH.....	6
1.3. HIPOTESIS.....	7
1.4. BATASAN MASALAH	7
1.5. TUJUAN PENELITIAN	8
1.6. MANFAAT PENELITIAN	8
1.7. GAMBARAN UMUM OBJEK PENELITIAN	8
1.7.1. <i>Sejarah BMKG.....</i>	9
1.7.2. <i>Struktur Organisasi.....</i>	11
1.7.3. <i>Visi</i>	12

1.7.4. <i>Misi</i>	13
BAB II LANDASAN TEORI.....	14
2.1. REKAYASA PERANGKAT LUNAK	14
2.1.1. <i>Proses Rekayasa Perangkat Lunak</i>	15
2.1.1.1. Komunikasi	15
2.1.1.2. Perencanaan.....	15
2.1.1.3. Pemodelan	15
2.1.1.4. Konstruksi	16
2.1.1.5. Penyerahan	16
2.1.2. <i>Software Development Life Cycle (SDLC)</i>	16
2.1.2.1. Tahap-Tahap SDLC	16
2.1.2.2. Model <i>Waterfall</i>	17
2.2. <i>UNIFIED MODELLING LANGUAGE (UML)</i>	19
2.2.1. <i>Behavior Diagrams</i>	21
2.2.1.1. <i>Use case Diagram</i>	21
2.2.1.2. <i>Activity Diagram</i>	22
2.2.1.3. <i>Statechart Diagram</i>	23
2.2.2. <i>Interaction Diagrams</i>	24
2.2.2.1. <i>Sequence Diagram</i>	24
2.2.2.2. <i>Collaboration Diagram</i>	26
2.2.3. <i>Structure Diagrams</i>	27
2.2.3.1. <i>Class Diagram</i>	27
2.2.3.2. <i>Deployment Diagram</i>	28
2.3. <i>ARTIFICIAL INTELLIGENCE</i>	29

2.4. <i>MACHINE LEARNING</i>	31
2.4.1. <i>Tipe-tipe Machine Learning</i>	32
2.4.1.1. <i>Supervised Learning</i>	32
2.4.1.2. <i>Unsupervised Learning</i>	33
2.4.1.3. <i>Reinforcement Learning</i>	34
2.5. <i>DEEP LEARNING</i>	35
2.6. JARINGAN SYARAF TIRUAN	36
2.6.1. <i>Arsitektur Jaringan Syaraf Tiruan</i>	38
2.6.1.1. Single Perceptron	39
2.6.1.2. Multilayer Perceptron (MLP)	40
2.6.1.3. Competitive Layer Net	41
2.6.2. <i>Teknik Training Jaringan Syaraf Tiruan</i>	42
2.6.2.1. <i>Forward Propagation / Forward pass</i>	42
2.6.2.2. <i>Backward propagation / Backward Pass</i>	43
2.7. LONG SHORT-TERM MEMORY	47
2.7.1. <i>Proses Training dan Testing Pada LSTM</i>	49
2.7.1.1. <i>Training Model LSTM</i>	49
2.7.1.2. <i>Testing Model LSTM</i>	51
2.7.2. <i>Fungsi Aktivasi Pada LSTM</i>	51
2.7.2.1. <i>Sigmoid (σ)</i>	51
2.7.2.2. <i>Hyperbolic (Tanh)</i>	52
2.7.3. <i>Langkah Training Gates Pada LSTM</i>	53
2.7.3.1. <i>Forget Gate</i>	54
2.7.3.2. <i>Input Gate</i>	55

2.7.3.3. <i>Cell state / Memory State</i>	56
2.7.3.4. <i>Output Gate</i>	58
2.7.4. <i>Loss Function</i>	59
2.7.4.1. <i>Mean Squared Error (MSE)</i>	59
2.7.5. <i>Batch dan Epochs</i>	60
2.7.6. <i>Normalisasi dan Denormalisasi</i>	61
2.7.7. <i>Interpolasi Linear</i>	62
2.8. PREDIKSI / FORECASTING	63
2.9. PENELITIAN TERDAHULU	64
BAB III METODOLOGI PENELITIAN.....	69
3.1. KERANGKA PENELITIAN.....	69
3.2. TAHAPAN PENELITIAN.....	70
3.2.1. <i>Penelitian Pendahuluan</i>	70
3.2.2. <i>Pengumpulan Data</i>	71
3.2.2.1. Waktu Penelitian	71
3.2.2.2. Tempat Penelitian.....	72
3.2.2.3. Metode Penelitian.....	72
3.2.3. <i>Analisa</i>	74
3.2.3.1. Analisa Data	74
3.2.3.2. Analisa Proses	74
3.2.3.3. Analisa Sistem.....	75
3.2.4. <i>Perancangan</i>	75
3.2.4.1. Perancangan Model	75
3.2.4.2. Perancangan <i>Interface</i>	77

3.2.5. <i>Implementasi</i>	77
3.2.5.1. Perangkat Keras (<i>Hardware</i>).....	78
3.2.5.2. Perangkat Lunak (<i>Software</i>).....	78
3.2.5.3. Manusia (<i>Brainware</i>)	78
3.2.6. <i>Pengujian</i>	78
3.2.6.1. Pengujian Lokal.....	78
3.2.6.2. Pengujian <i>Online</i>	79
3.2.6.3. Pengujian Aplikasi	79
3.2.6.4. Pengujian <i>Interface</i>	79
3.2.7. <i>Hasil Pembahasan</i>	79
BAB IV ANALISA DAN PERANCANGAN	81
4.1. ANALISA	81
4.1.1. <i>Analisa Data</i>	81
4.1.1.1. <i>Preprocessing Data</i>	83
4.1.1.2. <i>Pembagian Data Training dan Testing</i>	86
4.1.2. <i>Analisa Proses</i>	87
4.1.2.1. <i>Proses Training Model</i>	92
4.1.2.2. <i>Proses Testing Model</i>	93
4.1.2.3. <i>Perhitungan Manual LSTM</i>	93
4.1.3. <i>Analisa Sistem</i>	117
4.1.3.1. <i>Analisa Desain Database</i>	118
4.1.3.2. <i>Analisa Hasil Output Pengujian</i>	122
4.2. PERANCANGAN.....	122
4.2.1. <i>Perancangan Model</i>	123

4.2.1.1. <i>Use case Diagram</i>	123
4.2.1.2. <i>Class Diagram</i>	127
4.2.1.3. <i>Activity Diagram</i>	128
4.2.1.4. <i>Sequence Diagram</i>	130
4.2.1.5. <i>Collaboration Diagram</i>	136
4.2.1.6. <i>Statechart Diagram</i>	142
4.2.1.7. <i>Deployment Diagram</i>	148
4.2.2. <i>Perancangan Interface</i>	149
4.2.2.1. Desain Halaman <i>Login</i>	149
4.2.2.2. Desain Halaman <i>Home</i>	150
4.2.2.3. Desain Daftar Tabel Data Klimatologi.....	150
4.2.2.4. Desain <i>Form</i> Tambah Data Klimatologi	151
4.2.2.5. Desain <i>Form</i> Edit Data Klimatologi	152
4.2.2.6. Desain Tabel Riwayat Proyeksi	153
4.2.2.7. Desain <i>Form</i> Buat Proyeksi	154
4.2.2.8. Desain Hasil Proyeksi Data.....	155
BAB V IMPLEMENTASI DAN PENGUJIAN	157
5.1. IMPLEMENTASI SISTEM.....	157
5.1.1. <i>Hardware</i>	157
5.1.2. <i>Software</i>	157
5.1.3. <i>Brainware</i>	158
5.1.4. <i>Lingkungan Implementasi</i>	158
5.1.4.1. Perangkat Keras (<i>Hardware</i>).....	158
5.1.4.2. Perangkat Lunak (<i>Software</i>).....	159

<i>5.1.5. Proses Instalasi.....</i>	159
5.1.5.1. Tahap Instalasi Bahasa Pemograman <i>Python</i>	160
5.1.5.2. Tahap Instalasi <i>Module Dependensi Python</i>	163
5.1.5.3. Tahap Instalasi MySQL.....	165
5.2. PENGUJIAN SISTEM.....	180
<i>5.2.1. Pengujian Interface.....</i>	<i>180</i>
5.2.1.1. Interface Halaman <i>Login</i>	181
5.2.1.2. Interface Halaman <i>Home</i>	181
5.2.1.3. Interface Tabel Data Klimatologi	182
5.2.1.4. Interface Tambah Data Klimatologi.....	183
5.2.1.5. Interface Edit Data Klimatologi	184
5.2.1.6. Interface Tabel Riwayat Proyeksi	185
5.2.1.7. Interface Buat Proyeksi	186
5.2.1.8. Interface Hasil Proyeksi Data.....	187
<i>5.2.2. Pengujian Sistem.....</i>	<i>191</i>
5.2.2.1. Pengujian Perbedaan Nilai MSE Setiap <i>Epoch</i>	192
5.2.2.2. Pengujian Perbedaan Nilai MSE Pada Evaluasi <i>Testing</i>	194
5.2.2.3. Pengujian Perbedaan Nilai Hasil Prediksi	195
5.2.2.4. Konversi Hasil Prediksi Curah Hujan Dalam Nilai Nyata	196
BAB VI PENUTUP	198
6.1. KESIMPULAN	198
6.2. SARAN.....	199
DAFTAR PUSTAKA	ERROR! BOOKMARK NOT DEFINED.

DAFTAR GAMBAR

Gambar 1.1. Struktur Organisasi BMKG Padang Pariaman	11
Gambar 2.1. Bagan UML	20
Gambar 2.2. Struktur <i>Machine Learning</i>	32
Gambar 2.3. Cara Kerja <i>Supervised Learning</i> (SL)	33
Gambar 2.4. Cara Kerja <i>Unsupervised Learning</i> (UL)	34
Gambar 2.5. Cara Kerja <i>Reinforcement Learning</i> (RL)	35
Gambar 2.6. Hubungan antar metode yang dalam ML (UL, SL, RL, dan DL)	35
Gambar 2.7. Perbedaan Simple <i>Neural Network</i> dan <i>Deep Learning</i>	36
Gambar 2.8. Skema Jaringan Saraf Tiruan.....	37
Gambar 2.9. Perceptron <i>Input</i> dan <i>Output</i>	38
Gambar 2.10. Single Perceptron.....	39
Gambar 2.11. <i>Deep Neural Network Multilayer Perceptron</i>	40
Gambar 2.12. Competitive <i>Layer Net</i>	42
Gambar 2.13. <i>Forward Propagation</i>	43
Gambar 2.14. <i>Backward Propagation</i>	44
Gambar 2.15. Arsitektur LSTM berisi empat <i>layer</i> yang saling berinteraksi.	47
Gambar 2.16. Alur Informasi <i>Cell state</i> pada LSTM.....	48
Gambar 2.17. <i>Layer sigmoid</i> mengeluarkan angka antara nol dan satu.....	49
Gambar 2.18. Ilustrasi <i>Sigmoid</i>	52
Gambar 2.19. Ilustrasi <i>Tanh</i>	53
Gambar 2.20. Persamaan <i>Forget Gate</i> pada LSTM	54
Gambar 2.21. Persamaan yang melewati <i>Input Gate</i> pada LSTM	55
Gambar 2.22. Persamaan Memperbaharui <i>Cell state</i> pada LSTM	57

Gambar 2.23. Persamaan melewati <i>Output Gate</i> pada LSTM	58
Gambar 3.1. Kerangka Penelitian.....	70
Gambar 4.1. Skala Pembagian Data <i>Training</i> dan Data <i>Testing</i>	86
Gambar 4.2. Analisa Proses	87
Gambar 4.3. Contoh Sketsa Grafik <i>Output</i> Hasil Pengujian	122
Gambar 4.4. <i>Use case Diagram Admin</i>	126
Gambar 4.5. <i>Class Diagram</i>	128
Gambar 4.6. <i>Activity Diagram Admin</i>	129
Gambar 4.7. <i>Sequence Diagram Login</i>	131
Gambar 4.8. <i>Sequence Diagram Home</i>	132
Gambar 4.9. <i>Sequence Diagram Data Klimatologi</i>	133
Gambar 4.10. <i>Sequence Diagram Riwayat Proyeksi</i>	134
Gambar 4.11. <i>Sequence Diagram Logout</i>	136
Gambar 4.12. <i>Collaboration Diagram Login</i>	137
Gambar 4.13. <i>Collaboration Diagram Home</i>	138
Gambar 4.14. <i>Collaboration Diagram Data Klimatologi</i>	139
Gambar 4.15. <i>Collaboration Diagram Riwayat Proyeksi</i>	140
Gambar 4.16. <i>Collaboration Diagram Logout</i>	142
Gambar 4.17. <i>Statechart Diagram Login</i>	143
Gambar 4.18. <i>Statechart Diagram Home</i>	144
Gambar 4.19. <i>Statechart Diagram Data Klimatologi</i>	145
Gambar 4.20. <i>Statechart Diagram Riwayat Proyeksi</i>	146
Gambar 4.21. <i>Statechart Diagram Logout</i>	148
Gambar 4.22. <i>Deployment Diagram</i>	148

Gambar 4.23. Desain Halaman <i>Login</i>	149
Gambar 4.24. Desain Halaman <i>Home</i>	150
Gambar 4.25. Desain Daftar Tabel Data Klimatologi.....	151
Gambar 4.26. Desain <i>Form</i> Tambah Data Klimatologi	152
Gambar 4.27. Desain <i>Form</i> Edit Data Klimatologi.....	153
Gambar 4.28. Desain Tabel Riwayat Proyeksi.....	154
Gambar 4.29. Desain <i>Form</i> Buat Proyeksi.....	155
Gambar 4.30. Desain Hasil Proyeksi Data	156
Gambar 5.1. Antarmuka Awal Instalasi <i>Python</i>	160
Gambar 5.2. Antarmuka Bar Proses Instalasi <i>Python</i>	161
Gambar 5.3. Antarmuka Installasi <i>Python</i> Berhasil	162
Gambar 5.4. Perintah Melihat Versi <i>Python</i> yang Terinstall	163
Gambar 5.5. Perintah Untuk Menginstall <i>Module Python</i> yang di Butuhkan....	164
Gambar 5.6. <i>Python</i> Melakukan Installasi <i>Module</i> Yang di Butuhkan.....	165
Gambar 5.7. Antarmuka Awal Instalasi MySQL	166
Gambar 5.8. Antarmuka Select Products pada Instalasi MySQL	167
Gambar 5.9. Antarmuka Installation pada MySQL	168
Gambar 5.10. Antarmuka Proses Instalasi MySQL	169
Gambar 5.11. Antarmuka Instalasi Produk MySQL Berhasil.....	170
Gambar 5.12. Antarmuka Permintaan Konfiguasi Setelah Instalasi MySQL.....	171
Gambar 5.13. Antarmuka <i>Type and Networking</i> Pada Installasi MySQL	172
Gambar 5.14. Antarmuka Authentication Method Pada Installasi MySQL.....	173
Gambar 5.15. Antarmuka Accounts and Roles Pada Installasi MySQL.....	174
Gambar 5.16. Antarmuka Windows Service Pada Installasi MySQL	175

Gambar 5.17. Antarmuka Apply Configuration Pada Installasi MySQL	176
Gambar 5.18. Antarmuka Proses Apply Configuration MySQL	177
Gambar 5.19. Antarmuka Instalasi MySQL Selesai	178
Gambar 5.20. Perintah Melihat Versi <i>MySQL</i> yang Terinstall	179
Gambar 5.21. Antarmuka Awal Instalasi MySQL	180
Gambar 5.22. Interface Halaman <i>Login</i>	181
Gambar 5.23. Interface Halaman <i>Home</i>	182
Gambar 5.24. Interface Daftar Tabel Data Klimatologi	183
Gambar 5.25. Interface <i>Form</i> Tambah Data Klimatologi	184
Gambar 5.26. Interface <i>Form</i> Edit Data Klimatologi	185
Gambar 5.27. Interface Daftar Tabel Riwayat Proyeksi	186
Gambar 5.28. Interface <i>Form</i> Buat Proyeksi	187
Gambar 5.29. Interface Hyperparameter dan Timeline Proses Proyeksi	188
Gambar 5.30. Interface Grafik Hasil Proyeksi Data	189
Gambar 5.31. Interface Tabel Keterangan Grafik Hasil Proyeksi Data	189
Gambar 5.32. Interface Grafik <i>Error</i> Hasil Proyeksi Data	190

DAFTAR TABEL

Tabel 2.1. Notasi <i>Use case</i> Diagram	21
Tabel 2.2. Notasi <i>Activity</i> Diagram	22
Tabel 2.3. Notasi <i>Statechart</i> Diagram	23
Tabel 2.4. Notasi <i>State Machine</i> Diagram	25
Tabel 2.5. Notasi <i>Collaboration</i> Diagram.....	26
Tabel 2.6. Notasi <i>Class</i> Diagram.....	27
Tabel 2.7. Notasi <i>Deployment</i> Diagram	28
Tabel 3.1. Jadwal Penelitian.....	71
Tabel 4.1. Fitur Data Klimatologi BMKG Padang Pariaman	81
Tabel 4.2. Data <i>Stasiun Klimatologi Kelas II Sicincin Padang Pariaman</i>	82
Tabel 4.3. Data Klimatologi Sebelum dan Sesudah di Interpolate NaN	84
Tabel 4.4. Data Klimatologi Sebelum dan Sesudah di MinMaxScaller.....	85
Tabel 4.5. Penjelasan Blok Diagram Analisa Proses	88
Tabel 4.6. Nilai Inisialisasi <i>Hyperparameter</i>	94
Tabel 4.7. Data Yang di Gunakan Dalam Perhitungan Manual LSTM	95
Tabel 4.8. Dimensi <i>Parameter</i> Pada Jaringan LSTM	98
Tabel 4.9. Dimensi <i>Output</i> Pada Jaringan LSTM	99
Tabel 4.10. Hasil <i>Forward Epoch 1 Batch 2-52</i>	107
Tabel 4.11. Hasil <i>Backward Epoch 1 Batch 2-52</i>	109
Tabel 4.12. Nilai <i>Error Epoch 1 Batch 2-52</i>	111
Tabel 4.13. Nilai <i>Error Epoch 2-50</i>	114
Tabel 4.14. <i>Bias</i> dan <i>Weight</i> dari Learned Model	115
Tabel 4.15. Hasil <i>Testing Model</i>	116

Tabel 4.16. Tabel <i>auth_user</i>	118
Tabel 4.17. Tabel <i>django_session</i>	119
Tabel 4.18. Tabel <i>proyeksi_klimatologi</i>	120
Tabel 4.19. Tabel <i>proyeksi_riwayat</i>	121
Tabel 4.20. Definisi Aktor.....	123
Tabel 4.21. Definisi <i>Use case</i> yang digunakan	124
Tabel 4.22. Definisi <i>Class Diagram</i>	127
Tabel 5.1. Nilai <i>Hyperparameter</i> Dalam Pengujian Sistem.....	192
Tabel 5.2. Perbandingan Hasil Nilai <i>MSE Epoch</i> 1-50	193
Tabel 5.3. Perbandingan Hasil Nilai Evaluasi <i>Testing</i>	195
Tabel 5.4. Perbandingan Hasil Prediksi	195
Tabel 5.5. Rentang Nilai Curah Hujan	196
Tabel 5.6. Denormalisasi Nilai Hasil Prediksi Perhitungan Sistem	197

BAB I

PENDAHULUAN

1.1. Latar Belakang

Dewasa ini data merupakan penunjang pengambilan keputusan secara cepat, atau dikenal dengan istilah *Data Driven Decision Making (DDDM)* di mana kemajuan teknologi berperan besar dalam memanfaatkan data dan informasi tersebut (Aditya, Mulyana, Eka, & Widianto, 2020). Dalam berbagai aspek termasuk melakukan prediksi mengenai informasi curah hujan yang akurat di mana pemodelan tersebut masih memiliki kekurangan seperti penggunaan jumlah *parameter*, asumsi matematis, dan rumusan persamaan yang cenderung rumit, untuk menghasilkan sebuah model prediksi yang mendekati keakuratan optimal harus memiliki banyak *parameter* dan *variabel input* untuk memenuhi sebuah asumsi prediksi (Supriyadi, 2019).

Mengatasi perihal tersebut, dikembangkanlah sebuah *Kecerdasan Buatan (Artificial Intelligence)* yang memiliki kemampuan untuk melakukan pembelajaran untuk menganalisis berbagai macam asumsi dan aspek yang berpengaruh untuk menarik kesimpulan (Supriyadi, 2019). *Artificial Intelligence (AI)* atau *kecerdasan buatan* didefinisikan secara berbeda dalam konteks yang berbeda pula dalam disiplin ilmu komputer AI adalah mempelajari cara menstimulasikan untuk melakukan tugas yang biasanya membutuhkan pemahaman seperti manusia (Knowledge@Wharton, 2018). AI juga suatu cabang ilmu komputer yang menggunakan lebih banyak simbol daripada angka, dan

memproses informasi berdasarkan jumlah aturan dalam merepresentasikan pengetahuan (Swarnkar & Swarnkar, 2019).

Machine Learning adalah bagian dari AI di mana mesin digunakan untuk belajar dari pengalaman masa lalu (Aditya, Mulyana, Eka, & Widianto, 2020). Algoritma *Machine Learning* digunakan dalam berbagai aplikasi, seperti dalam kedokteran, pengenalan *email*, pengenalan suara, dan visi komputer, di mana sulit atau tidak mungkin untuk mengembangkan algoritma konvensional untuk melakukan tugas yang diperlukan (Hu, Niu, Carrasco, Lennox, & Arvin, 2020).

Beberapa implementasi *Machine Learning* menggunakan data dan *Neural Network (Jaringan Saraf)* dengan cara yang meniru kerja otak biologis manusia (Zhou, 2019). *Deep Learning* dapat dipahami sebagai bentuk *Neural Network layer* berganda yang merupakan bagian dari *Machine Learning* yang dapat digunakan dalam tugas termasuk *computer vision, speech recognition, natural language processing, Machine translation, bioinformatics, drug design, medical image analysis, material inspection* dan *board game programs*, di mana mereka telah menghasilkan hasil yang sebanding dan dalam beberapa kasus melebihi kinerja para pakar (Hu, Niu, Carrasco, Lennox, & Arvin, 2020).

Misalnya, sebuah komputasi yang menggunakan *Deep Learning*, mampu memahami konsep seperti garis, bentuk, tekstur, dan juga pengaruhnya dengan melihat data-data citra tanpa bantuan tambahan dari manusia (Schneiderman & Kanade, 2002). *Machine Learning* senantiasa bekerja menggunakan 1 *layer* di mana *Deep Learning* bekerja lebih dari 1 *layer*. Untuk batasan *layer* dari *Deep Learning* itu sendiri sebagai *Neural Network* biasanya memiliki 3 *layer* atau lebih,

makin banyak *layer* yang digunakan akan memengaruhi lama waktu yang terpakai untuk komputer mengakalkasi (Hinton, et al., 2012).

Layer pada *Deep Learning* dapat di gambarkan seperti lapisan *neuron* pada otak manusia *layer* itu nantinya akan menggambarkan jarak atau *vektor* menggunakan Fungsi matematika yaitu fungsi *sigmoid* (σ) (Putra J. G., 2020). Alasan fungsi *sigmoid* digunakan karena dalam fungsi ini membutuhkan perhitungan yang relatif mudah dan cepat. Selain itu, fungsi *sigmoid* dapat diartikan sebagai nilai peluang karena nilainya antara 0 dan 1 (Putra J. G., 2020).

Salah satu pendekatan *Deep Learning* yang mampu secara otomatis mempelajari fitur yang dideskripsikan dalam bentuk *vektor* adalah *Recurrent Neural Networks (RNN)* (Puspaningrum, Bunga, & Iryanto, 2020). Pada *RNN* sendiri teknik *Learning* bekerja dengan menyimpan *layer* dari *output* kembali sebagai *input* pada *hidden layer* berikutnya hingga memprediksi hasil akhir (Tarkus, Sompie, & Jacobus, 2020). Kelemahan *RNN* adalah tidak mampu lagi untuk belajar menghubungkan informasi ketika ada kesenjangan yang terus tumbuh, memori yang tersimpan akan semakin tidak relevan seiring waktu berjalan karena tertimpa dengan memori baru (Putra, Osmond, & Ansori, 2020), di sebabkan kelemahan dari *RNN* sendiri tidak dapat mempelajari informasi yang terlalu jauh atau *Long-Term Dependencies*, yang cukup jauh pada masukannya (Wibisono & Khodra, 2018).

Penelitian *Deep Learning* terdahulu yang dilakukan Juanda, Jondri, & Rohmawati, tentang *Prediksi Harga Bitcoin Dengan Menggunakan Recurrent Neural Network* menurutnya, masalah prediksi *timeseries* adalah jenis pemodelan

prediktif yang sulit, tidak seperti pemodelan prediktif regresi, *timeseries* juga menambah kompleksitas ketergantungan urutan antar *variabel input*. *Recurrent Neural Network* terbukti berhasil digunakan untuk prediksi data *timeseries* karena *RNN* mampu menggunakan informasi yang telah direkam sebelumnya yang panjang urutannya atau *sequence*-nya beragam-ragam. Oleh karena itu, pembangunan sistem ini dibuat dengan metode *Recurrent Neural Network* dengan menggunakan algoritma *Backpropagation Through Time*. Hasil akhir Prediksi harga Bitcoin dapat dilakukan menggunakan *Recurrent Neural Network*. Akurasi rata-rata terbaik yang didapatkan adalah 98.76% pada data latih dan 97.46% pada data uji, dengan *parameter* jumlah pola *input* terbaik adalah 5, jumlah *epoch* 1000, nilai *Learning rate* 0.001 dan jumlah *hidden unit* 50 (Juanda, Jondri, & Rohmawati, 2018).

Long Short-Term Memory (LSTM) merupakan sebuah pengembangan metode dari arsitektur *Recurrent Neural Network (RNN)*, Banyak peneliti yang mengembangkan metode *LSTM* di berbagai bidang seperti dalam bidang prediksi deret waktu atau *forecasting* dikarenakan metode *LSTM* mampu mengatasi kekurangan tersebut karena metode ini dapat mengatur memori pada setiap masukannya dengan menggunakan *memory cells* dan *gate units* pada setiap *neurons* yang berfungsi sebagai pengatur memori (Putra, Osmond, & Ansori, 2020). Contoh penggunaan *Deep Learning* untuk data *timeseries* yang banyak dihasilkan dari pengamatan cuaca adalah *LSTM*, *LSTM* sendiri diciptakan oleh *Hochreiter* dan *Schmidhuber* pada tahun 1997 (Supriyadi, 2019).

Penelitian *LSTM* terdahulu yang yang di teliti oleh *Poornima & Pushpalatha*, mengenai *Prediction of Rainfall Using Intensified LSTM Based Recurrent Neural*

Network with Weighted Linear Units dalam penelitian tersebut menyajikan *Long Short-Term Memory (LSTM)* berbasis *Recurrent Neural Network (RNN)* untuk memprediksi *curah hujan*. *Neural Network* dilatih dan diuji menggunakan kumpulan data standar curah hujan. Jaringan yang dilatih akan menghasilkan atribut prediksi curah hujan. *Parameter* yang dipertimbangkan untuk evaluasi kinerja dan efisiensi model prediksi curah hujan yang diusulkan adalah *Mean Square Error (MSE)*, *akurasi*, *jumlah epoch*, *loss*, dan *Learning rate*. Menurutnya *LSTM* dapat menyimpan data besar ke dalam memorinya dan dapat menghindari *gradient* yang hilang lebih baik dari pada *RNN* dan menunjukkan akurasi lebih baik di bandingkan *RNN*, *LSTM* pun juga mempertahankan akurasi di masa depan seiring dengan mempertimbangkan nilai *Mean Square Error (MSE)*, *akurasi*, *jumlah epoch*, *loss*, dan *Learning rate* (Poornima & Pushpalatha, 2019).

Penelitian *LSTM* terdahulu yang juga di lakukan oleh Supriyadi, mengenai metode *Deep Learning LSTM* untuk memprediksi *parameter* cuaca, seperti suhu udara, kelembaban, kecepatan angin, dan tekanan udara. Metode ini bekerja dengan memanfaatkan fungsi matematika seperti fungsi *tanh* dan *sigmoid* yang berada dalam *layer LSTM*. Adapun jumlah *layer* yang digunakan sebanyak 200 buah. Sedangkan jumlah datanya dibagi dua menjadi *training* data dan *test* data dengan rasio 9:1. Pada bulan Januari 2019. Diperoleh *MSE parameter* suhu udara, kelembaban, kecepatan angin, dan tekanan udara nilainya semakin baik ketika menggunakan *Deep Learning LSTM* dengan update dibandingkan *LSTM* tanpa update. Diperoleh hasil prediksi suhu udara, kelembaban, kecepatan angin, dan tekanan udara 1 hari ke depan memiliki *MSE* yang baik. Dari *parameter* cuaca tersebut hanya *parameter* suhu dan kelembaban udara yang mengalami

pertambahan *MSE* seiring bertambahnya waktu. Sedangkan *parameter* kecepatan angin dan tekanan udara mengalami penurunan di hari ketiga dan meningkat secara kontinu hingga 1 bulan ke depan (Supriyadi, 2019).

Berdasarkan rincian penjelasan sebelumnya, sangat dimungkinkan untuk menggunakan *Deep Learning* dengan metode *LSTM* dikarenakan mendukung kegiatan proyeksi curah hujan. Karena data pengamatan meteorologi umumnya berupa *vektor* dan *timeseries*, untuk itu peneliti membuat Penelitian dalam bentuk skripsi dengan judul “**OPTIMALISASI DEEP LEARNING METHOD DENGAN LONG SHORT-TERM MEMORY DALAM MEMPROYEKSI CURAH HUJAN**”.

1.2. Perumusan Masalah

Berdasarkan uraian pada latar belakang masalah maka yang menjadi perumusan masalah pada skripsi ini adalah sebagai berikut :

1. Bagaimana melakukan proses prediksi curah hujan dengan menggunakan pendekatan *Deep Learning* menggunakan metode *Long Short-Term Memory* dapat menghasilkan alternatif dalam pengambilan sebuah keputusan ?
2. Bagaimana penerapan *Deep Learning* menggunakan metode *Long Short-Term Memory* dapat melakukan prediksi curah hujan.
3. Bagaimana pengujian *Deep Learning* dengan metode *Long Short-Term Memory* di implementasikan ke dalam sebuah sistem yang dibangun untuk memprediksi curah hujan di daerah padang Pariaman ?

1.3. Hipotesis

Berdasarkan rumusan masalah yang telah ditentukan maka dapat diambil kesimpulan sebagai berikut :

1. Dengan melakukan proses prediksi curah hujan dengan menggunakan pendekatan *Deep Learning* diharapkan dapat menghasilkan alternatif dalam pengambilan sebuah keputusan.
2. Dengan menggunakan konsep pendekatan *Deep Learning* metode *Long Short-Term Memory* diharapkan dapat melakukan prediksi curah hujan.
3. Penerapan *Deep Learning* dengan metode *Long Short-Term Memory* diharapkan dapat di implementasikan ke dalam sebuah sistem yang dibangun untuk memprediksi curah hujan di daerah padang Pariaman.

1.4. Batasan Masalah

Adapun batasan masalah pada penelitian ini adalah sebagai berikut :

1. Data yang digunakan adalah data *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* dari tahun 1985 sampai tahun 2021.
2. Metode yang digunakan dalam penelitian ini *Long Short-Term Memory*.
3. Menggunakan Bahasa Pemograman *Python*.
4. Fungsi Aktivasi yang digunakan adalah fungsi *Sigmoid* (σ) dan *Tanh*.
5. Untuk fitur *variabel* yang digunakan dalam penelitian ini hanya terdiri dari curah hujan (rr).
6. Data dibagi menjadi dua bagian, yaitu data *training* dan data *testing* dengan rasio 9:1 di mana 9 untuk *training* dan 1 untuk *testing*.

1.5. Tujuan Penelitian

Adapun Tujuan dari penelitian ini adalah sebagai berikut :

1. Menerapkan *Deep Learning* menggunakan metode *Long Short-Term Memory* untuk melakukan proses prediksi curah hujan dalam menghasilkan alternatif dalam pengambilan sebuah keputusan.
2. Menerapkan pendekatan *Deep Learning* menggunakan metode *Long Short-Term Memory* untuk melakukan prediksi curah hujan.
3. Melakukan pengujian *Deep Learning* dengan metode *Long Short-Term Memory* di implementasikan ke dalam sebuah sistem yang dibangun untuk memprediksi curah hujan di daerah padang Pariaman.

1.6. Manfaat Penelitian

Hasil dari penelitian di harapkan dapat memberikan manfaat sebagai berikut :

1. Menambah pengetahuan peneliti dalam memprediksi / memproyeksi data berbentuk *timeseries* yang di selesaikan dengan cara *Deep Learning* dengan menggunakan metode *Long Short-Term Memory*.
2. Membuktikan keakuratan metode *Long Short-Term Memory* dalam melakukan peramalan khususnya curah hujan.
3. Memberikan informasi tambahan mengenai peramalan curah hujan di daerah padang Pariaman yang akan terjadi pada masa mendatang.

1.7. Gambaran Umum Objek Penelitian

Stasiun Klimatologi Kelas II Sicincin Padang Pariaman merupakan BMKG Stasiun Klimatologi Padang Pariaman yang terletak di daerah *Jalan Raya Padang*

– *Bukittinggi KM. 51 Kapalo Hilalang Sumatera Barat.* Berikut ini adalah gambaran umum tentang Objek Penelitian :

1.7.1. Sejarah BMKG

Pengamatan meteorologi dan geofisika di Indonesia dimulai pertama kali pada tahun 1841 diawali dengan pengamatan yang dilakukan secara individual oleh Dr. Pieter Loth Onnen, Kepala Rumah Sakit di Bogor. Dari tahun ke tahun kegiatannya berkembang seiring dengan meningkatnya kebutuhan akan data hasil pengamatan cuaca dan geofisika. Pada tahun 1866, pemerintah Hindia Belanda meresmikan kegiatan pengamatan *perrorangan* sebagai lembaga pemerintah dengan nama Observatorium Magnetisch en Meteorologisch atau Observatorium Magnetik dan Meteorologi yang dipimpin oleh Dr. Pieter Adrian Bergsma.

Pada tahun 1879, 74 jaringan alat pengukur hujan dibangun di Jawa. pengamatan medan magnet bumi dipindahkan dari Jakarta ke Bogor Pada tahun 1902. Pada tahun 1908 pemantauan gempa dimulai dengan pemasangan komponen horizontal seismograf Wiechert di Jakarta, sedangkan pemasangan komponen vertikal dilakukan pada tahun 1928. Pada tahun 1912, pengamatan meteorologi ditata ulang dengan menambahkan jaringan sekunder. Sedangkan pada tahun 1930 jasa meteorologi mulai digunakan untuk penerangan.

Pada masa pendudukan Jepang antara tahun 1942 dan 1945, nama badan meteorologi dan geofisika diubah menjadi Kisho Kauso Kusho atau Lembaga Meteorologi. Pada tahun 1945 Setelah proklamasi kemerdekaan Indonesia, badan tersebut dibagi menjadi dua: Di Yogyakarta dibentuk Badan Meteorologi yang berkedudukan di lingkungan Mabes TNI khusus untuk melayani kepentingan

Angkatan Udara. Di bawah Kementerian Pekerjaan Umum dan Energi Badan Meteorologi dan Geofisika dibentuk Di Jakarta.

Pada tanggal 21 Juli 1947 Biro Meteorologi dan Geofisika diambil alih oleh Pemerintah Belanda dan namanya diubah menjadi Meteorologisch en Geofisiche Dienst. Badan Meteorologi dan Geofisika yang dikelola oleh Pemerintah Republik Indonesia berada di Jl. Gondangdia, Jakarta. Pada tahun 1949, setelah penyerahan kedaulatan Republik Indonesia dari Belanda, Meteorologisch en Geofisiche Dienst diubah menjadi Biro Meteorologi dan Geofisika di bawah Departemen Perhubungan dan Pekerjaan Umum. Selanjutnya pada tahun 1950 Indonesia resmi masuk sebagai anggota Organisasi Meteorologi Dunia dan Kepala Badan Meteorologi dan Geofisika menjadi Wakil Tetap Indonesia dengan WMO.

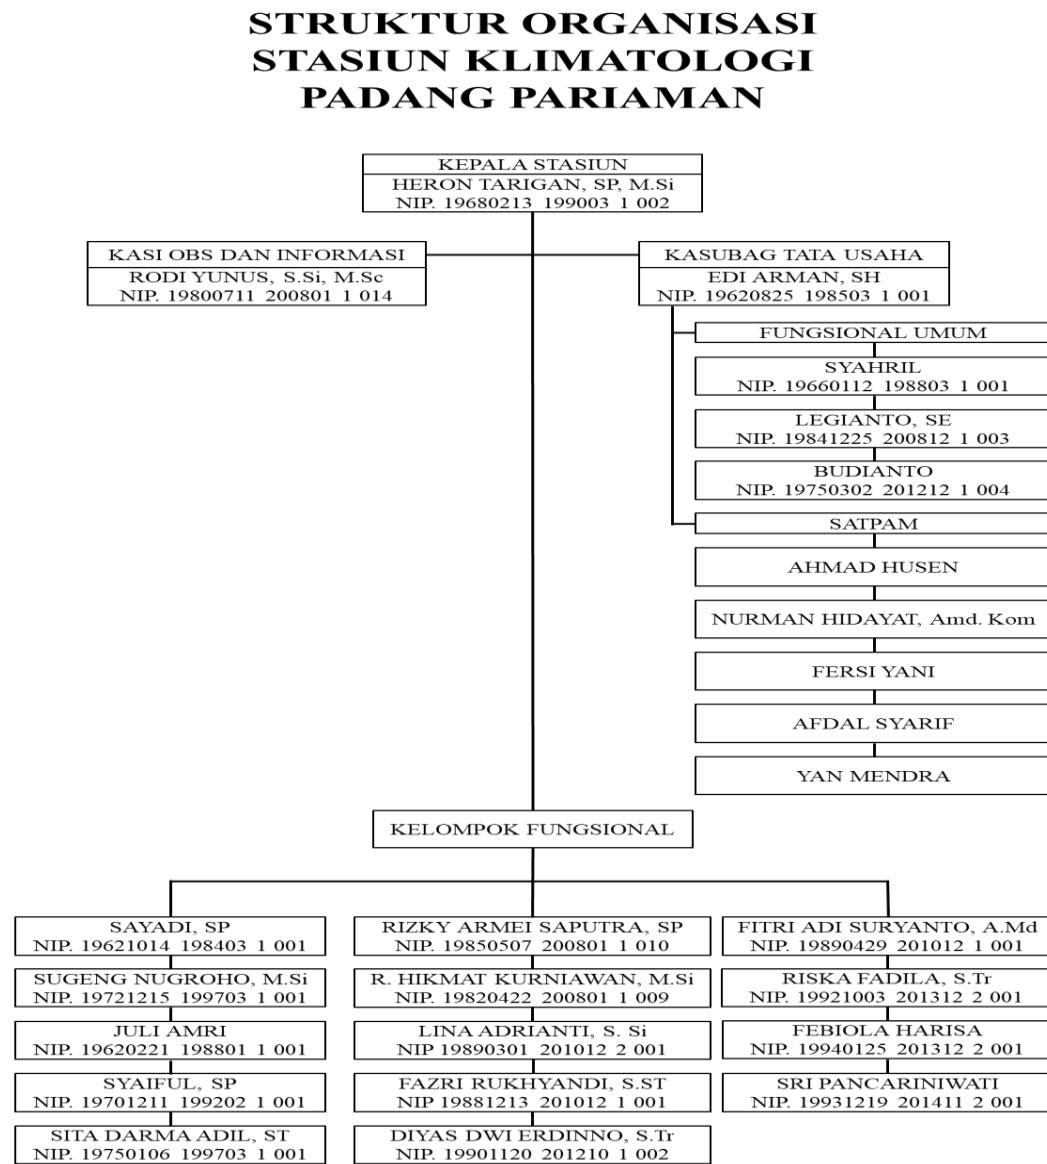
Pada tahun 1955 Biro Meteorologi dan Geofisika beubah nama menjadi Lembaga Meteorologi dan Geofisika di bawah Kementerian Perhubungan, dan pada tahun 1960 namanya dikembalikan menjadi Biro Meteorologi dan Geofisika di bawah Kementerian Perhubungan Udara.

Pada tahun 1965, namanya diubah menjadi Direktorat Meteorologi dan Geofisika, posisinya tetap di bawah Kementerian Perhubungan Udara. statusnya dinaikkan menjadi lembaga setingkat eselon I dengan nama Badan Meteorologi dan Geofisika, dengan jabatan tetap di bawah Kementerian Perhubungan. Badan Meteorologi dan Geofisika.

Melalui Peraturan Presiden Nomor 61 Tahun 2008, BMG berganti nama menjadi Badan Meteorologi, Klimatologi, dan Geofisika dengan status tetap sebagai Lembaga Pemerintah Non Departemen.

1.7.2. Struktur Organisasi

Berikut adalah bentuk struktur organisasi BMKG Padang Pariaman :



(Sumber : Sta. Klim. Kelas II Padang Pariaman, 2021)

Gambar 1.1. Struktur Organisasi BMKG Padang Pariaman

Stasiun Klimatologi Kelas II Sicincin Padang Pariaman dipimpin oleh Kepala Stasiun Klimatologi (Kaslim) bertanggung jawab terhadap seluruh bidang

yang ada pada instansi BMKG, Staf yang membantu Kaslim dalam menjalankan aktivitas di kantor adalah sebagai berikut :

1. Tata usaha yang bertanggung jawab terhadap *administrasi kantor*.
2. Bagian analisa yang bertanggung jawab terhadap pengolahan data dan analisis data-data yang dikirim ke Balai Wilayah I.
3. Tenaga teknis yang bertanggung jawab terhadap data-Data Klimatologi yang ada di *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman*.
4. Tim pengamat yang bertanggung jawab terhadap pengaturan jadwal pengamatan di *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman*.
5. Tim komunikasi dan peralatan yang bertanggung jawab terhadap pengiriman informasi kondisi peralatan yang ada di *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman*.

1.7.3. Visi

Mewujudkan BMKG yang handal, tanggap dan mampu dalam rangka mendukung keselamatan masyarakat serta keberhasilan pembangunan nasional, dan berperan aktif di tingkat Internasional.

Terminologi di dalam visi tersebut dapat dijelaskan sebagai berikut :

1. Pelayanan informasi meteorologi, klimatologi, kualitas udara, dan geofisika yang handal ialah pelayanan BMKG terhadap penyajian data, informasi pelayanan jasa meteorologi, klimatologi, kualitas udara, dan geofisika yang akurat, tepat sasaran, tepat guna, cepat, lengkap, dan dapat dipertanggungjawabkan.

2. Tanggap dan mampu dimaksudkan BMKG dapat menangkap dan merumuskan kebutuhan *stakeholder* akan data, informasi, dan jasa meteorologi, klimatologi, kualitas udara, dan geofisika serta mampu memberikan pelayanan sesuai dengan kebutuhan pengguna jasa.

1.7.4. Misi

Dalam rangka mewujudkan Visi BMKG, maka diperlukan visi yang jelas yaitu berupa langkah-langkah BMKG untuk mewujudkan Misi yang telah ditetapkan yaitu :

1. Mengamati dan memahami fenomena meteorologi, klimatologi, kualitas udara dan geofisika.
2. Menyediakan data, informasi dan jasa meteorologi, klimatologi, kualitas udara dan geofisika yang handal dan terpercaya.
3. Mengkoordinasikan dan memfasilitasi kegiatan di bidang meteorologi, klimatologi , kualitas udara dan geofisika.
4. Berpartisipasi aktif dalam kegiatan internasional di Bidang meteorologi, klimatologi, kualitas udara dan geofisika.

BAB II

LANDASAN TEORI

2.1. Rekayasa Perangkat Lunak

IEEE Computer Society mendefinisikan Rekayasa Perangkat Lunak (RPL) sebagai penerapan suatu pendekatan yang sistematis, disiplin dan terkuantifikasi atas pengembangan, penggunaan dan pemeliharaan perangkat lunak, serta studi atas pendekatan-pendekatan ini, yaitu penerapan pendekatan engineering atas perangkat lunak (Hasanah & Untari, 2020).

RPL sendiri adalah suatu disiplin ilmu yang membahas semua aspek produksi perangkat lunak, mulai dari tahap awal yaitu analisa kebutuhan pengguna, menentukan spesifikasi dari kebutuhan pengguna, desain, penggodaan, pengujian sampai pemeliharaan sistem setelah digunakan (Hasanah & Untari, 2020).

RPL lebih fokus pada praktik pengembangan perangkat lunak dan mengirimkan perangkat lunak yang bermanfaat kepada pelanggan (*customer*). Adapun ilmu komputer lebih fokus pada teori dan konsep dasar perangkat komputer. Rekayasa perangkat lunak lebih fokus pada bagaimana membuat perangkat lunak yang memenuhi kriteria berikut (Hasanah & Untari, 2020) :

- a) Dapat terus dipelihara setelah perangkat lunak selesai dibuat seiring berkembangnya teknologi dan lingkungan (*Maintainability*)
- b) Dapat diandalkan dengan proses bisnis yang dijalankan peubahannya yang terjadi (*Dependability robust*)
- c) Efisien dari segi sumber daya dan penggunaan
- d) Kemampuan untuk dipakai sesuai dengan kebutuhan (*Usability*)

2.1.1. Proses Rekayasa Perangkat Lunak

Kerangka kerja proses membangun dasar bagi proses rekayasa perangkat lunak yang lengkap dengan cara mengidentifikasi sejumlah kecil aktivitas kerangka kerja yang cocok bagi semua proyek rekayasa perangkat lunak (Setiyani, 2018).

Kerangka kerja proses pada rekayasa perangkat lunak terdiri atas lima aktivitas berikut (Setiyani, 2018) :

2.1.1.1. Komunikasi

Komunikasi, bertujuan untuk memahami tujuan-tujuan *stakeholder* atas proyek perangkat lunak yang sedang dikembangkan dan mengumpulkan kebutuhan-kebutuhan yang akan membantu mendefinisikan fitur-fitur perangkat lunak berikut dengan fungsi-fungsinya (Setiyani, 2018) :

2.1.1.2. Perencanaan

Kegiatan perencanaan menciptakan suatu peta yang dapat membantu membimbing tim perangkat lunak. Rencana proyek perangkat lunak menggambarkan risiko - risiko yang mungkin muncul, sumber daya yang akan dibutuhkan, produk – produk kerja yang harus dihasilkan dan *schedule* kerja (Setiyani, 2018) :

2.1.1.3. Pemodelan

Pemodelan, dilakukan bertujuan untuk membuat sketsa sehingga tim perangkat lunak dapat memahami gambaran besar produk yang akan di buat (Setiyani, 2018) :

2.1.1.4. Konstruksi

Konstruksi, sendiri adalah kegiatan yang menggabungkan penggodaan dan pengujian (Setiyani, 2018) :

2.1.1.5. Penyerahan

Penyerahan di sini merupakan Penyerahan perangkat lunak kepada *user*, penyajian perangkat lunak kepada *user* untuk di evaluasi (Setiyani, 2018) :

2.1.2. *Software Development Life Cycle (SDLC)*

System Development Life Cycle (SDLC) adalah metodologi klasik yang digunakan untuk mengembangkan, memelihara dan menggunakan sistem informasi. Siklus hidup sistem itu sendiri merupakan metodologi, tetapi polanya lebih dipengaruhi oleh kebutuhan untuk mengembangkan sistem yang lebih cepat. Pengembangan sistem yang lebih cepat dapat dicapai dengan peningkatan siklus hidup dan penggunaan peralatan pengembangan berbasis komputer (Wahyudi, 2018).

2.1.2.1. Tahap-Tahap SDLC

Secara umum tahap-tahap dalam *System Development Life Cycle (SDLC)* terbagi dalam beberapa tahap (Wahyudi, 2018):

2.1.2.1.1. Tahap Perencanaan Sistem (*system planning*)

Tahap *Planning* Merupakan tahap awal dari pengembangan sistem, tahap ini bertujuan untuk mengidentifikasi dan memprioritaskan sistem informasi apa yang akan dikembangkan, sasaran-sasaran yang ingin dicapai, jangka waktu pelaksanaan serta mempertimbangkan dana yang tersedia dan siapa yang melaksanakan (Wahyudi, 2018).

2.1.2.1.2. Tahap Analisis Sistem (system analysis)

Tahap Analisis Sistem adalah penelitian atas sistem yang telah ada dengan tujuan untuk merancang sistem baru atau memperbarui sistem yang sudah ada (Wahyudi, 2018).

2.1.2.1.3. Tahap Perancangan/Desain Sistem (system design)

Tahap Rancangan sistem adalah penentuan proses dan data yang diperlukan oleh sistem baru. Jika sistem ini berbasis komputer, rancangan dapat menyertakan spesifikasi jenis peralatan yang akan digunakan (Wahyudi, 2018).

2.1.2.1.4. Tahap Penerapan/Implementasi Sistem (system implementation)

Tahap Penerapan merupakan kegiatan memperoleh dan mengintegrasikan sumber daya fisik dan konseptual yang menghasilkan suatu sistem yang bekerja. Pada tahapan ini dilakukan beberapa hal yaitu: *Coding*, *Testing*, Instalasi. Dan *Output* dari tahapan ini adalah : source code, prosedur, pelatihan (Wahyudi, 2018).

2.1.2.1.5. Tahap Pemeliharaan/Perawatan Sistem

Tahap pemeliharaan/perawatan sistem merupakan tahap yang dilakukan setelah tahap implementasi yang meliputi penggunaan sistem, audit sistem, penjagaan sistem, perbaikan sistem dan peningkatan sistem (Wahyudi, 2018).

2.1.2.2. Model Waterfall

Model SDLC air terjun (*waterfall*) sering juga disebut model sequential linier atau alur hidup klasik (*classic life cycle*). Model air terjun menyediakan pendekatan alur hidup perangkat lunak secara sequential atau terurut dimulai dari analisis kebutuhan perangkat lunak, desain, pembuatan kode program, pengujian, dan

pemeliharaan (*maintenance*) (Tabrani & Pudjiarti, 2021). Berikut tahap tahapannya sebagai berikut (Tabrani & Pudjiarti, 2021):

2.1.2.2.1. Analisis Kebutuhan Perangkat Lunak

Proses pengumpulan kebutuhan dilakukan secara intensif untuk menspesifikasikan kebutuhan perangkat lunak agar dapat dipahami perangkat lunak seperti apa yang dibutuhkan oleh *user*. Spesifikasi kebutuhan perangkat lunak pada tahap ini perlu untuk didokumentasikan (Tabrani & Pudjiarti, 2021).

2.1.2.2.2. Desain

Desain perangkat lunak adalah proses multi langkah yang fokus pada desain pembuatan program perangkat lunak termasuk struktur data, arsitektur perangkat lunak, representasi antarmuka, dan prosedur penggodaan. Tahap ini mentranslasi kebutuhan perangkat lunak dari tahap analisis kebutuhan ke representasi desain agar dapat diimplementasikan menjadi program pada tahap selanjutnya. Desain perangkat lunak yang dihasilkan pada tahap ini juga perlu didokumentasikan (Tabrani & Pudjiarti, 2021).

2.1.2.2.3. Pembuatan Kode Program

Desain harus ditransaksikan ke dalam program perangkat lunak. Hasil dari tahap ini adalah program komputer sesuai dengan desain yang telah dibuat pada tahap desain (Tabrani & Pudjiarti, 2021).

2.1.2.2.4. Pengujian

Pengujian fokus pada perangkat lunak secara dari segi logik dan fungsional dan memastikan bahwa semua bagian sudah diuji. Hal ini dilakukan untuk

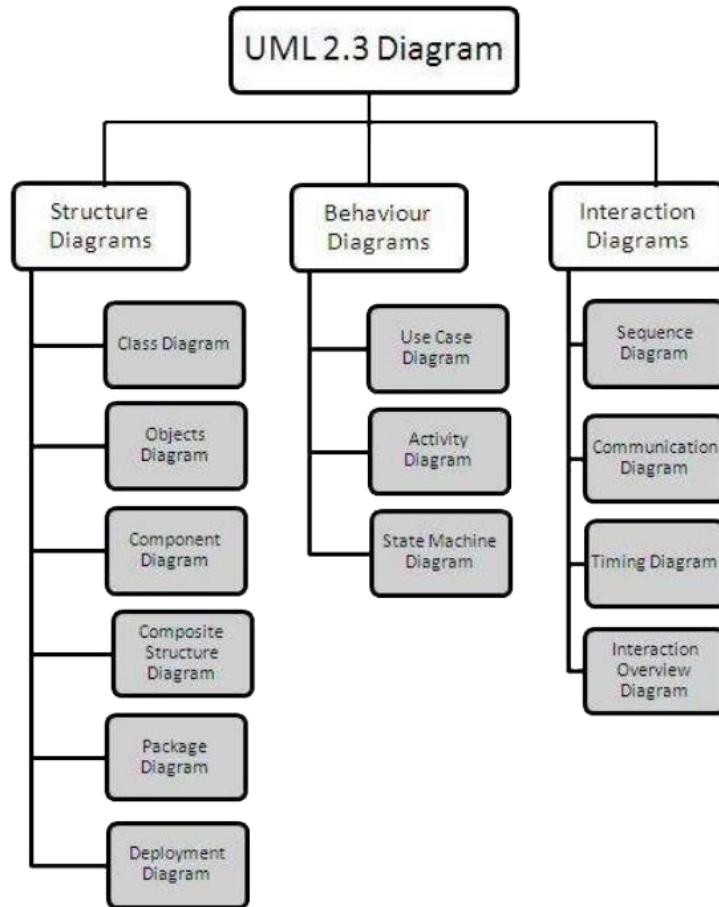
meminimalkan kesalahan (*error*) dan memastikan keluaran yang dihasilkan sesuai dengan yang diinginkan (Tabrani & Pudjiarti, 2021).

2.1.2.2.5. Pendukung atau Pemeliharaan (*maintenance*)

Tidak menutup kemungkinan sebuah perangkat lunak mengalami perubahan ketika sudah dikirimkan ke *user*. Perubahan bisa terjadi karena adanya kesalahan yang muncul dan tidak terdeteksi saat pengujian atau perangkat lunak harus beradaptasi dengan lingkungan baru. Tahap pendukung atau pemeliharaan dapat mengulangi proses pengembangan mulai dari analisis spesifikasi untuk perubahan perangkat lunak yang sudah ada, tapi tidak untuk membuat perangkat lunak baru (Tabrani & Pudjiarti, 2021).

2.2. Unified Modelling Language (UML)

Pemodelan dalam suatu rekayasa perangkat lunak merupakan suatu hal yang dilakukan di tahapan awal. Pemodelan dalam perangkat lunak merupakan suatu yang harus dikerjakan di bagian awal dari rekayasa, dan pemodelan ini akan mempengaruhi perkerjaan-pekerjaan dalam rekayasa perangkat lunak tersebut. Salah satu perangkat pemodelan adalah *Unified Modelling Language (UML)*. UML merupakan salah satu standar bahasa yang banyak digunakan di dunia industri untuk mendefinisikan *requirement*, membuat analisis & desain, serta menggambarkan arsitektur dalam pemrograman berrorientasi objek. UML muncul karena adanya kebutuhan pemodelan visual untuk menspesifikasikan, menggambarkan, membangun, dan mendokumentasikan sistem perangkat lunak (Hasanah & Untari, 2020).



(Sumber : Hasanah & Untari, 2020).

Gambar 2.1. Bagan UML

Berdasarkan Gambar 2.1 berikut penjelasan singkat dari pembagian kategori tersebut (Hasanah & Untari, 2020) :

- Behavior* diagram, merupakan kumpulan diagram yang digunakan untuk menggambarkan kelakuan sistem atau rangkaian perubahan yang terjadi pada suatu sistem.
- Interaction* diagram, merupakan kumpulan diagram yang digunakan untuk menggambarkan interaksi sistem dengan sistem lain maupun interaksi antar sub sistem pada suatu sistem.

- c) *Structure* diagram, merupakan kumpulan diagram yang digunakan untuk menggambarkan struktur statis dari sistem yang dimodelkan.

2.2.1. Behavior Diagrams

Behavior diagram adalah salah satu jenis diagram yang ada di dalam *Unified Modeling Language* (UML), di mana diagram ini digunakan untuk memberikan gambaran tingkah laku sebuah sistem informasi dan bagaimana sistem informasi tersebut melakukan tindakan terhadap kejadian atau perubahan (Sulistyo, Yudhana, & Sunardi, 2018).

2.2.1.1. Use case Diagram

Use case diagram adalah teknik untuk merekam persyaratan fungsional sebuah sistem, menggambarkan fungsionalitas yang diharapkan dari sebuah sistem. *Use case* diagram menekankan kepada “apa” yang diperlukan oleh sistem, dan bukan “bagaimana”. Sebuah *use case* merepresentasikan sebuah interaksi antara aktor dengan sistem. Seorang atau sebuah aktor adalah sebuah entitas dapat berupa manusia atau mesin yang berinteraksi dengan sistem untuk melakukan pekerjaan-pekerjaan tertentu. (Hasanah & Untari, 2020).

Tabel 2.1. Notasi Use case Diagram

No	Simbol	Keterangan
1	<i>Use case</i> 	Fungsionalitas yang disediakan sistem sebagai <i>unit-unit</i> yang saling bertukar pesan antar <i>unit</i> atau aktor.
2	<i>Actor</i>	Orang, proses atau sistem lain yang berinteraksi dengan sistem informasi yang

		akan dibuat di luar sistem itu.
3	<i>Association</i> _____	<i>use case</i> yang memiliki interaksi dengan aktor.
4	<i>Extend</i> -----→	Relasi <i>use case</i> tambahan ke sebuah <i>use case</i> di mana <i>use case</i> yang ditambahkan dapat berdiri sendiri.
5	<i>Generalization</i> →	Relasi <i>use case</i> tambahan ke sebuah <i>use case</i> di mana <i>use case</i> yang ditambahkan memerlukan ini untuk menjalankan fungsinya.

(Sumber : Hasanah & Untari, 2020)

2.2.1.2. Activity Diagram

Activity diagram menggambarkan berbagai alir aktivitas dalam sistem yang sedang dirancang, bagaimana masing-masing alir berawal, *decision* yang mungkin terjadi, dan bagaimana mereka berakhir. *Activity* diagram digunakan untuk menggambarkan langkah-langkah atau aktivitas pada suatu sistem (Hasanah & Untari, 2020).

Tabel 2.2. Notasi *Activity Diagram*

No	Simbol	Keterangan
1	<i>Initial State</i> 	Sebuah diagram aktivitas memiliki sebuah status awal
2	<i>Activity</i>	Aktivitas yang dilakukan sistem, aktivitas biasanya

		diawali dengan kata kerja
3	<i>Decision</i> 	Asosiasi percabangan di mana jika ada pilihan aktivitas lebih dari satu
4	<i>Join</i> 	Asosiasi penggabungan di mana lebih dari satu aktivitas digabungkan menjadi satu
5	<i>Final State</i> 	Status akhir yang dilakukan sistem, sebuah diagram aktivitas memiliki sebuah status akhir.
6	<i>Swimlane</i> or 	Memisahkan organisasi bisnis yang bertanggung jawab terhadap aktivitas yang terjadi.

(Sumber : Hasanah & Untari, 2020)

2.2.1.3. *Statechart* Diagram

Statechart diagram menelusuri individu-individu objek melalui keseluruhan daur hidupnya, menypesifikasikan semua urutan yang mungkin dari pesan-pesan yang akan diterima objek tersebut, bersama-sama dengan tanggapan atas pesan-pesan tersebut (Ilham & Fajri, 2020).

Tabel 2.3. Notasi *Statechart* Diagram

No	Simbol	Keterangan
----	--------	------------

1	<i>Initial State</i> 	Kelas pada struktur sistem
2	<i>Final State</i> 	Sama dengan konsep <i>interface</i> dalam beberapa pemrograman berrorientasi objek.
3	<i>Event</i> 	Relasi antar kelas dengan makna umum. Asosiasi biasanya juga disertai dengan <i>multiplicity</i>
4	<i>State</i> 	Relasi antar kelas dengan makna kelas yang satu digunakan oleh kelas yang lain.

(Sumber : Ilham & Fajri, 2020).

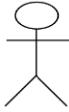
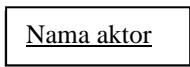
2.2.2. *Interaction Diagrams*

Interaction diagram merupakan diagram yang digunakan untuk menggambarkan bagaimana sebuah objek berinteraksi baik aktor dan objek sistem (Ependi, Panjaitan, & Yulianingsih, 2018).

2.2.2.1. *Sequence Diagram*

Sequence diagram menggambarkan interaksi antar objek di dalam dan di sekitar sistem (termasuk pengguna, display, dan sebagainya) berupa message yang digambarkan terhadap waktu. *Sequence* diagram terdiri atas dimensi vertikal (waktu) dan dimensi horizontal (objek-objek yang terkait). *Sequence* diagram biasa digunakan untuk menggambarkan skenario atau rangkaian langkah-langkah yang dilakukan sebagai respons dari sebuah event untuk menghasilkan *output* tertentu. Diawali dari apa yang memicu aktivitas tersebut, proses dan perubahan apa saja yang terjadi secara internal dan *output* apa yang dihasilkan (Rinaldi, 2019).

Tabel 2.4. Notasi State Machine Diagram

No	Simbol	Keterangan
1	<p><i>Actor</i></p>  <p>Or</p> 	Orang, proses, atau sistem lain yang berinteraksi dengan sistem informasi yang akan dibuat di luar sistem informasi biasanya dinyatakan menggunakan kata benda di awal frasa nama actor
2	<p><i>Lifeline</i></p> 	Menyatakan kehidupan suatu objek
3	<p><i>Object</i></p> 	Menyatakan objek yang berinteraksi pesan
4	<p><i>Active Time</i></p> 	Menyatakan objek dalam keadaan aktif berinteraksi, semua yang terhubung dengan waktu aktif ini adalah sebuah tahapan yang dilakukan di dalamnya,
5	<p><i>Message type Create</i></p> <p><<create>></p> 	Menyatakan suatu objek membuat objek yang lain, arah panah mengarah pada objek yang dibuat
6	<p><i>Message type Call</i></p> <p>1:nama_metode()</p> 	Menyatakan suatu objek memanggil operasi/metode yang ada pada objek lain atau dirinya sendiri
7	<p><i>Message type Send</i></p> <p>1: masukan</p>	Menyatakan bahwa suatu objek mengirimkan data/masukan/informasi ke objek lainnya, arah

		panah mengarah pada objek yang dikirim
8	<i>Message type Return</i> 1: keluaran 	Menyatakan bahwa suatu objek yang telah menjalankan suatu operasi atau metode menghasilkan suatu kembalian ke objek tertentu, arah panah mengarah pada objek yang menerima kembalian
9	<i>Message type Destroy</i> <<destroy>>	Menyatakan suatu objek mengakhiri hidup objek yang lain, arah panah mengarah pada objek yang diakhiri, jika ada create maka ada destroy.

(Sumber : Rinaldi, 2019)

2.2.2.2. Collaboration Diagram

Collaboration diagram adalah cara alternatif untuk mengetahui tahap-tahap terjadinya suatu aktivitas. Perbedaan antara *Collaboration* dan *sequence* diagram adalah *Collaboration* diagram memperlihatkan bagaimana hubungan antara beberapa objek berdasarkan urutan dari pesan, sedangkan *sequence* diagram memperlihatkan bagaimana urutan kejadian berdasarkan waktu (Ilham & Fajri, 2020).

Tabel 2.5. Notasi Collaboration Diagram

No	Simbol	Keterangan
1	<i>Object</i> 	Objek yang melakukan interaksi pesan.
2	<i>Link</i>	Relasi antara objek yang menghubungkan objek

		satu dengan lainnya atau dengan diri sendiri.
4	<p><i>State</i></p> 	Relasi antar kelas dengan makna kelas yang satu digunakan oleh kelas yang lain.

(Sumber : Ilham & Fajri, 2020)

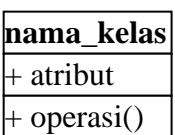
2.2.3. *Structure Diagrams*

Structure diagram merupakan diagram yang digunakan untuk menggambarkan struktur dari perangkat lunak atau sistem yang dikembangkan (Ependi, Panjaitan, & Yulianingsih, 2018).

2.2.3.1. *Class Diagram*

Class diagram adalah sebuah spesifikasi yang jika di instansiasi akan menghasilkan sebuah objek dan merupakan inti dari pengembangan dan desain berrorientasi objek. *Class* diagram menggambarkan keadaan (atribut/properti) suatu sistem, sekaligus menawarkan layanan untuk memanipulasi keadaan tersebut (metode/fungsi). *Class* diagram menggambarkan struktur dan deskripsi *class*, package dan objek beserta hubungan satu sama lain seperti containment, pewarisan, asosiasi, dan lain-lain (Rinaldi, 2019).

Tabel 2.6. Notasi *Class Diagram*

No	Simbol	Keterangan
1	<p><i>Class</i></p> 	Kelas pada struktur sistem
2	<p><i>Interface</i></p> 	Sama dengan konsep <i>interface</i> dalam beberapa pemrograman berrorientasi objek.

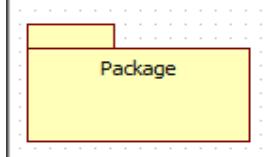
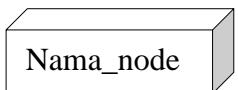
3	<i>Association</i> 	Relasi antar kelas dengan makna umum. Asosiasi biasanya juga disertai dengan <i>multiplicity</i>
4	<i>Directed Association</i> 	Relasi antar kelas dengan makna kelas yang satu digunakan oleh kelas yang lain.
5	<i>Dependency</i> 	Relasi antar kelas dengan ketergantungan antar kelas
6	<i>Aggregation</i> 	Relasi antar kelas dengan makna semua-bagian (whole-part)

(Sumber : Rinaldi, 2019)

2.2.3.2. Deployment Diagram

Menggambarkan secara lengkap bagaimana komponen di *deployment* dalam infrastruktur sistem, di mana komponen akan terletak, bagaimana kemampuan jaringan pada kondisi tertentu, spesifikasi *server*, dan hal-hal lain yang bersifat fiskal (Wijaya, Masriadi, & Ikhlas, 2020).

Tabel 2.7. Notasi Deployment Diagram

No	Simbol	Keterangan
1	<i>Package</i> 	Package merupakan sebuah bungkus dari satu atau lebih komponen.
2	<i>Node</i> 	Biasanya mengacu pada perangkat keras(<i>hardware</i>), perangkat lunak yang tidak dibuat sendiri (<i>software</i>), jika di dalam node

		disertakan komponen untuk mengonsistensikan rancangan maka komponen yang diikutsertakan harus sesuai dengan komponen yang telah didefinisikan sebelumnya pada diagram komponen.
4	<i>Dependency</i> _____ →	Ketergantungan antar komponen, arah panah mengarah pada komponen yang dipakai.
5	<i>Link</i> _____	Relasi antar komponen.

(Sumber : Wijaya, Masriadi, & Ikhlas, 2020).

2.3. *Artificial Intelligence*

Andreas Kaplan dan *Michael Haenlein* mendefinisikan kecerdasan buatan / *Artificial Intelligence (AI)* sebagai kemampuan sistem untuk menafsirkan data eksternal dengan benar, untuk belajar dari data tersebut, dan menggunakan pembelajaran tersebut guna mencapai tujuan dan tugas tertentu melalui adaptasi yang fleksibel. Sistem seperti ini umumnya dianggap sebagai komputer (Siahaan, et al., 2020).

Lebih lanjut *Budiharto* menyatakan bahwa *Intelligence* merupakan istilah yang kompleks yang dapat didefinisikan dengan ungkapan yang berbeda seperti logika, pemahaman, self-awareness, pembelajaran, perencanaan, dan problem solving. Sedangkan “*Artificial*” adalah sesuatu yang tidak nyata, seperti tipuan karena merupakan hasil simulasi (Sihombing & Syaputra, 2020).

Savitri menguraikan bahwa Kecerdasan buatan / *Artificial intelligence (AI)* merupakan bidang ilmu komputer yang menekankan pada penciptaan mesin

cerdas yang bekerja dan bereaksi seperti manusia yang perkembangannya terjadi sangat pesat di era revolusi industri keempat (Sihombing & Syaputra, 2020).

Kecerdasan diciptakan dan dimasukkan ke dalam suatu mesin / komputer agar dapat melakukan pekerjaan seperti yang dapat dilakukan oleh manusia. Beberapa macam bidang yang menggunakan kecerdasan buatan antara lain sistem pakar, permainan komputer (games), logika fuzzy, jaringan saraf tiruan dan robotika (Siahaan, et al., 2020).

Tujuan utama dari pembuatan AI adalah untuk membuat mesin memiliki fungsi yang memiliki kriteria-kriteria kecerdasan di dalamnya sehingga mesin tersebut mampu melakukan pekerjaan manusia yang lebih kompleks, tergantung dari tingkat kecerdasan AI yang digunakan (Gunova, 2021).

Dalam penerapannya, terdapat 6 kemampuan utama yang dapat diklasifikasikan sebagai AI (Gunova, 2021), Kemampuan tersebut antara lain :

- Representasi Informasi/Pengetahuan (Knowledge Representation)
- Perencanaan (Planning)
- Persepsi (Perception)
- *Machine Learning / Deep Learning*
- Pemahaman Bahasa (Natural Language Processing)
- Robotics

Meskipun 6 kemampuan di atas memiliki fungsi yang berbeda-beda, kemampuan tersebut saling berhubungan satu sama lain saat pengaplikasiannya. Bahkan hubungan antar kemampuan utama di atas akan membentuk kemampuan baru (Gunova, 2021).

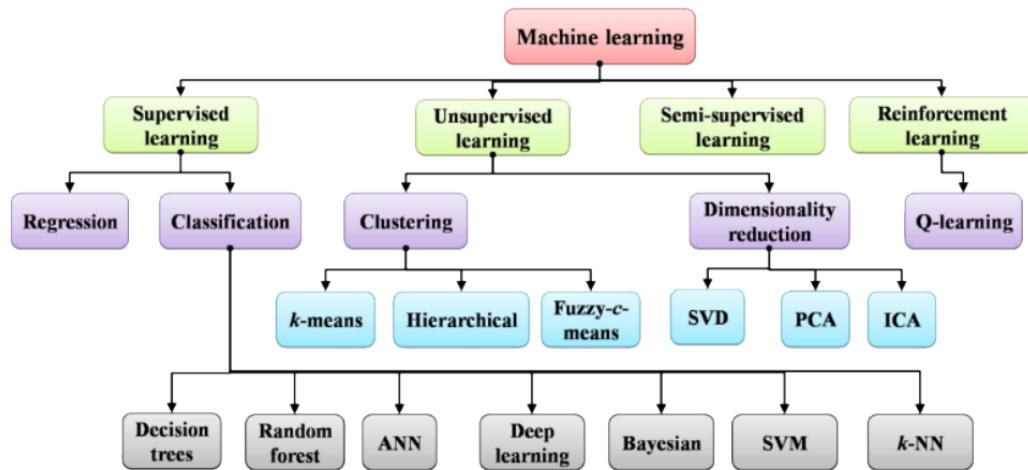
2.4. Machine Learning

Machine Learning merupakan Disiplin ilmu yang menggunakan berbagai pendekatan untuk mengajarkan komputer untuk menyelesaikan tugas-tugas di mana tidak ada algoritma yang sepenuhnya memuaskan tersedia. Dalam kasus di mana terdapat sejumlah besar jawaban potensial, satu pendekatan adalah memberi *label* beberapa jawaban yang benar sebagai valid. Ini kemudian dapat digunakan sebagai data pelatihan bagi komputer untuk meningkatkan algoritme yang digunakannya untuk menentukan jawaban yang benar. Misalnya, untuk melatih sistem untuk tugas pengenalan karakter digital, kumpulan data MNIST dari angka tulisan tangan sering digunakan (Alpaydin, 2020).

Program *Machine Learning* dapat melakukan tugas tanpa diprogram secara eksplisit untuk melakukannya. Ini melibatkan komputer belajar dari data yang disediakan sehingga mereka melakukan tugas-tugas tertentu. Untuk tugas-tugas sederhana yang ditugaskan ke komputer, dimungkinkan untuk memprogram algoritme yang memberi tahu mesin bagaimana menjalankan semua langkah yang diperlukan untuk memecahkan masalah yang dihadapi; di bagian komputer, tidak diperlukan pembelajaran. Untuk tugas yang lebih maju, mungkin sulit bagi manusia untuk membuat algoritme yang diperlukan secara manual. Dalam praktiknya, ternyata lebih efektif untuk membantu mesin mengembangkan algoritmenya sendiri, daripada meminta pemrogram manusia menentukan setiap langkah yang diperlukan (Alpaydin, 2020).

Algoritma *Machine Learning* digunakan dalam berbagai macam aplikasi, seperti dalam kedokteran, penyaringan *email*, pengenalan suara, dan visi komputer,

di mana sulit atau tidak mungkin untuk mengembangkan algoritma konvensional untuk melakukan tugas-tugas yang diperlukan (Hu, Niu, Carrasco, Lennox, & Arvin, 2020).



(Sumber : Kumar, Amgoth, & Annavarapu, 2019)

Gambar 2.2. Struktur *Machine Learning*

2.4.1. Tipe-tipe *Machine Learning*

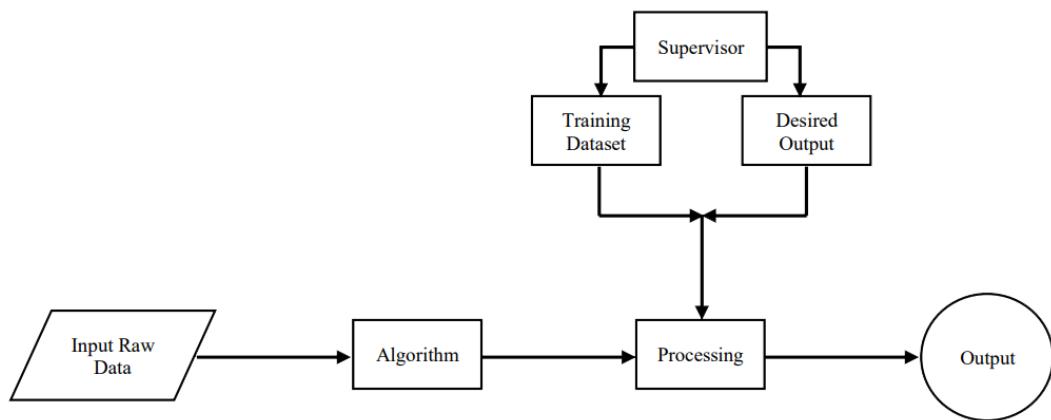
Dalam *Machine Learning*, terdapat beberapa metode atau pendekatan yang dapat digunakan mesin untuk melakukan pembelajaran. Namun secara garis besar, terdapat 3 metode *Machine Learning* yang dipisahkan berdasarkan tipe *input* atau dataset dan cara pelatihannya (Gunova, 2021). Metode-metode tersebut antara lain :

2.4.1.1. *Supervised Learning*

Supervised Learning (SL) merupakan sebuah metode ML di mana metode ini memberikan kumpulan data yang berlabel dan data *input* ke dalam mesin. Maksud dari dataset yang berlabel ini ialah untuk setiap tipe/bentuk kumpulan data yang

telah diberikan, *outputnya* telah ditentukan. Setelah menerima *input*, mesin kemudian akan memberikan *output* berdasarkan kumpulan data yang *dilabeli*. Metode ini cocok digunakan untuk penyelesaian masalah *classification* dan *regression* (Gunova, 2021).

Algoritma yang termasuk ke dalam teknik *supervised Learning* di antaranya *Decision Tree*, K-Nearest Neighboor (KNN), Naive Bayes, Regresi, dan Super Vector Machine (Pamungkas, Prasetya, & Kharisudin, 2020).



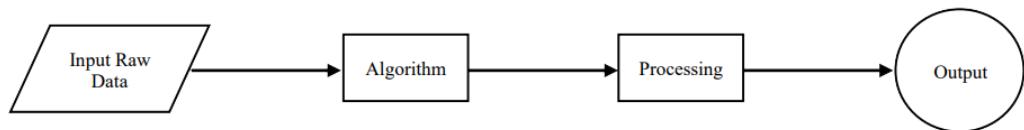
(Sumber : Gunova, 2021)

Gambar 2.3. Cara Kerja *Supervised Learning* (SL)

2.4.1.2. *Unsupervised Learning*

Unsupervised Learning (UL) merupakan sebuah metode ML di mana metode ini hanya memberikan data *input* saja ke dalam mesin. Setelah menerima *input*, mesin kemudian akan memberikan *output* berdasarkan pola data *input* yang diterima. Metode ini cocok digunakan untuk penyelesaian masalah pengelompokan data, baik itu association maupun clustering (Gunova, 2021).

Beberapa Algoritma dalam *unsupervised Learning* di antaranya DBSCAN, Fuzzy C-Means, K-Means, dan Self Organizing Map. DBSCAN pengelompokan berdasarkan kepadatan (density) data, konsep kepadatan menghasilkan status dari data yaitu core (inti), border (batas), dan noise (Ashari, Otniel, & Rianto, 2019).

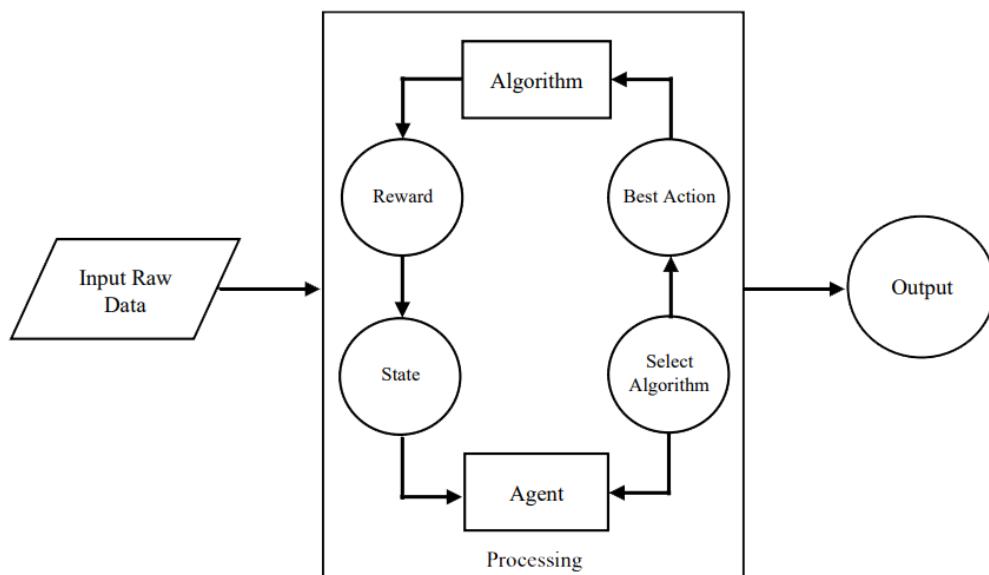


(Sumber : Gunova, 2021)

Gambar 2.4. Cara Kerja *Unsupervised Learning* (UL)

2.4.1.3. Reinforcement Learning

Reinforcement *Machine Learning* adalah algoritma yang mempunyai kemampuan untuk berinteraksi dengan proses belajar yang dilakukan, algoritma ini akan memberikan poin (reward) saat model yang diberikan semakin baik atau mengurangi poin (error) saat model yang dihasilkan semakin buruk. Salah satu penerapan yang sering dijumpai yaitu pada mesin pencari (Fajarsari, 2020).

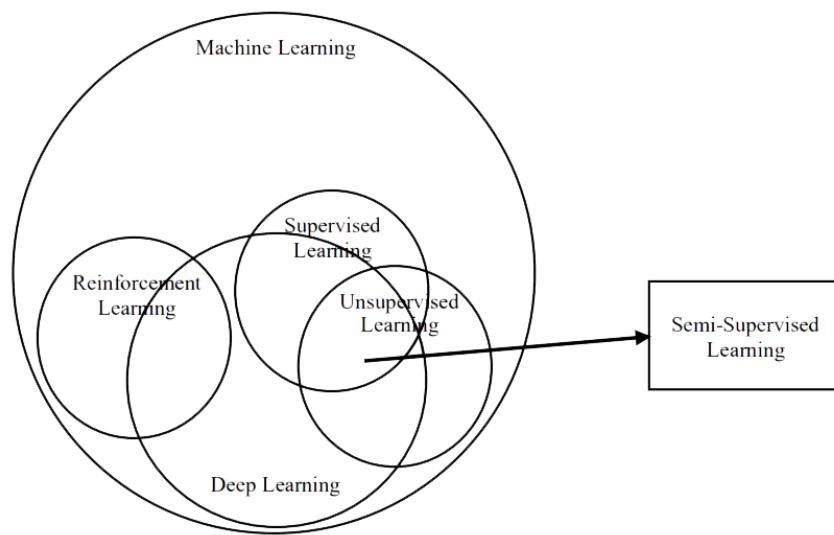


(Sumber : Gunova, 2021)

Gambar 2.5. Cara Kerja Reinforcement Learning (RL)

2.5. Deep Learning

Sejak tahun 2006, *Deep Structured Learning* atau yang lebih dikenal dengan *Deep Learning* atau *Hierarchical Learning* telah muncul sebagai area baru dalam penelitian *Machine Learning* yang berdasarkan pada suatu set algoritma yang mencoba untuk memodelkan abstraksi tingkat tinggi pada data dengan menggunakan graf yang mendalam dengan beberapa *layer* pengolahan, yang terdiri dari beberapa transformasi linier dan non-linier (Fran ois, 2018).

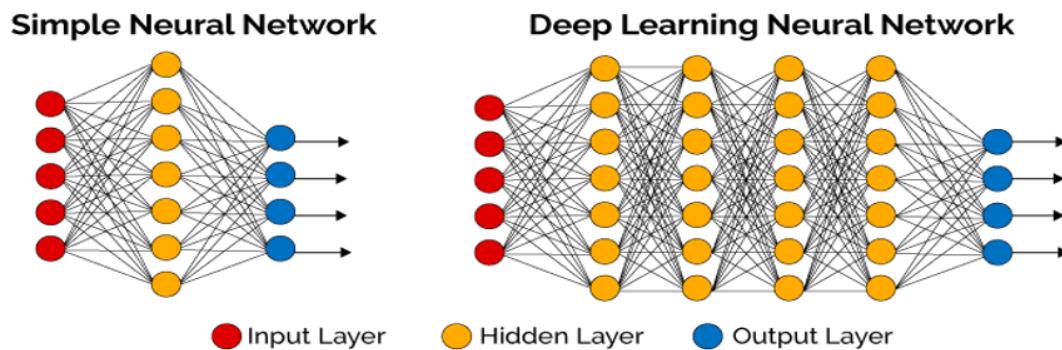


(Sumber : Gunova, 2021)

Gambar 2.6. Hubungan antar metode yang dalam ML (UL, SL, RL, dan DL)

Deep Learning sendiri adalah cabang ilmu *Machine Learning* berbasis *Neural Network* (*NN*) atau bisa dikatakan sebagai perkembangan dari *Neural Network* (Ilahiyah & Nilogiri, 2018). Metode pendekatan *Deep Learning* mengklasifikasi data dalam dua sesi yaitu sesi *training* dan *testing*. Pada sesi

training mempelajari ekstraksi fitur dari setiap data supaya bisa membedakan satu *label* dengan *label* yang lain. Pada sesi *testing* data-data yang diuji dapat di analisa dari hasil sesi *training* (Azizah, Umayah, & Fajar, 2018).



(Sumber : Savalia & Emamian, 2018)

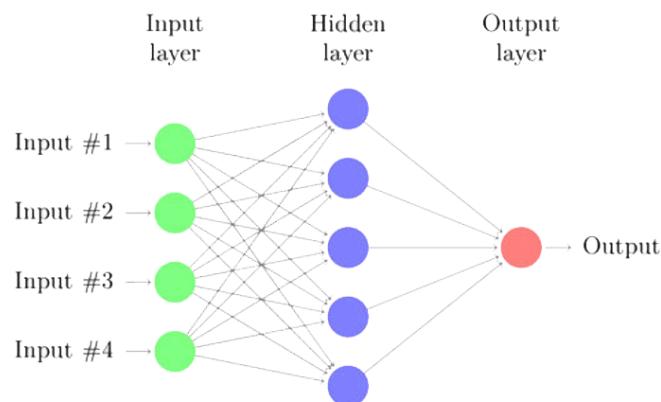
Gambar 2.7. Perbedaan Simple Neural Network dan Deep Learning

Dalam *Deep Learning*, sebuah komputer belajar mengklasifikasi secara langsung dari gambar atau suara. Metode *Deep Learning* menggunakan CPU dan RAM dalam proses komputasi, dan juga memanfaatkan GPU sehingga proses komputasi data yang besar dapat berlangsung lebih cepat (Ilahiyah & Nilogiri, 2018).

2.6. Jaringan Syaraf Tiruan

Jaringan saraf tiruan (JST) / Artificial Neural Network (ANN) / Neural Network (NN) adalah jaringan komputasi terinspirasi dari cara kerja otak manusia karena terbukti Otak manusia melakukan sesuatu hal yang sama persis seperti, hierarki pertama pada *neuron* menerima *formasi* pada visual cortex yang sensitif terhadap gambaran tepi dan gumpalan khusus (Fran ois, 2018).

Neural Network mempunyai lapisan masukan (*input layer*) dan lapisan keluaran (*output layer*). Pada setiap lapisan mempunyai satu atau beberapa *unit neuron*, dan mempunyai sebuah fungsi aktivasi dari *unit* tersebut untuk menentukan sebuah keluaran. Untuk meningkatkan kemampuan dari NN, dapat ditambahkan lapis tersembunyi atau *hidden layer*. Data *training* dapat digunakan untuk melatih NN, semakin banyak data *training* maka akan semakin baik unjuk kerja dari NN tersebut. Tetapi NN juga mempunyai keterbatasan pada jumlah lapisan, karena semakin banyak jumlah lapisan semakin banyaknya juga jumlah iterasi atau *training* yang dibutuhkan (Priyanto, Zarlis, Mawengkang, & Efendi, 2019).



(Sumber : Shekar, S'a, Ferreira, & Soares, 2018)

Gambar 2.8. Skema Jaringan Saraf Tiruan

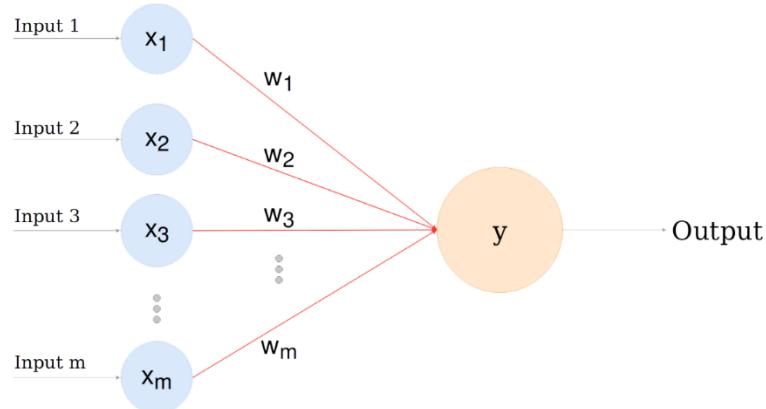
Seperti yang terlihat pada Gambar 2.8 Lapisan-lapisan penyusun JST tersebut dapat dibagi menjadi 3, yaitu (Satria, 2018) :

1. Lapisan *Input*, *unit-unit* di dalam lapisan *input* disebut *unit-unit input*. *Unit-unit input* tersebut menerima pola *inputan* data dari luar yang menggambarkan suatu permasalahan (Satria, 2018)

2. Lapisan tersembunyi, *unit -unit* di dalam lapisan tersembunyi disebut *unit-unit* tersembunyi (Satria, 2018)
3. Lapisan *output*, *unit-unit* di dalam lapisan *output* disebut *unit-unit output* (Satria, 2018)

2.6.1. Arsitektur Jaringan Syaraf Tiruan

Arsitektur atau struktur *Neural Network* adalah gambaran susunan komponen *layer* dan *neuron* pada *input*, *hidden* dan *output* yang terhubung dengan *weight* atau *weight*, activation *Function* dan *Learning Function*. Perceptron dan *Multilayer Perceptron* adalah dasar dari jaringan saraf tiruan. Sebuah perceptron adalah algoritma klasifikasi biner yang dimodelkan setelah berfungsinya otak manusia, hal ini dimaksudkan untuk meniru *neuron*. Meskipun perceptron memiliki struktur sederhana tetapi memiliki kemampuan untuk belajar dan menyelesaikan masalah yang sangat kompleks. *Neural Network* yang paling populer adalah jaringan multi perceptron *feed-forward* yang dilatih melalui algoritma *backpropagation* (Ranjit, Shrestha, Subedi, & Shakya, 2018).



(Sumber : cllau, 2020)

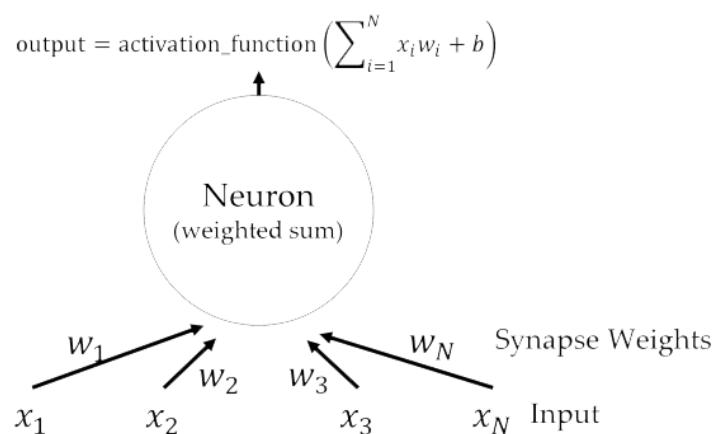
Gambar 2.9. Perceptron *Input* dan *Output*

Menurut Revi, Solikhun, & Safii JST memiliki beberapa arsitektur jaringan yang sering digunakan dalam berbagai sistem. Arsitektur JST tersebut, antara lain sebagai berikut (Revi, Solikhun, & Safii, 2018) :

2.6.1.1. Single Perceptron

ANN yang bentuknya paling kecil disebut single perceptron yang hanya terdiri dari sebuah *neuron*, seperti terlihat pada Gambar 2.9 (Priyanto, Zarlis, Mawengkang, & Efendi, 2019).

Single perceptron hanya terdiri dari 1 lapisan *input* dan 1 lapisan *output*. Setiap *neuron* yang terdapat di dalam lapisan *input* selalu terhubung dengan setiap *neuron* yang terdapat pada lapisan *output*. Jaringan ini hanya menerima *input* kemudian secara langsung akan mengolahnya menjadi *output* tanpa harus melalui lapisan tersembunyi (Revi, Solikhun, & Safii, 2018).



(Sumber : Putra J. G., 2020)

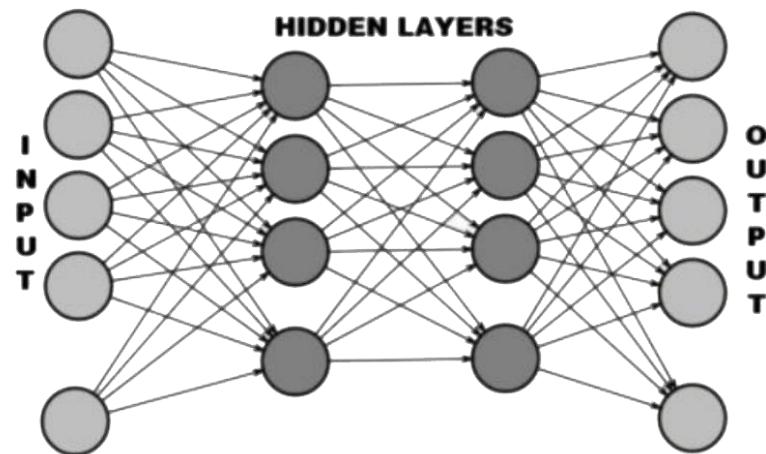
Gambar 2.10. Single Perceptron

Secara matematis pada Gambar 2.10 terdapat *feature* vector x yang menjadi *input* bagi *neuron* tersebut. *Feature* vector merepresentasikan suatu data point,

event atau instance. *Neuron* akan memproses *input* x melalui perhitungan jumlah perkalian antara nilai *input* dan *synapse weight*, yang dilewatkan pada fungsi non-linear. Pada *training*, yang dioptimasi adalah nilai *synapse weight* (*Learning parameter*). Selain itu, terdapat juga *bias b* sebagai kontrol tambahan. *Output* dari *neuron* adalah hasil fungsi aktivasi dari perhitungan jumlah perkalian antara nilai *input* dan *synapse weight*. Ada beberapa macam fungsi aktivasi, misal *step Function*, *sign Function*, *rectifier* dan *sigmoid Function* (Priyanto, Zarlis, Mawengkang, & Efendi, 2019).

2.6.1.2. Multilayer Perceptron (MLP)

Multilayer merupakan bentuk lapisan perceptron yang digabungkan, dengan menambahkan lebih banyak *layer* dan *neuron* tiap *layer*. *Multilayer Perceptron* (MLP) sendiri merupakan arsitektur yang paling banyak digunakan untuk jaringan saraf (Sen, Sugiarto, & Rochman, 2020).



(Sumber : Sen, Sugiarto, & Rochman, 2020)

Gambar 2.11. Deep Neural Network Multilayer Perceptron

Multilayer Perceptron memiliki ciri khas tertentu yaitu memiliki 3 jenis lapisan yakni lapisan *input*, lapisan *output*, dan lapisan tersembunyi. Jaringan dengan banyak lapisan ini dapat menyelesaikan permasalahan yang lebih kompleks dibandingkan jaringan dengan lapisan tunggal. Namun, proses pelatihan sering membutuhkan waktu yang cenderung lama (Revi, Solikhun, & Safii, 2018).

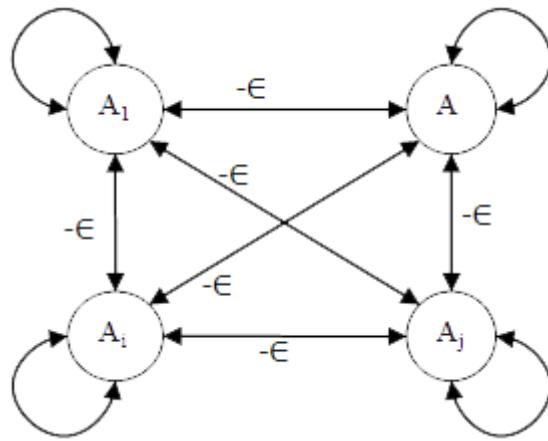
MLP dilatih dari data pelatihan melalui proses yang disebut *backpropagation*. Proses ini dapat digambarkan sebagai cara untuk memperbaiki kesalahan secara progresif segera setelah terdeteksi. Pada awalnya, semua *weight* ditetapkan secara acak. Kemudian jaringan diaktifkan untuk setiap *input* dalam set pelatihan: nilai disebarluaskan ke depan (*forward propagation*) dari tahap *input* melalui tahap tersembunyi ke tahap *output* di mana prediksi dibuat (Sen, Sugiarto, & Rochman, 2020).

Karena nilai real yang diamati dalam set pelatihan diketahui, maka memungkinkan untuk menghitung kesalahan yang dibuat dalam prediksi. Proses kerja utama dalam backtracking adalah melakukan alur kembali dari *output* menuju *input* dengan menggunakan algoritma pengoptimalan yang tepat, seperti *gradient descent*, untuk menyesuaikan *weight* (*weight*) jaringan saraf dengan tujuan mengurangi kesalahan (Sen, Sugiarto, & Rochman, 2020).

2.6.1.3. Competitive Layer Net

Bentuk lapisan kompetitif merupakan jaringan saraf tiruan yang sangat besar. Interkoneksi antar *neuron* pada lapisan ini tidak ditunjukkan pada arsitektur seperti jaringan yang lain. Pada jaringan ini sekumpulan *neuron* bersaing untuk

mendapatkan hak menjadi aktif atau sering pula disebut dengan prinsip *winner takes all* atau yang menanglah yang mengambil semua baginya (Sadli, 2018).



(Sumber : Sadli, 2018)

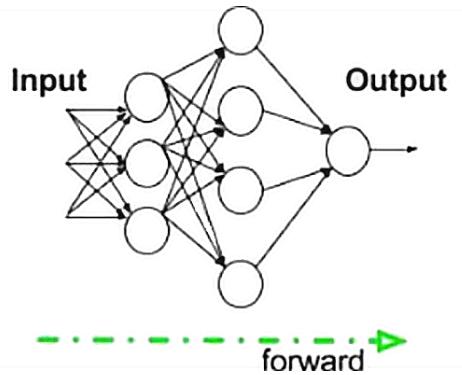
Gambar 2.12. Competitive Layer Net

2.6.2. Teknik *Training* Jaringan Syaraf Tiruan

Proses Jaringan Syaraf Tiruan proses *training* terbagi menjadi dua yaitu *Forward Pass* dan *Backpropagation* (Winoto, 2020). Antara lain sebagai berikut :

2.6.2.1. *Forward Propagation / Forward pass*

Pemrosesan dari *layer input* ke *hidden layer* dan kemudian ke lapisan *output* adalah disebut *forward propagation* (Sen, Sugiarto, & Rochman, 2020). *Forward propagation* adalah proses mengolah sinyal *input* dengan *weight* yang tersedia pada saat melewati *Hidden Layer* hingga sampai ke *Output Layer*. Setiap *Layer* memiliki fungsi aktivasi yang berfungsi untuk mengaktifkan atau tidak suatu sinyal (Winoto, 2020).



(Sumber : Sen, Sugiarto, & Rochman, 2020)

Gambar 2.13. Forward Propagation

2.6.2.1.1. Algoritma Training Forward Propagation

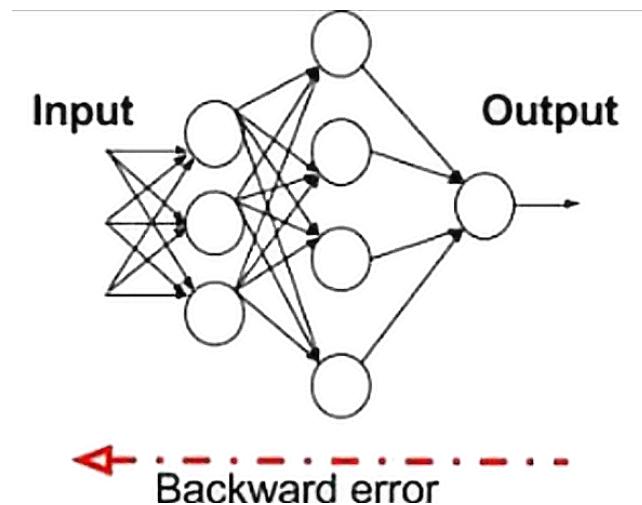
Algoritma pembelajaran untuk JST *forward propagation* adalah sebagai berikut (Azise, Andono, & Pramunendar, 2019) :

1. Masing-masing *input* $x_i, i = 1, 2, 3, \dots, n$ menerima sinyal x_i , kemudian melanjutkan ke semua *unit* pada *hidden layer*
2. Pada masing-masing *hidden layer*, menjumlahkan *weight* sinyal *input* dengan persamaan : $z_{in_j} = v_{0j} \sum_{i=1}^n x_i v_{ij}$ Untuk menghitung sinyal *output* pada fungsi aktivasi menggunakan persamaan $z_i = f(z_{in_j})$
3. Masing-masing *unit output* $y_k, k = 1, 2, \dots, m$ menjumlahkan *weight* sinyal *input* dengan persamaan $y_{ink} = w_{0k} \sum_{i=1}^p z_i w_{jk}$ Untuk menghitung nilai *output* dengan menerapkan fungsi aktivasi menggunakan persamaan $y_k = f(z_{in_j})$

2.6.2.2. Backward propagation / Backward Pass

Backpropagation merupakan metode pelatihan dari *Artificial Neural Network* yang menggunakan arsitektur *multilayer* dengan algoritma pembelajaran *supervised*. Metode ini bertujuan untuk melatih jaringan untuk mendapatkan

keseimbangan antara kemampuan jaringan untuk mengenali pola dalam pelatihan dan memberikan respons yang benar terhadap pola *input* yang hampir sama dengan pola yang dipakai selama pelatihan. Metode ini juga melakukan dua tahapan, yaitu *feedforward* atau perhitungan maju dan *backward propagation* atau perhitungan mundur (Pandji, Indwiarti, & Rohmawati, 2019).



(Sumber : Sen, Sugiarto, & Rochman, 2020)

Gambar 2.14. Backward Propagation

2.6.2.2.1. Tahap Training Backward Propagation

Secara garis besar, *training* jaringan dengan metode *backpropagation* meliputi tiga tahap (Satria, 2018) :

2.6.2.2.1.1. Tahap maju

Tahap *feedforward* yang dimaksud adalah proses pengolahan *input* dari pola *input training* pada *input layer* sampai respons yang dihasilkan mencapai *output layer* (Satria, 2018).

2.6.2.2.1.2. Tahap perhitungan error propagasi balik

Respons yang dihasilkan pada *output layer* akan dibandingkan dengan *output target*, kemudian dihitung *errornya*. Bila kriteria untuk kondisi berhenti (*stopping condition*) belum terpenuhi, maka dilanjutkan ke tahap ketiga (*adjustment of the weights and biases*). Namun jika kondisi berhenti sudah terpenuhi, maka proses perhitungan berhenti (Satria, 2018).

2.6.2.2.1.3. Tahap pembaharuan weight dan bias

Kondisi ini terjadi jika *output* yang diharapkan tidak sesuai, maka jaringan akan bergerak mundur (*backward*) dari *output layer* menuju ke *input layer* dan akan melakukan update *weight* dan bisa serta mengulangi proses dari tahap 1. *Backpropagation* merupakan algoritma pembelajaran yang biasanya digunakan oleh perceptron dengan banyak lapisan untuk mengubah *weight* yang terhubung dengan *neuron* yang ada pada lapisan tersembunyinya (Satria, 2018).

2.6.2.2. Algoritma Training Backward Propagation

Algoritma pembelajaran untuk JST *Backpropagation* adalah sebagai berikut (Mufligh, Sunardi, & Yudhana, 2019) :

1. Inisiasi *weight* (tetapkan dengan nilai acak kecil)
2. Selama syarat kondisi *false* kerjakan langkah 2-9
3. Untuk setiap pasangan yang akan dilakukan pembelajaran, kerjakan langkah 3-8
4. Setiap *unit input* $x_i, i = 1, 2, 3, \dots, n$ menerima sinyal dan meneruskan sinyal ke semua *unit* pada lapisan tersembunyi

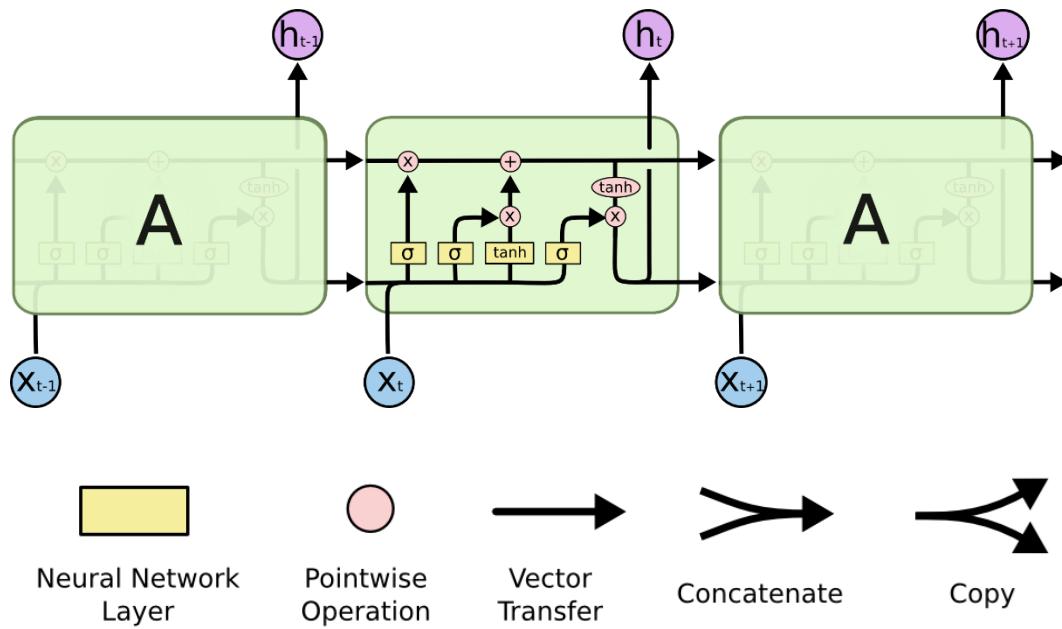
5. Setiap *unit* tersembunyi $z_j, j = 1, 2, \dots, p$ menjumlahkan *weight* sinyal *input* dengan persamaan berikut: $z_in_j = v_{oj} + \sum_{i=1}^n x_i v_{ij}$, Hitung sinyal *output* dengan fungsi aktivasinya $z_j = f(z_in_j)$ Kirimkan sinyal ini ke semua *unit* pada lapisan *output*.
 6. Setiap *unit output* $y_k, k = 1, 2, \dots, m$ menjumlahkan *input* ter*weightnya* $z_in_j = v_{oj} + \sum_{i=1}^n x_i v_{ij}$ Hitung sinyal *output* dengan fungsi aktivasinya $y_k = (t_k - y_k)f'(y_in_k)$
 7. Setiap *unit output* $y_k, k = 1, \dots, m$ menerima pola target sesuai dengan pola *input* pelatihan, kemudian hitung *error* seperti persamaan $\delta_k = (t_k - y_k)f'(y_in_k)$ Hitung suku koreksi *weight* (digunakan untuk perbaruan wjk) $\Delta w_{jk} = \alpha \delta_k z_j$ Hitung suku koreksi *bias* (digunakan untuk perbaruan wok) $\Delta w_{ok} = \delta_k$ Kirimkan δ_k ke *unit-unit* dilapis bawahnya
 8. Setiap *unit* tersembunyi $z_j, j = 1, \dots, p$ menjumlahkan delta *inputnya* (dari *unit-unit* yang berada pada lapis diatasnya) $\delta_in_j = \sum_{k=1}^m \delta_k w_{jk}$ Hitung suku informasi *error* $\delta_j = \delta_in_j f'(z_in_j)$ Hitung suku koreksi *weight* (untuk perbaruan vij) $\Delta v_{ij} = \alpha \delta_j x_i$ Hitung suku koreksi *bias* (untuk perbaruan voj) $\Delta v_{oj} = \alpha \delta_j$ Perbaruan *weight* dan *bias*
 9. Setiap *unit output* $y_k, k = 1, \dots, m$ perbarui *weight-weight* dan *biasnya* :
- $$w_{jk}(\text{baru}) = v_{ij}(\text{lama}) + \Delta w_{jk}$$
10. Setiap *unit* tersembunyi $z_j, j = 1, \dots, p$ perbarui *weight-weight* dan *biasnya* $i = 0, \dots, n$: $v_{ij}(\text{baru}) = v_{ij}(\text{lama}) + \Delta v_{ij}$
 11. Uji syarat berhenti, Fungsi aktivasi *sigmoid*

$$- f(x) = \frac{1}{1+e^{-x}}$$

$$- f'(x) = f(x)[1 - f(x)]$$

2.7. Long Short-Term Memory

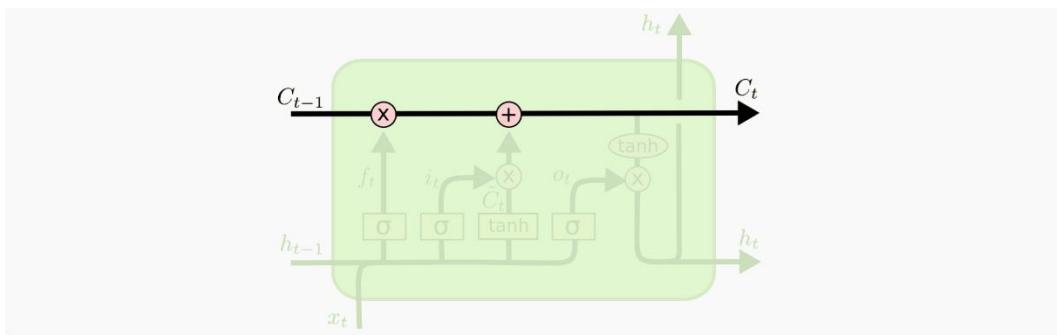
Long Short-Term Memory (LSTM) merupakan pengembangan dari *Recurrent Neural Network (RNN)* dengan mengatasi salah satu kekurangan *RNN* yaitu kemampuan pengelolaan informasi dalam periode yang lama yang mana dilakukan modifikasi pada *Recurrent Neural Network (RNN)* dengan memberi *memory cell* untuk dapat menyimpan informasi dalam waktu yang lama. Diusulkan oleh Sepp Hochreiter dan Jurgen Schmidhuber pada tahun 1997, *LSTM* banyak dipilih untuk prediksi berbasis waktu atau *timeseries* karena dikenal lebih unggul dan handal dalam melakukan prediksi dalam waktu lama dibanding algoritma lain (Zahara, Sugianto, & Ilmuddafiq, 2019; Manaswi, 2018).



(Sumber : Manu, 2021)

Gambar 2.15. Arsitektur LSTM berisi empat layer yang saling berinteraksi.

Kunci LSTM adalah *cell state*, garis horizontal yang melewati bagian atas diagram keadaan sel seperti ban berjalan. Ini berjalan lurus ke bawah seluruh rantai, memiliki beberapa linier kecil interaksi (Ghosh, Bose, Maji, Debnath, & Sen, 2019). Untuk setiap sel memori memiliki tiga *layer sigmoid* dan satu *layer tanh* (Qiu, Wang, & Zhou, 2019).



(Sumber : Manu, 2021)

Gambar 2.16. Alur Informasi *Cell state* pada LSTM

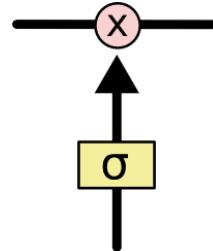
Keterangan (Pardede & Ibrahim, 2020) :

C_t : *Cell state*

C_{t-1} : Nilai *Cell state* sebelum order ke t

Pada Gambar 2.16, garis horizontal yang melalui bagian atas diagram dikenal sebagai *cell state* (C_{t-1}, C_t). Ini bertindak seperti ban berjalan yang berjalan di seluruh jaringan. Ini membawa informasi dari sel sebelumnya ke saat ini dan seterusnya (Hiransha, Gopalakrishnan, Menon, & Soman, 2018). Kemampuan untuk menambah atau menghapus informasi ke *cell state* dikendalikan oleh struktur yang disebut *gate*. *Gate* digunakan untuk secara opsional membiarkan informasi lewat. Informasi yang di saring melalui struktur *gate* yang akan

mempertahankan dan memperbarui *cell state* memori (Ghosh, Bose, Maji, Debnath, & Sen, 2019; Qiu, Wang, & Zhou, 2019).



(Sumber : Manu, 2021)

Gambar 2.17. Layer sigmoid mengeluarkan angka antara nol dan satu.

Pada Gambar 2.17 *layer sigmoid* mengeluarkan angka antara 0 dan 1, menggambarkan berapa banyak dari setiap komponen yang harus dilewati. Nilai 0 berarti “jangan biarkan apa pun lewat”, sedangkan nilai 1 berarti “biarkan semuanya lewat!” (Ghosh, Bose, Maji, Debnath, & Sen, 2019).

2.7.1. Proses *Training* dan *Testing* Pada LSTM

LSTM disebut juga sebagai jaringan saraf dengan arsitektur yang mudah beradaptasi, sehingga bentuknya dapat disesuaikan, tergantung pada aplikasinya. *Long Short-Term Memory* merupakan turunan dari metode RNN (*Recurrent Neural Network*). *Recurrent Neural Network* merupakan jaringan saraf berulang yang didesain khusus untuk menghadapi data berurutan (*sequence data*) (Wiranda & Sadikin, 2019).

2.7.1.1. *Training Model LSTM*

Beberapa tahapan dalam proses *training* model LSTM dengan *backpropagation* adalah (Arfan & ETP, 2019) :

1. Inisialisasi *weight* awal
2. *Input* data *training*
3. Perhitungan LSTM pada setiap *input* yaitu dimulai dengan *forget gates*, fungsi *input gates*, fungsi *cell states* dan yang terakhir fungsi *output gates*.
4. Perhitungan standard deviasi MSE untuk mendapatkan nilai selisih antara nilai LSTM dengan target *output*.
5. Perhitungan gradien untuk menentukan nilai *weight* supaya hasil *loss* mendekati 0 dengan menggunakan *Backpropagation Through Time* (BTTP).
6. Setelah mendapatkan nilai gradien, maka dilanjutkan dengan persamaan fungsi optimasi dan update *weight*.
7. Kembali ke langkah dua sebanyak *epoch* yang telah ditentukan.

Berdasarkan Penjabaran di atas, Pembentukan model LSTM diawali dengan menginisialisasi parameter yang dibutuhkan yaitu *hidden layer* (lapisan tersembunyi), *units* (memori sel), *epoch* (putaran), dan *batch size* (jumlah sampel data). Setelah model dibentuk maka data akan dilatih dengan melewati mekanisme *gates* pada LSTM. Data akan dilatih terus hingga mencapai batas *error* yang diinginkan dengan penentuan serta pengubahan *parameter* yang digunakan (Agusta, Ernawati, & Muliawati, 2021).

Ketika data sudah mencapai target yang diinginkan, proses iterasi akan berhenti dan berikutnya model akan diuji dengan data pengujian atau dapat mengulang kembali proses pelatihan. Proses iterasi ini juga diolah dengan menggunakan fungsi optimasi dan *dropout*. Optimasi berguna untuk menentukan *weight* optimal dan mengurangi kesalahan sehingga dapat memaksimalkan

keakuratan model. Sedangkan *dropout* berguna untuk mencegah terjadinya *overfitting* pada model (Agusta, Ernawati, & Muliawati, 2021).

2.7.1.2. Testing Model LSTM

Pengujian / *Testing* ini dengan mengambil data *testing* kemudian dibandingkan dengan data yang dihasilkan dengan metode LSTM pada rentang waktu yang ditentukan dengan metode akurasi yang digunakan menggunakan Standard deviasi (Arfan & ETP, 2019).

2.7.2. Fungsi Aktivasi Pada LSTM

Fungsi aktivasi sangat berperan dalam mengaktifkan setiap *neuron* pada *jaringan saraf tiruan* serta menentukan keluaran dari suatu jaringan saraf tiruan (Susilawati & Muhathir, 2019). Berikut adalah beberapa fungsi aktivasi yang di gunakan dalam penelitian ini :

2.7.2.1. Sigmoid (σ)

Fungsi aktivasi *sigmoid* merupakan fungsi non-linear. *Input* untuk fungsi aktivasi ini berupa bilangan real dan *output* dari fungsi aktivasi ini memiliki range antara 0 sampai 1 (Suhermi, Suhartono, Dana, & Prastyo, 2018). Berikut ini perhitungan dari fungsi aktivasi *sigmoid* :

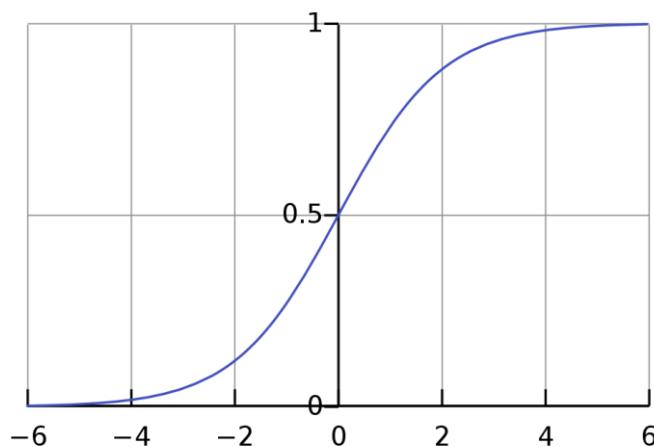
$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Di mana :

x : data *input*

e : konstanta matematika (2,718281828...)

Fungsi *sigmoid* mentransformasi range nilai dari *input* x menjadi antara 0 dan 1. Jika *inputnya* sangat negatif, maka keluaran yang didapatkan adalah 0, sedangkan jika *input* sangat positif maka nilai keluaran yang didapatkan adalah 1. Fungsi ini memiliki kekurangan yaitu dapat mematikan *gradient*, ketika aktivasi dari *neuron* mengeluarkan nilai yang berada pada range 0 atau 1, di mana *gradient* di wilayah ini hampir bernilai 0. Kemudian *output* dari *sigmoid* tidak zero-centered (Suhermi, Suhartono, Dana, & Prastyo, 2018).



(Sumber : Deng, Tong, Lan, & Huang, 2020)

Gambar 2.18. Illustrasi Sigmoid

2.7.2.2. Hyperbolic (*Tanh*)

Fungsi aktivasi *Tanh* merupakan fungsi non-linear. *Input* untuk fungsi aktivasi ini berupa bilangan real dan *output* dari fungsi tersebut memiliki range antara -1 sampai 1 (Suhermi, Suhartono, Dana, & Prastyo, 2018). Berikut ini perhitungan dari fungsi aktivasi *tanh* :

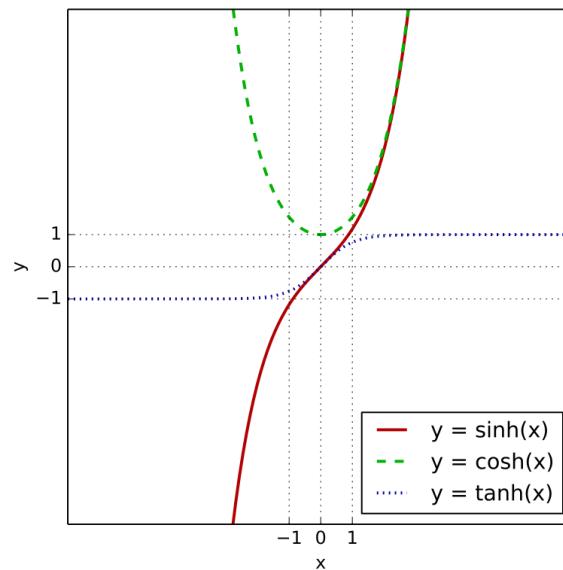
$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Di mana :

x : data *input*

e : konstanta matematika ($2,718281828\dots$)

Sama seperti fungsi *sigmoid*, fungsi ini memiliki kekurangan yaitu dapat mematikan *gradient*, akan tetapi fungsi ini juga memiliki kelebihan yaitu *output* yang dimiliki fungsi *Tanh* merupakan zero-centered. Dalam pengaplikasiannya fungsi *Tanh* lebih menjadi pilihan jika dibandingkan dengan fungsi *sigmoid*. Fungsi Perlu diketahui fungsi *tanh* merupakan pengembangan dari fungsi *Sigmoid* (Suhermi, Suhartono, Dana, & Prastyo, 2018).



(Sumber : Flywind, 2018)

Gambar 2.19. Ilustrasi *Tanh*

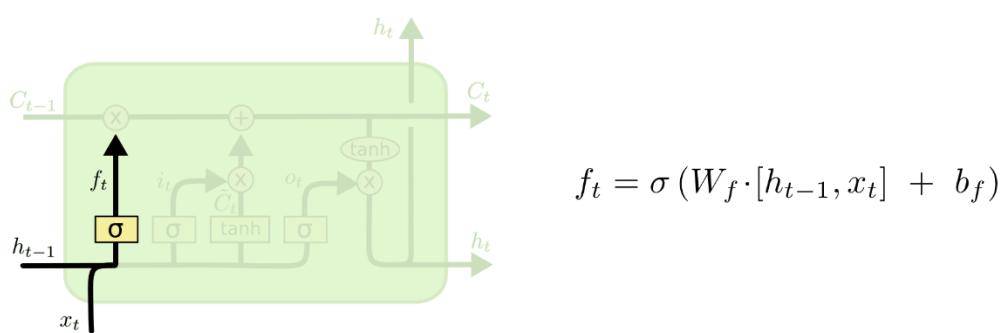
2.7.3. Langkah *Training Gates* Pada LSTM

LSTM memiliki tiga di antaranya gerbang, untuk melindungi dan mengontrol *cell state*, Struktur gerbangnya mencakup *forget gate*, *input gate*, dan *output gate*. *Gate* terdiri dari *layer* jaring saraf *sigmoid* dan operasi perkalian pointwise (Ghosh,

Bose, Maji, Debnath, & Sen, 2019; Qiu, Wang, & Zhou, 2019). Berikut ialah keterangan setiap *gate* yang ada pada Gambar 2.15 :

2.7.3.1. *Forget Gate*

Pada *forget gate* informasi pada setiap data *input* yang akan diolah dan dipilih data mana saja yang akan disimpan atau dibuang pada *memory cells*. Fungsi aktivasi yang digunakan pada *forget gate* ini adalah fungsi aktivasi *sigmoid*. Di mana hasil keluarannya antara 0 dan 1. Jika keluarannya adalah 1 maka semua data akan disimpan dan sebaliknya jika keluarannya 0 maka semua data akan dibuang (Aldi, Jondri, & Aditsania, 2018). Dengan rumus seperti pada Gambar 2.20 :



(Sumber : Manu, 2021)

Gambar 2.20. Persamaan *Forget Gate* pada LSTM

Keterangan (Pardede & Ibrahim, 2020) :

f_t : *Forget gate*

σ : Fungsi Aktivasi *Sigmoid*

W_f : Nilai *Weight* untuk *Forget gate*

h_{t-1} : Nilai *output* sebelum order ke t

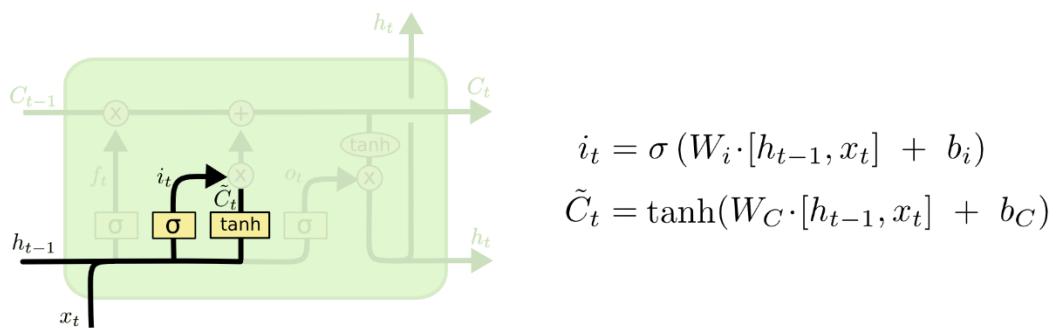
x_t : Nilai *input* pada order ke t

b_f : Nilai *bias* pada *Forget gate*

Pada Gambar 2.20 LSTM memutuskan informasi apa yang akan dibuang dari *cell state*. Keputusan ini dibuat oleh *layer sigmoid* yang disebut "*layer forget gate*" (f_t). Terlihat pada h_{t-1} dan x_t dan nilai *output* antara angka 0 dan 1 untuk setiap angka dalam *cell state* C_{t-1} pada Gambar 2.16. *Output* dari 1 mewakili 'sepenuhnya simpan ini' sementara 0 mewakili 'singkirkan ini sepenuhnya' (Boruah & Barman, 2018).

2.7.3.2. *Input Gate*

Pada *input gate* terdapat dua *gates* yang akan dilaksanakan, pertama akan diputuskan nilai mana yang akan diperbarui menggunakan fungsi aktivasi *sigmoid*. Selanjutnya fungsi aktivasi *tanh* akan membuat *vektor* nilai baru yang akan disimpan pada *memory cell* (Aldi, Jondri, & Aditsania, 2018). Dengan rumus seperti pada Gambar 2.21 :



(Sumber : Manu, 2021)

Gambar 2.21. Persamaan yang melewati *Input Gate* pada LSTM

Keterangan (Pardede & Ibrahim, 2020) :

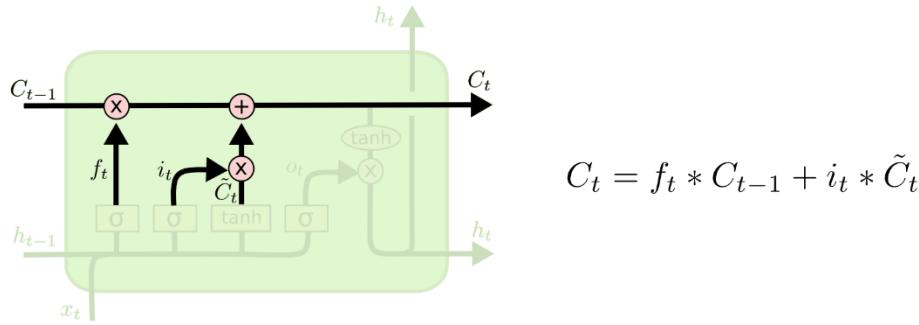
i_t : *Input gate*

\tilde{C}_t	: Nilai baru yang dapat ditambahkan ke <i>cell state</i>
σ	: Fungsi Aktivasi <i>Sigmoid</i>
$tanh$: Fungsi Aktivasi <i>Tanh</i>
W_i	: Nilai <i>Weight</i> untuk <i>Input gate</i>
W_c	: Nilai <i>Weight</i> untuk <i>Cell state</i>
h_{t-1}	: Nilai <i>output</i> sebelum order ke t
x_t	: Nilai <i>input</i> pada order ke t
b_i	: Nilai <i>bias</i> pada <i>Input gate</i>
b_c	: Nilai <i>bias</i> pada <i>cell state</i>

Pada langkah berikutnya di Gambar 2.21 LSTM memutuskan informasi apa yang akan disimpan dari *cell state*. Pertama *layer sigmoid* yang disebut "*layer input gate*" (i_t) memutuskan nilai mana yang akan diperbarui. Setelah itu, *layer tanh* membuat *vektor* nilai kandidat baru, \tilde{C}_t , yang dapat ditambahkan ke *state* (Ghosh, Bose, Maji, Debnath, & Sen, 2019).

2.7.3.3. *Cell state / Memory State*

Pada *cell state gates* akan mengganti nilai pada *memory cell* sebelumnya dengan nilai *memory cell* yang baru. Di mana nilai ini didapatkan dari menggabungkan nilai yang terdapat pada *forget gate* dan *input gate* (Aldi, Jondri, & Aditsania, 2018). Dengan rumus seperti pada Gambar 2.22 :



(Sumber : Manu, 2021)

Gambar 2.22. Persamaan Memperbaharui *Cell state* pada LSTM

Keterangan (Pardede & Ibrahim, 2020) :

C_t : *Cell state*

f_t : *Forget gate*

C_{t-1} : Nilai *Cell state* sebelum order ke t

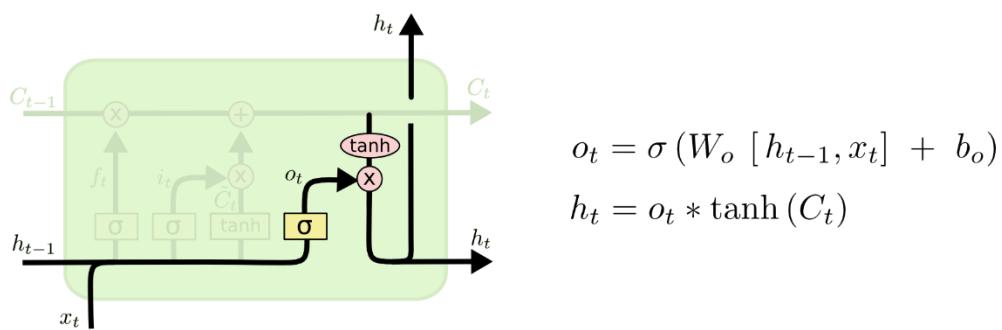
i_t : *Input gate*

\tilde{C}_t : Kandidat konteks baru yang dapat ditambahkan ke *cell state*

Pada langkah selanjutnya di Gambar 2.22, kedua *layer* di gabungkan digabungkan untuk membuat pembaruan ke *cell state*. Pada Langkah inilah nilai *cell state* lama (C_{t-1}), akan di perbarui ke nilai dari *cell state* baru (C_t) di mana LSTM akan mengalikan *cell state* lama dengan (f_t) kemudian ditambahkan dengan ($i_t * \tilde{C}_t$) . Ini adalah nilai kandidat baru, yang diskalakan berdasarkan seberapa banyak memutuskan untuk memperbarui setiap nilai *cell state*. (Ghosh, Bose, Maji, Debnath, & Sen, 2019).

2.7.3.4. Output Gate

Pada *output gate* terdapat dua *gate* yang akan dilaksanakan, pertama akan diputuskan nilai pada bagian *memory cell* mana yang akan dikeluarkan dengan menggunakan fungsi aktivasi *sigmoid*. Selanjutnya akan ditempatkan nilai pada *memory cell* dengan menggunakan fungsi aktivasi *tanh*. Terakhir kedua *gate* tersebut di kalikan sehingga menghasilkan nilai yang akan dikeluarkan (Aldi, Jondri, & Aditsania, 2018). Dengan rumus seperti pada Gambar 2.23 :



(Sumber : Manu, 2021)

Gambar 2.23. Persamaan melewati *Output Gate* pada LSTM

Keterangan (Pardede & Ibrahim, 2020) :

o_t : *Output gate*

C_t : *Cell state*

σ : Fungsi Aktivasi *Sigmoid*

\tanh : Fungsi Aktivasi *Tanh*

W_o : Nilai *Weight* untuk *Output gate*

h_{t-1} : Nilai *output* sebelum order ke t

x_t : Nilai *input* pada order ke t

b_o : Nilai *bias* pada *Output gate*

h_t : Nilai *output* pada order ke t

Terakhir pada Gambar 2.23 adalah tahap di mana perlu memutuskan apa yang akan hasilkan. *Output* akan didasarkan pada *cell state*, tetapi akan menjadi versi yang difilter. Pertama, peneliti menjalankan *layer sigmoid* yang memutuskan bagian mana dari *cell state* yang akan peneliti hasilkan. Kemudian, *cell state* di tempatkan melalui *tanh* (untuk mendorong nilai menjadi antara -1 dan 1) dan mengalikannya dengan *output gate layer sigmoid*, sehingga hanya akan menampilkan bagian yang putuskan (Ghosh, Bose, Maji, Debnath, & Sen, 2019).

2.7.4. Loss Function

Kinerja pembelajaran diukur dari optimalnya nilai suatu fungsi seperti minimalnya nilai *loss* dan *error*. *Loss* adalah ukuran seberapa dekat atau berbeda model yang dihasilkan dengan data asli, sedangkan *error* merupakan salah satu cara untuk menghitung *loss*. Nilai dari *loss* dan *error* tergantung dari *parameter* pembelajaran yang digunakannya. Kekurangan dari *Machine Learning* adalah membutuhkan data yang banyak untuk proses pembelajarannya (Putra J. G., 2020). Dalam Penelitian ini fungsi pengukuran nilai *error* yang akan di gunakan adalah *Mean Squared Error* (MSE).

2.7.4.1. Mean Squared Error (MSE)

Tingkat akurasi ditujukan selain secara visual dalam bentuk grafik juga dalam bentuk kuantitatif dengan mengukur nilai MSE (*Mean Square Error*) MSE berhubungan dengan variasi sebaran frekuensi (*frequency distribution*) dari besar

kesalahan yang diperoleh, tapi tidak dengan variasi kesalahan. (Karno, Hastomo, Nisfiani, & Lukman, 2020). Berikut ini perhitungan dari MSE :

$$MSE = \frac{\sum_{t=1}^n (A_t - F_t)^2}{n}$$

Di mana (Aprian, Azhar, & Nastiti, 2020) :

n : adalah jumlah data

F_t : adalah data prediksi pada waktu ke i

A_t : adalah data asli pada waktu i

Uji Validitas menggunakan *Mean Squared Error* (MSE) dilakukan untuk mengukur hasil akurasi pengujian. MSE merupakan salah satu contoh *parameter* yang biasa digunakan sebagai indikator untuk mengukur dan membandingkan kemiripan hasil prediksi dan data asli (Aprian, Azhar, & Nastiti, 2020).

2.7.5. Batch dan Epochs

Epoch adalah ketika seluruh kumpulan data sudah melalui proses *training* pada *Neural Network* sampai dikembalikan ke awal dalam satu putaran. Dalam *Neural Network* satu *epoch* itu terlalu besar dalam proses pelatihan karena seluruh data diikutkan ke dalam proses *training* sehingga akan membutuhkan waktu cukup lama. Agar mempermudah dan mempercepat proses *training*, biasanya data rate dibagi per *batch* (*Batch Size*).

Batch size merupakan jumlah sampel data yang akan disebarluaskan dalam sebuah *Neural Network*. *Batch size* efisien secara komputasi ketika berhadapan

dengan kumpulan data yang besar. Penentuan nilai dari *batch size* biasanya tergantung peneliti dengan melihat banyak sampel (Thohari & Hertantyo, 2018).

2.7.6. Normalisasi dan Denormalisasi

Dalam rangka meminimalkan *error* perlu dilakukan normalisasi. Normalisasi berfungsi untuk menghindari terjadinya berbagai anomali data dan tidak konsistensinya data. Normalisasi ini juga bertujuan untuk mengubah ukuran data menjadi lebih kecil tanpa harus mengubah data asli. Teknik normalisasi yang digunakan adalah *minmaxscaling*. Teknik ini digunakan untuk mengatasi perbedaan nilai yang cukup besar antar kumpulan data. Cara kerjanya yakni dengan mengubah nilai pada data aktual menjadi nilai dengan skala (0,1) tanpa mengubah informasi yang ada. Teknik normalisasi dengan *minmaxscaling* memiliki persamaan sebagai berikut (Aldi, Jondri, & Aditsania, 2018).

$$x_{norm} = \frac{(x - x_{min})}{(x_{max} - x_{min})}$$

Di mana :

x_{norm} : Data hasil normalisasi

x : Data asli

x_{min} : Nilai minimum dari data x

x_{max} : Nilai maximum dari data x

Denormalisasi adalah proses pengembalian data hasil normalisasi ke dalam data asli atau data sebenarnya. Hal tersebut dilakukan guna melihat hasil prediksi

dengan cara membandingkan dengan data sebenarnya (Aldi, Jondri, & Aditsania, 2018).

$$x = x_{norm}(x_{max} - x_{min}) + x_{min}$$

Di mana :

x : Hasil *output*

x_{norm} : Nilai dari data normalisasi

x_{min} : Nilai minimal data actual keseluruhan

x_{max} : Nilai maksimal data actual keseluruhan

2.7.7. Interpolasi Linear

Interpolasi linier yang sering disebut sebagai interpolasi adalah kemampuan untuk menduga nilai yang terdapat di antara dua nilai lain yang dinyatakan di dalam grafik garis. Interpolasi linier merupakan salah satu metode untuk mengetahui nilai dari suatu interval dua buah titik yang terletak dalam satu garis lurus (Al Amin, Lusiana, & Hartono, 2018).

Interpolasi linier adalah cara mendapatkan nilai di antara dua data berdasarkan persamaan linier. Untuk dapat melakukannya maka minimal harus diketahui dua buah data (Al Amin, Lusiana, & Hartono, 2018).

$$\frac{y - y_a}{y_b - y_a} = \frac{x - x_a}{x_b - x_a}$$

$$x = x_a + (x_b - x_a) \frac{(y - y_a)}{(y_b - y_a)}$$

Di mana (Al Amin, Lusiana, & Hartono, 2018). :

y : Orde data yang akan di interpolasi

y_a : Orde data sebelum data yang akan di interpolasi

y_b : Orde data sesudah data yang akan di interpolasi

x : Data hasil interpolasi

x_a : Data orde sebelum data yang akan di interpolasi

x_b : Data orde sesudah data yang akan di interpolasi

2.8. Prediksi / *Forecasting*

Menurut Sucipto & Syaharuddin Prediksi / Peramalan (*forecasting*) adalah kegiatan mengestimasi apa yang akan terjadi pada masa yang akan datang. Peramalan diperlukan karena adanya kesenjangan waktu (*timelag*) antara kesadaran dibutuhkannya suatu kebijakan baru dengan waktu pelaksanaan kebijakan tersebut (Sucipto & Syaharuddin, 2018).

Menurut Putro, Furqon, & Wijoyo prediksi merupakan suatu proses untuk meramalkan atau memperkirakan suatu *variabel* di masa yang akan datang. Dalam kasus prediksi biasanya data yang sering digunakan adalah data kuantitatif. Prediksi tidak harus menghasilkan suatu jawaban yang pasti kejadian, melainkan berusaha untuk mencari jawaban yang sedekat mungkin dengan kejadian yang akan terjadi (Putro, Furqon, & Wijoyo, 2018).

Secara umum, ada dua jenis prediksi yaitu kualitatif dan kuantitatif. Prediksi kualitatif merupakan prediksi yang bersifat subjektif, hal ini karena didasarkan

pada pengalaman empiris, intuisi pengambilan keputusan dan emosi manusia. Sedangkan, prediksi kuantitatif merupakan prediksi yang bersifat objektif sebab didasarkan pada data aktual dan diolah menggunakan metode tertentu (Surtiningsih, Furqon, & Adinugroho, 2018).

Jenis sesuai yang dijelaskan oleh para ahli sebelumnya prediksi yang digunakan dalam penelitian adalah prediksi kuantitatif. Dikarenakan data yang digunakan adalah data dari masa lalu berupa angka dengan runtutan waktu.

2.9. Penelitian Terdahulu

No	Pengarang, Tahun	Metode	Data	Hasil
1	(Moghar & Hamiche, 2020)	<i>Long Short-Term Memory</i>	Dokumentasi saham NYSE (GOOGL dan NKE) dari website yahoo finance	Setelah melatih NN, hasil pengujian peneliti menunjukkan hasil yang berbeda, jumlah <i>epoch</i> serta panjang data memiliki pengaruh yang signifikan terhadap hasil pengujian. Setelah mengamati data peneliti, peneliti dapat melihat bahwa pada awalnya data kurang stabil dan memiliki nilai yang lebih rendah, setelah NKE mulai mengintip nilai yang lebih besar, aset menjadi lebih fluktuatif, maka sifat aset ini berubah. Model peneliti telah kehilangan jejak harga pembukaan sekitar 600 hingga 700 hari pengujian yang sesuai dengan perubahan sifat data.
2	(Karno, Hastomo, Nisfiani, & Lukman, 2020)	<i>Long Short-Term Memory</i> berbasis <i>Gated Recurrent</i>	Dokumentasi saham bank di Indonesia dari website yahoo finance	Dengan menggunakan paket library seborn di <i>python</i> , hasil perhitungan korelasi dapat ditunjukkan di matrik heatmap dalam bentuk numerik dan tingkatan warna. Hasil numerik korelasi berupa

		<i>Units</i>		bilangan dengan rentang -1 dan 1, di mana nilai 1 menunjukkan hubungan yang kuat, dan nilai 0 menunjukkan hubungan yang rendah antara dua data. Jadi dapat dilihat bahwa RMSE mampu meredam perubahan kesalahan yang besar, sebaliknya MSE mampu melihat perubahan kesalahan yang kecil. GRU berupa sel yang berisi hanya 2 <i>gate</i> dengan rangkaian yang lebih sederhana dibandingkan dengan LSTM.
3	(Boruah & Barman, 2018)	<i>Long Short-Term Memory</i>	Identifikasi kalimat pada Novel <i>Bhanumati</i> ditulis oleh Assamese scholar <i>Padmanath Gohainbaruah</i>	<i>Epoch</i> dengan akurasi maksimum untuk model yang berbeda diberikan. Akurasi rata-rata yang terlihat setelah setiap seribu <i>epoch</i> menampilkan kerugian rata-rata setelah setiap seribu <i>epoch</i> dari Uji 1, yang memiliki akurasi maksimum di antara model berbeda yang memiliki konfigurasi berbeda. Tetapi untuk bahasa Assam yang ditranskripsi secara fonetis pada peneliti dapat melihat bahwa akurasi rata-rata meningkat ketika peneliti meningkatkan jumlah <i>neuron</i> dari 128 menjadi 256 di setiap lapisan. Tetapi peningkatan lebih lanjut dari <i>neuron</i> menjadi 512 di setiap lapisan menurunkan akurasi.
4	(Supriyadi, 2019)	<i>Long Short-Term Memory</i>	Observasi sinoptik Stasiun Meteorologi Maritim Tanjung Priok	Metode <i>Deep Learning</i> LSTM digunakan untuk memprediksi <i>parameter</i> cuaca, seperti suhu udara, kelembaban, kecepatan angin, dan tekanan udara. Sedangkan jumlah datanya dibagi dua menjadi <i>training</i> data dan test data dengan rasio 9:1 pada bulan Januari 2019. Diperoleh RMSE <i>parameter</i> suhu udara, kelembaban,

				kecepatan angin, dan tekanan udara nilainya semakin baik ketika menggunakan <i>Deep Learning</i> LSTM dengan update dibandingkan LSTM tanpa update. Dari <i>parameter</i> cuaca tersebut hanya <i>parameter</i> suhu dan kelembaban udara yang mengalami pertambahan RMSE seiring bertambahnya waktu.
5	(Poornima & Pushpalatha, 2019)	LSTM dengan <i>Weighted Linear Units</i>	Dokumentasi kumpulan data <i>China Meteorological Administration</i>	Dalam penelitian tersebut menyajikan Metode <i>Long Short-Term Memory</i> dengan <i>Weighted Linear Units</i> untuk memprediksi curah hujan. <i>Neural Network</i> dilatih dan diuji menggunakan dataset standar curah hujan. Jaringan yang dilatih akan menghasilkan atribut prediksi curah hujan. <i>Parameter</i> yang dipertimbangkan untuk evaluasi kinerja dan efisiensi model prediksi curah hujan yang diusulkan adalah <i>Root Mean Square Error</i> , akurasi, jumlah <i>epoch</i> , <i>loss</i> , dan <i>Learning rate</i> .
6	(Zahara, Sugianto, & Ilmuddafiq, 2019)	<i>Long Short-Term Memory</i>	Dokumentasi secara <i>online</i> dari website <i>Dinas Perdagangan dan Perindustrian Provinsi Jawa Timur</i>	Pembangunan model prediksi dilakukan di lingkungan cloud computing Amazon <i>Web service</i> tipe EC2. IHK prediksi pada bulan Desember 2016 yaitu 133.98, mempunyai nilai prediksi yang paling mendekati nilai IHK aktual yaitu 133.98 Dari hasil pengujian nilai RMSE tiap algoritma optimasi LSTM yang masih tergolong besar, terlihat bahwa metode LSTM belum bisa disebut metode yang maksimal dalam melakukan prediksi IHK.
7	(Aldi, Jondri, & Aditsania,	<i>Long Short-</i>	Dokumentasi dari website	Pada penelitian tersebut dibangun model LSTM untuk

	2018)	<i>Term Memory</i>	<i>blockchain.info</i>	memprediksi harga Bitcoin dengan pengujian <i>parameter</i> komposisi data, jumlah pola <i>timeseries</i> , jumlah <i>hidden neuron</i> dan max <i>epoch</i> . Pada pengujian tersebut didapatkan hasil yang terbaik yaitu dengan komposisi data latih 70% dan data uji 30%, <i>parameter</i> 1 pola <i>timeseries</i> , jumlah 25 <i>neuron hidden</i> , dan max <i>epoch</i> adalah 100 dengan akurasi rata-rata pada data latih 95.36% dan data <i>testing</i> 93.5%.
8	(Putra, Osmond, & Ansori, 2020)	<i>Long Short-Term Memory</i>	Dokumentasi data mentah dari Dinas Perindustrian dan Perdagangan Provinsi Jawa Barat	Ada 4 <i>parameter</i> yang akan diuji untuk setiap komoditas, yang terdiri dari Nilai <i>Epoch</i> , Nilai Lookback, Jumlah <i>Hidden Layer</i> , dan Nilai Train <i>Batch</i> . Jumlah <i>hidden layer</i> adalah banyaknya <i>layer</i> LSTM pada model, terdapat Single-Layer dan Multi-Layer di mana Multi-Layer sendiri terdiri dari 2 dan 3 <i>hidden layer</i> . Tujuan pengujian prediksi di sini yaitu untuk menguji tingkat akurasi dan kecocokan model LSTM dalam memprediksi harga masa depan dengan menggunakan konfigurasi dari hasil pada pengujian model.
9	(Ghosh, Bose, Maji, Debnath, & Sen, 2019)	<i>Long Short-Term Memory</i>	Dokumentasi dari website resmi <i>Bombay Stock Exchange</i>	Dalam penelitian tersebut, peneliti menganalisis pertumbuhan perusahaan dari berbagai sektor dan mencoba mencari tahu yang merupakan rentang waktu terbaik untuk memprediksi harga saham di masa depan. Prediksi bisa lebih akurat jika model akan berlatih dengan jumlah data yang lebih banyak mengatur. Kerangka kerja ini secara luas membantu dalam analisis

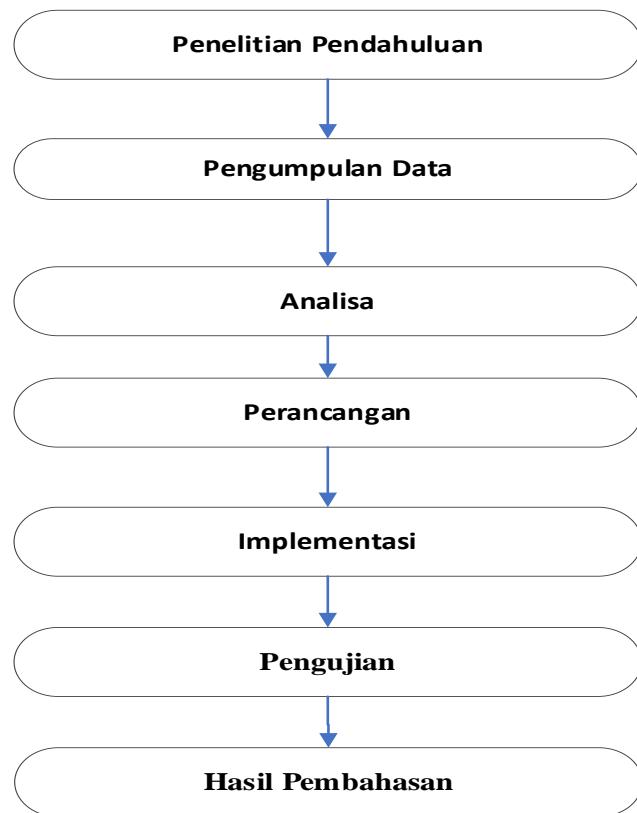
				pasar dan prediksi pertumbuhan perusahaan yang berbeda dalam rentang waktu yang berbeda.
10	(Rizki, Basuki, & Azhar, 2020)	<i>Long Short-Term Memory</i>	Dokumentasi dari website BMKG	Aplikasi berhasil memproses prediksi curah hujan kota Malang dengan <i>parameter curah hujan</i> . Jumlah <i>neuron hidden layer</i> dengan hasil paling optimal yaitu dengan 256 <i>neuron hidden layer</i> . Jumlah <i>epoch</i> dengan hasil paling optimal yaitu 150 <i>epoch</i> . Komposisi Data Train dan Data Test dengan hasil yang paling optimal yaitu dengan komposisi data train 50% dan data test 50%. Hal ini karena komposisi data train 50% dan data test 50% memiliki tingkat <i>error</i> yang paling rendah yaitu pada data train sebesar 12.079 dan pada data test sebesar 11.288.

BAB III

METODOLOGI PENELITIAN

3.1. Kerangka Penelitian

Kerangka penelitian merupakan rangkaian kegiatan yang dilakukan dalam suatu penelitian berupa rangkaian grafik yang menggambarkan alur proses penelitian proyeksi curah hujan daerah padang Pariaman menggunakan *Deep Learning* dengan metode *Long Short-Term Memory*, sehingga langkah-langkah yang dilakukan oleh peneliti dalam perancangan ini tidak melenceng dari pokok bahasan dan lebih mudah dipahami, yang diilustrasikan seperti pada Gambar 3.1 berikut.



Gambar 3.1. Kerangka Penelitian

3.2. Tahapan Penelitian

Tahapan penelitian merupakan langkah-langkah yang dilakukan untuk mempermudah dalam melakukan penelitian. Tahapan dalam penelitian ini terdiri dari penelitian pendahuluan, pengumpulan data, analisa, perancangan, implementasi, pengujian yang dijelaskan sebagai berikut :

3.2.1. Penelitian Pendahuluan

Penelitian pendahuluan merupakan proses melakukan pendekatan terhadap objek penelitian. Tujuan dari Penelitian pendahuluan tak lain dapat memberikan solusi terhadap masalah yang di identifikasi. Permasalahan pada proyeksi curah hujan khusus daerah padang Pariaman masih belum pernah di lakukan sama sekali. Oleh

karena itu dilakukanlah sebuah penelitian yang nantinya dapat membantu *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* dalam melakukan prediksi curah hujan di daerah padang Pariaman. Penelitian ini nantinya memerlukan alternatif lain dalam melakukan prediksi curah hujan di daerah padang Pariaman dengan menggunakan metode *Long Short-Term Memory*.

3.2.2. Pengumpulan Data

Dalam Penelitian ini semua data bersumber dari *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* dari tahun 1985-2021, dan beberapa pencarian referensi seperti buku-buku, karya-karya ilmiah maupun jurnal, baik yang ada di perpustakaan maupun yang ada di internet yang berhubungan dengan penelitian. Data juga didapat dari studi lapangan dengan melakukan wawancara secara langsung.

3.2.2.1. Waktu Penelitian

Penelitian dilakukan dengan merekap data-data pengamatan unsur-unsur cuaca yang dilakukan oleh *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* secara umum yang di lakukan dari bulan November sampai dengan selesai.

Tabel 3.1. Jadwal Penelitian

No	Kegiatan	Bulan Ke								
		1	2	3	4	5	6	7	8	9
1	Penelitian Pendahuluan	■	■	■						
2	Pengumpulan Data				■	■				
3	Analisa			■	■	■				
4	Perancangan				■	■	■	■	■	

3.2.2.2. Tempat Penelitian

Objek Penelitian di lakukan di *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* yang beralamat di Jalan Raya Padang – Bukittinggi KM. 51 Kapalo Hilalang Sumatera Barat.

3.2.2.3. Metode Penelitian

Metode pada Penelitian ini terdiri dari penelitian perpustakaan, wawancara, penelitian laboratorium. Dengan penjelasan yang diuraikan sebagai berikut :

3.2.2.3.1. Penelitian Perpustakaan (*Library Research*)

Pada tahap ini peneliti melakukan studi literatur dengan membaca buku, jurnal, makalah dan laporan penelitian yang terkait dengan topik Penelitian. Tujuannya adalah untuk memperkuat permasalahan serta sebagai dasar teori dalam melakukan studi dan juga menjadi dasar untuk melakukan Penelitian terhadap proyeksi curah hujan.

3.2.2.3.2. Wawancara (Interview)

Pada tahap ini peneliti dan narasumber berhadapan langsung untuk mendapatkan informasi secara lisan dengan tujuan mendapatkan data yang dapat menjelaskan permasalahan yang berhubungan dengan penelitian. Wawancara dilakukan dengan supervisor di *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* terkait

dengan permasalahan untuk proses menganalisis masalah, menentukan informasi yang di butuhkah oleh peneliti, seperti pengambilan data, dan lain-lain.

3.2.2.3.3. Penelitian Laboratorium (*Laboratorium Reaserch*)

Penelitian laboratorium adalah metode penelitian yang di lakukan menggunakan laptop/personal computer (PC). Alat bantu tersebut di gunakan untuk mempraktikkan sekaligus menguji keakuratan metode yang di gunakan.

Adapun Spesifikasi *Hardware* dan *Software* yang di gunakan dalam melakukan penelitian laboratorium ini adalah sebagai berikut :

3.2.2.3.3.1. Perangkat Keras (*Hardware*)

- a) Laptop ASUS Model A445LAB
- b) CPU Intel® Core™ i3-5005U CPU @ 2.00GHz (4 CPUs)
- c) *Memory* RAM 12GB
- d) Partisi Penyimpanan Samsung SSD 870 EVO 250GB
- e) GPU Intel(R) HD Graphics 5500

3.2.2.3.3.2. Perangkat Lunak (*Software*)

- a) Sistem Operasi *Windows* 11 Pro 64bit (Build 22000.778)
- b) Microsoft Office 365 (64-bit)
- c) Google Chrome (64-bit)
- d) Visual Studio Code (64-bit)
- e) Bahasa Pemrograman *Python* v.3.9.0 (64-bit)
- f) MySQL Ver 8.0.27 (64-bit)
- g) StarUML Version 4.0.1 (64-bit)
- h) Adobe XD 2021 (64-bit)

3.2.3. Analisa

Analisa dalam penelitian adalah penjabaran dari suatu masalah dari objek yang diteliti yang akhirnya menghasilkan suatu kesimpulan, dalam penelitian ini dimaksudkan untuk mengidentifikasi masalah dalam memprediksi curah hujan berdasarkan data harian klimatologi Dalam proses analisa terdapat tiga tahapan analisa yang harus dilakukan yakni tahapan analisa data, analisa proses dan analisa sistem dengan penjelasan sebagai berikut :

3.2.3.1. Analisa Data

Analisis data adalah sebuah proses untuk memeriksa, membersihkan, mengubah, dan membuat pemodelan data dengan maksud untuk menemukan informasi yang bermanfaat sehingga dapat memberikan petunjuk bagi peneliti untuk mengambil keputusan terhadap pertanyaan-pertanyaan penelitian. Data dalam Penelitian ini didapat langsung dari *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman.*

3.2.3.2. Analisa Proses

Pada tahap analisa proses ini, peneliti melakukan analisa tentang bagaimana proses pemecahan masalah yang di terapkan dan di tentukan sehingga penelitian dapat menghasilkan solusi yang tepat, mulai dari menganalisis masalah, mendokumentasikan, menggunakan metode yang tepat, dan hasil akhir penelitian dalam *format representasi* yang bervariasi dan dapat di mengerti. Dengan begitu di harapkan dapat menjadi solusi yang tepat untuk memecahkan permasalahan proyeksi curah hujan di daerah Padang Pariaman.

3.2.3.3. Analisa Sistem

Selanjutnya pada tahap analisis sistem ini merupakan tahapan yang sangat kritis dan sangat penting, di karenakan kesalahan pada tahapan analisis sistem menyebabkan juga kesalahan ditahap selanjutnya. Tahap analisis sistem merupakan dasar dalam merancang dan merencanakan sistem yang dibuat, analisa sistem dilakukan untuk mengetahui apa saja yang dibutuhkan oleh sistem. Analisa sistem dilakukan untuk mengidentifikasi dan menganalisis keperluan sesuai sistem yang di kembangkan. Agar sistem yang di kembangkan dapat terorganisir dengan baik.

3.2.4. Perancangan

Perancangan arsitektur sistem diperlukan agar setiap sistem yang dibangun memiliki konstruksi yang baik, proses pengolahan data yang tepat dan akurat, memiliki nilai, dan memberikan dasar-dasar untuk pengembangan selanjutnya.

3.2.4.1. Perancangan Model

Tahapan perancangan ini, peneliti menggunakan *Unified Modeling Language (UML)* sebagai alat dalam menjelaskan alur perancangan yang dibuat. Tahapan perancangan bertujuan untuk membuat sistem yang dirancang terorganisasi dan terstruktur dengan rancangan sesuai dengan tujuannya, sehingga tidak melenceng dari tujuan Penelitian.

3.2.4.1.1. Use case Diagram

Use case Diagram mendeskripsikan tipe interaksi antara pengguna sistem dengan sistemnya untuk mengetahui fungsi apa saja yang ada di dalam sistem dan siapa saja yang berhak menggunakan fungsi-fungsi tersebut.

3.2.4.1.2. *Class Diagram*

Class diagram merupakan suatu diagram yang digunakan untuk menampilkan kelas-kelas berupa paket untuk memenuhi salah satu kebutuhan yang di gunakan nantinya, dan juga memperlihatkan aturan-aturan dan tanggung jawab entitas yang menentukan perilaku dari sistem.

3.2.4.1.3. *Sequence Diagram*

Sequence Diagram menjelaskan urutan-urutan kejadian yang terjadi di dalam sistem, serta untuk menggambarkan interaksi antara keseluruhan objek di dalam dan interaksi objek yang disusun dalam sistem berdasarkan urutan waktu dalam bentuk gambaran tahap demi tahap yang seharusnya dilakukan.

3.2.4.1.4. *Statechart Diagram*

Statechart Diagram digunakan untuk menggambarkan perubahan status yang terjadi dengan menggambarkan transisi serta perubahan pada suatu objek pada sistem selama sistem dijalankan sampai dengan selesai.

3.2.4.1.5. *Activity Diagram*

Activity Diagram merupakan sebuah diagram yang dapat memodelkan berbagai proses yang terjadi pada sistem yang berfokus pada aktivitas yang terjadi yang terkait dalam suatu proses tunggal. Dengan kata lain, diagram ini menunjukkan bagaimana aktivitas yang dilakukan oleh pengguna.

3.2.4.1.6. *Collaboration Diagram*

Collaboration diagram dikenal dengan beberapa nama, seperti *communication diagram* dan *Interaction diagram*, yang mana penggambaran interaksi dan hubungan antara objek dalam sistem.

3.2.4.1.7. Deployment Diagram

Deployment diagram adalah diagram yang digunakan memetakan *software* ke processing node. Menunjukkan konfigurasi elemen pemroses pada saat runtime dan *software* yang ada di dalamnya, dan digunakan untuk menggambarkan detail bagaimana komponen disusun di infrastruktur sistem.

3.2.4.2. Perancangan Interface

Interface merupakan mekanisme komunikasi antara pengguna dengan sistem. Meliputi tampilan layar yang menyediakan navigasi di dalam sistem, layar dan formulir untuk menangkap data, dan laporan yang dihasilkan oleh sistem.

Perancangan *interface* dibuat untuk memberikan penjelasan tentang tampilan yang dihadapkan pada pengguna saat menggunakan sistem untuk membantu mengarahkan alur penelitian masalah sampai ditemukan suatu solusi.

3.2.5. Implementasi

Implementasi sistem merupakan tahap meletakkan sistem sehingga siap untuk dioperasikan. Implementasi bertujuan untuk mengkonfirmasi modul-modul perancangan, sehingga pengguna dapat memberi masukan kepada pengembangan sistem.

Untuk mengimplementasikan sistem yang telah dirancang, maka diperlukan sebuah alat bantu komputer untuk mengoperasikan komputer itu sendiri yang memerlukan tiga buah komponen pendukung seperti *Hardware*, *Software*, dan *Brainware*.

3.2.5.1. Perangkat Keras (*Hardware*)

Hardware yang digunakan untuk merancang atau menjalankan program sistem yang telah dibuat dalam satu *unit* komputer yang lengkap dengan CPU, harddisk sebagai media penyimpanan data.

3.2.5.2. Perangkat Lunak (*Software*)

Untuk menjalankan program sistem yang dirancang harus menggunakan beberapa *software* pendukung.

3.2.5.3. Manusia (*Brainware*)

Brainware merupakan *operator* yang berfungsi untuk mengoperasikan atau menjalankan program sistem.

3.2.6. Pengujian

Pengujian sistem merupakan tahap melakukan *testing* untuk mengetahui kesalahan dalam Sistem. Pengujian terhadap sistem dilakukan untuk dapat mengetahui Sistem yang dirancang telah berjalan sesuai dengan yang diharapkan. Sehingga memudahkan *admin* mengetahui informasi terkini dari sistem, dan kemudian mengambil tindakan selanjutnya jika dibutuhkan.

3.2.6.1. Pengujian Lokal

Pengujian Lokal atau LAN, yaitu pengujian yang dilakukan melalui akses jaringan komputer dengan sistem *Local Area Network*, dengan cara menghubungkan komputer *server* ke komputer *client* dengan media kabel, yang terlebih dahulu dilakukan configurasi *IP Address* pada komputer *server* dan komputer *client*. Sehingga *client* dapat mengakses data pada komputer *server*, sedangkan pada komputer *server* menyediakan informasi yang dibutuhkan oleh *client*.

3.2.6.2. Pengujian *Online*

Pembuatan program ini nantinya bisa diakses secara *online* dengan di hosting di tempat penyedia *web service*. Selanjutnya melakukan konfigurasi *database* agar terhubung ke *web server*. Setelah semua proses dilakukan maka *website* bisa diakses oleh *admin* yang ingin menggunakan sistem ini.

3.2.6.3. Pengujian Aplikasi

Pengujian Aplikasi dengan menggunakan *Black Box*, yaitu pengujian yang dilakukan hanya mengamati hasil eksekusi melalui data uji dan memeriksa fungsional dari perangkat lunak bahwa aplikasi yang dirancang dapat memenuhi kebutuhan yang mendasari perancangan aplikasi tersebut dan berjalan sesuai dengan diharapkan.

3.2.6.4. Pengujian *Interface*

Pengujian Antarmuka/*Interface*, yaitu pengujian yang dilakukan untuk melihat bagaimana tampilan akhir dari sistem yang telah dirancang dengan pengamatan secara langsung oleh pengguna interaksi secara langsung dengan model *interface* yang disajikan dalam bentuk prototipe. Proses ini dilakukan agar kesalahan dapat terdeteksi dan di ubah secara cepat.

3.2.7. Hasil Pembahasan

Hasil pembahasan merupakan hasil observasi atau penelitian. Hasil pembahasan merupakan isi dari suatu bagian penting dari suatu penelitian. Hasil pembahasan memiliki sifat objektif atau subjektif. Hasil pembahasan dapat dijelaskan sebagai hasil interpretasi dari hasil penelitian yang telah dianalisis guna menjawab pertanyaan-pertanyaan dalam penelitian.

Penyajian hasil pembahasan dapat dilakukan secara deskriptif, dengan menggunakan tabulasi, tabel atau grafik, atau dengan menggunakan kombinasi dua atau ketiganya sekaligus. Untuk penelitian ini, hasil pembahasan dijelaskan melalui tabel maupun grafik statistik.

BAB IV

ANALISA DAN PERANCANGAN

4.1. Analisa

Berdasarkan penjelasan yang telah diuraikan pada bab sebelumnya, maka diperlukan suatu proses penganalisan dengan tujuan untuk memberikan hasil yang akurat berdasarkan informasi maupun data yang sudah peneliti dapatkan untuk di terapkan pada perancangan.

4.1.1. Analisa Data

Analisa Data adalah tahap rentan dalam mengembangkan sebuah sistem yang padu. Di mana analisa data merupakan tahap awal agar sistem yang di rancang memiliki gambaran sesuai pola data yang terbentuk

Data dalam Penelitian ini data di dapat langsung dari *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman*, data yang di gunakan merupakan data harian dari tanggal *1 January 1985 sampai 31 Desember 2021* data tersebut terdiri dari beberapa fitur / *variabel* seperti yang terlihat pada Tabel 4.1 berikut :

Tabel 4.1. Fitur Data Klimatologi BMKG Padang Pariaman

Kode	Keterangan	Satuan
Tn	Temperatur minimum	°C
Tx	Temperatur maksimum	°C
$Tavg$	Temperatur rata-rata	°C
RH_avg	Kelembapan rata-rata	%
RR	Curah hujan	mm

<i>ss</i>	Lamanya peninjiraran matahari	<i>jam</i>
<i>ff_x</i>	Kecepatan angin maksimum	<i>m/s</i>
<i>ddd_x</i>	Arah angin saat kecepatan maksimum	°
<i>ff_avg</i>	Kecepatan angin rata-rata	<i>m/s</i>
<i>ddd_car</i>	Arah angin terbanyak	°

Sesuai Data Klimatologi yang di tampilkan pada Tabel 4.1 di mana setiap fitur *variabel* pada data tersebut merupakan *variabel* in-dependen. Tidak semua fitur data pada Tabel 4.1 di gunakan pada Penelitian ini, dan peneliti hanya menyertakan fitur *RR*.

Tabel 4.2. Data Stasiun Klimatologi Kelas II Sicincin Padang Pariaman

Tanggal	<i>RR</i>	Tn	Tx	Tav_g	RH_{avg}	ss	ff_x	ddd_x	ff_avg	ddd_car
01-01-1985	0			26, 5	72	0	0	0	0	N
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
13-06-2020	2	22, 8	999 9	25, 5	90	1,9	1	120	0	C
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
10-07-2020	0,4	23	32,2	26, 8	85	1	4	100	1	C
11-07-2020	8888	22	32,6	25	91	3	3	210	1	C
12-07-2020	15	22	31,2	25, 2	88	6,3	6	250	1	C
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
31-12-2021	24,9	24, 1	29,6	25, 2	94	4,8	2	30	1	C

Pada Tabel 4.2 Data Klimatologi pada Tanggal 11-07-2020, data yang bernilai 8888 berarti data tidak diukur, dan Data Klimatologi pada Tanggal 13-06-

2020 yang bernilai 9999 berarti tidak ada data (tidak dilakukan pengukuran). Nilai tersebut dianggap nilai yang hilang *Nan*.

4.1.1.1. Preprocessing Data

Dalam Penelitian ini di lakukan *preprocessing* data dengan data yang di gunakan memiliki beberapa nilai yang hilang *missing values* dan juga data bernilai *NaN* dari data yang di teliti. Nilai-nilai yang hilang / *NaN* tersebut ini muncul dari banyak faktor yang berada di luar kendali staf *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman*. di mana nantinya peneliti melakukan cara penanganan dengan beberapa cara sebagai berikut :

4.1.1.1.1. Interpolate *Nan*

Interpolate Nan merupakan Teknik *preprocessing* data yang *NaN* atau missing values dengan dengan melakukan interpolasi linear pada data dengan nilai yang hilang / *NaN*, dan data tidak hilang melainkan data di isi dari nilai rentang nilai sebelum dan sesudahnya. Sebagai contoh peneliti mencoba menghitung missing value dari tanggal 14-06-2020 sebagai berikut.

$$\frac{2 - 1}{5 - 1} = \frac{x - 2}{30 - 2}$$

$$x = 2 + (30 - 2) \frac{(2 - 1)}{(5 - 1)}$$

$$x = 2 + 28 \frac{1}{4}$$

$$x = 9$$

Hasil akhir terlihat seperti yang di jabarkan pada Tabel 4.3 dari tanggal 12-06-2020 - 17-06-2020 sebagai berikut.

Tabel 4.3. Data Klimatologi Sebelum dan Sesudah di Interpolate NaN

Tanggal	RR	Tanggal	RR
⋮	⋮	⋮	⋮
12-06-2020	0.0	12-06-2020	0.0
13-06-2020	2.0	13-06-2020	2.0
14-06-2020	NaN	14-06-2020	9.0
15-06-2020	NaN	15-06-2020	16.0
16-06-2020	NaN	16-06-2020	23.0
17-06-2020	30.0	17-06-2020	30.0
⋮	⋮	⋮	⋮

Seperti yang terlihat pada Tabel 4.3 baris data tanggal 14-06-2020 - 16-06-2020 dimana nilai *NaN* di gantikan dengan nilai rentang dari nilai sebelum dan sesudahnya berdasarkan kedudukan nilai yang di interpolasi dan nilai rentang terdekat.

4.1.1.1.2. Normalisasi MinMaxScaller

Sebelum data di processing ada baiknya data di normalisasi terlebih dahulu. di mana data yang di proses memiliki nilai rentang yang sama, tidak ada yang terlalu besar maupun terlalu kecil untuk setiap fitur data yang termasuk. Normalisasi data ini berguna agar proses analisis statistik pada data menjadi lebih mudah.

Normalisasi data yang di gunakan adalah normalisasi data *minmax* scaller, *Minmaxscaling* bekerja dengan scaling data dalam rentang tertentu (range nilai minimum hingga nilai maksimum), mengubah data berada pada rentang nilai 0

sampai 1. Sebagai contoh peneliti mencoba menormalisasi nilai dari tanggal *14-06-2020* sebagai berikut.

$$x_{norm} = \frac{(9 - 0)}{(30 - 0)}$$

$$x_{norm} = 0.3$$

Hasil akhir terlihat seperti yang di jabarkan pada Tabel 4.3 dari tanggal *12-06-2020 - 17-06-2020* sebagai berikut.

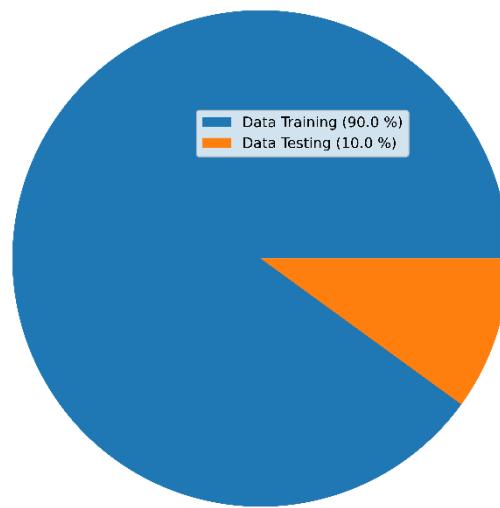
Tabel 4.4. Data Klimatologi Sebelum dan Sesudah di MinMaxScaller

Tanggal	RR	Tanggal	RR
⋮	⋮	⋮	⋮
12-06-2020	0.0	12-06-2020	0.0000
13-06-2020	2.0	13-06-2020	0.0667
14-06-2020	9.0	14-06-2020	0.3000
15-06-2020	16.0	15-06-2020	0.5333
16-06-2020	23.0	16-06-2020	0.7667
17-06-2020	30.0	17-06-2020	1.0000
⋮	⋮	⋮	⋮

Berdasarkan pada Tabel 4.4 semua nilai dari kolom *RR* di normalisasi dengan rentang nilai 0 – 1 berdasarkan nilai sebelumnya yang berkorelasi dengan nilai tertinggi dan terendah dari semua baris data yang di sertakan dalam perhitungan minmaxscaler.

4.1.1.2. Pembagian Data *Training* dan *Testing*

Pembagian data *training* di lakukan agar meningkatkan kinerja dari LSTM terhadap data *testing*. Data *training* digunakan untuk proses pelatihan model dengan metode LSTM sehingga terbentuk suatu model yang diuji performansinya terhadap data *testing*. Pembagian data yang digunakan yaitu 90% data *training* dan 10% data *testing*. Jumlah data *training* lebih besar dikarenakan agar mesin pembelajaran lebih terlatih untuk mempelajari model. Sehingga model yang dihasilkan dapat memberikan peramalan data *testing* yang lebih optimal.

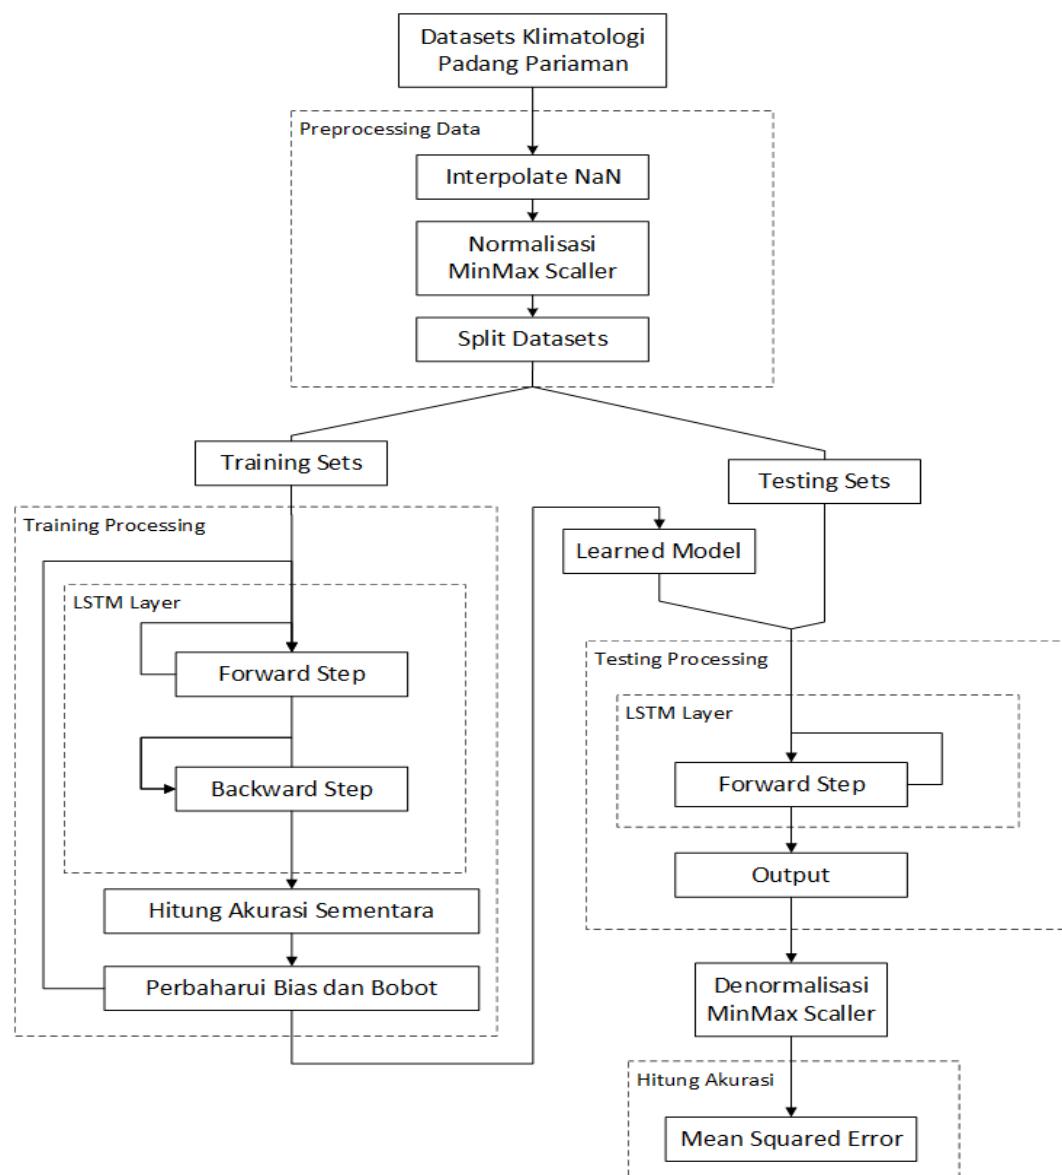


Gambar 4.1. Skala Pembagian Data *Training* dan Data *Testing*

Pembagian data latih dan data uji seperti yang telihat pada Gambar 4.1 bertujuan agar pembelajaran dapat belajar dari pola yang telah didapatkan dari hasil proses pelatihan yang diimplementasikan dalam pengujian data. Proses pelatihan dan pengujian menggunakan metode LSTM terus dilakukan hingga didapatkan model yang optimal.

4.1.2. Analisa Proses

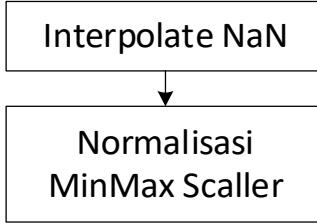
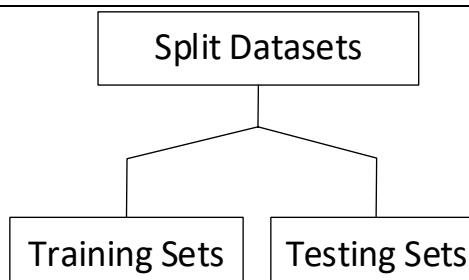
Analisis proses dilakukan untuk mengetahui cara pemecahan masalah sehingga dapat menghasilkan solusi dengan menggunakan metode yang tepat, melalui proses yang kooperatif dan interaktif mulai dari menganalisis masalah, mengidentifikasi masalah, hasil akhir pengamatan dalam berbagai *format representasi*, hingga memeriksa ketepatan pemahaman yang diperoleh. Berikut merupakan flowchart dari langkah Analisa proses :



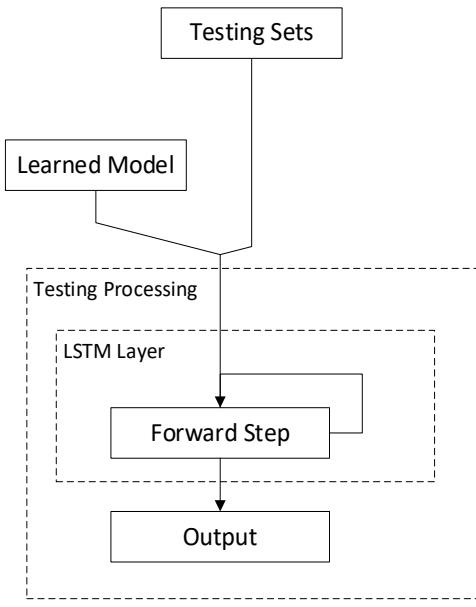
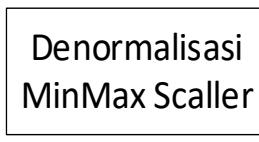
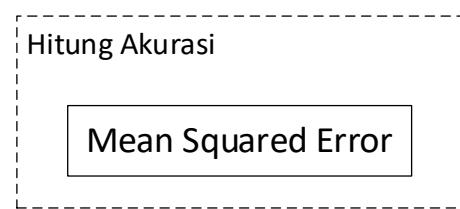
Gambar 4.2. Analisa Proses

Pada Gambar 4.2 terdapat 4 proses utama yaitu terdiri dari *preprocessing* data, *training* processing, *testing* processing, dan hitung akurasi, masing-masing proses harus di lakukan secara bertahap untuk mencapai tujuan penelitian dan mengetahui performansi dari arsitektur yang di rancang terhadap dataset yang di kumpulkan. Untuk penjelasan lebih detail berikut adalah Penjelasan Blok Diagram dari Gambar 4.2 yang terlihat seperti pada Tabel 4.5 di bawah ini :

Tabel 4.5. Penjelasan Blok Diagram Analisa Proses

Blok Diagram	Penjelasan
	Kumpulan data / datasets yang di ambil dari <i>Stasiun Klimatologi Kelas II Sicincin Padang Pariaman</i>
	Data yang telah masuk di proses pada tahap <i>preprocessing</i> . Tahapan ini dilakukan agar data yang dimiliki bersih dari NaN value. Penjelasan lengkap dapat di lihat pada <i>Preprocessing Data</i> di atas. Untuk normalisasi data di skalakan dengan interval 0-1.
	Hasil <i>preprocessing</i> data menghasilkan data yang bersih. Data bersih ini dibagi menjadi dua bagian yang itu data pelatihan (<i>training</i>) dan data pengujian (<i>testing</i>).

<pre> graph TD TS[Training Sets] --> TP[Training Processing] subgraph TP [Training Processing] direction TB LSTM[LSTM Layer] FS[Forward Step] BS[Backward Step] HAS[Hitung Akurasi Sementara] PBB[Perbaharui Bias dan Bobot] LSTM --> FS FS --> BS BS --> HAS HAS --> PBB end </pre>	<p>Pada <i>training</i> processing terdapat jaringan LSTM dimana proses <i>training</i> menggunakan 2 tahap, yaitu:</p> <ol style="list-style-type: none"> 1) <i>Forward Step</i>: proses dimana <i>output</i> value dari sebuah <i>Neural Network</i> di dapatkan sesudah <i>input</i> values dari <i>input-neuron</i> telah di selesaikan di proses. Proses ini di panggil <i>forward</i> karena proses kalkulasinya mulai dari <i>input Neural Network</i> ke <i>output</i>. 2) <i>Backward Step</i>: proses dimana <i>weights Neural Network</i> di kalkulasikan menggunakan algoritme seperti <i>gradient-descent</i>. Proses ini di panggil <i>backward</i> karena proses kalkulasinya mulai dari <i>output Neural Network</i> ke <i>input</i>. <p>Setelah proses <i>training</i> selesai dalam <i>LSTM Layer</i>, nilai akurasi sementara di hitung dengan menggunakan rumus MSE, dan juga <i>parameter bias</i> dan <i>weight</i> di perbaharui dan di gunakan pada iterasi dan <i>epoch</i> berikutnya.</p>
--	--

	<p><i>Learned model</i> adalah nilai optimal <i>weight</i> dan <i>bias</i> dari proses <i>training</i> sebanyak <i>epoch</i> yang telah di tentukan yang digunakan untuk melakukan proses pengujian.</p>
	<p>Hasil optimal dari <i>weight</i> dan <i>bias</i> dari <i>learned model</i> di gunakan untuk melakukan pengujian dari data <i>testing</i> yang berupa <i>input</i> dan <i>label</i>. Pada <i>testing</i> processing terdapat jaringan LSTM dengan proses <i>testing forward step</i> sebanyak data yang di <i>testing</i>. Hasil <i>Output</i> merupakan keluaran dan hasil pengujian dari jaringan LSTM.</p>
	<p>Hasil dari normalisasi dengan interval keluaran 0-1 perlu di lakukan denormalisasi Kembali agar nilai yang terlihat Tambah seperti nyata Kembali.</p>
	<p>Pada tahapan ini dilihat nilai <i>Root Mean Squared Error</i> pada masing masing pengujian yang dilakukan. Dimana hasil nilai <i>error</i> dari MSE menjadi acuan ketepatan prediksi.</p>

Seperti yang terlihat pada Tabel 4.5 setelah dilakukan Analisa data, selanjutnya data yang telah melewati tahap *preprocessing* bisa memasuki tahap processing yang mana perlu di persiapkan beberapa kriteria depensi seperti berikut :

1. Memisahkan kumpulan data menjadi 2 bagian yaitu *train set* dan *test set* 90% untuk data *training* 10% untuk data *testing*.
2. Pada pemodelan *Long Short-Term Memory input* data berupa tensor 3D berupa (*ukuran batch, jumlah features, dan timestep/sequence*).
3. Algoritma *training* untuk model LSTM di gunakan algoritma pembelajaran *backpropagation*, di mana model pemrosesan berurutan yang terdiri dari dua step, step satu mengambil *input* dalam arah maju (*forward direction*), *input* step kedua ke arah mundur (*backward direction*).
4. Di tentukan nilai *Epoch* sebanyak 30 yang nantinya bisa di ubah sesuai keinginan *admin*.
5. Di tentukan nilai *batch size* sebanyak 64 yang nantinya bisa di ubah sesuai keinginan *admin*.
6. Di tentukan nilai *unit cell* LSTM menjadi 1 yang nantinya bisa di ubah sesuai keinginan *admin*.
7. Di tentukan nilai *sequence length / jumlah timestep* dari data yang di gunakan.
8. Di tentukan nilai *Learning rate* di set nilai awalan 0.01 yang nantinya bisa di ubah sesuai keinginan *admin*.

9. Ditentukan nilai probabilitas *dropout* di set nilai awalan 0.1 yang nantinya bisa di ubah sesuai keinginan *admin*, pengecualian apabila jumlah *unit cell* LSTM hanya 1 maka nilai probabilitas *dropout* 0.
10. Fungsi optimasi yang digunakan adalah *Stochastic Gradient Descent* (SGD).
11. Nilai kesalahan / *error* value dari peramalan digunakan *loss Function* MSE, dan MSE.

4.1.2.1. Proses *Training Model*

Pada tahap *training* model LSTM dilakukan secara *backpropagation* sesuai data yang digunakan. Berikut beberapa tahapan dalam proses *training* model LSTM dengan *backpropagation* sebagai berikut :

1. Menginisialisasi nilai *epoch*, *batch*, *timestep/sequence*, *features*, *dropout*, *units*, dan *Learning rate* yang nantinya nilai hyperparamater yang dibutuhkan seperti nilai *weight* awal, *hidden layer* (lapisan tersembunyi) secara otomatis ditentukan oleh sistem.
2. *Input* data *training* berbentuk tensor 3D.
3. Melakukan *training* model LSTM pada setiap *input* yaitu dimulai dengan *forget gates*, *input gates*, *cell states* dan yang terakhir *output gates*.
4. Perhitungan MSE untuk mendapatkan nilai selisih antara nilai hasil jaringan LSTM dengan *output* sebenarnya.
5. Perhitungan gradien untuk menentukan nilai *weight* dan *bias* supaya hasil *loss/error* mendekati 0 dengan menggunakan algoritma *backpropagation*.

6. Setelah mendapatkan nilai gradien, maka dilanjutkan dengan persamaan fungsi optimasi *Stochastic Gradient Descent* (SGD) dan update kembali nilai *weight* dan *bias*.
7. Jika seluruh *batch* data telah selesai di iterasi Kembali ke Langkah 2 hingga jumlah *epoch* yang telah ditentukan.

Berdasarkan Langkah-langkah *training* di atas, Pembentukan model LSTM diawali dengan model dibentuk dengan data dilatih dengan melewati mekanisme *Gates* pada LSTM. Data dilatih terus hingga mencapai batas *error* yang sesuai jumlah *epoch* yang diinginkan dengan penentuan serta peubah *hyperparameter* yang digunakan.

4.1.2.2. Proses *Testing Model*

Ketika pembelajaran sudah mencapai target sesuai nilai *epoch* yang di *inputkan*, proses iterasi berhenti dan berikutnya model diuji dengan data pengujian.

Pada proses ini memuatkan kembali *learned model* yang sudah dihasilkan pada proses *training* sebelumnya dan menghitung hasil keluaran berdasarkan nilai *bias* dan *weight* yang diberikan pada saat proses *training* yang sudah ada di dalam *learned model*. Kemudian dibandingkan dengan data yang dihasilkan dengan metode LSTM pada rentang waktu yang ditentukan dengan metode akurasi yang digunakan menggunakan MSE.

4.1.2.3. Perhitungan Manual LSTM

Sebelum perancangan sistem dilakukan, peneliti melakukan analisis deskriptif untuk perancangan sistem dari Metode LSTM dengan perhitungan manual/numerik pada data Sebagian data yang di dapat langsung dari *Stasiun*

Klimatologi Kelas II Sicincin Padang Pariaman. Berikut contoh perhitungan manual jaringan LSTM.

4.1.2.3.1. Inisialisasi Hyperparameter

Untuk melakukan perhitungan LSTM di perlukan menginisialisasi beberapa nilai *hyperparameter* yang perlu di tentukan sebelum tahap *training* data di lakukan seperti yang terlihat pada Tabel 4.6 berikut.

Tabel 4.6. Nilai Inisialisasi Hyperparameter

<i>Hyperparameter</i>	Nilai
Jumlah <i>Epoch</i>	50
Ukuran <i>Batch</i> (<i>n</i>)	1
Panjang <i>Timestep/Sequence</i>	2
<i>Features</i>	rr
Jumlah <i>Units</i> LSTM	1
Jumlah <i>Hidden Layer</i>	1
<i>Learning rate</i> (γ)	0.1
Probabilitas <i>Dropout</i>	0

Berdasarkan fungsi optimizer untuk perbaruan *weight* dan *bias* yang di gunakan adalah *Stochastic Gradient Descent* (SGD), maka perbaruan *weight* dan *bias* di lakukan setiap proses *timestep* selesai, maka dari itu ukuran *batch* optimal adalah tidak lebih dari 1 seperti yang telihat pada Tabel 4.6 di atas.

4.1.2.3.2. Data Selection dan Preprocessing

Untuk data yang di gunakan sebanyak 60 baris data dengan *feature* Data Klimatologi yang di gunakan dalam perhitungan manual ini terbatas hanya menggunakan *feature* (*rr*) curah hujan, dimulai dari rentang waktu *16 Oktober 2004* sampai *14 Desember 2004*, *input* data *training* berbentuk tensor 3D di antaranya terdiri dari ukuran *batch* dimana hanya 1 *timestep*, jumlah *features* juga hanya 1 yaitu *feature* (*rr*) curah hujan, dan panjang *timestep/sequence* dengan panjang 2 baris data menjadi *input* x_1 dan x_2 , seperti yang terlihat pada Tabel 4.7 berikut.

Tabel 4.7. Data Yang di Gunakan Dalam Perhitungan Manual LSTM

No	Tanggal	rr	(rr) MinMaxScale	Input		y (label)
				x_1	x_2	
1	16 Oktober 2004	0.5	0.0052	0.0052	0.0206	1.0000
2	17 Oktober 2004	2	0.0206	0.0206	1.0000	0.5258
3	18 Oktober 2004	97	1.0000	1.0000	0.5258	0.6206
4	19 Oktober 2004	51	0.5258	0.5258	0.6206	0.2371
5	20 Oktober 2004	60.2	0.6206	0.6206	0.2371	0.1031
6	21 Oktober 2004	23	0.2371	0.2371	0.1031	0.1753
7	22 Oktober 2004	10	0.1031	0.1031	0.1753	0.0206
8	23 Oktober 2004	17	0.1753	0.1753	0.0206	0.0010
9	24 Oktober 2004	2	0.0206	0.0206	0.0010	0.1546
10	25 Oktober 2004	0.1	0.0010	0.0010	0.1546	0.0897
11	26 Oktober 2004	15	0.1546	0.1546	0.0897	0.2773
12	27 Oktober 2004	8.7	0.0897	0.0897	0.2773	0.1526
13	28 Oktober 2004	26.9	0.2773	0.2773	0.1526	0.4402
14	29 Oktober 2004	14.8	0.1526	0.1526	0.4402	0.1392
15	30 Oktober 2004	42.7	0.4402	0.4402	0.1392	0.0670
16	31 Oktober 2004	13.5	0.1392	0.1392	0.0670	0.1753
17	01 November 2004	6.5	0.0670	0.0670	0.1753	0.1897
18	02 November 2004	17	0.1753	0.1753	0.1897	0.2598
19	03 November 2004	18.4	0.1897	0.1897	0.2598	0.2959
20	04 November	25.2	0.2598	0.2598	0.2959	0.2577

	2004					
21	05 November 2004	28.7	0.2959	0.2959	0.2577	0.0103
22	06 November 2004	25	0.2577	0.2577	0.0103	0.1619
23	07 November 2004	1	0.0103	0.0103	0.1619	0.1959
24	08 November 2004	15.7	0.1619	0.1619	0.1959	0.0412
25	09 November 2004	19	0.1959	0.1959	0.0412	0.7021
26	10 November 2004	4	0.0412	0.0412	0.7021	0.0639
27	11 November 2004	68.1	0.7021	0.7021	0.0639	0.3093
28	12 November 2004	6.2	0.0639	0.0639	0.3093	0.6495
29	13 November 2004	30	0.3093	0.3093	0.6495	0.2268
30	14 November 2004	63	0.6495	0.6495	0.2268	0.5495
31	15 November 2004	22	0.2268	0.2268	0.5495	0.0320
32	16 November 2004	53.3	0.5495	0.5495	0.0320	0.0062
33	17 November 2004	3.1	0.0320	0.0320	0.0062	0.0031
34	18 November 2004	0.6	0.0062	0.0062	0.0031	0.0258
35	19 November 2004	0.3	0.0031	0.0031	0.0258	0.1299
36	20 November 2004	2.5	0.0258	0.0258	0.1299	0.8557
37	21 November 2004	12.6	0.1299	0.1299	0.8557	0.0103
38	22 November 2004	83	0.8557	0.8557	0.0103	0.3093
39	23 November 2004	1	0.0103	0.0103	0.3093	0.0144
40	24 November 2004	30	0.3093	0.3093	0.0144	0.0010
41	25 November 2004	1.4	0.0144	0.0144	0.0010	0.0474
42	26 November 2004	0.1	0.0010	0.0010	0.0474	0.5320
43	27 November 2004	4.6	0.0474	0.0474	0.5320	0.0515

44	28 November 2004	51.6	0.5320	0.5320	0.0515	0.0021
45	29 November 2004	5	0.0515	0.0515	0.0021	0.0938
46	30 November 2004	0.2	0.0021	0.0021	0.0938	0.7938
47	01 Desember 2004	9.1	0.0938	0.0938	0.7938	0.0165
48	02 Desember 2004	77	0.7938	0.7938	0.0165	0.1278
49	03 Desember 2004	1.6	0.0165	0.0165	0.1278	0.0000
50	04 Desember 2004	12.4	0.1278	0.1278	0.0000	0.4753
51	05 Desember 2004	0	0.0000	0.0000	0.4753	0.0206
52	06 Desember 2004	46.1	0.4753	0.4753	0.0206	0.0000
53	07 Desember 2004	2	0.0206			
54	08 Desember 2004	0	0.0000			
55	09 Desember 2004	14.5	0.1495	0.1495	0.0072	0.0082
56	10 Desember 2004	0.7	0.0072	0.0072	0.0082	0.0000
57	11 Desember 2004	0.8	0.0082	0.0082	0.0000	0.0175
58	12 Desember 2004	0	0.0000	0.0000	0.0175	0.0124
59	13 Desember 2004	1.7	0.0175			
60	14 Desember 2004	1.2	0.0124			

Seperi yang terlihat pada Tabel 4.7 dari 60 baris data yang di gunakan, data di bagi menjadi skala 9:1 untuk data *training* dan data *testing*, dimana baris data 1-54 di gunakan untuk data *training* dan baris data 55-60 di gunakan untuk data *testing*. Nilai dari *input* (x) dan label (y) di dasarkan dengan bentuk pola data *sliding windows* dimana panjang *input* di dasarkan pada Panjang *timestep* dari inisialisasi nilai *hyperparameter* seperti yang terlihat pada Tabel 4.6 dari nilai yang

di gunakan, untuk perhitungan manual ini peneliti hanya menggunakan 2 nilai *timestep* yang berarti bahwa hanya terdapat 2 *input* untuk model yang di rancang yaitu *input* x_1 dan x_2 , dimana *input* x_1 merupakan nilai dari baris *feature* ke n , dan nilai *input* x_2 merupakan nilai dari baris $n + 1$, dan untuk nilai dari *label* y merupakan nilai dari baris *feature* ke $n + 2$ dan begitu seterusnya hingga batas dari data yang di gunakan dari masing-masing data *training* dan *testing*.

4.1.2.3.3. Inisialisasi Dimensi Data dan Parameter

Inisialisasi Dimensi pada setiap *parameter* sangat di perlukan untuk pembangunan blok dasar dari jaringan LSTM termasuk jenis jaringan syaraf tiruan yang lainnya. Dimensi dari semua *parameter* dari LSTM tergantung pada dimensi *unit* tersesembunyi. Untuk penjelasan lebih lengkapnya dapat di lihat pada Tabel 4.8 berikut.

Tabel 4.8. Dimensi Parameter Pada Jaringan LSTM

Parameter	Keterangan	Dimensi
<i>Units</i>	Jumlah <i>neuron unit</i> dalam <i>hidden layer</i>	(n_h)
<i>feature</i>	Jumlah <i>Feature</i>	(f)
n_x	Ukuran <i>input</i> (panjang <i>timestep</i>)	(n_x)
$C^{<t-1>}$	Dimensi <i>cell state</i> sebelumnya	(n_h, f)
$h^{<t-1>}$	Dimensi <i>output</i> sebelumnya	(n_h, f)
$x^{<t>}$	<i>Input</i> saat ini	(n_x, f)
$[x^{<t>}, h^{<t-1>}]$	Gabungan <i>output</i> sebelumnya dan <i>input</i> saat ini	($n_x + n_h, f$)
W_f, W_i, W_c, W_o	<i>Weight</i> untuk semua <i>gate</i>	($n_h, n_x + n_h$)
b_f, b_i, b_c, b_o	<i>Bias</i> untuk semua operasi	($n_h, 1$)

Seperti yang telihat pada Tabel 4.8 pada kolom Dimensi, Hampir setiap dimensi dari *parameter* di LSTM memiliki hubungan langsung maupun tidak langsung dengan *unit* tersembunyi (n_h) pada *layer* LSTM, dan penting untuk di pahami bahwa perkalian matrik dari 2 metrik berukuran $(a, b) * (b, c)$ maka menghasilkan *output* berukuran (a, c) . Setelah menganalisa dimensi komponen, tahap selanjutnya adalah menganalisa dimensi *output* pada setiap komponen. Untuk penjelasan lebih lengkapnya dapat di lihat pada Tabel 4.9 berikut.

Tabel 4.9. Dimensi *Output* Pada Jaringan LSTM

Output	Operasi	Dimensi
f_t	$\sigma(W_f * [x^{<t>} \ h^{<t-1>}] + b_f)$	$(n_h, n_x + n_h) * (n_x + n_h, m) + (n_h, 1) = (n_h, m)$
i_t	$\sigma(W_i * [x^{<t>} \ h^{<t-1>}] + b_i)$	$(n_h, n_x + n_h) * (n_x + n_h, m) + (n_h, 1) = (n_h, m)$
\tilde{C}_t	$\tanh(W_c * [x^{<t>} \ h^{<t-1>}] + b_c)$	$(n_h, n_x + n_h) * (n_x + n_h, m) + (n_h, 1) = (n_h, m)$
o_t	$\sigma(W_o * [x^{<t>} \ h^{<t-1>}] + b_o)$	$(n_h, n_x + n_h) * (n_x + n_h, m) + (n_h, 1) = (n_h, m)$
C_t	$f_t * C_{t-1} + i_t * \tilde{C}_t$	$(n_h, m) * (n_h, m) + (n_h, m) * (n_h, m) = (n_h, m)$
h_t	$o_t * \tanh(C_t)$	$(n_h, m) * (n_h, m) = (n_h, m)$

Berdasarkan Tabel 4.9 fungsi aktivasi *sigmoid* dan *tanh* di tetapkan sebagai elemen dari matrix sehingga dimensi *input* dan *output* tidak berubah. Setelah melakukan *preprocessing* data dari normalisasi, menentukan nilai *hyperparameter* dan membagi *input* data sampai dengan pola *sliding windows*

untuk model LSTM yang di gunakan. Tahap selanjutnya adalah menginisialisasi nilai awal dari *parameter forward* step seperti *bias* dan *weight*, *cell state* sebelumnya, dan *output* sebelumnya.

- Dimensi dari *Bias* seperti yang terlihat pada Tabel 4.8 berdimensi $(n_h, 1)$, di karenakan jumlah *unit* yang di gunakan adalah 1 maka bentuk dimensi menjadi $(1, 1)$, maka nilai *Bias* dari *forget*, *input*, *cell state*, *output* bisa di inisialisasikan dengan nilai nol seperti : [0], [0], [0], [0]
- Dimensi dari C_o seperti yang terlihat pada Tabel 4.8 berdimensi (n_h, f) , Dengan jumlah *unit* yang di gunakan adalah 1 dan jumlah *feature* adalah 1 maka bentuk dimensi menjadi $(1, 1)$, Untuk nilainya dikarenakan *Cell State* sebelumnya tidak ada maka nilai C_o di inisialisasi menjadi : [0]
- Dimensi dari h_0 seperti yang terlihat pada Tabel 4.8 berdimensi (n_h, f) , Dengan jumlah *unit* yang di gunakan adalah 1 dan jumlah *feature* adalah 1 maka bentuk dimensi menjadi $(1, 1)$, Untuk nilainya dikarenakan *Output* sebelumnya tidak ada maka nilai h_0 di inisialisasi menjadi : [0]
- Untuk nilai *Weight* seperti yang terlihat pada Tabel 4.8 berdimensi $(n_h, n_x + n_h)$, Dengan jumlah *unit* yang di gunakan adalah 1, Panjang *timestep* adalah 2 maka bentuk dimensi menjadi $(1, 2+1)$, maka nilai *Weight* untuk masing-masing *Weight forget*, *input*, *cell state*, *output* bisa di inisialisasikan dengan nilai acak atau dengan rumus *xavier Initialization* seperti berikut :

$$W = \left[\pm \frac{1}{\sqrt{(n_x + n_h)}}, \pm \frac{1}{\sqrt{(n_x + n_h)}}, \pm \frac{1}{\sqrt{(n_x + n_h)}} \right]$$

$$W_f = [0.5774 \ 0.5774 \ 0.5774]$$

$$W_i = [0.5774 \ 0.5774 \ 0.5774]$$

$$W_c = [0.5774 \ 0.5774 \ 0.5774]$$

$$W_o = [0.5774 \ 0.5774 \ 0.5774]$$

Untuk saat ini standar pendekatan terbaik untuk inisialisasi bobot untuk setiap lapisan jaringan syaraf tiruan yang menggunakan fungsi aktivasi *sigmoid* dan *tanh* adalah dengan menggunakan rumus *xavier Initialization*, berdasarkan riset ilmuan dari *Google DeepMind* pada tahun 2010 oleh (Glorot & Bagio, 2010).

Selanjutnya adalah menginisialisasi nilai awal dari *parameter backward step* seperti Δh_{n+1} , f_{n+1} , dan δC_{n+1} .

- Untuk Δh_{n+1} di inisialisasi menjadi 0 di karenakan tidak ada *timestep* selanjutnya.
- Untuk f_{n+1} sama seperti sebelumnya untuk nilai dari f_{n+1} di inisialisasi menjadi 0.
- Untuk δC_{n+1} sama seperti sebelumnya untuk nilai dari δC_{n+1} di inisialisasi menjadi 0.

4.1.2.3.4. Training Model LSTM

Setelah di ketahui nilai *weight* awal kemudian barulah di mulai proses *training*. Pada proses *training* algoritma pada model LSTM yang di gunakan *forward step* dan *backward step*. Berikut contoh perhitungan manual jaringan LSTM.

4.1.2.3.4.1. Perhitungan Epoch 1 Batch 1

Perhitungan di mulai dari *epoch* 1 dan *batch* 1 untuk satu kali iterasi yang dihitung secara numerik atau manual sebagai berikut.

4.1.2.3.4.1.1. Forward Timestep ke 1 Batch 1

Setelah menentukan *hyperparameter*, *parameter/nilai awal*, dan *dimensi selanjutnya* adalah menghitung forward step *timestep* 1 seperti berikut.

$$\begin{aligned}
 f_t &= \sigma(W_f * [x^{<t>} \ h^{<t-1>}]) + b_f \\
 &= \sigma((n_h, n_x + n_h) * (n_x + n_h, f) + (n_h, 1)) \\
 &= \sigma([0.5774 \ 0.5774 \ 0.5774] * [0.0052 \ 0.0206 \ 0] + [0]) \\
 &= \sigma(0.0149) \\
 &= \frac{1}{1 + e^{-0.0149}} \\
 &= 0.5037
 \end{aligned}$$

$$\begin{aligned}
 i_t &= \sigma(W_i * [x^{<t>} \ h^{<t-1>}]) + b_i \\
 &= \sigma((n_h, n_x + n_h) * (n_x + n_h, f) + (n_h, 1)) \\
 &= \sigma([0.5774 \ 0.5774 \ -0.5774] * [0.0052 \ 0.0206 \ 0] + [0]) \\
 &= \sigma(0.0149) \\
 &= \frac{1}{1 + e^{-0.0149}} \\
 &= 0.5037
 \end{aligned}$$

$$\begin{aligned}
 \tilde{c}_t &= \tanh(W_c * [x^{<t>} \ h^{<t-1>}]) + b_c \\
 &= \tanh((n_h, n_x + n_h) * (n_x + n_h, f) + (n_h, 1)) \\
 &= \tanh([0.5774 \ 0.5774 \ 0.5774] * [0.0052 \ 0.0206 \ 0] + [0]) \\
 &= \tanh(0.0149)
 \end{aligned}$$

$$= 2 * \left(\frac{1}{1 + e^{-2*0.0149}} \right) - 1$$

$$= 0.0149$$

$$o_t = \sigma(W_o * [x^{<t>} \ h^{<t-1>}]) + b_o$$

$$= \sigma((n_h, n_x + n_h) * (n_x + n_h, f) + (n_h, 1))$$

$$= \sigma([0.5774 \ 0.5774 \ 0.5774] * [0.0052 \ 0.0206 \ 0] + [0])$$

$$= \sigma(0.0149)$$

$$= \frac{1}{1 + e^{-0.0149}}$$

$$= 0.5037$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

$$= 0.5037 * 0 + 0.5037 * 0.0149$$

$$= 0.0075$$

$$h_t = o_t * \tanh(C_t)$$

$$= 0.5037 * \tanh(0.0075)$$

$$= 0.5037 * \left(2 * \left(\frac{1}{1 + e^{-2*0.0075}} \right) - 1 \right)$$

$$= 0.0037$$

4.1.2.3.4.1.2. Backward Timestep ke 1 Batch 1

Dikarenakan ukuran *batch* tidak lebih dari 1 maka setiap forward step selesai

dalam 1 *timestep* langsung di lakukan backward step.

$$\delta h_t = h_t - y^{<t>} + \Delta h_{t+1}$$

$$= 0.0037 - 1.0 + 0$$

$$= -0.9962$$

$$\delta C_t = \delta h_t * o_t * (1 - \tanh(C_t)^2) + \delta C_{t+1} * f_{t+1}$$

$$= -0.9962 * 0.5037 * (1 - \tanh(0.0075)^2) + 0 * 0$$

$$= -0.5018$$

$$\delta o_t = \delta h_t * \tanh(C_t) * o_t * (1 - o_t)$$

$$= -0.9962 * \tanh(0.0075) * 0.5037 * (1 - 0.5037)$$

$$= -0.0019$$

$$\widetilde{\delta C}_t = \delta C_t * i_t * \left(1 - \tilde{C}_t^2\right)$$

$$= -0.5018 * 0.5037 * (1 - 0.0149^2)$$

$$= -0.2527$$

$$\delta i_t = \delta C_t * \tilde{C}_t * i_t * (1 - i_t)$$

$$= -0.5018 * 0.0149 * 0.5037 * (1 - 0.5037)$$

$$= -0.0019$$

$$\delta f_t = \delta C_t * C_{t-1} * f_t * (1 - f_t)$$

$$= -0.5018 * 0 * 0.5037 * (1 - 0.5037)$$

$$= 0.0000$$

$$U_f = weight\ h\ dari\ W_f [x_1 \ x_2 \ h] [0.5774 \ 0.5774 \ 0.5774]$$

$$= 0.5774$$

$$U_i = weight\ h\ dari\ W_i [x_1 \ x_2 \ h] [0.5774 \ 0.5774 \ 0.5774]$$

$$= 0.5774$$

$$U_c = weight\ h\ dari\ W_c [x_1 \ x_2 \ h] [0.5774 \ 0.5774 \ 0.5774]$$

$$= 0.5774$$

$$U_o = weight\ h\ dari\ W_o [x_1 \ x_2 \ h] [0.5774 \ 0.5774 \ 0.5774]$$

$$= 0.5774$$

$$\Delta h_t = [U_f \ U_i \ U_c \ U_o] * [\delta f_t \ \delta i_t \ \widetilde{\delta C}_t \ \delta o_t]$$

$$= \begin{bmatrix} 0.5774 \\ 0.5774 \\ 0.5774 \\ 0.5774 \end{bmatrix} * \begin{bmatrix} 0.0000 \\ -0.0019 \\ -0.2527 \\ -0.0019 \end{bmatrix}$$

$$= -0.1481$$

4.1.2.3.4.1.3. Perbaharui Bias dan Weight Batch 1

Berdasarkan optimizer yang di gunakan adalah *Stochastic Gradient Descent* (SGD), maka perbaharuan *bias* dan *weight* di lakukan di setiap *timestep*.

$$\begin{aligned} W_f^{new} &= W_f^{old} - \gamma * \sum_{t=1}^n [\delta f_t] * [x^{<t>} \quad h^{<t-1>}] \\ &= W_f^{old} - 0.1 * ([0.0000] * [0.0052 \quad 0.0206 \quad 0.0000]) \\ &= [0.5774 \quad 0.5774 \quad 0.5774] - 0.1 * [0.0000 \quad 0.0000 \quad 0.0000] \\ &= [0.5774 \quad 0.5774 \quad 0.5774] \end{aligned}$$

$$\begin{aligned} b_f^{new} &= b_f^{old} - \gamma * \sum_{t=1}^n [\delta f_t] \\ &= 0 - 0.1 * ([0.0000]) \\ &= 0.0000 \\ \\ W_i^{new} &= W_i^{old} - \gamma * \sum_{t=1}^n [\delta i_t] * [x^{<t>} \quad h^{<t-1>}] \\ &= W_i^{old} - 0.1 * ([-0.0019] * [0.0052 \quad 0.0206 \quad 0.0000]) \\ &= [0.5774 \quad 0.5774 \quad 0.5774] - 0.1 * [-0.00001 \quad -0.00004 \quad 0.000] \\ &= [0.577401 \quad 0.577404 \quad 0.5774] \end{aligned}$$

$$\begin{aligned} b_i^{new} &= b_i^{old} - \gamma * \sum_{t=1}^n [\delta i_t] \\ &= 0 - 0.1 * ([-0.0019]) \end{aligned}$$

$$= 0.0002$$

$$\begin{aligned} W_c^{new} &= W_c^{old} - \gamma * \sum_{t=1}^n [\bar{\delta}C_t] * [x^{} \ h^{}] \\ &= W_c^{old} - 0.1 * ([-0.2527] * [0.0052 \ 0.0206 \ 0.0000]) \\ &= [0.5774 \ 0.5774 \ 0.5774] - 0.1 * [-0.0013 \ -0.0052 \ 0.0000] \\ &= [0.57753 \ 0.57792 \ 0.5774] \end{aligned}$$

$$\begin{aligned} b_c^{new} &= b_c^{old} - \gamma * \sum_{t=1}^n [\bar{\delta}C_t] \\ &= 0 - 0.1 * ([-0.2527]) \\ &= 0.0253 \end{aligned}$$

$$\begin{aligned} W_o^{new} &= W_o^{old} - \gamma * \sum_{t=1}^n [\delta o_t] * [x^{} \ h^{}] \\ &= W_o^{old} - 0.1 * ([-0.0019] * [0.0052 \ 0.0206 \ 0.0000]) \\ &= [0.5774 \ 0.5774 \ 0.5774] - 0.1 * [-0.00001 \ -0.00004 \ 0.000] \\ &= [0.577401 \ 0.577404 \ 0.5774] \end{aligned}$$

$$\begin{aligned} b_o^{new} &= b_o^{old} - \gamma * \sum_{t=1}^n [\delta o_t] \\ &= 0 - 0.1 * ([-0.0019]) \\ &= 0.0002 \end{aligned}$$

4.1.2.3.4.1.4. Hitung Akurasi Batch 1

Nilai Akurasi di hitung menggunakan rumus MSE dari perhitungan kereluruhan timeteps pada *batch 1* seperti berikut.

$$MSE = \frac{\sum_{t=1}^n (y_t - h_t)^2}{n}$$

$$= \frac{(1.0000 - 0.0037)^2}{1}$$

$$= 0.992463094$$

Berdasarkan hasil nilai *error* dari data *batch* 1 di dapat nilai *error* sebesar 0.992463094. di mana nilai *error* 0.992463094 memiliki arti bahwa prediksi *feature* (*rr*) memiliki tingkat ketidakakuratan lebih kurang sebesar 0.992463094 dalam memprediksi curah hujan dari data curah hujan yang di normalisasi minmaxscaller.

4.1.2.3.4.2. Perhitungan Epoch 1 Batch 2-52

Perhitungan *batch* 2-52 sama seperti sebelumnya, hanya saja beberapa *parameter* seperti *bias* dan *weight* di perbaharui setelah menghitung *Stochastic Gradient Descent* (SGD) dari perhitungan *batch* sebelumnya.

4.1.2.3.4.2.1. Forward Epoch 1 Batch 2-52

Forward batch 2-52 berikut hasil perhitungan *forward* pada *batch* 2-52 seperti yang terlihat pada Tabel 4.10 berikut.

Tabel 4.10. Hasil Forward Epoch 1 Batch 2-52

<i>batch</i>	<i>time step</i>	<i>Forward</i>					
		<i>Gate</i>				<i>c_t</i>	<i>h_t</i>
		<i>f_t</i>	<i>i_t</i>	<i>̃c_t</i>	<i>o_t</i>		
2	1	0.6432	0.6432	0.5477	0.6432	0.3523	0.2177
3	1	0.7070	0.7078	0.7254	0.7078	0.5134	0.3345
4	1	0.6597	0.6615	0.6108	0.6618	0.4041	0.2537
5	1	0.6213	0.6230	0.4924	0.6232	0.3068	0.1854
6	1	0.5490	0.5502	0.2301	0.5503	0.1266	0.0693
7	1	0.5401	0.5414	0.1992	0.5416	0.1079	0.0582
8	1	0.5282	0.5294	0.1508	0.5296	0.0798	0.0422
9	1	0.5031	0.5042	0.0492	0.5043	0.0248	0.0125
10	1	0.5225	0.5237	0.1310	0.5238	0.0686	0.0359

11	1	0.5352	0.5365	0.1824	0.5366	0.0978	0.0523
12	1	0.5528	0.5543	0.2575	0.5545	0.1427	0.0786
13	1	0.5617	0.5633	0.2928	0.5635	0.1649	0.0921
14	1	0.5847	0.5868	0.3879	0.5870	0.2276	0.1313
15	1	0.5829	0.5849	0.3801	0.5851	0.2223	0.1280
16	1	0.5297	0.5314	0.1775	0.5316	0.0943	0.0500
17	1	0.5349	0.5368	0.2017	0.5369	0.1083	0.0579
18	1	0.5525	0.5545	0.2731	0.5547	0.1514	0.0834
19	1	0.5645	0.5667	0.3234	0.5669	0.1833	0.1028
20	1	0.5795	0.5820	0.3834	0.5823	0.2231	0.1278
21	1	0.5792	0.5819	0.3856	0.5821	0.2244	0.1285
22	1	0.5386	0.5409	0.2294	0.5411	0.1241	0.0668
23	1	0.5248	0.5272	0.1788	0.5274	0.0943	0.0496
24	1	0.5515	0.5540	0.2860	0.5542	0.1584	0.0871
25	1	0.5342	0.5366	0.2174	0.5368	0.1166	0.0623
26	1	0.6057	0.6090	0.4936	0.6092	0.3006	0.1778
27	1	0.6088	0.6118	0.4995	0.6120	0.3056	0.1814
28	1	0.5537	0.5567	0.3098	0.5569	0.1725	0.0951
29	1	0.6350	0.6389	0.5956	0.6392	0.3805	0.2321
30	1	0.6239	0.6278	0.5619	0.6280	0.3527	0.2128
31	1	0.6102	0.6149	0.5281	0.6152	0.3247	0.1930
32	1	0.5832	0.5874	0.4351	0.5877	0.2555	0.1470
33	1	0.5055	0.5090	0.1361	0.5092	0.0693	0.0352
34	1	0.5013	0.5047	0.1184	0.5049	0.0598	0.0301
35	1	0.5042	0.5076	0.1298	0.5078	0.0659	0.0334
36	1	0.5225	0.5261	0.2058	0.5263	0.1082	0.0567
37	1	0.6385	0.6432	0.6218	0.6435	0.3999	0.2445
38	1	0.6225	0.6267	0.5706	0.6269	0.3576	0.2151
39	1	0.5460	0.5499	0.3134	0.5501	0.1723	0.0939
40	1	0.5466	0.5506	0.3144	0.5508	0.1731	0.0944
41	1	0.5022	0.5058	0.1376	0.5059	0.0696	0.0351
42	1	0.5070	0.5105	0.1570	0.5107	0.0802	0.0409
43	1	0.5829	0.5869	0.4520	0.5871	0.2653	0.1522
44	1	0.5834	0.5876	0.4526	0.5878	0.2660	0.1528
45	1	0.5077	0.5112	0.1659	0.5113	0.0848	0.0433
46	1	0.5138	0.5173	0.1914	0.5175	0.0990	0.0511
47	1	0.6254	0.6296	0.5946	0.6298	0.3744	0.2253
48	1	0.6149	0.6190	0.5604	0.6192	0.3469	0.2066
49	1	0.5208	0.5242	0.2305	0.5243	0.1208	0.0630
50	1	0.5184	0.5218	0.2199	0.5220	0.1147	0.0596
51	1	0.5682	0.5718	0.4133	0.5719	0.2364	0.1327

52	1	0.5711	0.5749	0.4223	0.5751	0.2428	0.1369
----	---	--------	--------	--------	--------	--------	--------

Pada Tabel 4.10 memperlihatkan hasil forward step LSTM pada *epoch* 1 dari setiap *timestep* di dalam *batch* 2-52 dengan ukuran *batch* tidak lebih dari 1 *timestep*.

4.1.2.3.4.2.2. Backward Epoch 1 Batch 2-52

Backward batch 2-52 berikut hasil perhitungan *backward* pada *batch* 2-52 seperti yang terlihat pada Tabel 4.11 berikut.

Tabel 4.11. Hasil Backward Epoch 1 Batch 2-52

<i>batch</i>	time step	<i>Backward</i>							Δh_t	
		δh_t	δC_t	<i>Gate</i>						
				δo_t	$\widetilde{\delta C}_t$	δi_t	δf_t			
2	1	- 0.3081	- 0.1755	- 0.0239	- 0.0790	- 0.0221	0.0000	- 0.0722		
3	1	- 0.2861	- 0.1573	- 0.0280	- 0.0528	- 0.0236	0.0000	- 0.0602		
4	1	0.0166	0.0094	0.0014	0.0039	0.0013	0.0000	0.0038		
5	1	0.0823	0.0467	0.0057	0.0221	0.0054	0.0000	0.0192		
6	1	- 0.1060	- 0.0574	- 0.0033	- 0.0299	- 0.0033	0.0000	- 0.0211		
7	1	0.0376	0.0201	0.0010	0.0105	0.0010	0.0000	0.0072		
8	1	0.0411	0.0217	0.0008	0.0112	0.0008	0.0000	0.0074		
9	1	- 0.1421	- 0.0716	- 0.0009	- 0.0360	- 0.0009	0.0000	- 0.0218		
10	1	- 0.0538	- 0.0281	- 0.0009	- 0.0144	- 0.0009	0.0000	- 0.0094		
11	1	- 0.2250	- 0.1196	- 0.0055	- 0.0620	- 0.0054	0.0000	- 0.0421		
12	1	- 0.0740	- 0.0402	- 0.0026	- 0.0208	- 0.0026	0.0000	- 0.0150		
13	1	- 0.3481	- 0.1909	- 0.0140	- 0.0983	- 0.0137	0.0000	- 0.0728		
14	1	- 0.0078	- 0.0044	- 0.0004	- 0.0022	- 0.0004	0.0000	- 0.0017		
15	1	0.0609	0.0340	0.0032	0.0170	0.0031	0.0000	0.0135		

16	1	- 0.1253	- 0.0660	- 0.0029	- 0.0340	- 0.0029	0.0000	- 0.0230
17	1	- 0.1318	- 0.0699	- 0.0035	- 0.0360	- 0.0035	0.0000	- 0.0249
18	1	- 0.1764	- 0.0957	- 0.0065	- 0.0491	- 0.0065	0.0000	- 0.0358
19	1	- 0.1931	- 0.1059	- 0.0086	- 0.0537	- 0.0084	0.0000	- 0.0408
20	1	- 0.1299	- 0.0720	- 0.0069	- 0.0358	- 0.0067	0.0000	- 0.0285
21	1	0.1182	0.0654	0.0063	0.0324	0.0061	0.0000	0.0259
22	1	- 0.0951	- 0.0507	- 0.0029	- 0.0260	- 0.0029	0.0000	- 0.0183
23	1	- 0.1463	- 0.0765	- 0.0034	- 0.0390	- 0.0034	0.0000	- 0.0265
24	1	0.0458	0.0248	0.0018	0.0126	0.0018	0.0000	0.0093
25	1	- 0.6397	- 0.3388	- 0.0185	- 0.1732	- 0.0183	0.0000	- 0.1212
26	1	0.1139	0.0635	0.0079	0.0292	0.0075	0.0000	0.0258
27	1	- 0.1279	- 0.0714	- 0.0090	- 0.0328	- 0.0085	0.0000	- 0.0290
28	1	- 0.5544	- 0.2997	- 0.0234	- 0.1508	- 0.0229	0.0000	- 0.1138
29	1	0.0053	0.0030	0.0004	0.0012	0.0004	0.0000	0.0012
30	1	- 0.3367	- 0.1872	- 0.0267	- 0.0804	- 0.0246	0.0000	- 0.0760
31	1	0.1610	0.0893	0.0120	0.0396	0.0112	0.0000	0.0362
32	1	0.1408	0.0776	0.0085	0.0369	0.0082	0.0000	0.0310
33	1	0.0321	0.0163	0.0006	0.0081	0.0006	0.0000	0.0053
34	1	0.0044	0.0022	0.0001	0.0011	0.0001	0.0000	0.0007
35	1	- 0.0965	- 0.0488	- 0.0016	- 0.0243	- 0.0016	0.0000	- 0.0159
36	1	- 0.7989	- 0.4156	- 0.0215	- 0.2094	- 0.0213	0.0000	- 0.1456
37	1	0.2342	0.1289	0.0204	0.0509	0.0184	0.0000	0.0518
38	1	- 0.0942	- 0.0521	- 0.0076	- 0.0220	- 0.0070	0.0000	- 0.0211
39	1	0.0794	0.0424	0.0034	0.0210	0.0033	0.0000	0.0160
40	1	0.0934	0.0499	0.0040	0.0248	0.0039	0.0000	0.0188
41	1	- 0.0123	- 0.0062	- 0.0002	- 0.0031	- 0.0002	0.0000	- 0.0020

42	1	- 0.4911	- 0.2492	- 0.0098	- 0.1241	- 0.0098	0.0000	- 0.0830
43	1	0.1007	0.0551	0.0063	0.0257	0.0060	0.0000	0.0220
44	1	0.1507	0.0826	0.0095	0.0386	0.0091	0.0000	0.0330
45	1	- 0.0506	- 0.0257	- 0.0011	- 0.0128	- 0.0011	0.0000	- 0.0086
46	1	- 0.7428	- 0.3806	- 0.0183	- 0.1897	- 0.0182	0.0000	- 0.1306
47	1	0.2089	0.1147	0.0174	0.0467	0.0159	0.0000	0.0462
48	1	0.0787	0.0433	0.0062	0.0184	0.0057	0.0000	0.0175
49	1	0.0630	0.0326	0.0019	0.0162	0.0019	0.0000	0.0115
50	1	- 0.4156	- 0.2141	- 0.0118	- 0.1063	- 0.0117	0.0000	- 0.0750
51	1	0.1121	0.0607	0.0064	0.0288	0.0061	0.0000	0.0238
52	1	0.1369	0.0743	0.0080	0.0351	0.0077	0.0000	0.0293

Pada Tabel 4.11 memperlihatkan hasil backward step LSTM pada *epoch* 1 dari setiap *timestep* di dalam *batch* 2-52 dengan ukuran *batch* tidak lebih dari 1 *timestep*.

4.1.2.3.4.2.3. Hitung Error Epoch 1 Batch 2-52

Nilai *Error* di hitung menggunakan rumus MSE dari perhitungan kereluruhan timeteps pada *batch* 2-52 seperti pada Tabel 4.12 berikut.

Tabel 4.12. Nilai Error Epoch 1 Batch 2-52

Batch	y_t	h_t	MSE
2	0.525773	0.217691	0.094914
3	0.620619	0.334509	0.081859
4	0.237113	0.253746	0.000277
5	0.103093	0.185386	0.006772
6	0.175258	0.069303	0.011226
7	0.020619	0.058186	0.001411
8	0.001031	0.042180	0.001693
9	0.154639	0.012518	0.020198
10	0.089691	0.035888	0.002895
11	0.277320	0.052340	0.050616

12	0.152577	0.078612	0.005471
13	0.440206	0.092096	0.121181
14	0.139175	0.131349	0.000061
15	0.067010	0.127959	0.003715
16	0.175258	0.049988	0.015693
17	0.189691	0.057914	0.017365
18	0.259794	0.083358	0.031130
19	0.295876	0.102768	0.037291
20	0.257732	0.127808	0.016880
21	0.010309	0.128495	0.013968
22	0.161856	0.066793	0.009037
23	0.195876	0.049575	0.021404
24	0.041237	0.087081	0.002102
25	0.702062	0.062329	0.409258
26	0.063918	0.177787	0.012966
27	0.309278	0.181410	0.016350
28	0.649485	0.095103	0.307339
29	0.226804	0.232145	0.000029
30	0.549485	0.212775	0.113373
31	0.031959	0.192999	0.025934
32	0.006186	0.146992	0.019826
33	0.003093	0.035225	0.001033
34	0.025773	0.030139	0.000019
35	0.129897	0.033411	0.009310
36	0.855670	0.056741	0.638287
37	0.010309	0.244476	0.054834
38	0.309278	0.215074	0.008875
39	0.014433	0.093857	0.006308
40	0.001031	0.094395	0.008717
41	0.047423	0.035144	0.000151
42	0.531959	0.040860	0.241178
43	0.051546	0.152215	0.010134
44	0.002062	0.152757	0.022709
45	0.093814	0.043252	0.002557
46	0.793814	0.051054	0.551693
47	0.016495	0.225346	0.043619
48	0.127835	0.206567	0.006199
49	0.000000	0.063048	0.003975
50	0.475258	0.059627	0.172749
51	0.020619	0.132724	0.012568
52	0.000000	0.136923	0.018748

Berdasarkan Tabel 4.12 hasil nilai *error* MSE dari *epoch* 1 di dapat nilai *error* seperti yang terlihat pada kolom MSE memiliki arti bahwa prediksi *feature* (*rr*) setiap *batch* memiliki tingkat ketidakakuratan lebih kurang seperti yang terlihat pada kolom tersebut dalam memprediksi curah hujan dari data curah hujan yang di normalisasi minmaxscaller.

4.1.2.3.4.2.4. Hitung Total Nilai Error Epoch 1

Untuk mengetahui total *error* dari 1 kali *epoch* diperlukan untuk mencari nilai rata-rata dari total semua nilai *error* dari tiap *batch*.

$$\sum MSE = \frac{0.992463 + 0.094914 + 0.081859 + 0.000277 + 0.006772 + \\ 0.011226 + 0.001411 + 0.001693 + 0.020198 + 0.002895 + \\ 0.050616 + 0.005471 + 0.121181 + 0.000061 + 0.003715 + \\ 0.015693 + 0.017365 + 0.031130 + 0.037291 + 0.016880 + \\ 0.013968 + 0.009037 + 0.021404 + 0.002102 + 0.409258 + \\ 0.012966 + 0.016350 + 0.307339 + 0.000029 + 0.113373 + \\ 0.025934 + 0.019826 + 0.001033 + 0.000019 + 0.009310 + \\ 0.638287 + 0.054834 + 0.008875 + 0.006308 + 0.008717 + \\ 0.000151 + 0.241178 + 0.010134 + 0.022709 + 0.002557 + \\ 0.551693 + 0.043619 + 0.006199 + 0.003975 + 0.172749 + \\ 0.012568 + 0.018748 +}{52} \\ = 0.082276130$$

Berdasarkan hasil total nilai *error* MSE dari data *epoch* 1 di dapat nilai *error* sebesar 0.082276130. Dimana nilai *error* 0.082276130 memiliki arti bahwa prediksi *feature* (*rr*) memiliki tingkat ketidakakuratan lebih kurang sebesar 0.082276130 dalam memprediksi curah hujan dari data curah hujan yang di normalisasi minmaxscaller.

4.1.2.3.4.3. Perhitungan Epoch 2-50

Pada perhitungan *Epoch* 2-50 nilai *error* di hitung menggunakan total dari rumus MSE seperti pada Tabel 4.13 berikut.

Tabel 4.13. Nilai *Error Epoch* 2-50

<i>Epoch</i>	$\sum MSE$
2	0.075683
3	0.072499
4	0.070754
5	0.069697
6	0.069002
7	0.068510
8	0.068140
9	0.067844
10	0.067598
11	0.067386
12	0.067198
13	0.067029
14	0.066873
15	0.066729
16	0.066594
17	0.066467
18	0.066348
19	0.066235
20	0.066127
21	0.066025
22	0.065927
23	0.065834
24	0.065745
25	0.065660
26	0.065578
27	0.065500
28	0.065425
29	0.065352
30	0.065283
31	0.065216
32	0.065151
33	0.065089

34	0.065029
35	0.064971
36	0.064915
37	0.064861
38	0.064808
39	0.064758
40	0.064709
41	0.064661
42	0.064615
43	0.064570
44	0.064527
45	0.064485
46	0.064444
47	0.064404
48	0.064366
49	0.064328
50	0.064291

Berdasarkan Tabel 4.13 hasil nilai *error* MSE dari *epoch* 2-52 di dapat nilai *error* seperti yang terlihat pada kolom $\sum MSE$, dimana nilai *error* selalu berkurang seiring dengan perulangan *epoch* selama 50 kali. memiliki arti bahwa prediksi *feature* (rr) setiap perulangan *epoch* yang di lakukan memiliki tingkat ketidakakuratan terus berkurang seperti yang terlihat pada kolom tersebut dalam memprediksi curah hujan dari data curah hujan yang di normalisasi minmaxscaller.

4.1.2.3.5. Testing Model LSTM

Setelah melakukan *Training* Model LSTM maka di ketahui nilai *bias* dan *weight* optimal dari 50 *epoch* seperti pada Tabel 4.14 berikut.

Tabel 4.14. Bias dan Weight dari Learned Model

Parameters	Forget Gate	Input Gate	Memory Gate	Output Gate
<i>bias</i>	[0.0000]	[0.0257]	[0.8835]	[-0.0236]
<i>weight</i>	[0.5774]	[0.4437]	[0.3817]	[0.4342]
	0.5774	0.3524	0.3405	0.3135
	0.5774]	0.5774]	0.5774	0.5574]

Hasil optimal dari *bias* dan *weight* dari learned model di gunakan untuk melakukan pengujian dari data *testing*. Pada proses *testing* algoritma pada model LSTM yang di gunakan hanya *forward step* sebanyak data yang di *testing* seperti yang terlihat pada Tabel 4.15.

Tabel 4.15. Hasil Testing Model

<i>t</i>	<i>y_t</i>	<i>h_t</i>	MSE
1	0.0082	0.1878	0.032252586
2	0.0000	0.1716	0.029432851
3	0.0175	0.1709	0.023530073
4	0.0124	0.1716	0.025350684

Pada Tabel 4.15 untuk nilai *error* sama seperti pada tahap *training*, peneliti hanya menggunakan rumus MSE untuk perhitungan nilai *error*.

$$\begin{aligned} \sum MSE &= \frac{0.032252586 + 0.029432851 + 0.023530073 + 0.025350684}{4} \\ &= 0.027641549 \end{aligned}$$

Berdasarkan hasil nilai *error* MSE dari proses *testing* di dapat nilai *error* sebesar 0.027641549. Dimana nilai *error* 0.027641549 memiliki arti bahwa prediksi *feature* (*rr*) pada saat *testing* memiliki tingkat ketidakakuratan lebih kurang sebesar 0.027641549 dalam memprediksi *feature/variabel* (*rr*) curah hujan. Dapat dikatakan bahwa Proyeksi atau perhitungan manual LSTM yang dilakukan peneliti dengan hanya menggunakan 1 *feature/variabel* yaitu (*rr*) curah hujan, dengan beberapa nilai *hyperparameter* lainnya seperti yang terlihat pada Tabel 4.6, dan menggunakan *deep Learning* dengan metode *Long Short-Term*

Memory dengan algoritma *backpropagation* masih jauh dari nilai keakuratan yang di harapkan.

4.1.3. Analisa Sistem

Analisa ini dilakukan untuk mengetahui apa saja yang dibutuhkan dalam perancangan sistem dengan maksud untuk mengidentifikasi dan mengevaluasi permasalahan-permasalahan, dan hambatan yang muncul. Sehingga menghasilkan sebuah sistem yang efektif dan efisien. Sistem yang di kembangkan berbasis *web* dengan Bahasa Pemrograman *Python* dan *database MySQL*.

Sistem yang di kembangkan Bernama “Sistem Proyeksi Curah Hujan Padang Pariaman”. Sistem ini di rancang untuk melakukan pembelajaran mendalam dengan mengalkulasi dari kumpulan Data Klimatologi hingga menghasilkan sebuah prediksi sesuai yang di harapkan.

Data yang di dapat dari *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* masih di dokumentasi dalam bentuk *format excel* yang nantinya semua data tersebut di masukkan ke dalam *database MySQL* yang di gunakan untuk sistem dalam melakukan pembelajaran mendalam.

Keuntungan dari Sistem ini adalah menghilangkan kebiasaan melakukan pemodelan prediksi dengan penggunaan jumlah *parameter*, asumsi-asumsi matematis, dan *formulasi* persamaan yang cenderung rumit. Karena untuk menghasilkan model dengan prediksi yang tepat di butuhkah banyak *parameter* yang mustahil di lakukan secara manual.

4.1.3.1. Analisa Desain Database

Database adalah kumpulan dari beberapa tabel dependen maupun independen satu sama lain dengan tabel yang lainnya. Tabel-tabel yang dependen dengan tabel lainnya terhubung berdasarkan primary key yang ada. Seperti yang di jabarkan sebagai berikut :

4.1.3.1.1. Tabel Users

Merupakan tabel yang di gunakan untuk menampung data penggunaan untuk proses authentikasi masuk ke sistem dengan rancangan struktur tabel seperti pada

Tabel 4.16 berikut:

- Nama *Database* : proyeksi
- Nama Tabel : *auth_user*

Tabel 4.16. Tabel *auth_user*

No	Field Name	Type	Width	Description
1	<i>id</i>	Integer	11	Primary Key
2	<i>password</i>	Varchar	128	Password <i>User</i>
3	<i>last_login</i>	Datetime	-	<i>Login Terakhir User</i>
4	<i>is_superuser</i>	Bool	2	Apakah Super <i>User</i>
5	<i>username</i>	Varchar	150	Panggilan <i>User</i>
6	<i>last_name</i>	Varchar	150	Nama Terakhir <i>User</i>
7	<i>email</i>	Varchar	254	<i>Email User</i>
8	<i>is_staff</i>	Bool	2	Apakah Staff
9	<i>is_active</i>	Bool	2	Apakah Aktif
10	<i>date_joined</i>	Datetime	-	Waktu Daftar ke Sistem

11	first_name	Varchar	150	Nama Depan <i>User</i>
----	------------	---------	-----	------------------------

Pada Tabel 4.16 telihat seperti pola table authentikasi yang kerap digunakan pada sistem pada umumnya, dimana tabel tersebut memiliki, password, *username*, *email*, dan *date_joined*, sebagai inti dari kolom informasi authentikasi, dan beberapa kolom lainnya sebagai pendukung/fitur tambahan.

4.1.3.1.2. *Tabel Session Middleware*

Merupakan tabel yang di gunakan untuk menampung data sesi penggunaan yang telah berhasil melakukan authentikasi ke dalam sistem dengan rancangan struktur tabel seperti pada Tabel 4.17 berikut:

- Nama *Database* : proyeksi
- Nama Tabel : django_session

Tabel 4.17. Tabel *django_session*

No	Field Name	Type	Width	Description
1	session_key	Varchar	40	Primary Key
2	session_data	Text	-	Data Session <i>User</i>
3	expire_date	Datetime	-	Waktu Kadaluarsa Session <i>User</i>

Pada Tabel 4.17 memiliki beberapa kolom untuk menyimpan informasi ketika *admin* dalam sesi *login* ke dalam sistem, dimana tabel tersebut memiliki kolom session_data untuk menyimpan data sesi *login admin*, dan expire_date menyimpan informasi waktu kadaluarsa *admin* dalam sesi *login*.

4.1.3.1.3. Tabel Klimatologi

Merupakan tabel yang di gunakan untuk menampung Data Klimatologi yang nantinya di gunakan dalam pembelajaran mesin dalam sistem dengan rancangan struktur tabel seperti pada Tabel 4.18 berikut :

- Nama *Database* : proyeksi
- Nama Tabel : proyeksi_klimatologi

Tabel 4.18. Tabel *proyeksi_klimatologi*

No	Field Name	Type	Width	Description
1	id	Integer	11	Primary Key
2	tanggal	Date	-	Tanggal Observasi
3	tn	Double	4	Temperatur Minimum
4	tx	Double	4	Temperatur Maksimum
5	tavg	Double	4	Temperatur Rata-rata
6	rh_avg	Double	4	Kelembapan Rata-rata
7	rr	Double	4	Curah Hujan
8	ff_x	Double	4	Lama Penyinaran Matahari
9	ddd_x	Double	4	Kecepatan Angin Maksimum
10	ff_avg	Double	4	Kecepatan Angin Rata-rata
11	ddd_car	Double	4	Arah Angin Terbanyak

Pada Tabel 4.18 merupakan tabel yang menyimpan dataset klimatologi yang di dapat dari *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman* dari tahun 1985 sampai tahun 2021, hanya saja untuk batasan masalah pada penelitian ini kolom data yang di gunakan hanyalah kolom *rr*.

4.1.3.1.4. Tabel Proyeksi Riwayat

Merupakan tabel yang di gunakan untuk menampung hasil proyeksi yang nantinya dapat di gunakan untuk menjad perbandingan pada Proyeksi lainnya dengan rancangan struktur tabel seperti pada Tabel 4.18 berikut :

- Nama *Database* : proyeksi
- Nama Tabel : proyeksi_riwayat

Tabel 4.19. Tabel *proyeksi_riwayat*

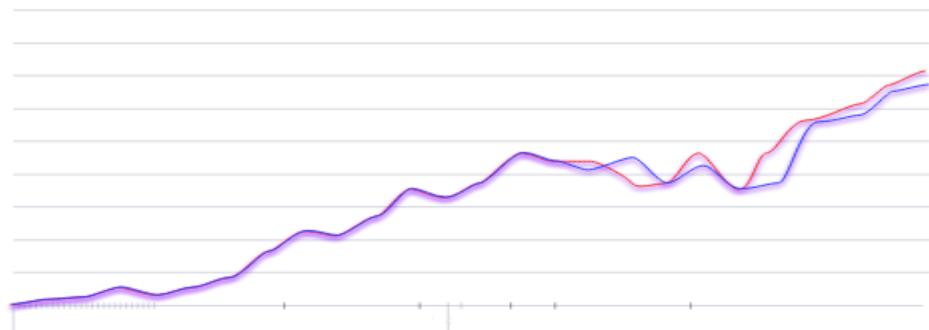
No	Field Name	Type	Width	Description
1	id	Integer	11	Primary Key
2	<i>timestep</i>	Integer	11	Panjang <i>Sequence/Timestep</i>
3	max_batch_size	Integer	11	Ukuran <i>Batch</i> Maksimal
4	max_epoch	Integer	11	Maksimal <i>Epoch</i>
5	layer_size	Integer	11	Jumlah <i>Hidden Layer</i>
6	unit_size	Integer	11	Jumlah <i>Unit</i> Setiap <i>Layer</i>
7	dropout	Double	8	Probabilitas Dropout
8	<i>Learning_rate</i>	Double	8	Nilai <i>Learning Rate</i>
9	row_start	Integer	11	ID Awal Baris Data
10	row_end	Integer	11	ID Akhir Baris Data
11	num_predict	Integer	11	Jumlah Prediksi ke Depan
12	feature_training	Varchar	64	<i>Variabel</i> dalam training
13	feature_predict	Varchar	8	<i>Variabel</i> untuk di proyeksi
14	loss	Double	8	Rata-rata nilai error proyeksi
15	valueset	Json	-	Catatan <i>Output</i>

16	hdf	Blob	-	H5 tempat bobot dan <i>bias</i>
----	-----	------	---	---------------------------------

Pada Tabel 4.19 berperan penting dalam menyimpan Riwayat setiap Proyeksi di lakukan, semua nilai *hyperparameter* dan *parameter* yang diperlukan di simpan ke dalam tabel tersebut ketika selesai melakukan Proyeksi, guna agar dapat di buka Kembali Proyeksi yang telah di lakukan untuk menjadi pembanding dari Proyeksi selanjutnya.

4.1.3.2. Analisa Hasil *Output* Pengujian

Output dari hasil perhitungan model LSTM adalah bentuk tabel dan grafik statistik yang berisi hasil akurasi dari data aktual dengan data prediksi, serta hasil prediksi hari kedepanya seperti yang terlihat pada Gambar 4.3 berikut.



Gambar 4.3. Contoh Sketsa Grafik *Output* Hasil Pengujian

Pada Gambar 4.3 Hasil dari algoritma LSTM di tampilkan dari proses tersebut guna mengetahui akurasi hasil prediksi, bentuk hasil prediksi berbentuk grafik garis dimana terdapat 2 garis yaitu garis hasil proyeksi, garis data sebenarnya, dan garis prediksi masa depan.

4.2. Perancangan

Perancangan merupakan proses di mana suatu sistem di gambarkan sesuai kebutuhan pada fase analisis. Tahap yang di lakukan dalam perancangan sesuai

dengan arsitektur sistem yang di perlukan agar setiap agar setiap sistem yang dibangun memiliki konstruksi yang baik, guna mempermudah untuk melakukan pengembangan apabila di perlukan nantinya di lain waktu.

4.2.1. Perancangan Model

Pada perancangan model dilakukan pengumpulan beberapa fakta kebutuhan yang mendukung dalam arsitektur rancangan sistem. Dengan menggunakan *Unified Modelling Language* (UML) sebagai *tools* dalam memaparkan alur arsitektur dari sistem yang di rancang. Adapun UML yang digunakan adalah sebagai berikut :

4.2.1.1. Use case Diagram

Use case Diagram menggambarkan bagaimana pengguna atau aktor menggunakan atau memanfaatkan sistem. Pada *use case* diagram mendeskripsikan interaksi dari beberapa aktor dengan sistem yang dirancang.

4.2.1.1.1. Definisi Aktor

Definisi aktor adalah aktivitas yang bisa dilakukan oleh para pengguna dalam menggunakan sistem. Definisinya dapat dijelaskan pada Tabel 4.20 berikut :

Tabel 4.20. Definisi Aktor

No	Aktor	Deskripsi
1	<i>Admin</i>	Aktor <i>Admin</i> melakukan operasi dan pengelolaan terhadap sistem. Pengelolaan tersebut di lakukan dengan akses secara penuh terhadap sistem, baik berupa <i>Create (tambah data)</i> , <i>Read (daca data)</i> <i>Update (edit data)</i> dan <i>Delete (hapus data)</i> data yang berhubungan dengan sistem.

Pada Gambar 4.20 menjelaskan seluruh aktor yang terlibat dalam sistem di jelaskan, tentang hak akses dan fitur yang dapat di gunakan oleh aktor tersebut di dalam sistem yang di rancang.

4.2.1.1.2. Definisi Use case

Definisi *use case* adalah kegiatan yang dapat di lakukan oleh aktor di dalam sebuah sistem. Definisinya dapat dijelaskan pada Tabel 4.21 berikut :

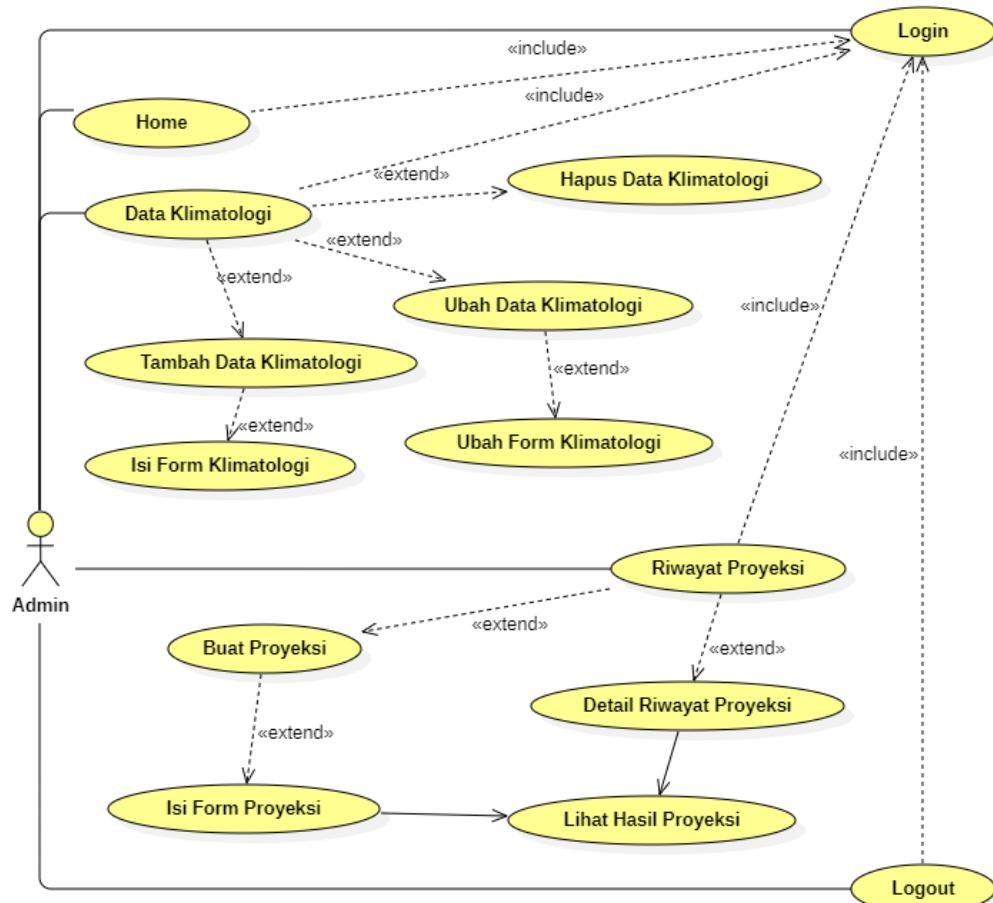
Tabel 4.21. Definisi Use case yang digunakan

No	Use case	Aktor	Deskripsi
1	<i>Home</i>	<i>Admin</i>	Merupakan <i>Use case</i> untuk menampilkan halaman Utama yang menampilkan, keterangan dari sistem.
2	<i>Login</i>	<i>Admin</i>	<i>Use case</i> yang di gunakan aktor untuk authentikasi ke dalam sistem untuk mendapatkan hak akses terhadap beberapa <i>use case</i> di dalam sistem.
3	<i>Logout</i>	<i>Admin</i>	<i>Use case</i> yang digunakan untuk melepaskan authentikasi <i>login</i> pada sistem, menghapus sesi <i>login</i> dan hak akses yang berjalan.
4	<i>Data Klimatologi</i>	<i>Admin</i>	Merupakan <i>Use case</i> untuk menampilkan kumpulan Data Klimatologi yang ada di sistem.
5	<i>Tambah Data Klimatologi</i>	<i>Admin</i>	<i>Use case</i> yang digunakan apabila <i>admin</i> ingin menambah baris baru pada kumpulan Data Klimatologi

6	<i>Isi Form Klimatologi</i>	<i>Admin</i>	<i>Use case dimana admin mengisi Data Klimatologi yang di input ke sistem.</i>
7	<i>Ubah Data Klimatologi</i>	<i>Admin</i>	<i>Use case yang digunakan apabila admin ingin mengubah baris suatu data pada kumpulan Data Klimatologi</i>
8	<i>Ubah Form Klimatologi</i>	<i>Admin</i>	<i>Use case dimana admin mengubah isi form dari Data Klimatologi yang di ubah.</i>
9	<i>Hapus Data Klimatologi</i>	<i>Admin</i>	<i>Use case yang digunakan apabila admin ingin menghapus baris suatu data pada kumpulan Data Klimatologi</i>
10	<i>Riwayat Proyeksi</i>	<i>Admin</i>	<i>Use case yang berguna untuk melihat Riwayat Proyeksi yang telah di lakukan sebelumnya.</i>
11	<i>Buat Proyeksi</i>	<i>Admin</i>	<i>Use case yang berguna untuk melakukan Proyeksi baru dari Data Klimatologi dengan metode LSTM.</i>
12	<i>Isi Form Proyeksi</i>	<i>Admin</i>	<i>Use case dimana admin mengisi beberapa parameter yang harus di inputkan sebelum melakukan Proyeksi</i>
13	<i>Detail Riwayat Proyeksi</i>	<i>Admin</i>	<i>Use case yang digunakan apabila admin ingin melihat hasil Proyeksi dari suatu proyeksi pada kumpulan Riwayat proyeksi</i>
14	<i>Lihat Hasil Proyeksi</i>	<i>Admin</i>	<i>Use case dimana admin dapat melihat hasil proyeksi yang di lakukan.</i>
16	<i>Ubah Form</i>	<i>Admin</i>	<i>Use case dimana admin mengubah isi form profil</i>

	<i>Profil</i>		<i>admin</i> yang sudah ada.
17	<i>Isi Form Password</i>	<i>Admin</i>	<i>Use case</i> dimana <i>admin</i> perlu mengisi password untuk keperluan authentikasi saat ingin mengubah data profil <i>admin</i> .

Berdasarkan Tabel 4.21 untuk rancangan UML berupa *Use case Diagram* dapat dilihat pada Gambar 4.4 di bawah ini :



Gambar 4.4. Use case Diagram Admin

Berdasarkan Gambar 4.4 terdapat 5 case inti yaitu case *Login*, *Home*, *Data Klimatologi*, *Riwayat Proyeksi* dan *Logout*, selebihnya adalah extends dari case inti tersebut seperti yang dijelaskan pada Tabel 4.21 sebelumnya.

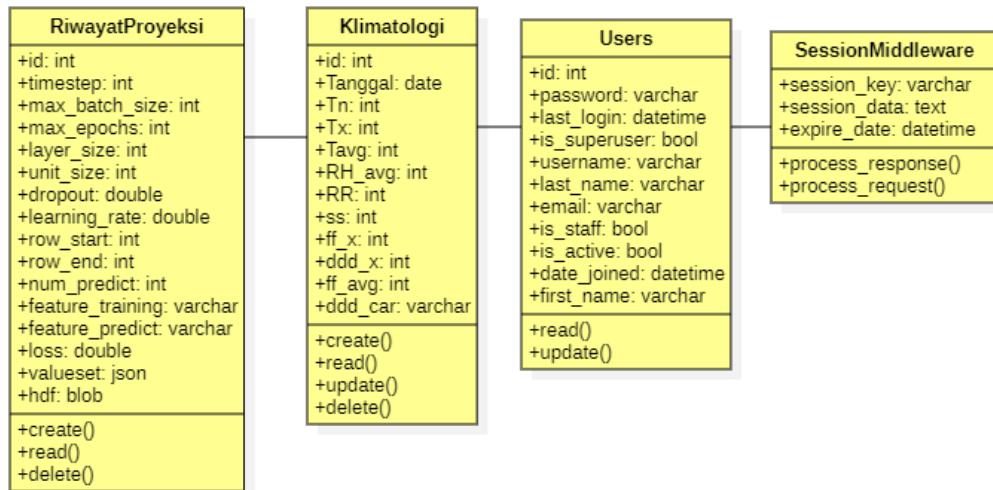
4.2.1.2. Class Diagram

Class Diagram menjelaskan mengenai jenis – jenis objek yang terdapat di dalam sebuah sistem dan berbagai hubungan statis yang terdapat pada sistem. Merupakan inti dari pengembangan dan desain dari program berrorientasi objek. Definisi dari *Class Diagram* dapat di lihat pada Tabel 4.22 berikut ini :

Tabel 4.22. Definisi Class Diagram

No	Class Diagram	Deskripsi
1	<i>Users</i>	<i>Class Diagram</i> di gunakan untuk <i>Object Relation Mapping (ORM)</i> untuk melakukan query dan manipulasi data <i>users</i> yang tergabung dalam sistem dari <i>database</i> dengan API DMBS MySQL.
2	<i>Klimatologi</i>	<i>Class Diagram</i> di gunakan untuk <i>Object Relation Mapping (ORM)</i> untuk melakukan query dan manipulasi data dari <i>database</i> dengan API DMBS MySQL.
4	<i>RiwayatProyeksi</i>	Merupakan <i>Class Diagram</i> yang berfungsi untuk menyimpan model dari LSTM beserta <i>parameter</i> hasil
5	<i>SessionMiddleware</i>	Merupakan <i>Class Diagram</i> yang berfungsi untuk menyimpan data sesi authentikasi <i>users</i> .

Berdasarkan Tabel 4.22 rancangan UML berupa *Use case Diagram* dapat dilihat pada Gambar 4.5 di bawah ini :



Gambar 4.5. Class Diagram

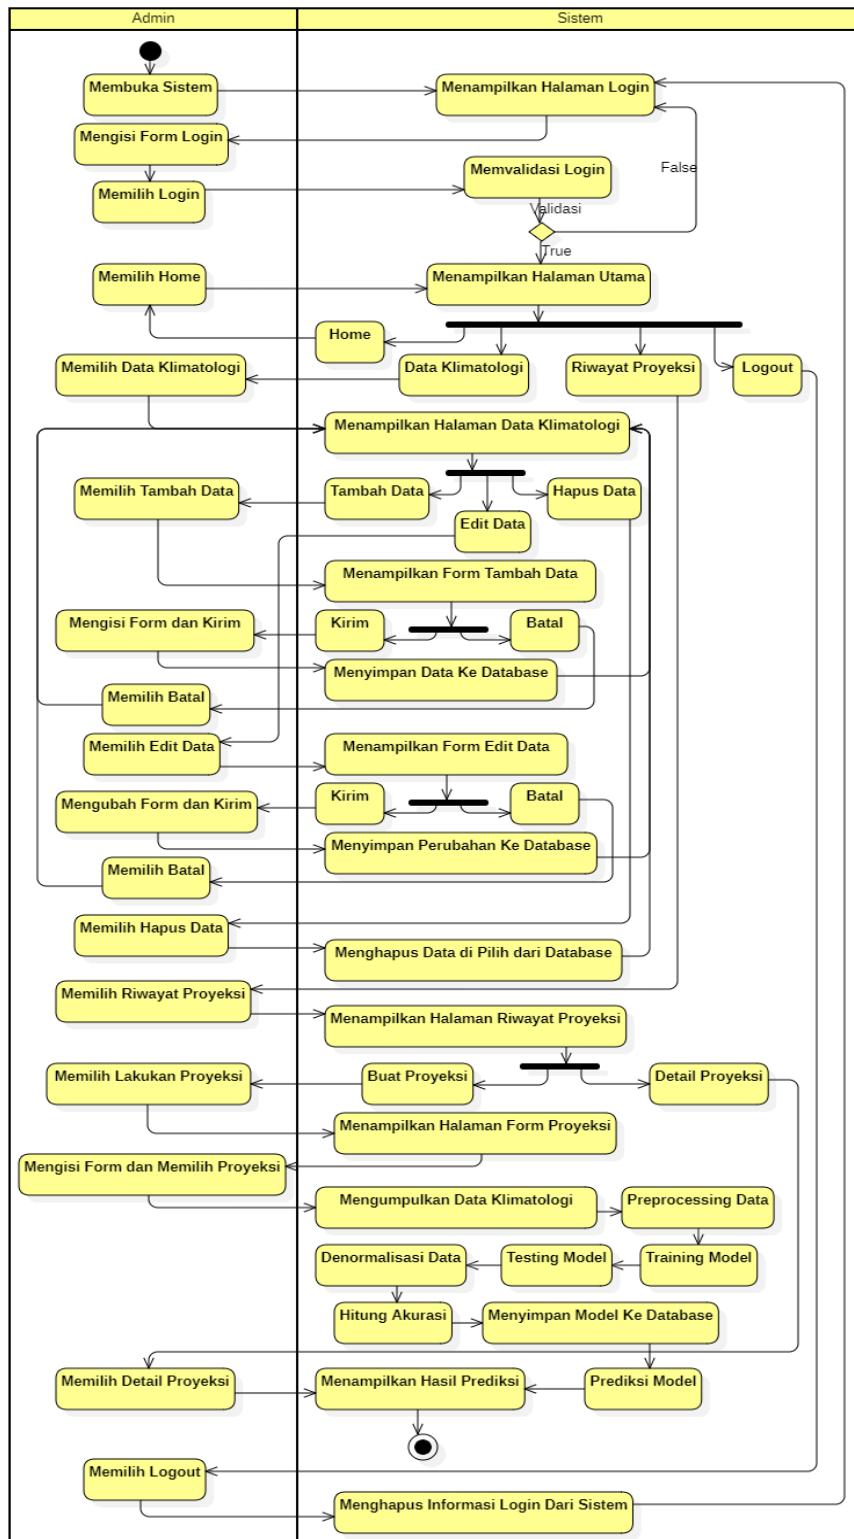
Class diagram Pada Gambar 4.5 seperti *class RiwayatProyeksi* dan *Klimatologi* memiliki keterkaitan pada kolom *row_start* dan *row_end* pada *RiwayatProyeksi* dengan *id* pada *Klimatologi*, sebagai penanda rentang data yang digunakan dalam melakukan sebuah Proyeksi.

4.2.1.3. Activity Diagram

Activity diagram adalah teknik untuk mendeskripsikan logika prosedural, aliran kerja dalam banyak kasus *Activity diagram* menggambarkan bagaimana aktivitas yang terjadi dalam sistem yang dirancang. *Activity diagram* sama seperti halnya flowchart yang menggambarkan proses yang terjadi antara aktor dan sistem.

Pada *Activity diagram* yang di rancang *admin* perlu melakukan authentikasi terlebih dahulu untuk mendapatkan hak akses menggunakan sistem lebih lanjut, Setelah *Admin* melakukan authentikasi *login admin*, *admin* memiliki hak akses untuk masuk ke dalam halaman *home*, Data *Klimatologi* untuk mengelola Data *Klimatologi*, dan proyeksi untuk melakukan proyeksi Data

Klimatologi, dan halaman edit profil untuk mengelola akun *admin*. seperti yang terlihat pada Gambar 4.6 berikut :



Gambar 4.6. Activity Diagram Admin

Berdasarkan Gambar 4.6 perancangan diagram di atas menggambarkan apa saja aktivitas *admin* pada sistem. Mulai dari membuka sistem sampai melihat halaman utama dari sistem. Pada saat *admin* mengakses sistem dan berhasil tahap validasi setelah melakukan *login admin* langsung di arahkan ke halaman utama yaitu halaman *home*, dan dapat mengakses beberapa menu lainnya seperti Data Klimatologi, Riwayat Proyeksi, dan *Logout*.

Pada Data Klimatologi *admin* dapat mengelola Data Klimatologi seperti membaca Data Klimatologi, Tambah Data Klimatologi, Edit Data Klimatologi, dan Hapus Data Klimatologi.

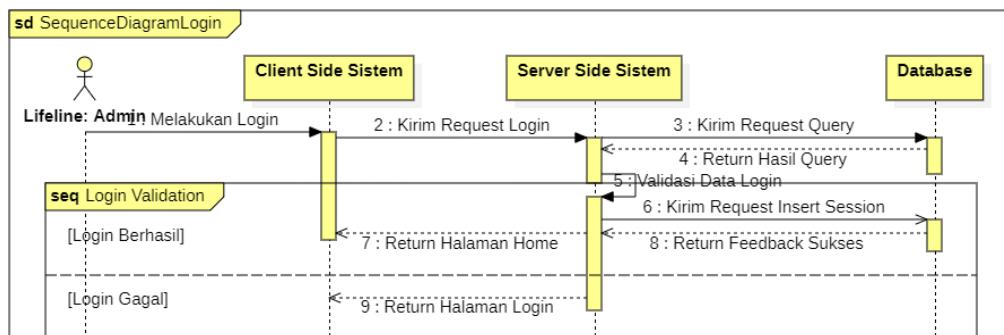
Pada Riwayat Proyeksi melihat Riwayat hasil Proyeksi sebelumnya yang sudah di lakukan berdasarkan *hyperparameter* pendukung Proyeksi, *admin* juga dapat melakukan proyeksi yang baru dengan mengakses Lakukan Proyeksi di mana *admin* harus mengisi beberapa *hyperparameter* pendukung dengan mengisi *form* untuk melakukan Proyeksi data yang nantinya sistem menampilkan hasil Proyeksi berbentuk tabel dan diagram statistik.

4.2.1.4. Sequence Diagram

Sequence diagram merupakan suatu rangkaian yang mendeskripsikan alur kerja dan interaksi-interaksi yang terjadi, dan menjelaskan hubungan timbal balik antara pengguna dan sistem saat berinteraksi. *Sequence diagram* dipengaruhi oleh *use case diagram*, dengan demikian masing-masing *use case* memiliki satu *sequence diagram* yang mendeskripsikan alur kerja dan interaksi yang ada saat *use case* dijelaskan.

4.2.1.4.1. Sequence Diagram Login

Sequence Diagram ini menjelaskan urutan yang dilakukan oleh *admin* untuk mendapatkan hak akses sistem dengan melakukan *login* sistem. Dapat di lihat pada Gambar 4.7 berikut ini :

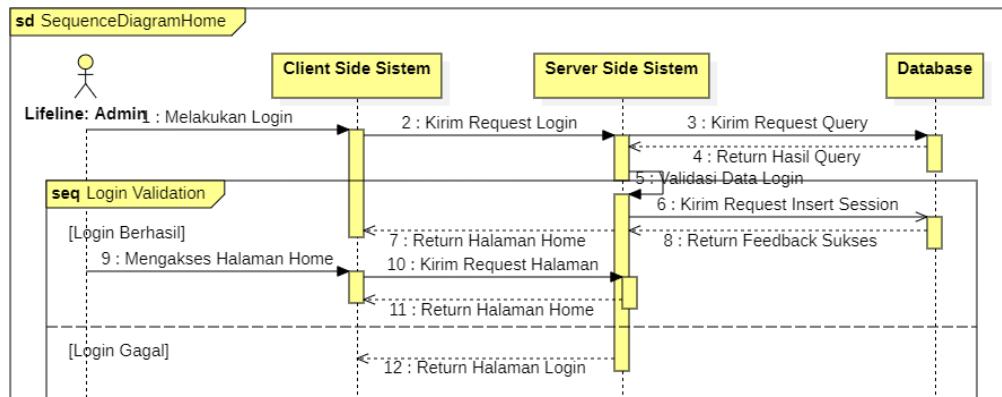


Gambar 4.7. Sequence Diagram Login

Sesuai urutan Diagram Gambar 4.7 di atas dapat dilihat bagaimana interaksi pada sistem yang dibangun. Diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di inputkan sama dengan *database* maka *admin* dapat hak akses sistem dan sistem untuk menyimpan data sesi *admin* ke dalam sistem dan *database* sebagai penanda kalau *admin* tersebut sedang *login* saat sesi yang berlangsung. Jika data yang di *input form login* salah maka *admin* langsung di alihkan kembali ke halaman *login*.

4.2.1.4.2. Sequence Diagram Home

Sequence Diagram ini menjelaskan urutan yang dilakukan oleh *admin* agar dapat mengakses halaman *home* dengan melakukan *login* sistem. Dapat di lihat pada Gambar 4.8 berikut ini :

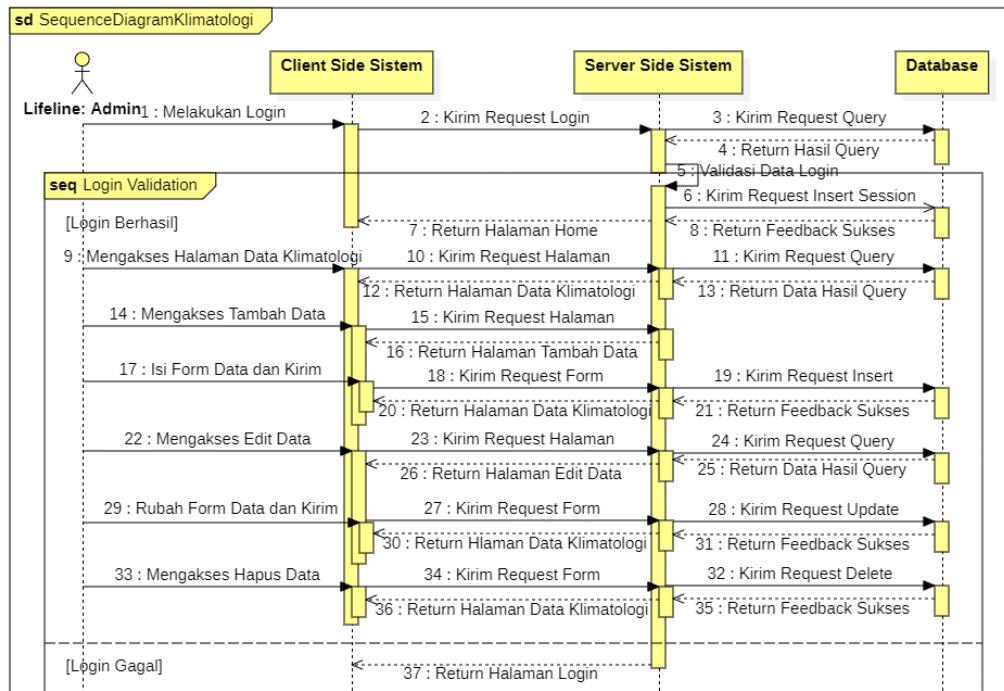


Gambar 4.8. Sequence Diagram Home

Sesuai urutan Diagram Gambar 4.8 di atas dapat dilihat bagaimana interaksi pada sistem yang dibangun. Diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di inputkan sama dengan *database* maka *admin* dapat mengakses halaman *home*. Jika data yang di *input form login* salah maka *admin* di arahkan kembali ke halaman *login*.

4.2.1.4.3. Sequence Diagram Data Klimatologi

Sequence Diagram ini menjelaskan urutan yang dilakukan oleh *admin* agar dapat mengakses halaman Data Klimatologi dan mengelola Data Klimatologi tersebut dengan melakukan *login* sistem. Dapat di lihat pada Gambar 4.9 berikut ini :



Gambar 4.9. Sequence Diagram Data Klimatologi

Sesuai urutan Diagram Gambar 4.9 di atas dapat dilihat bagaimana interaksi pada sistem yang dibangun. Diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di inputkan sama dengan *database* maka *admin* dapat mengakses halaman Data Klimatologi dan menggunakan fitur di dalamnya seperti tambah Data Klimatologi, Jika data yang di *input form login* salah maka *admin* di arahkan kembali ke halaman *login*.

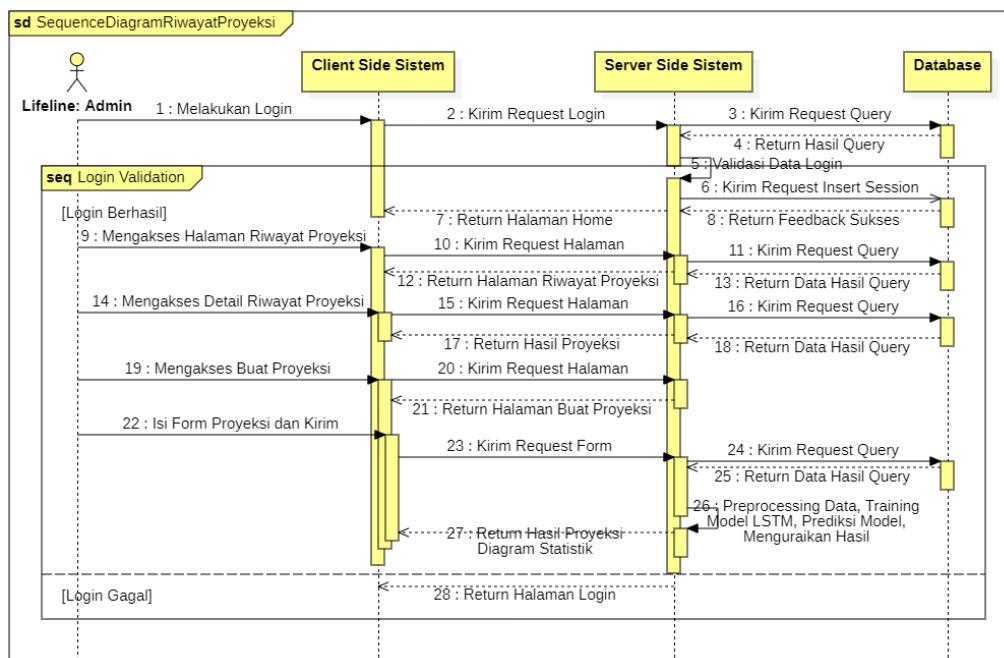
Pada Data Klimatologi *admin* dapat melakukan *input form* dan mengirim permintaan ke *server* agar *server* dapat menyimpan data *form* yang di inputkan *admin* ke dalam *database* yang nantinya *database* memberikan tanggapan sukses di mana *server* meneruskan pesan sukses tadi dengan mengalihkan *admin* tadi Kembali ke halaman Data Klimatologi.

Pada edit Data Klimatologi sama halnya dengan Tambah data hanya saja *form input* otomatis terisi dengan data yang ada di *database* dan *admin* di haruskan mengubah *form* tersebut dan mengirim permintaan ke *server*.

Pada hapus Data Klimatologi *admin* dapat menghapus data yang di pilih dan mengirim permintaan ke *server*.

4.2.1.4.4. Sequence Diagram Riwayat Proyeksi

Sequence Diagram ini menjelaskan urutan yang dilakukan oleh *admin* agar dapat mengakses halaman Riwayat Proyeksi guna melakukan prediksi dari Data Klimatologi dengan melakukan *login* sistem. Dapat di lihat pada Gambar 4.10 berikut ini :



Gambar 4.10. Sequence Diagram Riwayat Proyeksi

Sesuai urutan Diagram Gambar 4.10 di atas dapat dilihat bagaimana interaksi pada sistem yang dibangun. Diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di

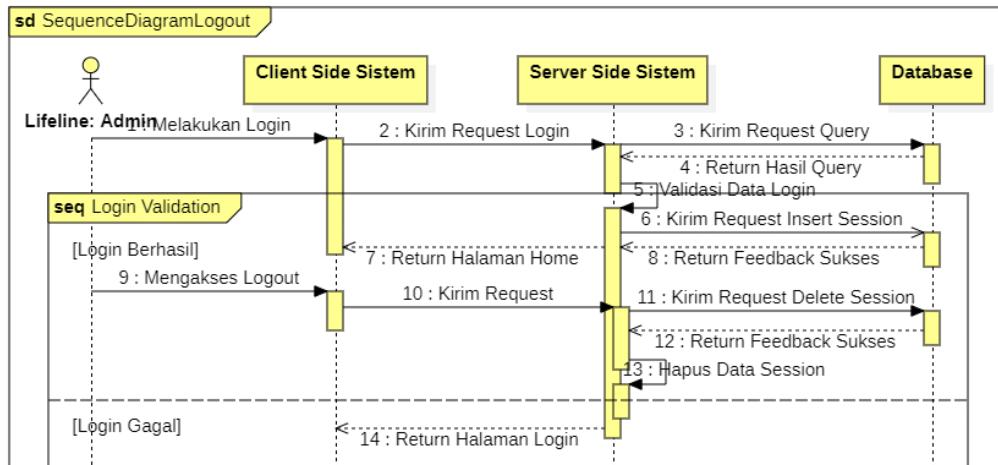
inputkan sama dengan *database* maka *admin* dapat mengakses halaman Riwayat Proyeksi, Jika data yang di *input form login* salah maka *admin* di arahkan kembali ke halaman *login*.

Pada halaman Riwayat Proyeksi *admin* dalam melihat detail setiap baris riwayat Proyeksi yang di pilih untuk melihat hasil Proyeksi dari Riwayat Proyeksi sebelumnya.

Admin juga dapat membuat baru Proyeksi dengan mengakses halaman buat Proyeksi, selanjutnya *admin* di haruskan untuk mengisi *form* opsi dan *input* untuk menentukan kriteria Proyeksi yang di inginkan, setelah *admin* mengirim permintaan ke sistem maka sistem membaca semua Data Klimatologi yang di gunakan untuk melakukan Proyeksi dengan tahapnya seperti, *preprocessing* data, *training* model LSTM, prediksi model, dan mengembalikan hasil berupa uraian hasil berbentuk diagram statistik.

4.2.1.4.5. Sequence Diagram Logout

Sequence Diagram ini menjelaskan urutan yang dilakukan oleh *admin* untuk *logout* guna menghapus sesi yang sedang berlangsung dan keluar dari sistem di mana *admin* harus melakukan *login* terlebih dahulu. Dapat di lihat pada Gambar 4.11 berikut ini :



Gambar 4.11. Sequence Diagram Logout

Sesuai urutan Diagram Gambar 4.11 di atas dapat dilihat bagaimana interaksi pada sistem yang dibangun. Diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di inputkan sama dengan *database* maka *admin* alah berada dalam status sesi *login*. Jika data yang di *input form login* salah maka *admin* di arahkan kembali ke halaman *login*.

Logout hanya dapat di lakukan jika *admin* dalam sesi *login*, *admin* dapat keluar dari sistem dengan mengakses *logout* dan permintaan di kirimkan ke *server*, kemudian *server* mengirimkan permintaan ke *database* agar data sesi *admin* yang berlangsung untuk di hapus dari *database* sekaligus sistem menghapus data sesi dari sistem, terakhir sistem mengalihkan *admin* ke halaman *login* kembali.

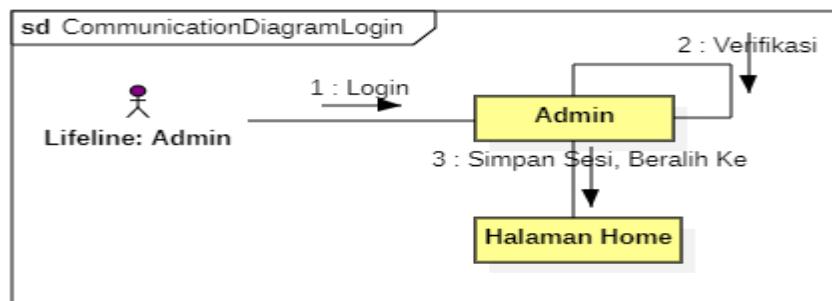
4.2.1.5. Collaboration Diagram

Collaboratioan Diagram adalah cara alternatif untuk mengetahui tahap-tahap terjadinya suatu aktivitas. Perbedaan antara *Collaboration Diagram* dan *Squence Diagram* adalah *Collaboration Diagram* memperlihatkan bagaimana hubungan

antara beberapa objek berdasarkan urutan dari pesan, sedangkan *Sequence Diagram* memperlihatkan bagaimana urutan kejadian berdasarkan waktu.

4.2.1.5.1. Collaboration Diagram Login

Collaboration Diagram ini menjelaskan di mana *admin* perlu melakukan *login* dan sukses dalam validasi untuk mendapatkan hak akses *admin* dalam sistem, yang kemudian di alihkan ke halaman *home*. Dapat di lihat pada Gambar 4.12 berikut.



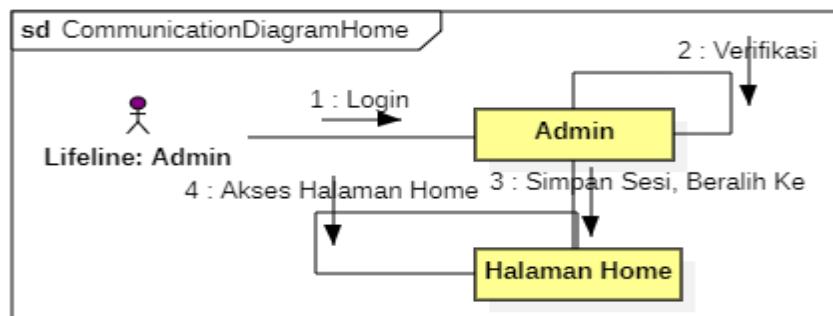
Gambar 4.12. Collaboration Diagram Login

Pada *Collaboration Diagram* Gambar 4.12 terlihat bagaimana kolaborasi actor *admin* dengan sistem yang dibangun, diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di *inputkan* sama dengan *database* maka *admin* dapat hak akses sistem dan sistem untuk menyimpan data sesi *admin* ke dalam sistem dan *database* sebagai penanda kalau *admin* tersebut sedang *login* saat sesi yang berlangsung.

Ketika *admin* sudah *login* *admin* di alihkan ke halaman *home* dan mendapat status dalam keadaan sesi *login*.

4.2.1.5.2. Collaboration Diagram Home

Collaboration Diagram ini menjelaskan di mana setelah *admin* perlu verifikasi bahwa dia adalah *admin* mendapatkan hak akses sebagai *admin*, kemudian *admin* tersebut dapat berkolaborasi dengan sistem seperti mengakses halaman *home*. Dapat di lihat pada Gambar 4.13 berikut.



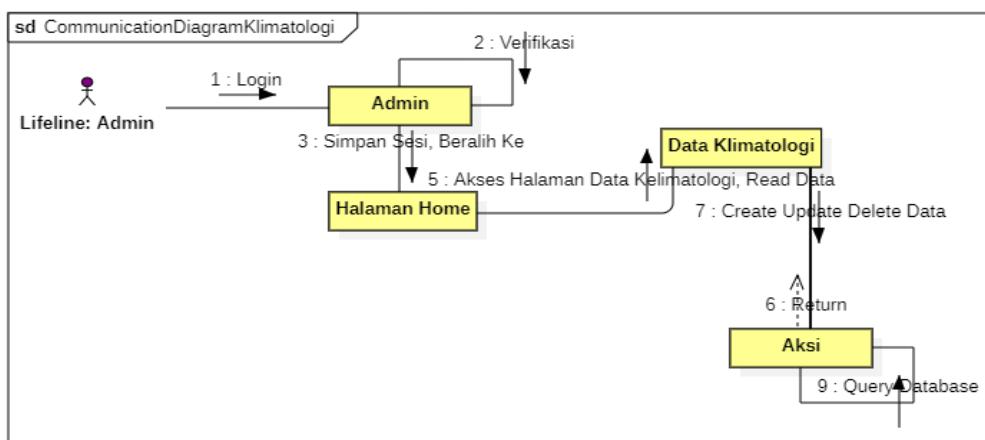
Gambar 4.13. Collaboration Diagram Home

Pada *Collaboration Diagram* Gambar 4.13 terlihat bagaimana kolaborasi actor *admin* dengan sistem yang dibangun, diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di *inputkan* sama dengan *database* maka *admin* dapat hak akses sistem dan sistem untuk menyimpan data sesi *admin* ke dalam sistem dan *database* sebagai penanda kalau *admin* tersebut sedang *login* saat sesi yang berlangsung.

Ketika *admin* sudah *login* *admin* di alihkan ke halaman *home* dan mendapat status dalam keadaan sesi *login*, kemudian *admin* dapat selalu berinteraksi dengan halaman *home* dengan mengakses Kembali halaman *home* selama *admin* masih dalam sesi *login*.

4.2.1.5.3. Collaboration Diagram Data Klimatologi

Collaboration Diagram ini menjelaskan di mana setelah *admin* perlu verifikasi bahwa dia adalah *admin* mendapatkan hak akses sebagai *admin*, kemudian *admin* tersebut dapat mengelola Data Klimatologi dengan mengakses halaman Data Klimatologi, di mana *admin* dapat berkolaborasi dengan sistem seperti aksi *Create*, *Update* dan *Delete*, dan aksi selebihnya di tangani oleh sistem. Dapat di lihat pada Gambar 4.14 berikut.



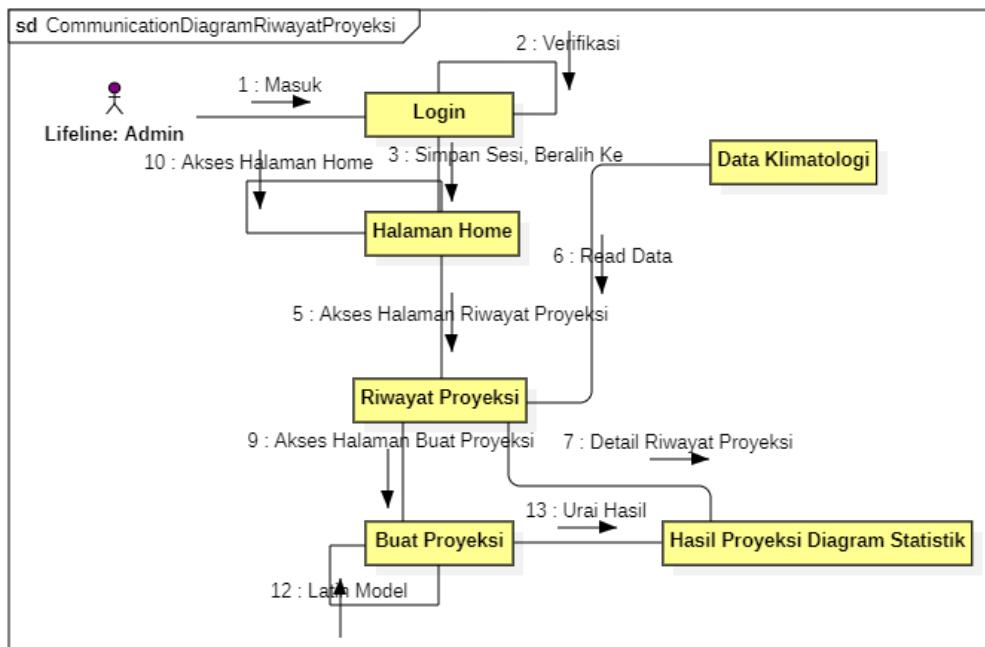
Gambar 4.14. Collaboration Diagram Data Klimatologi

Pada *Collaboration Diagram* Gambar 4.14 terlihat bagaimana kolaborasi actor *admin* dengan sistem yang dibangun, diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di *inputkan* sama dengan *database* maka *admin* dapat hak akses sistem dan sistem untuk menyimpan data sesi *admin* ke dalam sistem dan *database* sebagai penanda kalau *admin* tersebut sedang *login* saat sesi yang berlangsung.

Ketika *admin* sudah *login* *admin* di alihkan ke halaman *home*, selanjutnya *admin* dapat berkolaborasi dengan Data Klimatologi untuk memanajemen Data Klimatologi seperti Tambah data edit data dan hapus Data Klimatologi.

4.2.1.5.4. Collaboration Diagram Riwayat Proyeksi

Collaboration Diagram ini menjelaskan di mana setelah *admin* perlu verifikasi bahwa dia adalah *admin* mendapatkan hak akses sebagai *admin*, kemudian *admin* tersebut berkolaborasi dengan melakukan Proyeksi dengan mengakses halaman Buat Proyeksi di dalam halaman Riwayat Proyeksi, selanjutnya peran sistemlah yang melakukan pengambilan data dan melatih data tersebut dengan model serta menguraikan hasilnya agar mudah di mengerti oleh *admin*. Dapat di lihat pada Gambar 4.15 berikut.



Gambar 4.15. Collaboration Diagram Riwayat Proyeksi

Pada *Collaboration Diagram* Gambar 4.15 terlihat bagaimana kolaborasi actor *admin* dengan sistem yang dibangun, diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang di kirim, jika data yang di *inputkan* sama dengan *database* maka *admin* dapat hak akses sistem dan

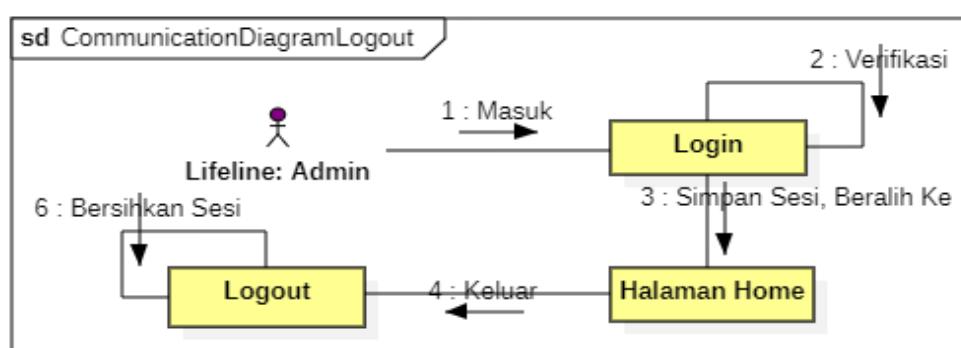
sistem untuk menyimpan data sesi *admin* ke dalam sistem dan *database* sebagai penanda kalau *admin* tersebut sedang *login* saat sesi yang berlangsung.

Ketika *admin* sudah *login* *admin* di alihkan ke halaman *home*, selanjutnya *admin* dapat berkolaborasi dengan Riwayat Proyeksi untuk mengakses fitur Proyeksi pada sistem, sistem berkolaborasi dengan membaca data table Klimatologi dari *database* Proyeksi untuk di tampilkan dan dapat di lihat oleh *admin*.

Ketika *admin* sudah di dalam halaman Riwayat Proyeksi *admin* dapat mengakses detail Proyeksi dari baris table Riwayat Proyeksi yang di lihat, *admin* juga dapat membuat Proyeksi baru dengan mengakses Buat Proyeksi dimana yang nantinya sistem melatih model dan menampilkan hasil Proyeksi berbentuk diagram statistik.

4.2.1.5.5. Collaboration Diagram Logout

Collaboration Diagram ini menjelaskan di mana setelah *admin* perlu verifikasi bahwa dia adalah *admin* mendapatkan hak akses sebagai *admin*, kemudian *admin* tersebut dapat memutuskan kolaborasi dengan sistem atau keluar dari sistem seperti melakukan *logout*, dan sistem berkolaborasi seperti membersihkan data sesi pada *admin* yang masih tersimpan. Dapat di lihat pada Gambar 4.16 berikut.



Gambar 4.16. Collaboration Diagram Logout

Pada *Collaboration Diagram* Gambar 4.16 terlihat bagaimana kolaborasi actor *admin* dengan sistem yang dibangun, diawali *admin* harus melalui tahap *login* ke dalam sistem dan sistem melakukan validasi *form* yang dikirim, jika data yang di *inputkan* sama dengan *database* maka *admin* dapat hak akses sistem dan sistem untuk menyimpan data sesi *admin* ke dalam sistem dan *database* sebagai penanda kalau *admin* tersebut sedang *login* saat sesi yang berlangsung.

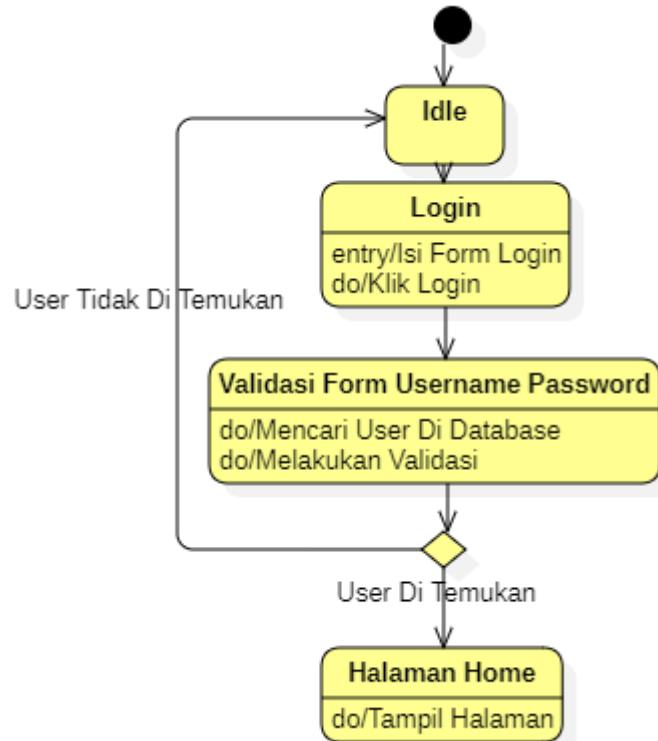
Logout hanya dapat dilakukan jika *admin* dalam sesi *login*, *admin* dapat berkolaborasi dengan mengakses *logout* dan permintaan dikirimkan ke *server*, kemudian *server* berkolaborasi dengan mengirimkan permintaan ke *database* agar data sesi *admin* yang berlangsung untuk dihapus dari *database* sekaligus sistem menghapus data sesi dari sistem.

4.2.1.6. Statechart Diagram

Statechart diagram menggambarkan perubahan status yang terjadi ketika sistem dijalankan. Perubahan yang terjadi pada suatu objek digambarkan oleh diagram ini dalam bentuk grafik berarah.

4.2.1.6.1. Statechart Diagram Login

Statechart Diagram ini memperlihatkan bagaimana alur perpindahan status *admin* dalam menggunakan sistem mulai dari authentikasi *login* sistem. Dapat dilihat pada Gambar 4.17 berikut.

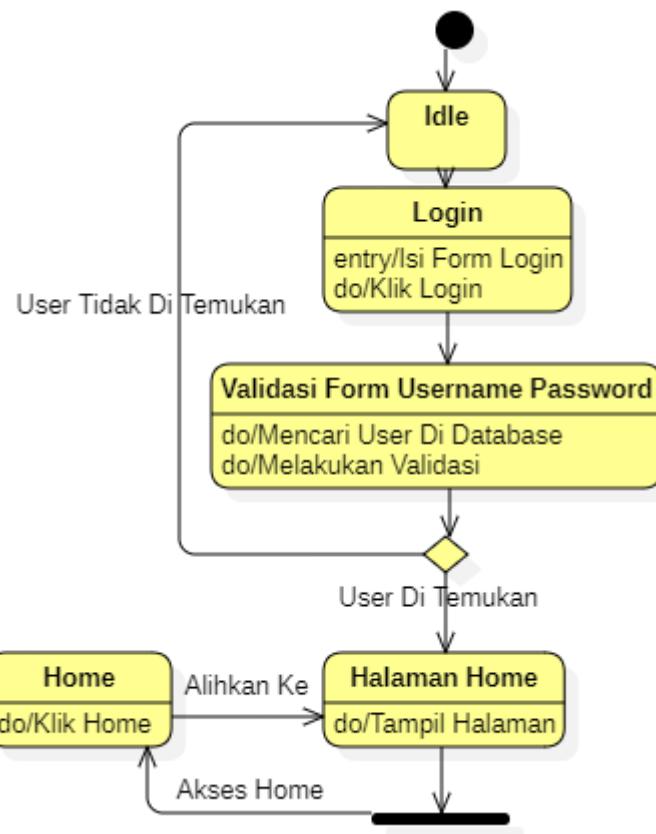


Gambar 4.17. Statechart Diagram Login

Dari *statechart* diagram pada Gambar 4.17 di atas dapat di lihat bagaimana alur perpindahan status pada *admin* saat *idle* hingga ke halaman *home*, di mana *admin* perlu melakukan entri *form* pada *login* dan klik *login*, kemudian sistem mencari *user* di *database* dan melakukan validasi, apabila *user* di temukan maka *admin* di teruskan ke halaman *admin*, apabila *user* tidak di temukan maka *admin* di alihkan kembali ke kondisi sebelumnya.

4.2.1.6.2. Statechart Diagram Home

Statechart Diagram ini memperlihatkan bagaimana alur perpindahan status *admin* dalam menggunakan sistem mulai dari authentikasi hingga klik halaman *home*. Dapat di lihat pada Gambar 4.18 berikut ini :

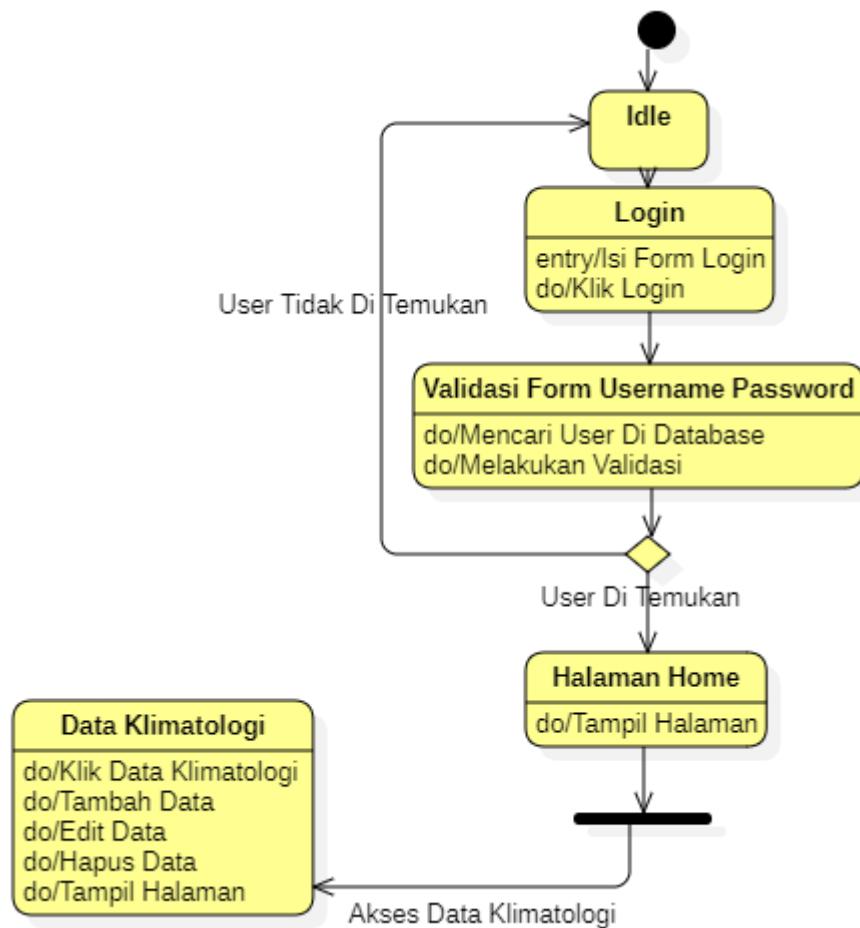


Gambar 4.18. Statechart Diagram Home

Dari *statechart* diagram pada Gambar 4.18 di atas Ketika *admin* sudah di verifikasi dan *admin* dalam keadaan status sebagai *admin* dapat mengeklik *home* agar di alihkan ke halaman *home*.

4.2.1.6.3. Statechart Diagram Data Klimatologi

Statechart Diagram ini memperlihatkan bagaimana alur perpindahan status *admin* dalam menggunakan sistem mulai dari authentikasi *login* hingga akses Data Klimatologi. Dapat di lihat pada Gambar 4.19 berikut ini :

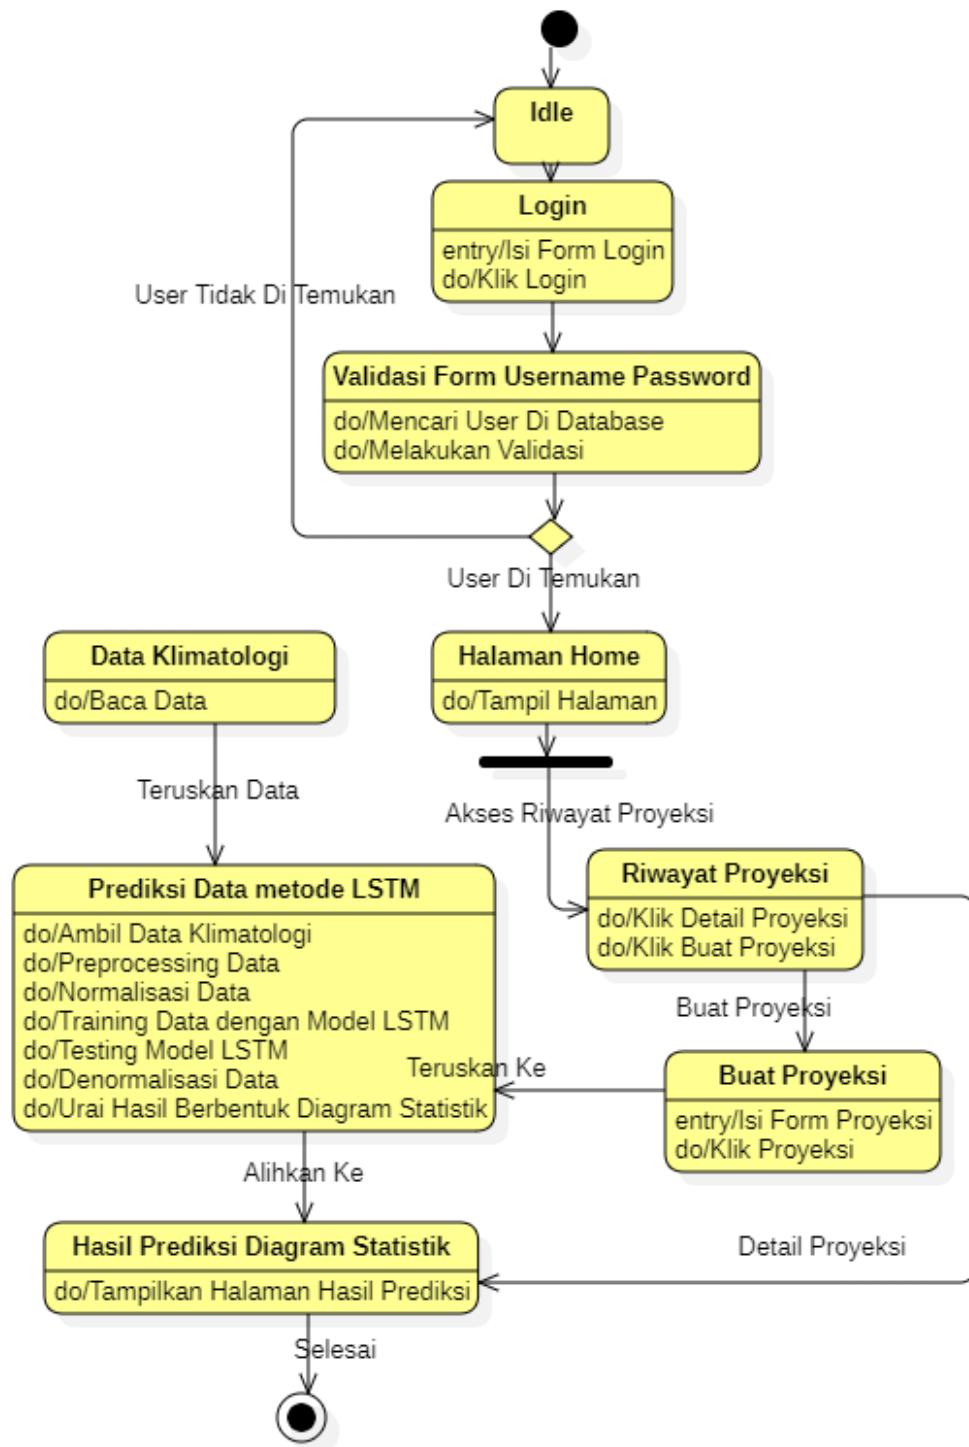


Gambar 4.19. Statechart Diagram Data Klimatologi

Dari *statechart* diagram pada Gambar 4.19 di atas Ketika *admin* sudah di verifikasi dan *admin* dalam keadaan status sebagai *admin* dapat mengakses Data Klimatologi, kemudian *admin* dapat melakukan operasi klik Data Klimatologi, Tambah data, Edit Data, Hapus Data.

4.2.1.6.4. Statechart Diagram Riwayat Proyeksi

Statechart Diagram ini memperlihatkan bagaimana alur perpindahan status *admin* dalam menggunakan sistem hingga melakukan Proyeksi data. Dapat di lihat pada Gambar 4.20 berikut ini :



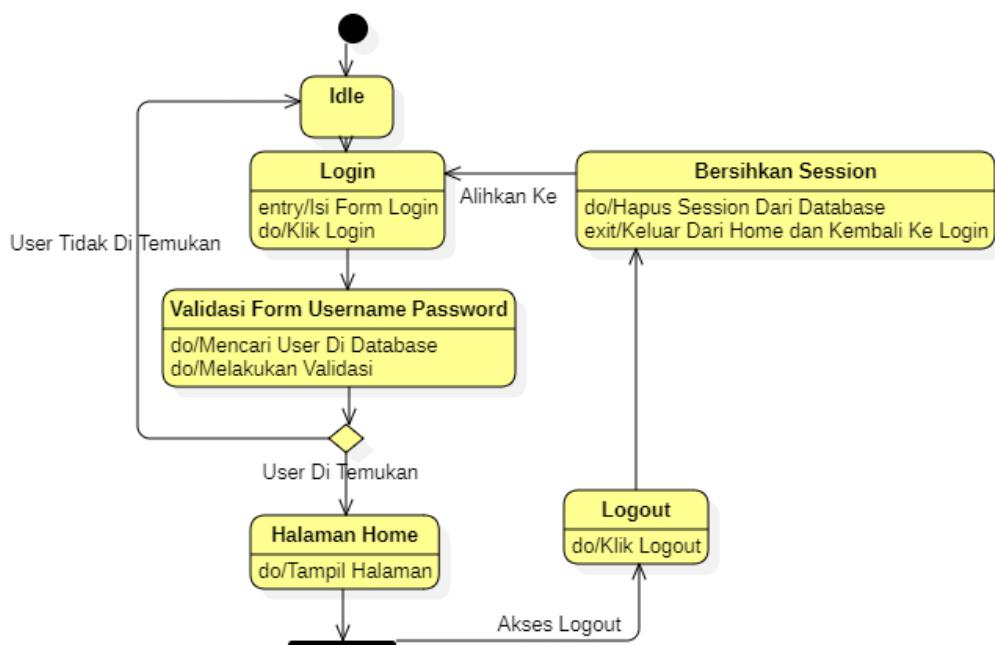
Gambar 4.20. Statechart Diagram Riwayat Proyeksi

Dari *statechart* diagram pada Gambar 4.20 di atas Ketika *admin* sudah di verifikasi dan *admin* dalam keadaan status sebagai *admin* dapat langsung

menggunakan fitur Riwayat Proyeksi yang di buat khusus pada penelitian ini. *admin* yang sudah mengakses halaman buat proyeksi dapat mengisi *form* Proyeksi kemudian klik Proyeksi dan *state* selanjutnya diteruskan oleh sistem, pertama-tama sistem mengambil semua Data Klimatologi, *state* berikutnya sistem melakukan *preprocessing* pada data yang sudah di ambil, lalu melakukan normalisasi data, *state* berikutnya melakukan *training* data dengan model LSTM, lalu data yang sudah di latih kemudian di *testing*, *state* selanjutnya adalah untuk mengembalikan data ke nilai sebelumnya di lakukan denormalisasi data, *state* terakhir sistem menguraikan hasil dan menampilkan hasil berbentuk diagram statistik.

4.2.1.6.5. Statechart Diagram Logout

Statechart Diagram ini memperlihatkan bagaimana alur perpindahan status *admin* dalam menggunakan sistem dari melakukan authentikasi hingga melakukan *logout* sistem. Dapat di lihat pada Gambar 4.21 berikut ini :

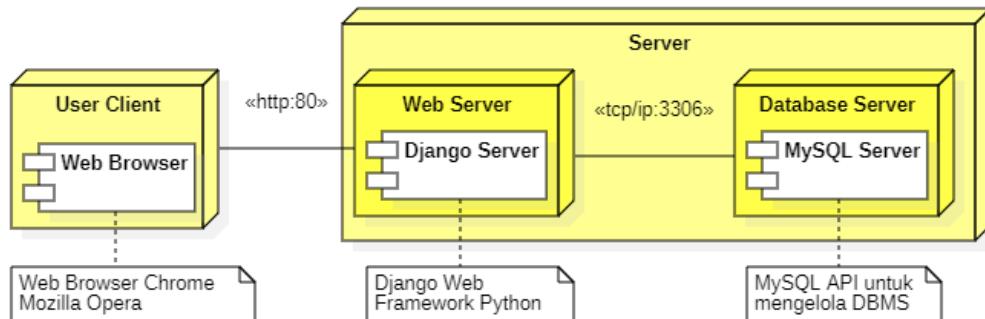


Gambar 4.21. Statechart Diagram Logout

Dari *statechart* diagram pada Gambar 4.21 di atas Ketika *admin* sudah di verifikasi dan *admin* dalam keadaan status sebagai *admin* dapat mengeklik *logout* untuk keluar dari *state login*, kemudian sistem menghapus sesi dan sistem dan *database* dan mengembalikan *admin* ke halaman *login*.

4.2.1.7. Deployment Diagram

Deployment diagram menggambarkan detail bagaimana komponen dikembangkan dalam infrastruktur sistem, termasuk di mana komponen terletak protokol jaringan saling berkomunikasi satu sama lain, misalnya seperti tcp/ip dan protokol http, spesifikasi *server*, dan hal-hal lain yang bersifat fisik.



Gambar 4.22. Deployment Diagram

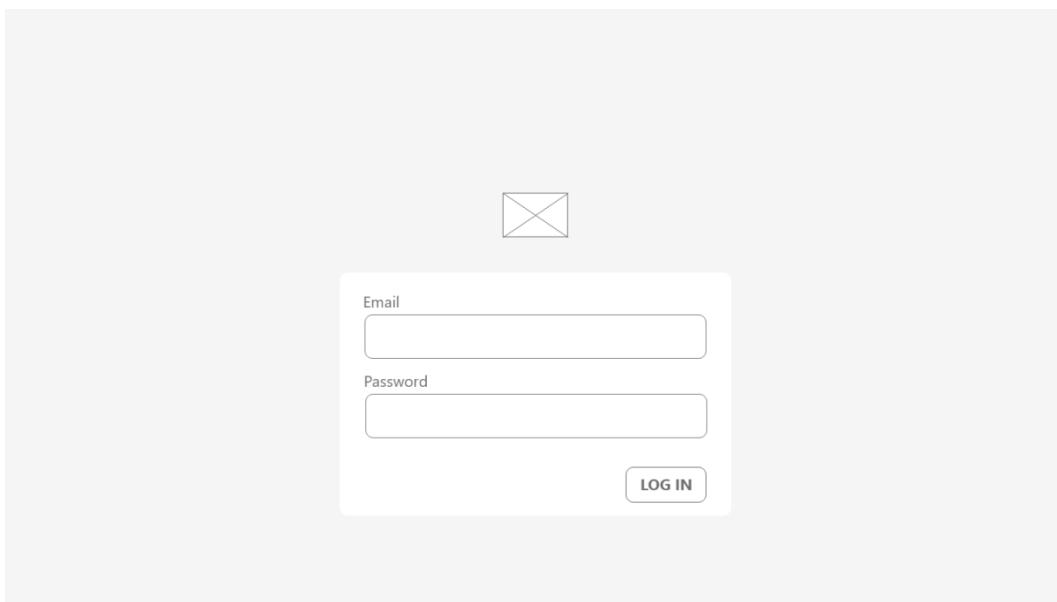
Pada Gambar 4.22 terlihat dari *admin* sebagai *user client* menggunakan *web browser* seperti chrome, mozilla, atau opera untuk berkomunikasi dengan *server* khususnya pada *web server* Django dengan protokol http dengan Port 80, dan *web server* tersebut juga berkomunikasi dengan *database server* khususnya API DBMS MySQL pada protokol jaringan tcp/ip Port 3306, dalam 1 lingkup *server induk*.

4.2.2. Perancangan *Interface*

Desain *Interface* dilakukan dengan tujuan memberikan gambaran dari tampilan yang dilihat oleh *admin* pada saat menggunakan sistem, dan membangun aplikasi dengan memenuhi prinsip perancangan *interface* yang baik untuk *admin*. Dengan menggunakan *Adobe XD 2021* sebagai tools dalam sebagai rancangan desain sistem yang dibuat nantinya. Berikut adalah beberapa desain *interface* sistem Proyeksi pada penelitian ini :

4.2.2.1. Desain Halaman *Login*

Halaman *login* adalah tampilan awal kinerja proses di mana *admin* harus melakukan authentikasi terlebih dahulu sebelum memasuki sistem setelah *admin login* maka sistem mengarah ke halaman *home admin*. Seperti yang terlihat pada rancangan desain pada Gambar 4.23 berikut :

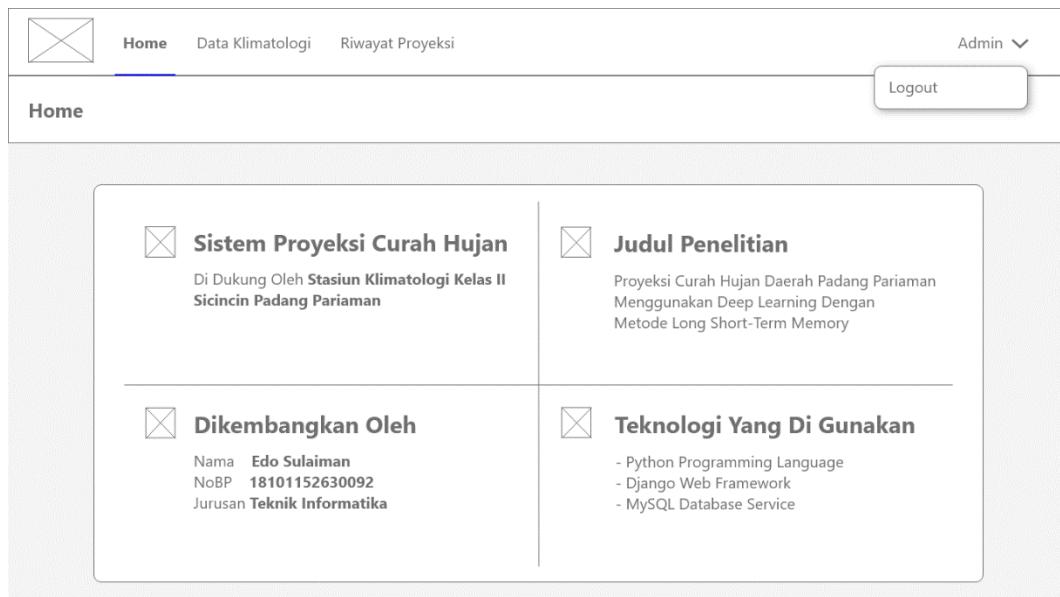


Gambar 4.23. Desain Halaman *Login*

Pada Gambar 4.23 di atas terdapat *form input email* dan password untuk authentikasi *admin* agar sistem dapat mengirimkan informasi data *login* ke *server*.

4.2.2.2. Desain Halaman *Home*

Setelah *admin* lolos pada tahap autentikasi *admin* masuk pada halaman *home* sebagai landasan halaman untuk menelusuri halaman sistem lainnya. Seperti yang terlihat pada rancangan desain pada Gambar 4.24 berikut :



Gambar 4.24. Desain Halaman *Home*

Pada Gambar 4.24 halaman *home* merupakan halaman landasan yang memperlihatkan tentang sistem yang di gunakan, terdapat tombol *logout* di opsi *dropdown* pada sudut kanan atas apabila *admin* ingin keluar dan mengakhiri sesi akses sistem yang sedang berlangsung.

4.2.2.3. Desain Daftar Tabel Data Klimatologi

Halaman Data Klimatologi berbentuk daftar tabel dari Data Klimatologi, di mana *admin* dapat melihat potongan-potongan dari keseluruhan data berbentuk tabel. Seperti yang terlihat pada rancangan desain pada Gambar 4.25 berikut :

The screenshot shows a web-based application interface for managing climate data. At the top, there's a navigation bar with links for Home, Data Klimatologi (which is the active page), and Riwayat Proyeksi. On the right side of the top bar, there are Admin dropdown menus and a Logout button. Below the navigation, the title "Data Klimatologi" is displayed next to a "Tambah Data" (Add Data) button. The main content area features a table with the following columns:

No	Tanggal	Tn	Tx	Tavg	RH_avg	RR	ss	ff_x	ddd_x	ff_avg	ddd_car	Aksi
int	Date	double	varchar(3)	Button								

At the top left of the table area, there are buttons for "Show" and a dropdown menu set to "10 entries". To the right, there is a search input field labeled "Search".

Gambar 4.25. Desain Daftar Tabel Data Klimatologi

Pada Gambar 4.25 terdapat tombol Tambah data apabila *admin* ingin melakukan penambahan Data Klimatologi, kemudian juga terdapat *input search* dan *show option* yang dapat membantu *admin* dalam mencari data yang di kelola dan terdapat kolom aksi agar *admin* dapat menghapus atau beubah data dari baris tabel yang bersangkutan.

4.2.2.4. Desain *Form* Tambah Data Klimatologi

Admin langsung berpindah ke halaman Tambah Data Klimatologi apabila *admin* melakukan aksi klik tombol Tambah data pada halaman daftar tabel Data Klimatologi seperti yang terlihat pada Gambar 4.25. Pada halaman Tambah data inilah *admin* dapat mengisi informasi data yang di tambahkan. Seperti yang terlihat pada rancangan desain pada Gambar 4.26 berikut :

The screenshot shows a web-based climate data management system. At the top, there's a navigation bar with links for Home, Data Klimatologi (which is highlighted in blue), and Riwayat Proyeksi. On the far right of the nav bar are Admin, Logout, and a dropdown menu. Below the nav bar, the main content area has tabs for Data Klimatologi and Tambah Data. The current view is the 'Tambah Data Klimatologi' (Add Climate Data) screen. The form itself is titled 'Tambah Data Klimatologi'. It contains several groups of input fields. One group for 'Tanggal' (Date) has a datepicker input and a checkbox. Another group for 'Temperatur Min.' (Minimum Temperature) has a text input. Similar groups follow for 'Temperatur Max.', 'Temperatur Mean.', 'Kelembapan Mean.', 'Curah Hujan' (Rainfall), and 'Lama Sinar Matahari' (Solar Radiation). To the right of these are groups for 'Kecepatan Angin Max.' (Maximum Wind Speed) and 'Arah Angin Max.' (Maximum Wind Direction), each with two text input fields. At the bottom right of the form is a large 'Kirim' (Send) button.

Gambar 4.26. Desain *Form* Tambah Data Klimatologi

Pada Gambar 4.26 terdapat *input form* tanggal bertipe *datepicker* dan selainnya merupakan *input form text* dan terdapat 1 tombol kirim untuk mengirimkan informasi permintaan Tambah data ke *server*.

4.2.2.5. Desain *Form* Edit Data Klimatologi

Apabila *admin* mengakses tombol edit data pada kolom aksi pada tabel yang terdapat pada Gambar 4.25 *admin* langsung di alihkan ke halaman edit Data Klimatologi. Seperti yang terlihat pada rancangan desain pada Gambar 4.27 berikut :

The screenshot shows a web-based application interface for editing climate data. At the top, there's a navigation bar with links for Home, Data Klimatologi (which is highlighted in blue), and Riwayat Proyeksi. On the right side of the top bar, there are 'Admin' dropdown and 'Logout' buttons. Below the navigation, the main content area has a title 'Data Klimatologi' and a 'Tambah Data' button. The central part is titled 'Edit Data Klimatologi'. It contains two columns of input fields. The left column includes fields for Tanggal (Date), Temperatur Min. (Minimum Temperature), Temperatur Max. (Maximum Temperature), Temperatur Mean. (Mean Temperature), Kelembapan Mean. (Mean Humidity), Curah Hujan (Rainfall), and Lama Sinar Matahari (Length of Daylight). The right column includes fields for Kecepatan Angin Max. (Maximum Wind Speed), Arah Angin Max. (Maximum Wind Direction), Kecepatan Angin Mean. (Mean Wind Speed), Arah Angin Terbanyak (Most Frequent Wind Direction), and a 'Kirim' (Send) button. All fields are filled with specific values.

Kategori	Parameter	Nilai	
Tanggal	19/06/1998		
Temperatur Min.	22.0	Arah Angin Max.	270.0
Temperatur Max.	32.0	Kecepatan Angin Mean.	
Temperatur Mean.	25.4	Arah Angin Terbanyak	W
Kelembapan Mean.	88.0		
Curah Hujan	0.0		
Lama Sinar Matahari	7.4		

Gambar 4.27. Desain *Form Edit Data Klimatologi*

Pada Gambar 4.27 *form input text* dan *datepicker* secara otomatis terisi sesuai dengan data dari tombol edit yang di akses pada daftar tabel Data Klimatologi sebelumnya.

4.2.2.6. Desain Tabel Riwayat Proyeksi

Halaman Riwayat Proyeksi berbentuk daftar tabel dari Riwayat Proyeksi, di mana *admin* dapat melihat potongan-potongan dari keseluruhan data berbentuk tabel. Seperti yang terlihat pada rancangan desain pada Gambar 4.28 berikut :

The screenshot shows a web-based application interface. At the top, there is a navigation bar with icons for Home, Data Klimatologi, Riwayat Proyeksi (which is highlighted in blue), Admin (with a dropdown arrow), and Logout. Below the navigation bar, there is a sub-navigation menu with 'Proyeksi' and 'Buat Proyeksi'. The main content area features a table titled 'Riwayat Proyeksi'. The table includes a header row with columns for 'No', 'Range', 'Epoch', 'Batch', 'TimeStep', 'Layer Size', 'Unit Size', 'Dropout', 'L Rate', 'Train', 'Predict', 'MSE', and 'Aksi'. The body of the table has 10 rows, each containing 14 cells. The first two cells in each row are labeled 'int' and 'text'. The last cell in each row is labeled 'Button'. There are also search and show options at the top of the table.

No	Range	Epoch	Batch	TimeStep	Layer Size	Unit Size	Dropout	L Rate	Train	Predict	MSE	Aksi
int	text	int	int	int	int	int	double	double	double	double	double	Button

Gambar 4.28. Desain Tabel Riwayat Proyeksi

Pada Gambar 4.28 terdapat tombol Buat Proyeksi apabila admin ingin melakukan Proyeksi baru Data Klimatologi, kemudian juga terdapat *input search* dan *show option* yang dapat membantu admin dalam mencari data yang di kelola dan terdapat kolom aksi agar admin memilih detail dari bari data Riwayat Proyeksi yang di pilih.

4.2.2.7. Desain *Form* Buat Proyeksi

Halaman Proyeksi berbentuk *form input*, di mana *admin* dapat membuat opsi untuk prediksi yang di lakukan oleh sistem. Seperti yang terlihat pada rancangan desain pada Gambar 4.28 berikut :

The screenshot shows a web-based application interface for project management. At the top, there's a navigation bar with links for Home, Data Klimatologi, Riwayat Proyeksi (which is highlighted in blue), Admin, and Logout. Below the navigation, there are two main buttons: 'Proyeksi' and 'Buat Proyeksi'. The main content area is titled 'Proyeksi Hyperparameter' and contains a form with the following fields:

Panjang Timestep	2	Nilai Dropout	0.0
Max Epoch	50	Tanggal Mulai Training	01/01/1985 <input type="checkbox"/>
Ukuran Batch	1	Tanggal Akhir Training	12/31/2021 <input type="checkbox"/>
Jumlah Hidden Layers	1	Jumlah Prediksi ke Depan	5
Jumlah Units	1	Feature Prediksi	(RR) Curah Hujan <input checked="" type="checkbox"/>
Nilai Learning Rate	0.1	Feature Training	(RR) Curah Hujan <input checked="" type="checkbox"/>

At the bottom right of the form is a 'Kirim' button.

Gambar 4.29. Desain Form Buat Proyeksi

Pada Gambar 4.28 terdapat *input form* tanggal bertipe *datepicker* dan *input form select option* bertipe opsi text untuk memilih *feature* data untuk training dan *feature* data untuk Prediksi dan selainnya merupakan *input form text* dan terdapat 1 tombol kirim untuk mengirimkan nilai *hyperparameter* yang sudah di *inputkan* sehingga bisa di kirim permintaan ke *server* untuk di lakukan sebuah proyeksi.

4.2.2.8. Desain Hasil Proyeksi Data

Setelah *admin* membuat opsi untuk prediksi dan klik tombol kirim seperti yang terlihat pada Gambar 4.28 *admin* di harapkan untung menunggu beberapa menit hingga proses *training* model dan prediksi mode selesai hingga mendapatkan respons dari *server*. Seperti yang terlihat pada rancangan desain pada Gambar 4.30 berikut :

The screenshot shows a web-based project management or data analysis interface. At the top, there's a navigation bar with links for Home, Data Klimatologi, Riwayat Proyeksi (selected), Admin, and Logout. Below the navigation is a sub-menu with Proyeksi and Buat Proyeksi options. The main content area is titled 'Hasil Proyeksi Data' and contains a table of hyperparameters and their values. To the right of the table, a progress bar indicates the completion of a training batch. The table data is as follows:

Opsi	Value	Training Model....
Panjang Timestep	2	Predict Selected: : rr
Max Epoch	50	X Train Shape : (... , ... , ...)
Ukuran Batch	1	Y Train Shape : (... , ...)
Jumlah Hidden Layers	1	
Jumlah Units	1	Starting Training with Tensor 3D (N, F, S) : (... , ... , ...)
Nilai Learning Rate	0.1	
Nilai Dropout	0.0	Start Epoch 1/50
Jumlah Prediksi ke Depan	Jan 1, 1985	Training Batch .../... [██████████] 100.0% Complete - loss: 0.09876
Jumlah Prediksi ke Depan	Dec 31, 2021	
Jumlah Prediksi ke Depan	5	

Gambar 4.30. Desain Hasil Proyeksi Data

Pada Gambar 4.30 respons hasil Proyeksi terlihat dalam bentuk detail nilai *hyperparameter* yang di *inputkan* sebelumnya dan juga catatan garis waktu proses algoritma Proyeksi berjalan mulai dari *preprocessing* data, *training* model, *testing* model, Prediksi model. Untuk hasil akhir di tampilkan bentuk grafik statistik sehingga lebih menarik untuk di lihat dan di pahami, mulai dari data asli, hasil *training*, hasil *testing*, maupun hasil Prediksi, nilai *error* hasil *training* dan *testing* data juga di tampilkan pada bagian akhir dari halaman hasil Proyeksi.

BAB V

IMPLEMENTASI DAN PENGUJIAN

5.1. Implementasi Sistem

Implementasi Sistem merupakan tahap dalam alur siklus hidup mengembangkan sistem. Sebuah implementasi diperlukan agar perancangan *interface* dan penelitian kode program sesuai dengan sistem yang dirancang ataupun yang telah di analisa sebelumnya.

Untuk melakukan atau mengimplementasikan program aplikasi yang telah dirancang, maka diperlukan sebuah alat bantu berupa komputer, yang mana untuk mengoperasikan komputer itu sendiri yang memerlukan tiga buah komponen pendukung seperti *hardware*, *software*, dan *brainware*.

5.1.1. *Hardware*

Hardware yang di gunakan dalam implementasikan program yang telah dirancang berupa satu *unit* komputer atau laptop yang lengkap keseluruhan perangkatnya. Berikut Spesifikasi minimum dari Perangkat Keras / *Hardware* yang di butuhkah dalam menjalankan sistem sebagai berikut :

- a) CPU Quad Core @ 2.00GHz, atau lebih
- b) *Memory* RAM 4GB, atau lebih
- c) Partisi Penyimpanan 20GB, atau lebih

5.1.2. *Software*

Untuk menjalankan sistem yang dirancang harus menggunakan beberapa dependensi dan *software* pendukung, beberapa *software* pendukung yang harus di

instal berfungsi untuk tempat menjalankan sistem tersebut. Berikut beberapa Versi Perangkat Lunak / *Software* yang di butuhkah dalam menjalankan sistem sebagai berikut :

- a) Sistem Operasi *Windows 7* 64-bit, atau lebih
- b) Bahasa Pemrograman *Python* v.3.6.0 s/d v.3.9.0
- c) MySQL Ver 8.0, atau lebih

5.1.3. *Brainware*

Brainware merupakan *operator* yang berfungsi untuk mengoperasikan atau menjalankan program. Seorang *operator/brainware* dalam sistem ini diharapkan memiliki pengalaman dalam mengoprasikan komputer sekaligus memiliki pengetahuan dalam hal kecerdasan buatan terutama dalam permasalahan jaringan syaraf tiruan. Ketiga komponen di atas memiliki komponen abstrak dari susunan sistem komputer dan *hardware* dan memiliki fungsi jika digunakan bersama-sama dengan *software* sedangkan *brainware* adalah orang yang mengoperasikan program, tanpa *brainware* komputer tidak bisa beroperasi.

5.1.4. Lingkungan Implementasi

Dalam implementasi dan pengujian peneliti menggunakan beberapa perangkat keras dan perangkat lunak dan Bahasa pemograman *python* termasuk beberapa *module* beserta dependensi yang di butuhkah dalam Bahasa pemograman *python* yang di gunakan dalam penelitian ini sebagai berikut :

5.1.4.1. Perangkat Keras (*Hardware*)

Perangkat Keras yang di gunakan untuk menunjang proses implementasi pembuatan program dan pengujian sistem yang menggunakan perangkat *device*

laptop dengan spesifikasi hardware atau perangkat keras yang di jabarkan sebagai berikut :

- a) Laptop ASUS Model A445LAB
- b) CPU Intel® Core™ i3-5005U CPU @ 2.00GHz (4 CPUs)
- c) *Memory* RAM 12GB
- d) Partisi Penyimpanan Samsung SSD 870 EVO 250GB
- e) GPU Intel(R) HD Graphics 5500

5.1.4.2. Perangkat Lunak (*Software*)

Perangkat Lunak atau *Software* yang di gunakan untuk menunjang proses implementasi pembuatan program dan pengujian sistem menggunakan beberapa software sistem operasi, web browser, *database*, dan Bahasa pemogramma yang di jabarkan sebagai berikut :

- a) Sistem Operasi *Windows* 11 Pro 64bit (Build 22000.778)
- b) Google Chrome (64-bit)
- c) Bahasa Pemrograman *Python* v 3.9.0 (64-bit)
- d) MySQL Ver 8.0.23 (64-bit)

5.1.5. Proses Instalasi

Dalam tahap implementasi dan perancangan sistem yang di rancang diperlukannya sebuah sistem operasi *windows*, *software* dan *module* atau dependensi pendukung untuk Bahasa pemograman python yang digunakan sebagai *web server* untuk mengetahui hasil dari sistem yang sudah dibuat.

5.1.5.1. Tahap Instalasi Bahasa Pemrograman Python

Python merupakan Bahasa pemrograman interpretatif, versi yang di gunakan merupakan versi 3.9.0 yang dapat di download *website* resmi *python* di www.python.org, Perlu di lakukan instalasi dan konfigurasi terlebih dahulu agar bahasa pemrograman *python* dapat berjalan pada perangkat yang di gunakan. Adapun tahap instalasi dan konfigurasinya sebagai berikut :

- 1) Klik 2 kali pada tampilan logo *file Windows Installer Package Python* versi 3.9.0 yang sudah terdownload pada *web browser* di *website* resmi *software python programming language* www.python.org, seperti tampilan Gambar 5.1 di bawah ini.

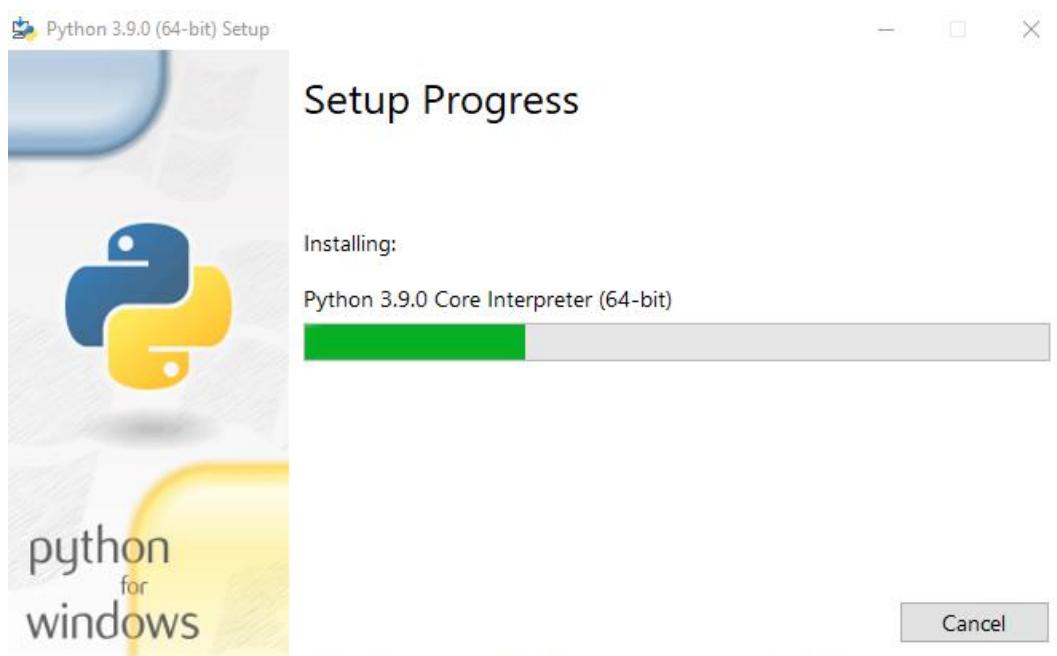


Gambar 5.1. Antarmuka Awal Instalasi Python

Pada Gambar 5.1 centang opsi *Install launcher for all users (recommended)*, dan centang juga pada opsi *Add Python 3.9 to PATH*, lalu setelah itu langsung klik pada tombol *Install Now* untuk opsi *install bawaan* yang terdapat pada *file*

Windows Installer Package Python, atau memilih opsi *Customize installation* untuk opsi lebih lanjut pada instalasi Bahasa pemrograman *python*, untuk penelitian ini peneliti memilih opsi *Install Now*.

- 2) Kemudian proses instalasi dari pilihan opsi instalasi *Install Now* pada *file installer Bahasa permograman python* di mulai, tunggu hingga beberapa saat hingga proses bar proses instalasi selesai, proses instalasi terlihat seperti Gambar 5.2 di bawah ini :

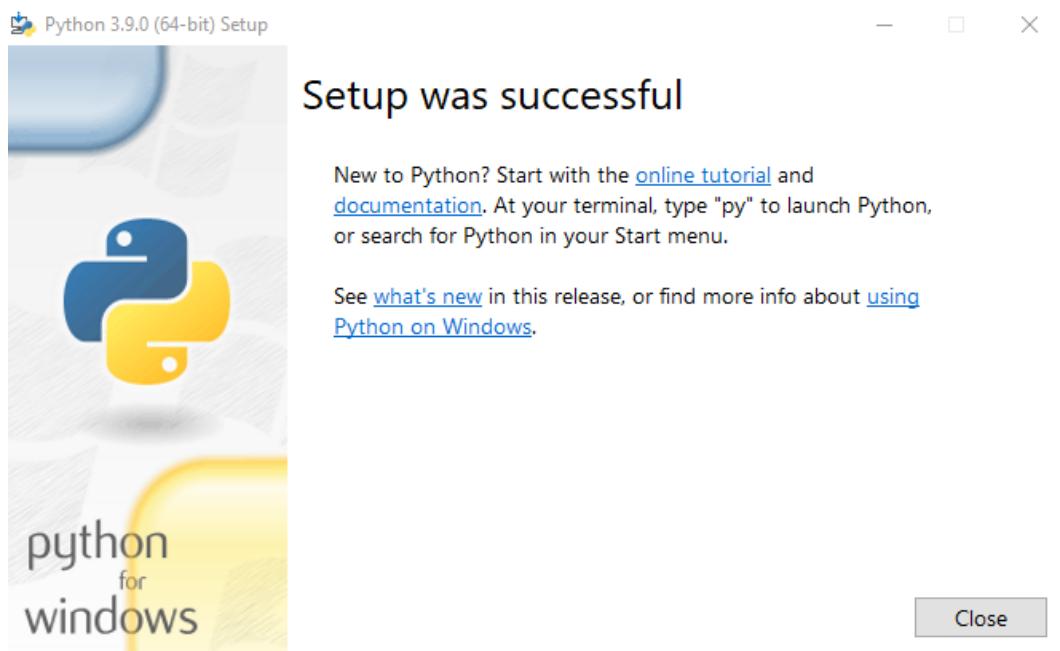


Gambar 5.2. Antarmuka Bar Proses Instalasi Python

Pada Gambar 5.2 proses instalasi yang berjalan akan memakan waktu hingga beberapa menit maupun beberapa saat, tergantung kecepatan *processor* dan spesifikasi hardware atau perangkat keras dari sistem yang di gunakan pada proses instalasi Bahasa Pemrograman *Python*.

- 3) Terakhir ketika proses instalasi Bahasa pemrograman *pyhton* telah sukses di install. Tampilan antarmuka file instalasi Bahasa Pemograman *Python*

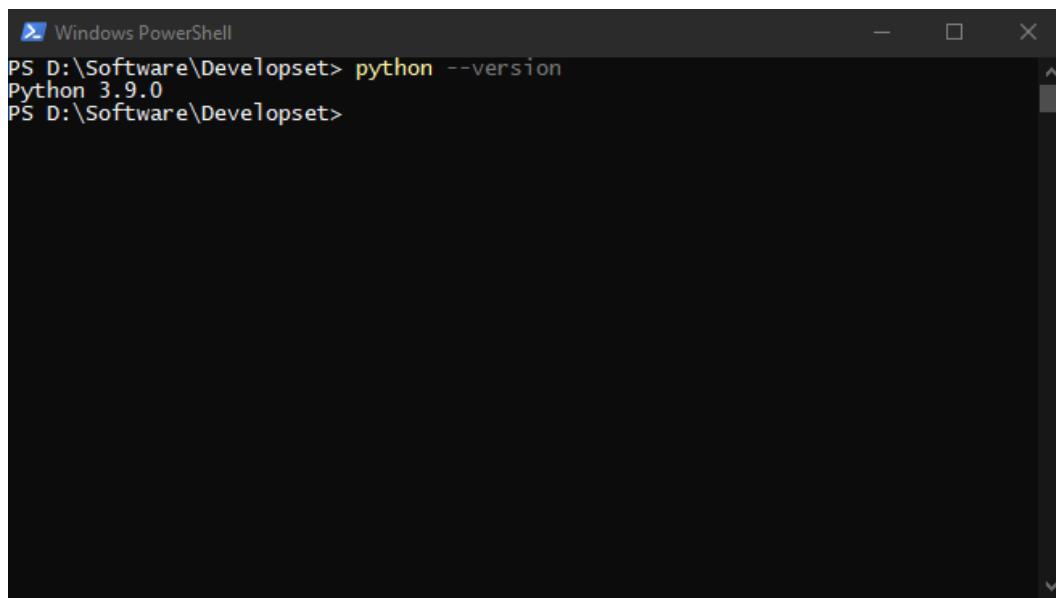
menampilkan antarmuka instalasi yang terlihat seperti pada Gambar 5.3 di bawah ini :



Gambar 5.3. Antarmuka Installasi *Python* Berhasil

Ketika proses instalasi sudah selesai tampil seperti Gambar 5.3 dimana Bahasa pemrograman *pyhton* sudah terinstall di dalam sistem yang di implementasikan, selanjutnya dapat menutup proses inatallasi dengan menklik *Close*, atau memilih beberapa opsi seperti *online tutorial*, *documentation* untuk petuntuk dalam penggunaan Bahasa Pemograman *Python*.

- 4) Untuk memastikan *Python* sudah terinstal dan *Python PATH* sudah terdaftar pada *windows environment variables* dapat di lihat dengan memberikan sebuah perintah pada terminal pada sistem operasi yang di gunakan, seperti yang terlihat pada Gambar 5.4 berikut.



```
Windows PowerShell
PS D:\Software\Developset> python --version
Python 3.9.0
PS D:\Software\Developset>
```

Gambar 5.4. Perintah Melihat Versi *Python* yang Terinstall

Untuk melihat versi Bahasa pemrograman *python* yang terinstall seperti pada Gambar 5.4 dapat di lakukan dengan membuka program *powershell* atau *command prompt* bawaan *windows 11*, lalu ketik memerapa perintah seperti “*python –version*” untuk menampilkan versi Bahasa pemrograman *python* yang terinstall.

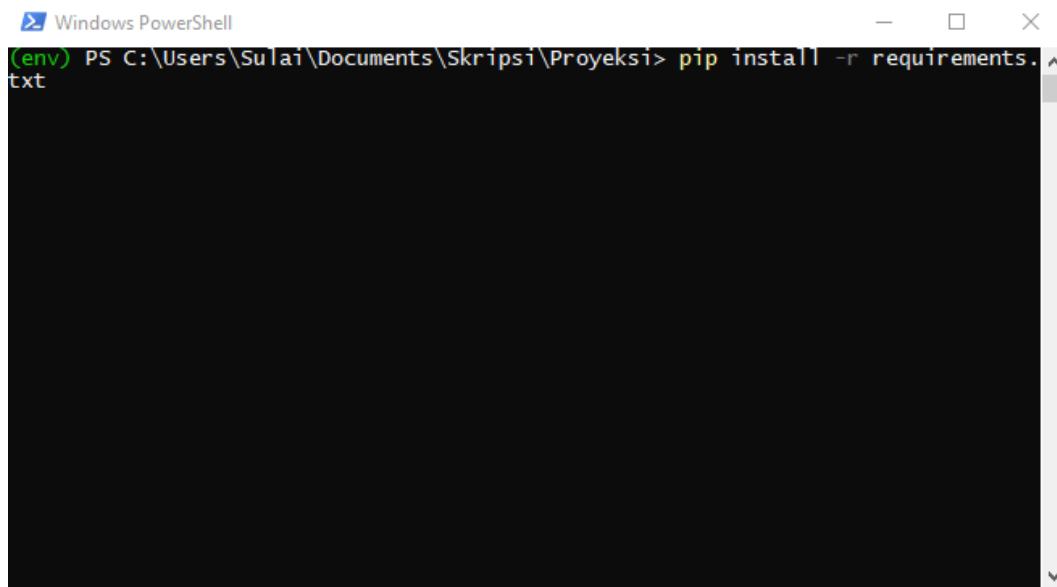
5.1.5.2. Tahap Instalasi *Module Dependensi Python*

Module pada *python* merupakan blok-blok kode yang memiliki peran peran tertentu biasanya memiliki nama tersendiri, yang bertugas untuk menyelesaikan satu set perintah tertentu, bisa di anggap sebagai pekakas tertentu yang dapat di panggil dari bagian program manapun. Adapun tahap instalasi dan konfigurasinya sebagai berikut :

- 1) Pertama sekali persiapkan terminal yang akan di gunakan seperti *command prompt*, *powershell*, *linux bash*, *unix shell*, dan lain-lain, sebagai contoh

peneliti yang di sini menggunakan *software terminal powershell* bawaan sistem operasi *Windows 11 profesional*.

- 2) Kemudian masuk ke direktori tempat program sistem di simpan, contohnya pada *powershell* peneliti meletakan program sistem pada lokasi direktori “*C:\Users\Sulai\Documents\Skripsi\Proyeksi*” dimana tempat direktori *root* dari program yang di rancang.
- 3) Lalu ketika terminal sudah berada di dalam direktori *root* tempat program sistem yang di rancang di letakkan, selanjutnya ketik perintah “*pip install -r requirements.txt*”, lalu tekan *Enter* pada keyboard, seperti yang terlihat pada Gambar 5.5 berikut :

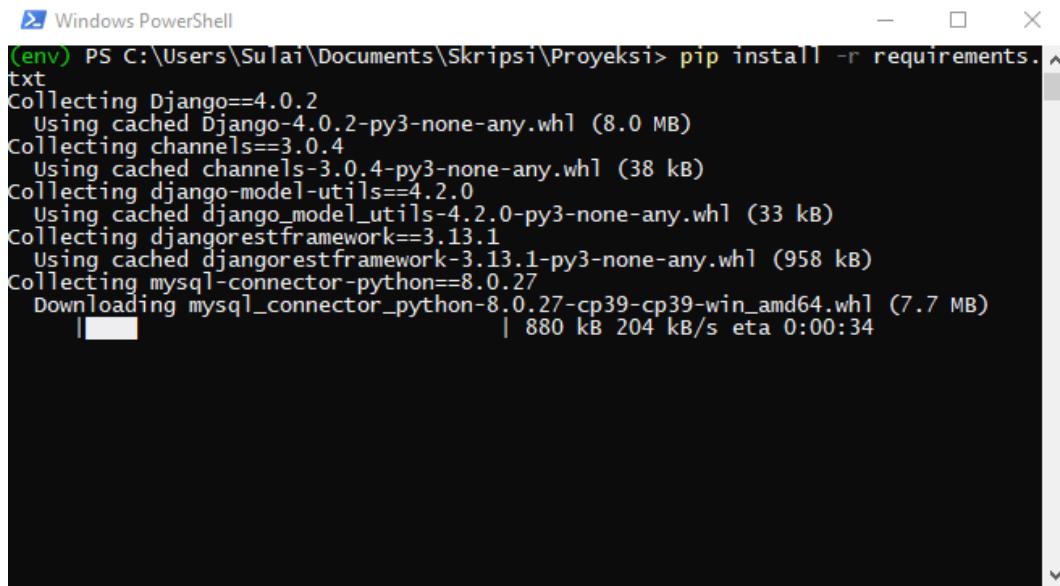


A screenshot of a Windows PowerShell window titled "Windows PowerShell". The window shows a command being typed: "(env) PS C:\Users\Sulai\Documents\Skripsi\Proyeksi> pip install -r requirements.txt". The rest of the window is black, indicating that the command has been entered but no output is yet visible.

Gambar 5.5. Perintah Untuk Menginstall *Module Python* yang di Butuhkan

Pada Gambar 5.5 ketika menjalankan perintah “*pip install -r requirements.txt*” seperti yang terlihat, pastikan terdapat file bernama “*requirements.txt*” sebagai referensi *library* dari *module* yang akan di install, yang terdapat di direktori *root* atau dimana tempat terminal mengeksekusi perintah.

- 5) Kemudian saat muncul tampilan *bar* installasi *module* pada layar laptop, tunggu beberapa saat hingga tergantung kecepatan internet yang di gunakan hingga bar pada proses instalasi benar-benar selesai dan tanpa muncul notifikasi pesan *error*, seperti Gambar 5.6 yang ada di bawah ini :



```
(env) PS C:\Users\Sulai\Documents\Skripsi\Proyeksi> pip install -r requirements.txt
Collecting Django==4.0.2
  Using cached Django-4.0.2-py3-none-any.whl (8.0 MB)
Collecting channels==3.0.4
  Using cached channels-3.0.4-py3-none-any.whl (38 kB)
Collecting django-model-utils==4.2.0
  Using cached django_model_utils-4.2.0-py3-none-any.whl (33 kB)
Collecting djangorestframework==3.13.1
  Using cached djangorestframework-3.13.1-py3-none-any.whl (958 kB)
Collecting mysql-connector-python==8.0.27
  Downloading mysql_connector_python-8.0.27-cp39-cp39-win_amd64.whl (7.7 MB)
    |██████████| 880 kB 204 kB/s eta 0:00:34
```

Gambar 5.6. Python Melakukan Installasi *Module* Yang di Butuhkan

Pada Gambar 5.6 proses installasi memerlukan jaringan koneksi internet dimana kecepatan installasi berpengaruh pada kualitas jaringan yang di gunakan sekaligus spesifikasi hardware dari sistem yang di gunakan, agar proses installasi dapat berjalan dengan cepat dan lancar, ketika proses installasi sudah selesai tanpa muncul notifikasi pesan *error* apapun maka proses installasi *module python* di anggap sudah selesai.

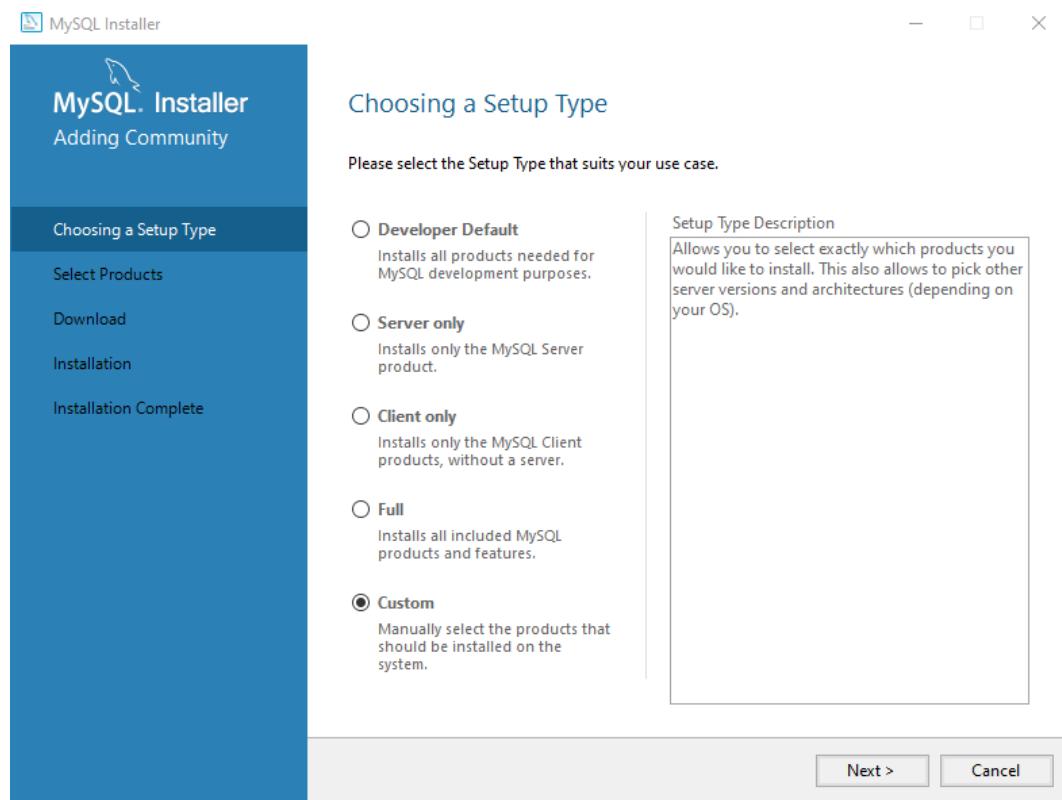
5.1.5.3. Tahap Instalasi MySQL

Python merupakan Bahasa pemrograman interpretatif, versi yang di gunakan merupakan versi 3.9.0 yang dapat di download website resmi *python* di dev.mysql.com, Perlu di lakukan instalasi dan konfigurasi terlebih dahulu agar

bahasa pemrograman *python* dapat berjalan pada perangkat yang di gunakan.

Adapun tahap instalasi dan konfigurasinya sebagai berikut :

- 1) Klik 2 kali pada file *Windows Installer Package MySQL Community* versi 8.0.23.0 yang sudah di download pada website resmi MySQL di dev.mysql.com/downloads/inslatter dan tampil antarmuka seperti Gambar 5.1 di bawah ini.

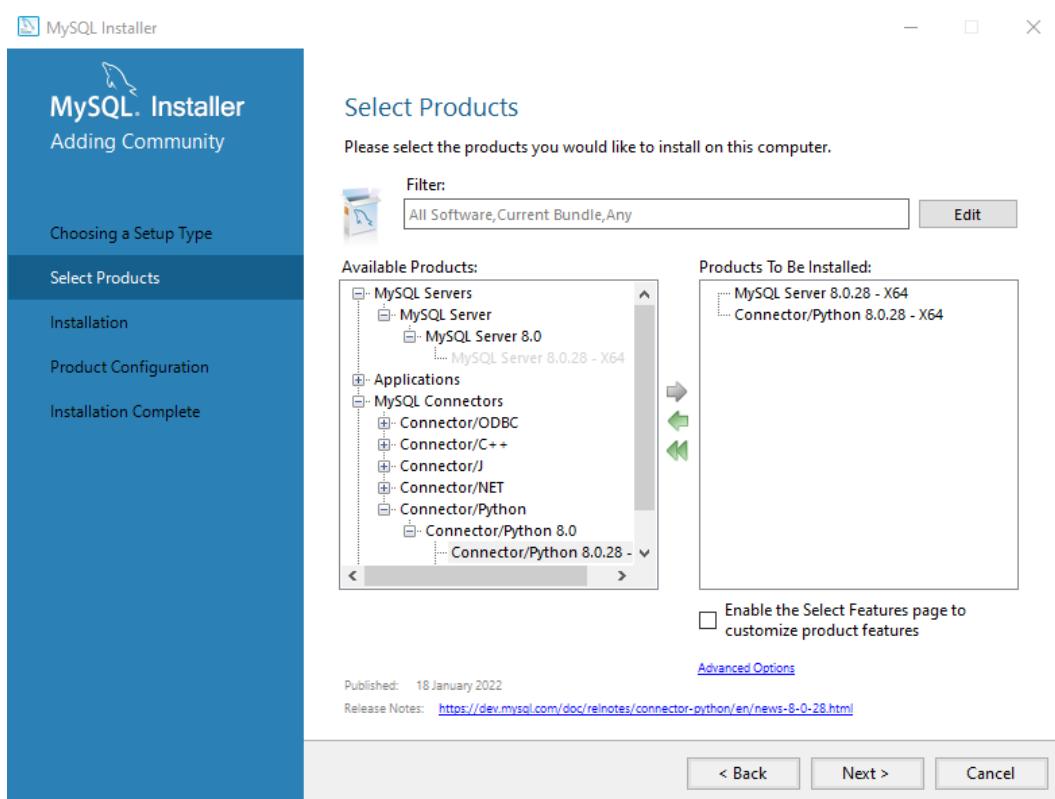


Gambar 5.7. Antarmuka Awal Instalasi MySQL

Pada Gambar 5.7 centang pada opsi *Developer Default* untuk mode installasi semua produk yang di butuhkan untuk tujuan pengembangan menggunakan MySQL, memilih opsi *Server Only* apabila hanya ingin menginstall produk MySQL Server, memilih opsi *Client Only* apabila hanya ingin menginstall produk MySQL Client dan beberapa *feature* pendukung, atau memilih opsi *Full* apabila

ingin menginstall semua produk MySQL Community dan seluruh *feature* pendukung, atau opsi terakhir *Custom* untuk menginstall, untuk penelitian ini peneliti akan menginstall MySQL Community dengan memilih opsi *Custom* untuk opsi installasi, setelah itu untuk menyeleksi pada produk aplikasi mysql yang akan di install, selanjutnya klik pada tombol *Next* di atas untuk lanjut di tahap berikutnya.

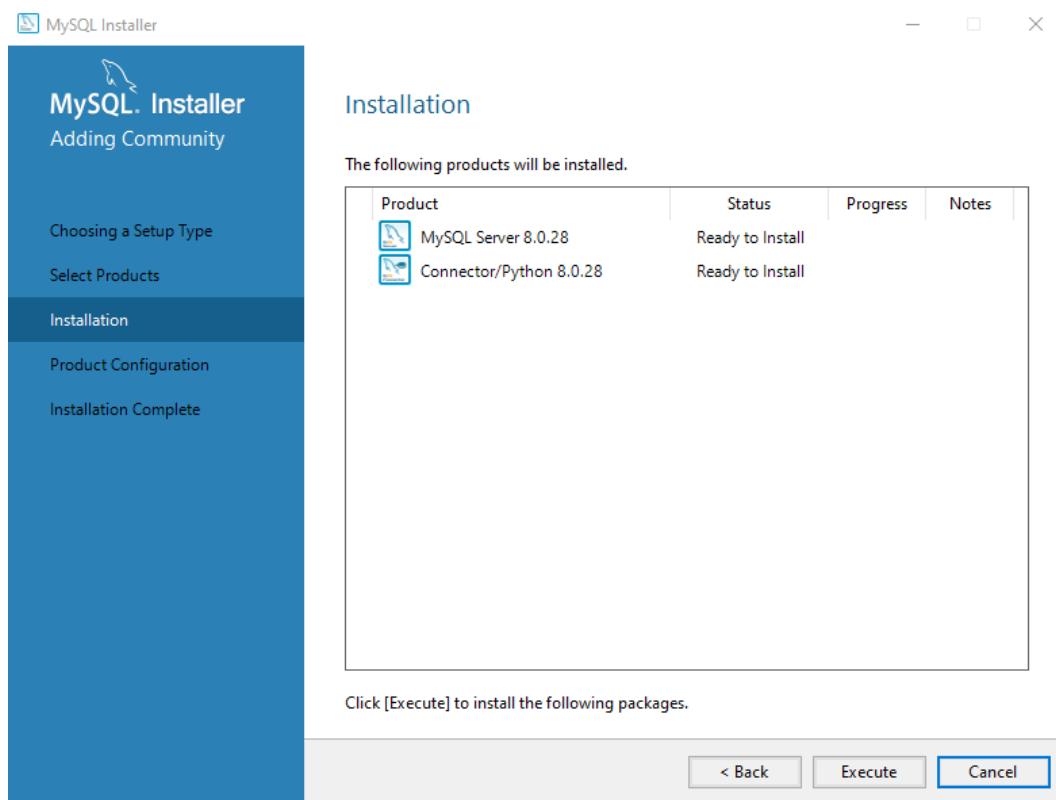
- 2) Kemudian saat muncul antarmuka atau tampilan berikutnya yaitu adalah antarmuka *select products* untuk menentukan feature dan produk dari MySQL *Installer Community* yang akan di install pada sistem yang di implementasikan, seperti pada Gambar 5.8 di bawah ini :



Gambar 5.8. Antarmuka Select Products pada Instalasi MySQL

Pada Gambar 5.8 terlihat beberapa product mysql yang dapat di install ke dalam sistem, untuk implementasi dalam penelitian ini product yang di butuhkan hanya berupa *MySQL Server 8.0.28 – X64* dan *Connector/Python 8.0.28 – X62*, setelah di lakukan seleksi product, tahap selanjutnya klik *Next*.

- 3) Setelah saat proses seleksi pada produk telah selesai di lakukan kemudian pada tahap selanjutnya installer langsung mengarahkan antarmuka installasi ke dalam antarmuka konfirmasi *installation* seperti yang akan terlihat pada Gambar 5.9 berikut ini.

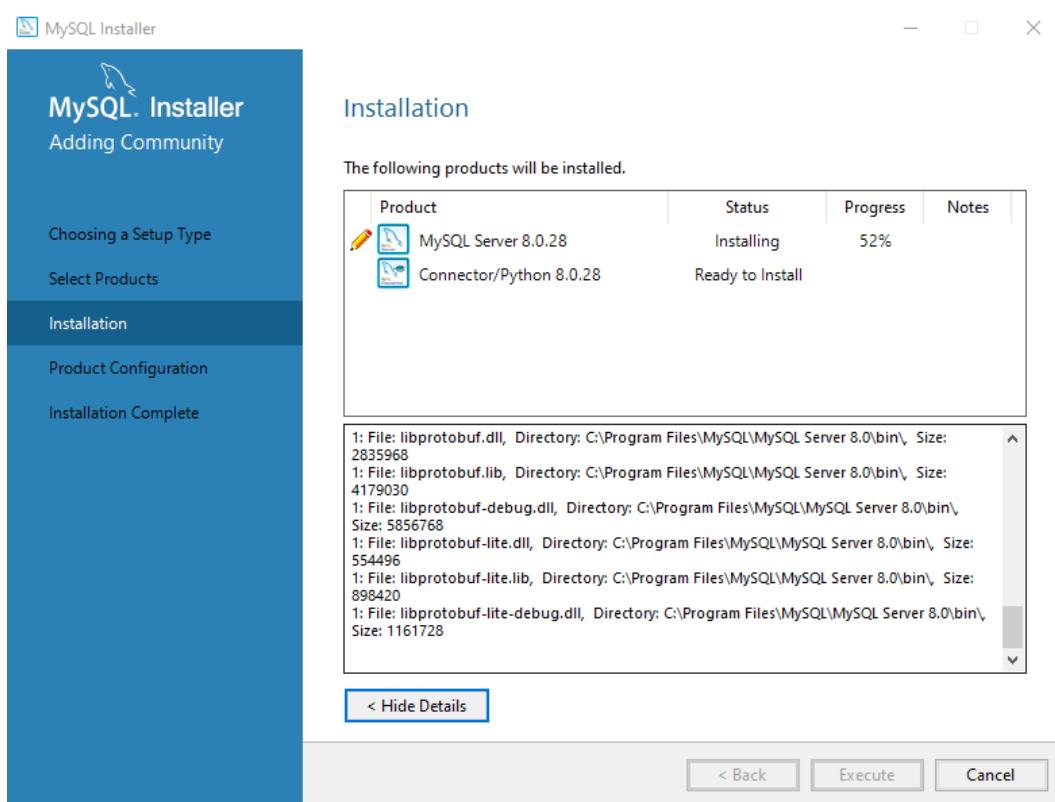


Gambar 5.9. Antarmuka Installation pada MySQL

Pada Gambar 5.9 terlihat hasil seleksi product dari proses sebelumnya dimana *MySQL Installer* memastikan produk yang di install tersedia dalam 1 *pack* installer yang di download yang bertuliskan *Ready to Install*, apabila versi yang di

ambil tidak terdapat dalam *pack* installer yang di download maka status bertuliskan Download yang menandakan product tersebut harus di download untuk di install. Setelah semua persiapan sudah lengkap tahap selanjutnya melakukan install product dengan klik *Execute*.

- 4) Setelah semua opsi sudah sesuai kebutuhan yang di perlukan kemudian tahap selanjutnya klik pada saat tombol *Execute*, maka proses installasi produk MySQL Community 8.0.23.0 berjalan beberapa saat seperti yang akan terlihat pada Gambar 5.10 yang ada berikut ini.

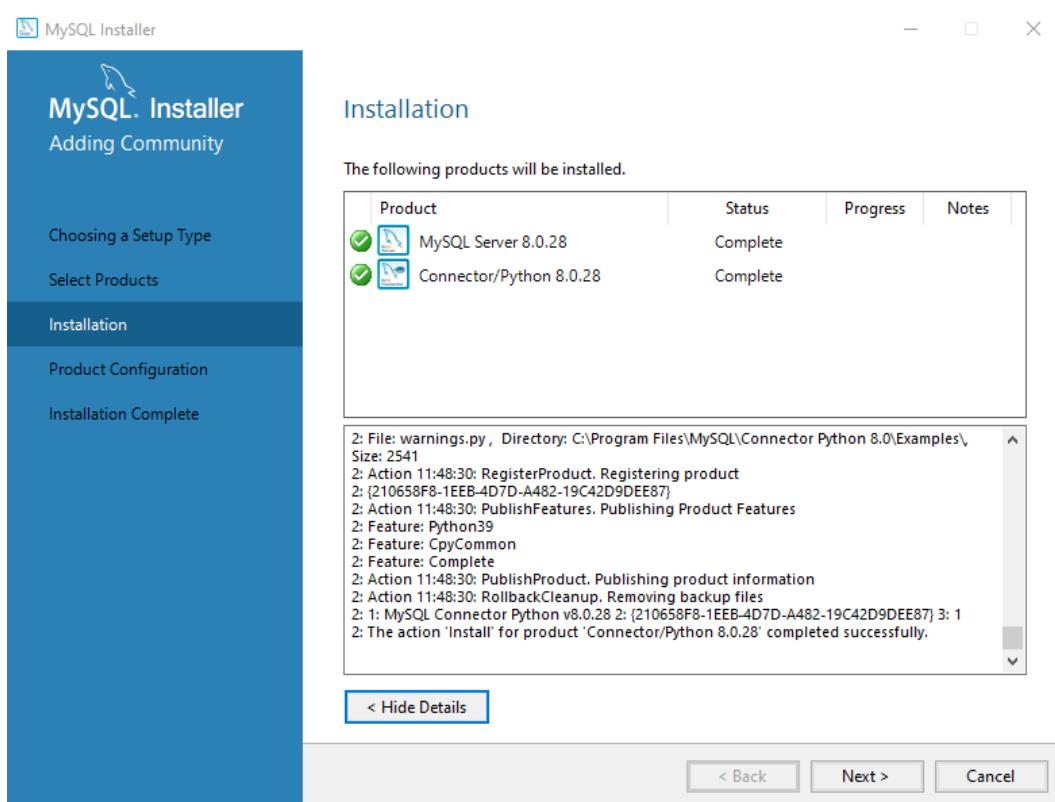


Gambar 5.10. Antarmuka Proses Instalasi MySQL

Pada Gambar 5.10 yang terlihat proses akan installasi memakan waktu hingga beberapa menit tergantung spesifikasi hardware atau perangkat keras pada sistem yang di implementasikan, apabila installasi membutuhkan download tulisan

installing pada kolom status akan berubah menjadi *downloading* maka di butuhkan koneksi internet pada proses instalasi hingga proses selesai.

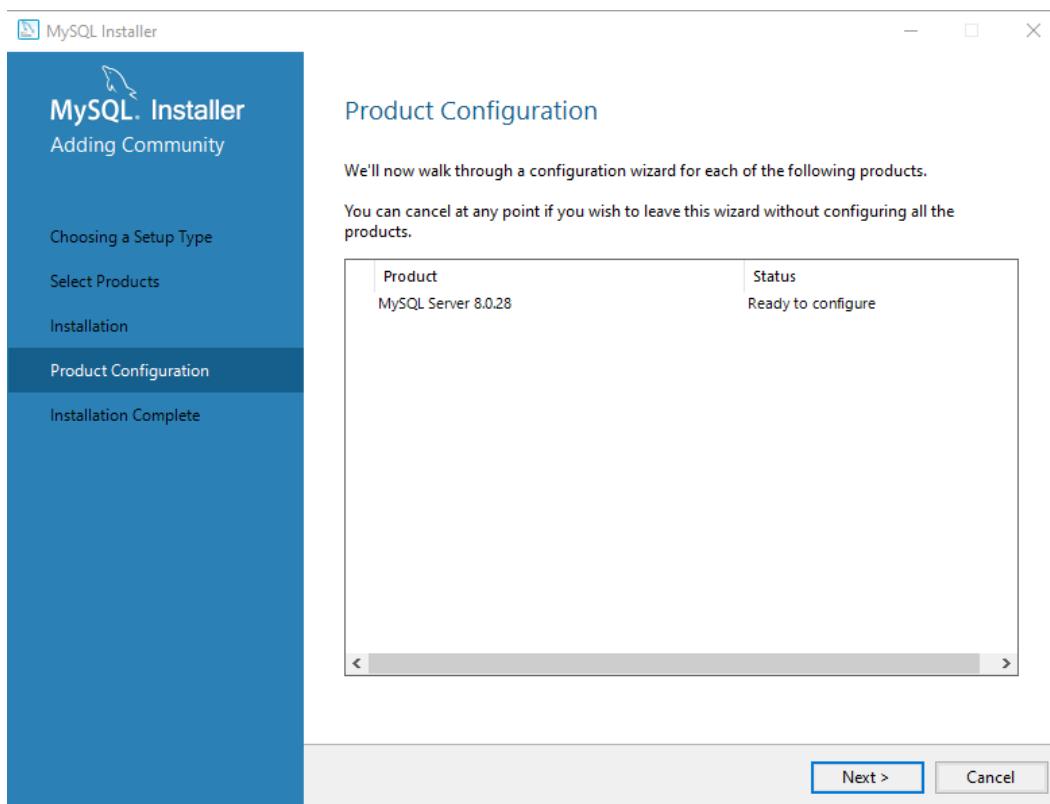
- 5) Setelah saat proses instalasi produk MySQL Community 8.0.28 selesai maka pada kolom status produk yang selesai di install bertuliskan *Complete*, maka proses instalasi pada produk tertentu dianggap sudah selesai seperti yang terlihat pada Gambar 5.11 yang ada berikut ini.



Gambar 5.11. Antarmuka Instalasi Produk MySQL Berhasil

Pada Gambar 5.11 proses instalasi sudah dapat dikatakan selesai dikarenakan semua produk yang di install pada kolom status sudah bertuliskan *Complete* yang menandakan proses instalasi produk yang di inginkan telah berhasil, kemudian lanjut ke tahap selanjutnya dengan klik *Next*.

- 6) Pada tahap yang selanjutnya semua produk MySQL Community 8.0.28 yang di install harus melakukan persiapan beberapa konfigurasi sistem maupun konfigurasi authentikasi sesuai produk yang di install seperti yang terlihat pada Gambar 5.12 yang ada berikut ini.

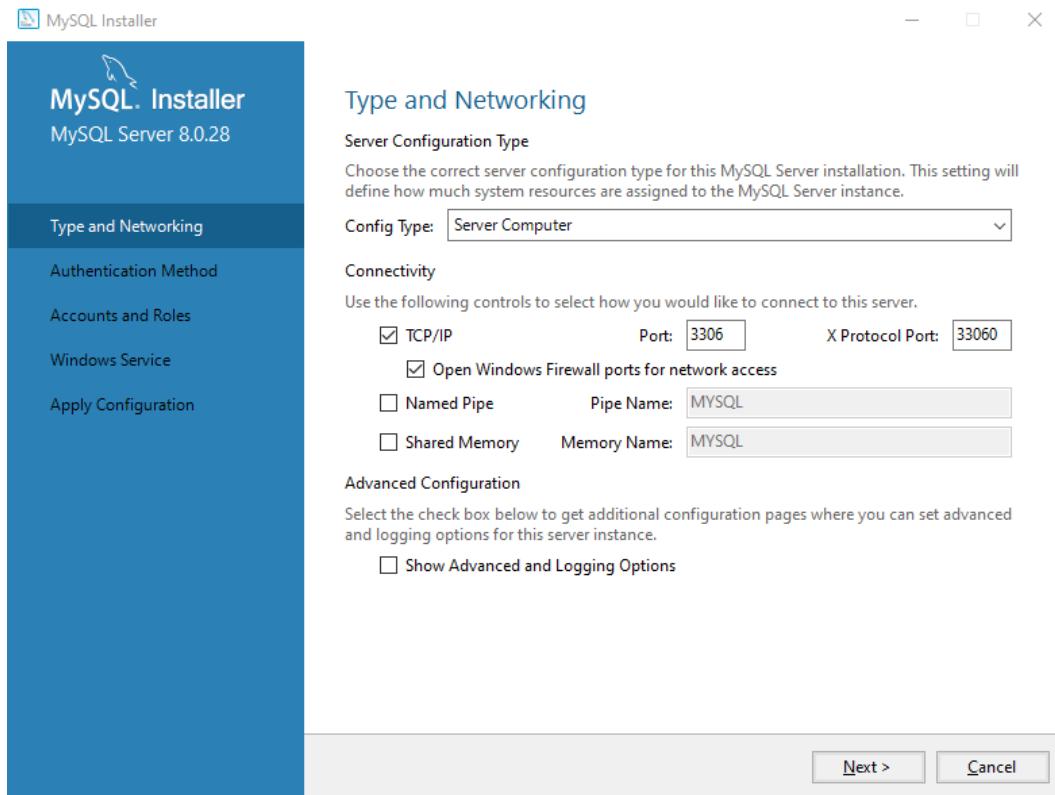


Gambar 5.12. Antarmuka Permintaan Konfiguasi Setelah Instalasi MySQL

Pada Gambar 5.12 terlihat beberapa produk yang di install memerlukan konfirmasi untuk konfigurasi awal seperti konfigurasi sistem maupun konfigurasi authentikasi untuk produk *MySQL Server 8.0.28* seperti yang terlihat pada Gambar 5.12, untuk melanjut ke tahap konfigurasi klik *Next*.

- 7) Saat menu konfigurasi tampil sesuai opsi produk yang di install maka akan tampil halaman konfigurasi sistem maupun konfigurasi authentikasi pada

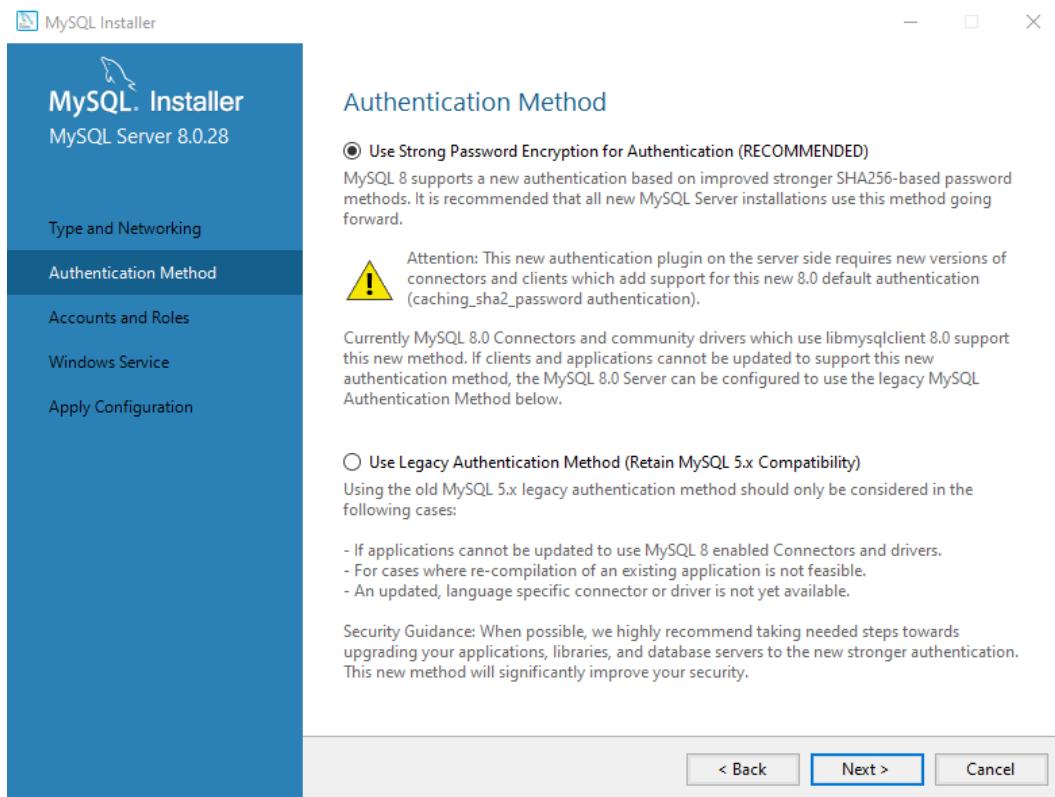
antarmuka installasi dari konfirmasi tahap sebelumnya, seperti yang akan terlihat pada Gambar 5.13 berikut.



Gambar 5.13. Antarmuka *Type and Networking* Pada Installasi MySQL

Seperti yang terlihat pada Gambar 5.13 beberapa konfigurasi perlu di atur sesuai kebutuhan yang di inginkan, untuk penelitian ini peneliti mengkonfigurasi *Config Type* sebagai *Server Computer* untuk konfigurasi lainnya di biarkan sebagai pengaturan bawaan, kemudian untuk lanjut ke tahap selanjutnya klik *Next*.

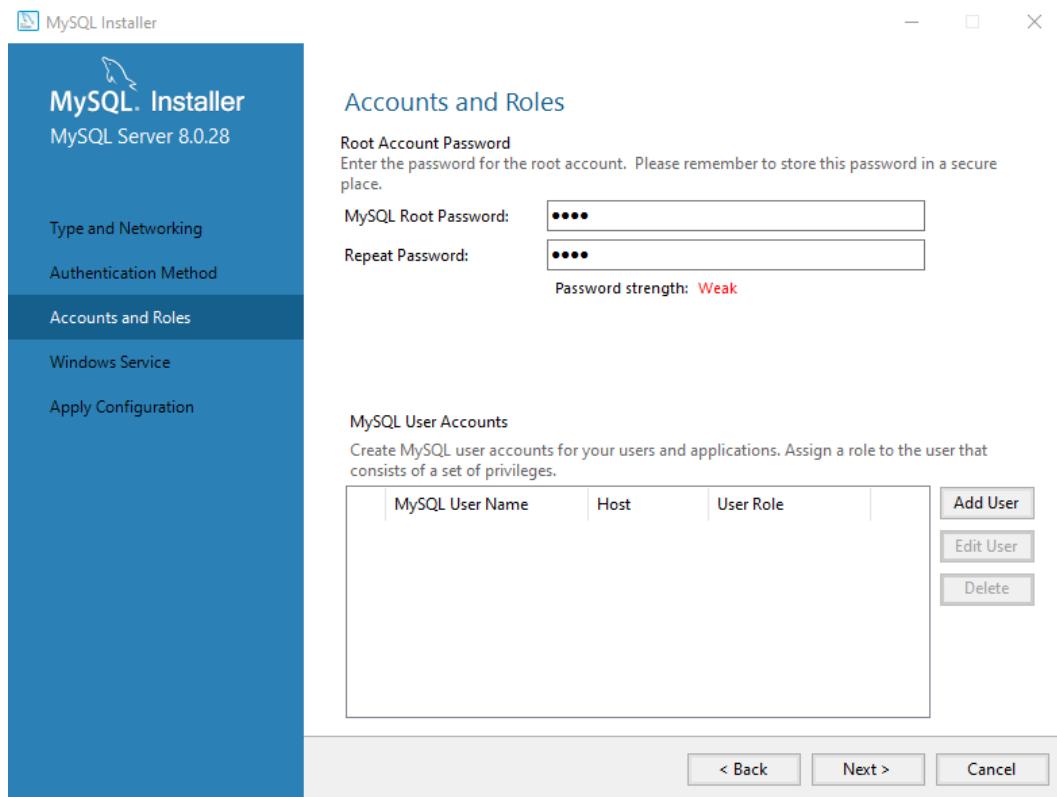
- 8) Setelah tahap konfigurasi *Type and Networking* selesai di lakukan kemudian pada tahap selanjutnya melakukan konfigurasi *Authentication Method* untuk proses authentikasi produk MySQL yang di gunakan, seperti yang terlihat pada Gambar 5.14 berikut.



Gambar 5.14. Antarmuka Authentication Method Pada Instalasi MySQL

Pada Gambar 5.14 diperlukan konfigurasi authentikasi untuk menggunakan product *MySQL Server 8.0.28* dengan memilih tipe enkripsi yang di gunakan sesuai versi MySQL yang di dukung, untuk penelitian ini peneliti memilih *Use String Password Encryption for authentication (RECOMMENDED)* dari tipe enkripsi autentikasi yang di gunakan, kemudian untuk lanjut ke tahap selanjutnya klik *Next*.

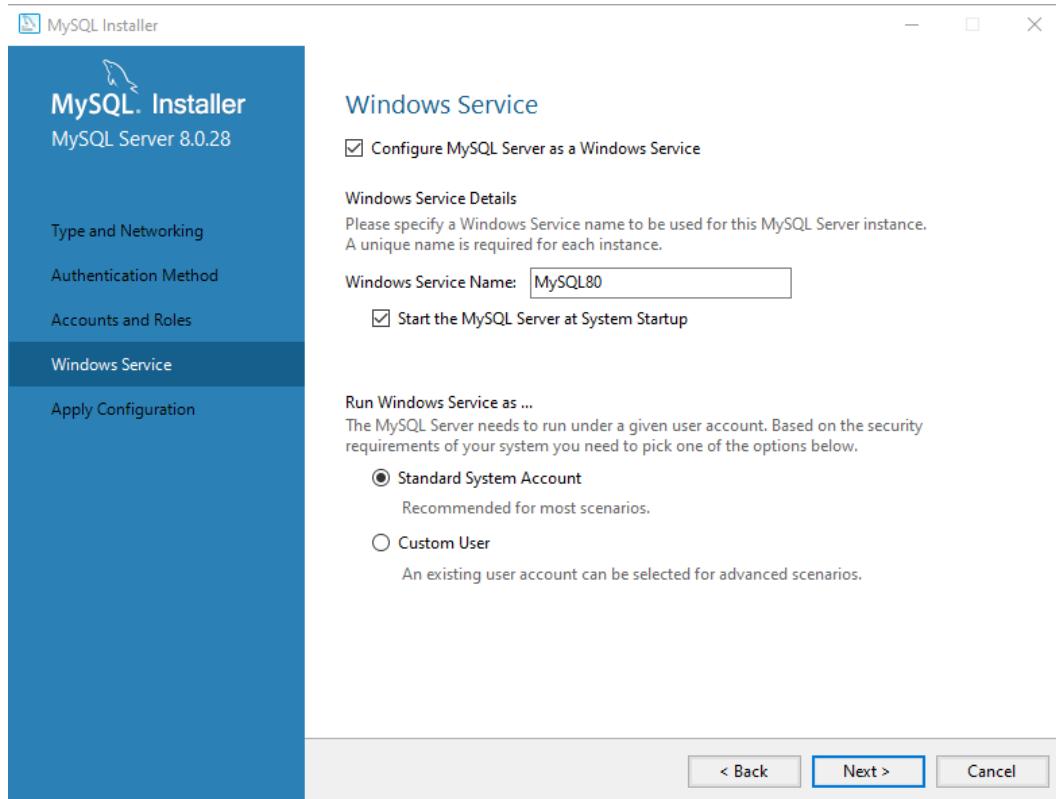
- 9) Setelah memilih tipe Encripsi dari proses authentikasi yang ingin di gunakan maka tahap selanjutnya installer langsung menampilkan antarmuka *Accounts and Roles* untuk mengelola beberapa akun termasuk akun *root* untuk proses authentikasi, seperti yang terlihat pada Gambar 5.15 berikut.



Gambar 5.15. Antarmuka Accounts and Roles Pada Instalasi MySQL

Pada Gambar 5.15 diperlukan pengisian *MySQL Root Password* yang digunakan untuk authentikasi product *MySQL Server 8.0.28* dan pengisian *Repeat Password* untuk memastikan password yang dimasukkan tidak ada kekeliruan pada submenu *MySQL User Accounts* dapat membuat beberapa termasuk menentukan *privilege* dari beberapa akun yang dibuat sesuai yang diinginkan, untuk lanjut ke tahap berikutnya klik *Next*.

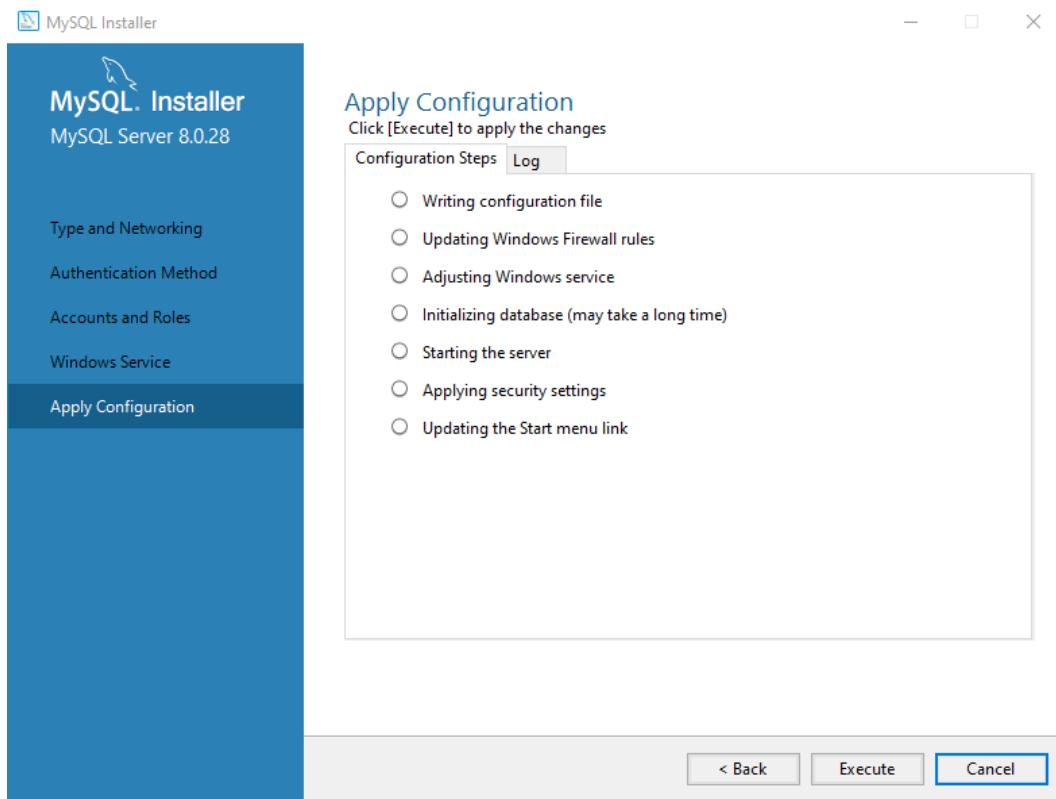
- 10) Setelah berhasil menyimpan *password root* dan memanage beberapa akun sesuai *privilege* masing-masing maka *installer* langsung mengalihkan antarmuka ke halaman konfigurasi sistem seperti konfigurasi *windows service* untuk MySQL Server seperti yang terlihat pada Gambar 5.16 berikut.



Gambar 5.16. Antarmuka Windows Service Pada Installasi MySQL

Pada Gambar 5.16 diperlukan pengisian informasi *windows service* agar program *MySQL Server 8.0.28* dapat berjalan di sebagai latar belakang, dari awal ketika computer di hidupkan hingga komputer di matikan dimana *MySQL Server 8.0.28* otomatis di hidupkan tanpa perlu menghidupkanya secara manual, kemudian ketika sudah klik *Next*.

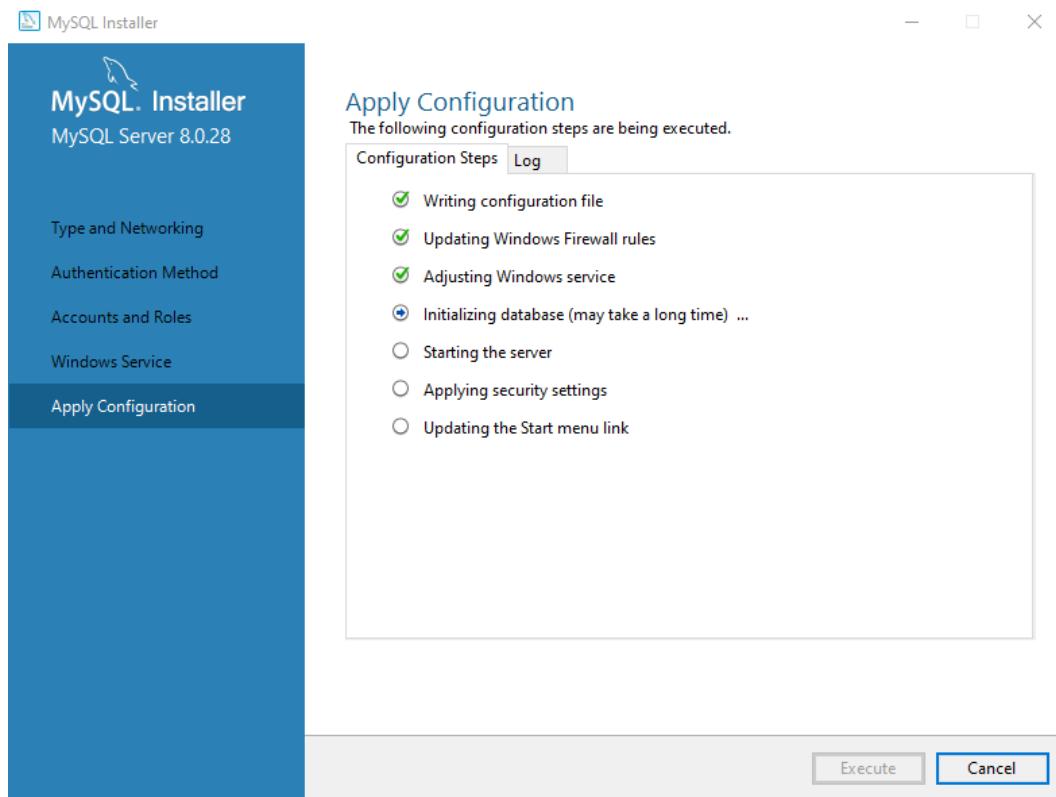
- 11) Saat ketika semua proses konfigurasi mulai dari konfigurasi authentikasi hingga konfigurasi sistem untuk MySQL selesai dilakukan maka *installer* langsung mengalihkan ke halaman antarmuka *Apply Configuration* seperti yang terlihat pada Gambar 5.17 berikut.



Gambar 5.17. Antarmuka Apply Configuration Pada Installasi MySQL

Pada Gambar 5.17 MySQL *Community installer* langsung memperlihatkan beberapa konfigurasi yang telah di atur pada tahap sebelumnya, dimana kemudian MySQL Community Installer memastikan konfigurasi yang di simpan sudah sesuai yang di harapkan, kemudian untuk memproses dan menyimpan konfigurasi yang telah di atur dapat di lakukan dengan klik *Execute*.

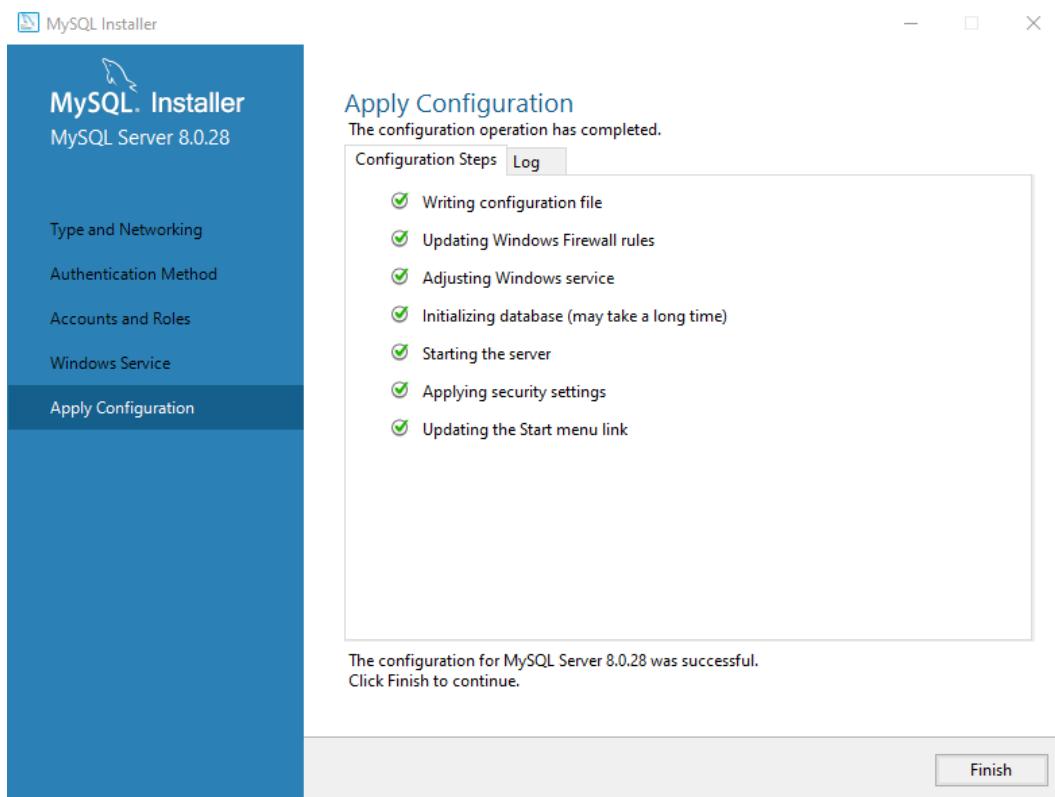
12) Saat setelah memilih Execute pada antarmuka installasi *Apply Configuration* pada tahap sebelumnya kemudian proses pemasangan dan penyimpanan konfigurasi langsung di lakukan beberapa Langkah yang bisa dilihat seperti yang terlihat pada Gambar 5.18 berikut :



Gambar 5.18. Antarmuka Proses Apply Configuration MySQL

Pada Gambar 5.18 terdapat juga proses pemasangan dan penyimpanan konfigurasi yang di lakukan hingga semua opsi di proses telah tercentang hijau, sehingga yang menandakan semua proses konfigurasi diatas telah selesai di lakukan dengan benar.

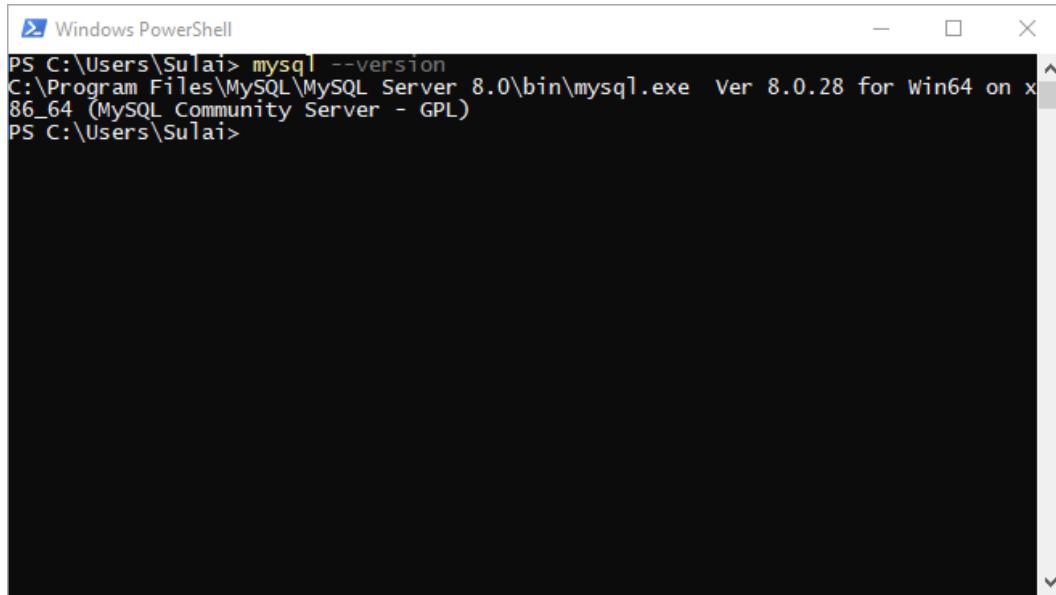
- 13) Setelah mengikuti semua rangkaian penjelasan proses pemasangan dan penyimpanan di dalam penjelasan konfigurasi di atas maka akan tampil semua proses opsi konfigurasi bewarna hijau seperti yang terlihat di bawah ini pada Gambar 5.19.



Gambar 5.19. Antarmuka Instalasi MySQL Selesai

Pada Gambar 5.19 terlihat pesan balasan *The configuration for MySQL Server 8.0.28 was successful. Click Finish to continue* menandakan semua proses telah selesai di lakukan, maka proses installasi dapat di akhiri dengan menekan tombol *Finish*.

- 14) Untuk memastikan *MySQL Server* sudah terinstal dan *MySQL PATH* sudah terdaftar pada *windows environment variabels* dapat di lihat dengan memberikan sebuah perintah pada terminal *windows* seperti yang terlihat pada Gambar 5.20 berikut.

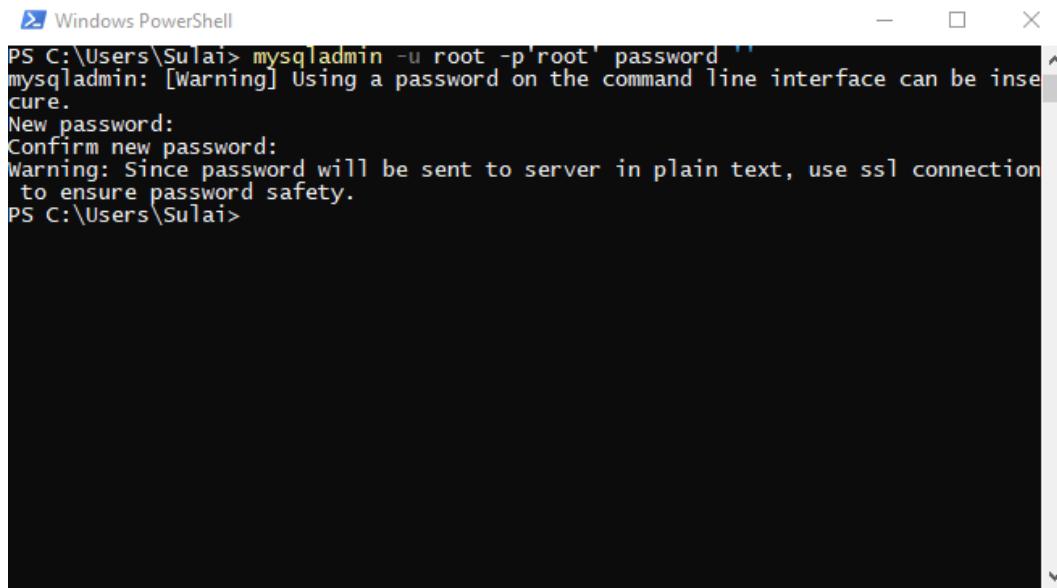


```
PS C:\Users\Sulai> mysql --version
C:\Program Files\MySQL\MySQL Server 8.0\bin\mysql.exe Ver 8.0.28 for Win64 on x
86_64 (MySQL Community Server - GPL)
PS C:\Users\Sulai>
```

Gambar 5.20. Perintah Melihat Versi *MySQL* yang Terinstall

Untuk melihat versi *MySQL Server* yang terinstall dapat di lihat seperti pada Gambar 5.20 dapat di lakukan dengan membuka program *powershell* atau *command prompt* bawaan *windows 11*, lalu ketik memerapa perintah seperti “*mysql –version*”, maka akan untuk versi dari *MySQL Server* yang terinstall di sistem.

- 15) Kemudian setelah mengikuti proses di atas, maka akan tampil tambahan apabila proses authentikasi saat menggunakan *database MySQL* yang di inginkan nantinya tidak menggunakan password dapat di lihat seperti yang terlihat pada Gambar 5.21 berikut.



```
PS C:\Users\Sulai> mysqladmin -u root -p'root' password ''
mysqladmin: [Warning] Using a password on the command line interface can be insecure.
New password:
Confirm new password:
Warning: Since password will be sent to server in plain text, use ssl connection to ensure password safety.
PS C:\Users\Sulai>
```

Gambar 5.21. Antarmuka Awal Instalasi MySQL

Pada Gambar 5.21 terlihat perintah terminal yang berfungsi untuk mengubah password authentikasi untuk menggunakan *database MySQL Server* menjadi kosong seperti yang terlihat dengan mengetik perintah *mysqladmin -u root -p'root' password ''* dengan begitu password untuk authentikasi menjadi kosong.

5.2. Pengujian Sistem

Pengujian system merupakan tahap dalam melakukan sebuah implementasi untuk mengetahui kesalahan dalam sistem. maka diperlukan program komputer yaitu pengujian *interface* dan penelitian kode program sesuai dengan sistem yang dirancang.

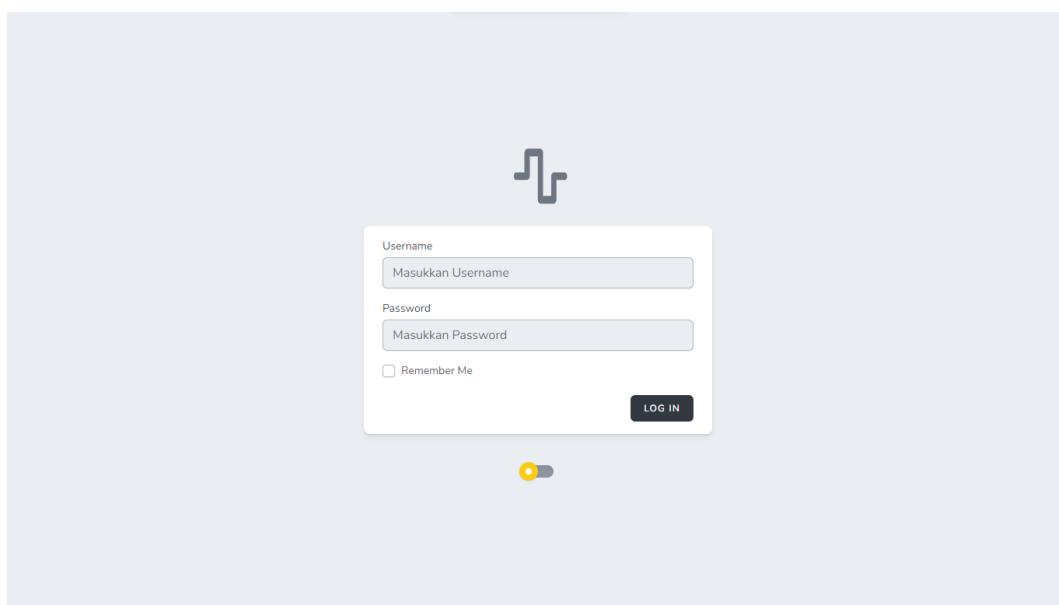
5.2.1. Pengujian *Interface*

Pengujian *interface* merupakan mekanisme komunikasi antara pengguna dengan system, yang meliputi tampilan layer yang menyediakan navigasi di dalam system dilakukan agar interaksi *user* dengan sistem yang telah dibuat dapat berjalan

sebagaimana mestinya. Untuk itu pada bab ini dijelaskan bentuk asli dari tampilan sebenarnya apabila sistem ini diakses oleh *admin*.

5.2.1.1. Interface Halaman *Login*

Halaman *login* adalah tampilan awal kinerja proses di mana *admin* harus melakukan authentikasi terlebih dahulu sebelum memasuki sistem setelah *admin login* maka sistem mengarah ke halaman *home admin*. Seperti yang terlihat pada Gambar 5.22 berikut :



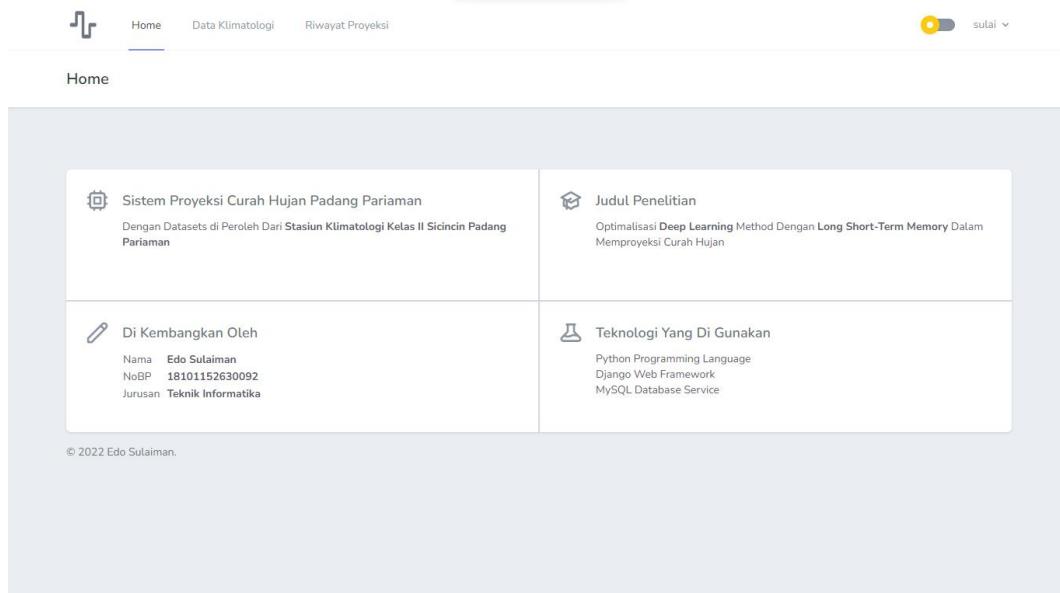
Gambar 5.22. Interface Halaman *Login*

Pada Gambar 5.22 di atas terdapat *form input email* dan password untuk authentikasi *admin* agar sistem dapat mengirimkan informasi data *login* ke *server*, dan juga terdapat *checkbox Remember Me* agar sesi authentikasi *admin* menjadi permanen tanpa ada kadaluarsa sesi authentikasi.

5.2.1.2. Interface Halaman *Home*

Halaman Home adalah tampilan dari halaman utama website, Pada halaman ini adalah proses setelah *admin* lolos pada tahap authentikasi *admin* masuk pada

halaman *home* sebagai landasan halaman untuk menelusuri halaman sistem lainnya. Seperti yang terlihat pada Gambar 5.23 berikut :

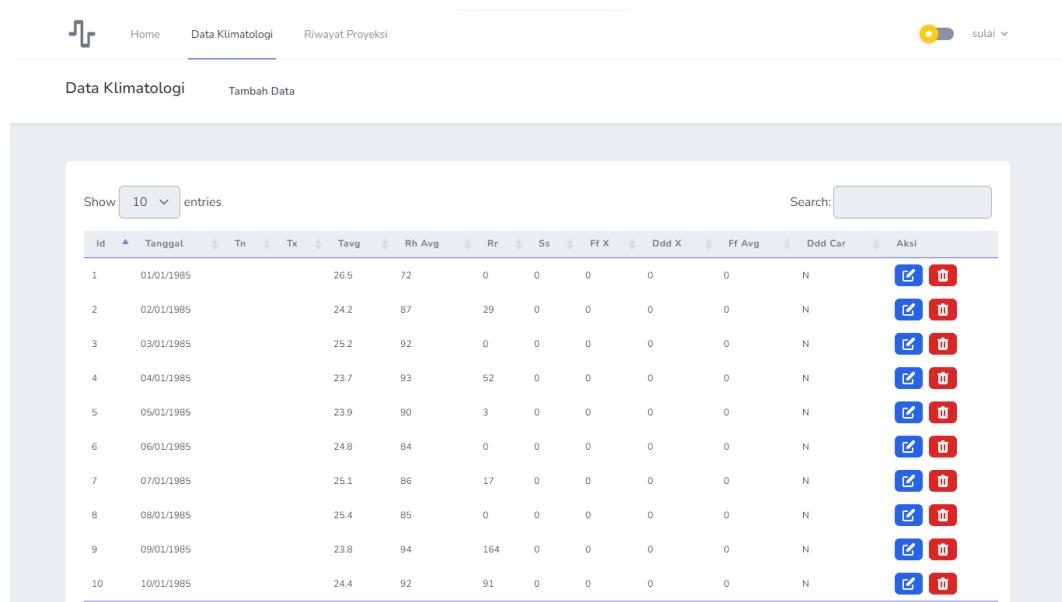


Gambar 5.23. Interface Halaman *Home*

Pada Gambar 5.23 halaman *home* merupakan halaman landasan yang memperlihatkan tentang sistem yang di gunakan, terdapat tombol *logout* di opsi *dropdown* pada sudut kanan atas apabila *admin* ingin keluar dan mengakhiri sesi akses sistem yang sedang berlangsung.

5.2.1.3. Interface Tabel Data Klimatologi

Interface Halaman Data Klimatologi ini berbentuk daftar tabel dari Data Klimatologi, di dalam initerface halaman ini *admin* dapat melihat potongan-potongan dari keseluruhan data berbentuk tabel. Seperti yang terlihat pada Gambar 5.24 berikut :



The screenshot shows a web-based application interface for managing climate data. At the top, there are navigation links: Home, Data Klimatologi (which is the active tab), and Riwayat Proyeksi. On the right side, there is a user profile icon and a dropdown menu labeled 'sulai'. Below the navigation, there are two buttons: 'Data Klimatologi' and 'Tambah Data'. The main content area displays a table with 10 rows of data. The columns are labeled: Id, Tanggal, Tn, Tx, Tavg, Rh Avg, Rr, Ss, Ff X, Ddd X, Ff Avg, Ddd Car, and Aksi. Each row contains numerical values for the first 11 columns and a set of edit (pencil) and delete (trash bin) icons in the last column. The 'Aksi' column is highlighted with a blue border.

Id	Tanggal	Tn	Tx	Tavg	Rh Avg	Rr	Ss	Ff X	Ddd X	Ff Avg	Ddd Car	Aksi	
												<input checked="" type="checkbox"/>	
1	01/01/1985			26.5	72	0	0	0	0	0	N	<input checked="" type="checkbox"/>	
2	02/01/1985			24.2	87	29	0	0	0	0	N	<input checked="" type="checkbox"/>	
3	03/01/1985			25.2	92	0	0	0	0	0	N	<input checked="" type="checkbox"/>	
4	04/01/1985			23.7	93	52	0	0	0	0	N	<input checked="" type="checkbox"/>	
5	05/01/1985			23.9	90	3	0	0	0	0	N	<input checked="" type="checkbox"/>	
6	06/01/1985			24.8	84	0	0	0	0	0	N	<input checked="" type="checkbox"/>	
7	07/01/1985			25.1	86	17	0	0	0	0	N	<input checked="" type="checkbox"/>	
8	08/01/1985			25.4	85	0	0	0	0	0	N	<input checked="" type="checkbox"/>	
9	09/01/1985			23.8	94	164	0	0	0	0	N	<input checked="" type="checkbox"/>	
10	10/01/1985			24.4	92	91	0	0	0	0	N	<input checked="" type="checkbox"/>	

Gambar 5.24. Interface Daftar Tabel Data Klimatologi

Pada Gambar 5.24 terdapat tombol Tambah data apabila *admin* ingin melakukan penambahan Data Klimatologi, dan untuk setiap baris tabel terdapat kolom aksi yang berisi tombol edit data () dan tombol hapus data () untuk mengelola baris data dari tabel data klimatologi, kemudian juga terdapat *input search* dan *show option* yang dapat membantu *admin* dalam mencari data yang di kelola dan terdapat kolom aksi agar *admin* dapat hapus atau edit data dari baris tabel yang bersangkutan.

5.2.1.4. Interface Tambah Data Klimatologi

Pada Halaman Interface *admin* dapat langsung berpindah ke halaman Tambah Data Klimatologi apabila *admin* melakukan aksi klik tombol Tambah data pada halaman daftar tabel Data Klimatologi maka tampil seperti yang terlihat pada Gambar 5.25 berikut :

Gambar 5.25. Interface *Form* Tambah Data Klimatologi

Pada Gambar 5.25 terdapat halaman Tambah data di sinilah *admin* dapat mengisi informasi data yang di tambahkan. Seperti yang terlihat pada Gambar 5.25 *input form* tanggal bertipe *datepicker* dan selainnya merupakan *input form text* dan terdapat 1 tombol kirim untuk mengirimkan informasi permintaan Tambah data ke *server*.

5.2.1.5. Interface Edit Data Klimatologi

Pada Halaman Interface ini *admin* diberikan pilihan untuk dapat mengakses tombol edit data (edit icon) pada kolom aksi pada tabel yang terdapat pada Gambar 5.24 *admin* langsung di alihkan ke halaman edit Data Klimatologi. Seperti yang terlihat pada Gambar 5.26 berikut :

	Tanggal	Temperatur Min.	Temperatur Max.	Temperatur Rata-Rata	Kelembapan Rata-Rata	Curah Hujan	Lama Sinar Matahari	Kecepatan Angin Max	Arah Angin Max	Kecepatan Angin Rata-Rata	Arah Angin Terbanyak
Tanggal	01/01/1985	Tn.	Tx.	26.5	72.0	0.0	0.0	0.0	0.0	0.0	N

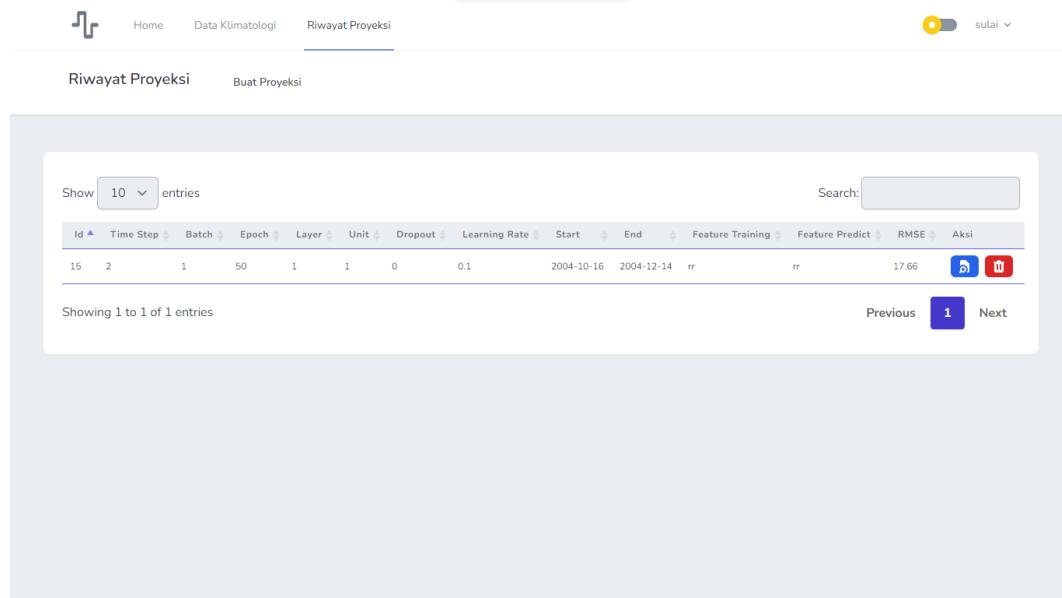
 The 'Tanggal' field is a date input, while the other fields are text inputs. The 'KIRIM' button is a dark blue rectangular button at the bottom right of the form area."/>

Gambar 5.26. Interface Form Edit Data Klimatologi

Pada Gambar 5.26 *form input text* dan *datepicker* secara otomatis terisi sesuai dengan data dari tombol edit yang di akses pada daftar tabel Data Klimatologi sebelumnya, dan terdapat 1 tombol kirim untuk mengirimkan informasi permintaan Edit data ke *server*.

5.2.1.6. Interface Tabel Riwayat Proyeksi

Pada Interface Halaman Riwayat Proyeksi berbentuk daftar tabel dari Riwayat Proyeksi, di mana *admin* diberikan akses untuk dapat melihat potongan-potongan dari keseluruhan data Riwayat proyeksi berbentuk tabel. Seperti yang terlihat pada Gambar 5.27 berikut.



The screenshot shows a web-based application interface for managing project history. At the top, there is a navigation bar with icons for Home, Data Klimatologi, Riwayat Proyeksi, and a user profile icon labeled 'sulai'. Below the navigation bar, the title 'Riwayat Proyeksi' is displayed, along with a 'Buat Proyeksi' button.

The main content area features a table with the following columns: Id, Time Step, Batch, Epoch, Layer, Unit, Dropout, Learning Rate, Start, End, Feature Training, Feature Predict, RMSE, and Aksi. There is one visible row of data:

Id	Time Step	Batch	Epoch	Layer	Unit	Dropout	Learning Rate	Start	End	Feature Training	Feature Predict	RMSE	Aksi	
15	2	1	50	1	1	0	0.1	2004-10-16	2004-12-14	rr	rr	17.66		

Below the table, a message indicates 'Showing 1 to 1 of 1 entries'. At the bottom right, there are buttons for 'Previous', a page number '1' (highlighted in blue), and 'Next'.

Gambar 5.27. Interface Daftar Tabel Riwayat Proyeksi

Pada Gambar 5.27 terdapat tombol Buat Proyeksi apabila admin ingin melakukan Proyeksi baru Data Klimatologi, kemudian juga terdapat *input search* dan *show option* yang dapat membantu admin dalam mencari data yang di kelola dan terdapat kolom aksi agar admin memilih detail dari baris data table Riwayat Proyeksi yang di pilih.

5.2.1.7. Interface Buat Proyeksi

Pada Interface Halaman Buat Proyeksi ini berbentuk *form input*, di mana *admin* diberikan akses untuk membuat opsi atau pilihan untuk melakukan prediksi yang di lakukan oleh sistem ini. Untuk dapat melihat proses nya, dapat dilihat pada Gambar 5.28 berikut ini.

Gambar 5.28. Interface Form Buat Proyeksi

Pada Gambar 5.28 terdapat *input form* tanggal bertipe *datepicker* dan *input form select option* bertipe opsi text untuk memilih *feature* data untuk training dan *feature* data untuk Prediksi, selainnya merupakan *input form text* dan terdapat 1 tombol kirim untuk mengirimkan nilai *hyperparameter* yang sudah di *inputkan* sehingga bisa di kirim permintaan ke *server* untuk di lakukan sebuah proyeksi.

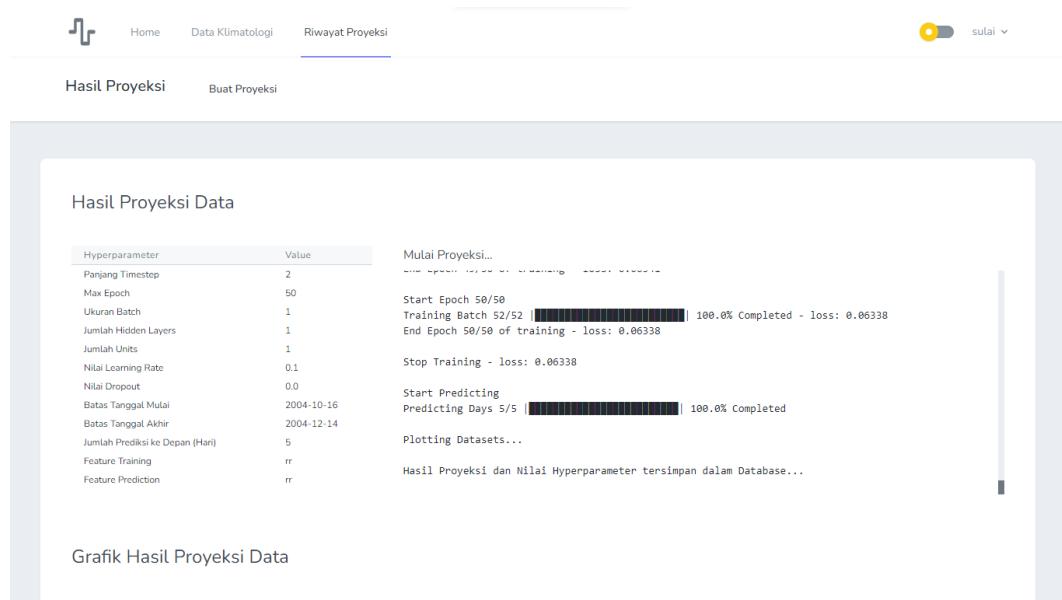
5.2.1.8. Interface Hasil Proyeksi Data

Setelah *admin* membuat opsi untuk prediksi dan klik tombol kirim seperti yang terlihat pada Gambar 5.28 *admin* di harapkan untung menunggu beberapa detik hingga menit tergantung spesifikasi sistem yang di gunakan hingga proses *training* model dan prediksi model selesai hingga mendapatkan respons dari *server*. Seperti yang terlihat pada interface berikut :

5.2.1.8.1. Interface Hasil Proyeksi Hyperparameter dan Timeline Proses

Pada Interface Halaman Hasil Proyeksi pada bagian atas memperlihatkan nilai *hyperparameter* dari yang di *inputkan* sebelumnya seperti yang terlihat pada

Gambar 5.28, dan juga memperlihatkan linimasa proses Proyeksi seperti yang terlihat pada Gambar 5.29 berikut.

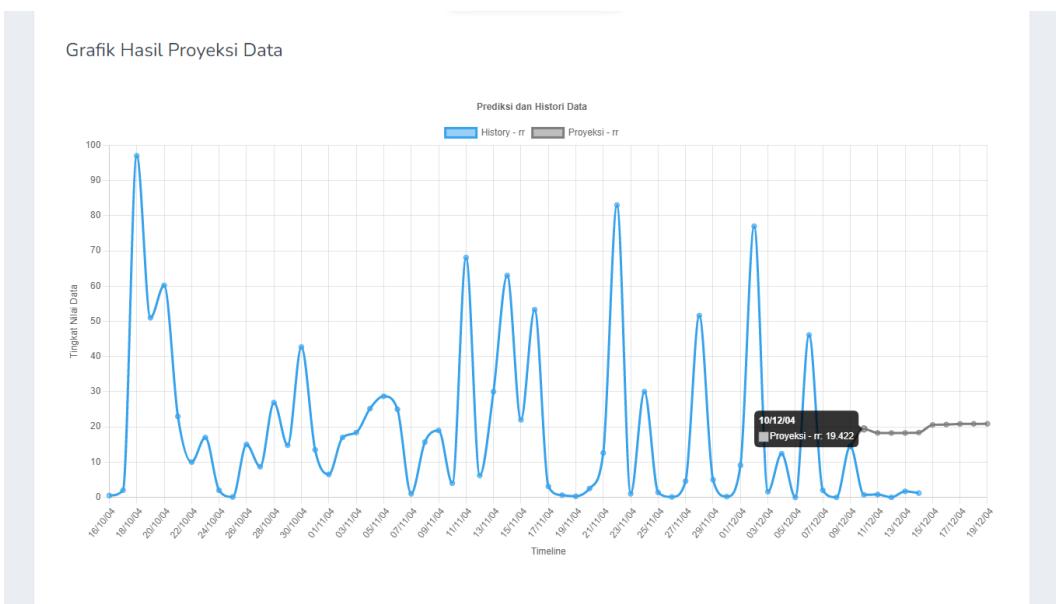


Gambar 5.29. Interface Hyperparameter dan Timeline Proses Proyeksi

Pada Gambar 5.29 respons Hasil Proyeksi terlihat pada linimasa proses Proyeksi di mulai dari pemilihan *feature* training dan *feature* Prediksi, preprocessing data seperti interpolasi data kosong, pembagian data training dan data testing, pembentukan dimensi data berbentuk tensor 3D (*Ukuran batch*, *Jumlah Feature*, dan *Panjang timestep*), kemudian pembentukan model LSTM, dan melatih model LSTM sebanyak *epoch* yang telah di tentukan sebelumnya, kemudian juga linimasa proses Prediksi dari model yang telah di latih.

5.2.1.8.2. Interface Grafik Hasil Proyeksi Data

Pada tampilan *interface* dibawah ini, dapat dilihat sebuah Halaman Hasil Proyeksi pada bagian tengah yang memperlihatkan grafik dari hasil Proyeksi model sebelumnya yang berbentuk grafik garis statistik seperti yang terlihat pada Gambar 5.30 berikut.



Gambar 5.30. Interface Grafik Hasil Proyeksi Data

Pada tampilan halaman interface grafik *statistic* seperti Gambar 5.30 terdapat tampilan garis grafik *History – rr* dari proyeksi data sebenarnya, dan garis grafik *Proyeksi – rr* yang memperlihatkan Hasil Proyeksi data dari model yang telah di latih sebelumnya.

Tabel Keterangan Grafik Hasil Proyeksi Data

Tabel Data History		Tabel Data Prediksi	
Tanggal	RR	Tanggal	RR
16/10/04	0.50	09/12/04	14.50
17/10/04	2.00	10/12/04	19.42
18/10/04	97.00	11/12/04	18.29
19/10/04	51.00	12/12/04	18.26
20/10/04	60.20	13/12/04	18.28
21/10/04	23.00	14/12/04	18.39
22/10/04	10.00	15/12/04	20.56
23/10/04	17.00	16/12/04	20.67
24/10/04	2.00	17/12/04	20.85
25/10/04	0.10	18/12/04	20.87

Show 10 entries Show 10 entries

Showing 1 to 10 of 54 entries Showing 1 to 10 of 11 entries

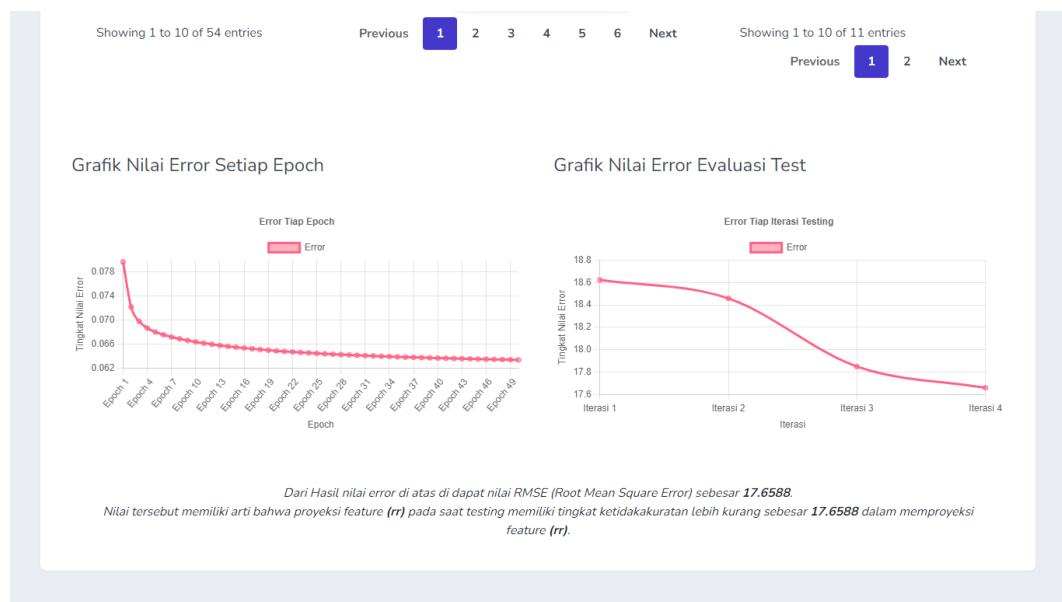
Previous 1 2 3 4 5 6 Next Previous 1 2 Next

Gambar 5.31. Interface Tabel Keterangan Grafik Hasil Proyeksi Data

Kemudian dapat dilihat yang terdapat pada Gambar 5.31 di atas merupakan sebuah tampilan interface yang berbentuk tabel keterangan sebagai penjelasan dari nilai grafik pada Gambar 5.30 dari Hasil Proyeksi sebelumnya dengan model yang telah di latih.

5.2.1.8.3. Interface Grafik Error Hasil Proyeksi Data

Pada tampilan *interface* Halaman dari Hasil Proyeksi pada bagian bawah yang memperlihatkan nilai *error* dari hasil setelah melakukan beberapa tahap-tahap terhadap pengujian training dan testing, yang dapat di lihat seperti yang terlihat pada Gambar 5.32 berikut



Gambar 5.32. Interface Grafik Error Hasil Proyeksi Data

Pada Gambar 5.32 respons nilai *error* Hasil Proyeksi terlihat dalam bentuk grafik garis statistik *Error* pada kedua grafik, yang mana pada grafik sebelah kiri memperlihatkan nilai *error* dari setiap *epoch* yang di lakukan, dan sebelah kanan memperlihatkan nilai *error* dari setiap iterasi testing model di lakukan, kemudian pada bagian bawah terdapat kalimat penegas dari rata-rata akar nilai *error* hasil

testing model yang memiliki arti bahwa prediksi *feature* yang di pilih pada saat testing memiliki tingkat ketidakakuratan sebesar nilai yang di tampil dengan rentang nilai sesuai dengan nilai asli pada kehidupan nyata.

5.2.2. Pengujian Sistem

Pengujian Sistem ini dilakukan agar mendapatkan hasil proses kalkulasi dan rancangan algoritma sesuai yang di harapkan agar tidak menyimpang dari tujuan masalah yang ingin di capai atau di dapatkan dan tidak melebihi dari batasan masalah yang di inginkan.

Dalam pengujian peneliti menguji dengan membandingkan Hasil Proyeksi dari sistem yang telah di rancang dengan perhitungan manual yang di lakukan pada bab sebelumnya, termasuk melakukan pengujian dengan *python library* milik *Google* yaitu *Tensorflow.JS* sebagai acuan nilai tepat dari hasil kalkulasi algoritma untuk model LSTM yang di rancang.

Tensorflow.JS merupakan perpustakaan perangkat lunak yang dikembangkan oleh *Tim Google Brain* dalam organisasi penelitian *Mesin Cerdas Google*, untuk tujuan melakukan pembelajaran mesin dan penelitian jaringan syaraf dalam. *Tensorflow.JS* dapat membuat implementasi *Artificial Neural Network (ANN)*, termasuk *Recurrent Neural Network (RNN)* maupun *Long Short-Term Memory*, dan lain sebagainya.

Untuk itu peneliti melakukan pengujian sistem dengan membandingkan hasil Prediksi beserta hasil error dari proses training dan testing yang di lakukan dengan acuan nilai akhir tidak menjauhi nilai akhir dari kalkulasi dengan menggunakan software *Tensorflow.JS*.

Nilai *Hyperparameter* yang di uji dalam Pengujian Sistem, sama persis dengan pengujian dan dilakukan dalam perhitungan manual, manupun dalam *Python library* milik *Google* yaitu *Tensorflow.JS*, untuk lebih jelasnya nilai *Hyperparameter* yang di uji terlihat seperti pada Tabel 5.1 berikut.

Tabel 5.1. Nilai *Hyperparameter* Dalam Pengujian Sistem

<i>Hyperparameter</i>	Nilai
Jumlah <i>Epoch</i>	50
Ukuran <i>Batch</i> (n)	1
Panjang <i>Timestep/Sequence</i>	2
<i>Features</i>	rr
Jumlah <i>Units LSTM</i>	1
Jumlah <i>Hidden Layer</i>	1
<i>Learning rate</i> (γ)	0.1
Probabilitas <i>Dropout</i>	0
Inisialisasi <i>Weight</i> dan <i>Bias</i>	<i>Xavier Initialization</i>

Nilai Hyperparameter dari Tabel 5.1 di atas dapat dijadikan sebagai acuan pengujian data yang dapat dilakukan sesuai dengan proses analisa dan perancangan yang dilakukan pada penjelasan langkah-langkah yang dapat dilihat dari bab sebelumnya.

5.2.2.1. Pengujian Perbedaan Nilai MSE Setiap *Epoch*

Pengujian nilai *MSE* setiap *Epoch* yang dilakukan dapat hasil dari nilai rata-rata seluruh nilai *error* pada setiap *batch* dalam setiap *epoch*, nilai tersebut di

bandingkan satu sama lain dengan *tensorflow.js* sebagai acuan nilai akurat dalam perhitungan model LSTM, seperti yang terlihat pada Tabel 5.2 berikut.

Tabel 5.2. Perbandingan Hasil Nilai MSE Epoch 1-50

<i>Epoch</i>	$\sum MSE$ (Perhitungan Manual)	$\sum MSE$ (Tensorflow.JS)	$\sum MSE$ (Perhitungan Sistem)
1	0.082276	0.079853	0.079693
2	0.075683	0.071690	0.072162
3	0.072499	0.069027	0.069772
4	0.070754	0.067831	0.068674
5	0.069697	0.067166	0.068021
6	0.069002	0.066732	0.067557
7	0.068510	0.066414	0.067190
8	0.068140	0.066161	0.066882
9	0.067844	0.065949	0.066614
10	0.067598	0.065765	0.066377
11	0.067386	0.065601	0.066164
12	0.067198	0.065454	0.065971
13	0.067029	0.065319	0.065795
14	0.066873	0.065196	0.065634
15	0.066729	0.065082	0.065486
16	0.066594	0.064977	0.065349
17	0.066467	0.064878	0.065222
18	0.066348	0.064787	0.065105
19	0.066235	0.064701	0.064995
20	0.066127	0.064621	0.064893
21	0.066025	0.064546	0.064797
22	0.065927	0.064475	0.064706
23	0.065834	0.064408	0.064622
24	0.065745	0.064344	0.064542
25	0.065660	0.064284	0.064466
26	0.065578	0.064227	0.064395
27	0.065500	0.064173	0.064327
28	0.065425	0.064122	0.064263
29	0.065352	0.064073	0.064202
30	0.065283	0.064026	0.064144
31	0.065216	0.063981	0.064088
32	0.065151	0.063938	0.064035

33	0.065089	0.063897	0.063985
34	0.065029	0.063858	0.063937
35	0.064971	0.063820	0.063891
36	0.064915	0.063784	0.063847
37	0.064861	0.063749	0.063804
38	0.064808	0.063716	0.063764
39	0.064758	0.063684	0.063725
40	0.064709	0.063653	0.063687
41	0.064661	0.063623	0.063651
42	0.064615	0.063594	0.063617
43	0.064570	0.063566	0.063584
44	0.064527	0.063539	0.063552
45	0.064485	0.063513	0.063521
46	0.064444	0.063487	0.063491
47	0.064404	0.063463	0.063462
48	0.064366	0.063439	0.063435
49	0.064328	0.063416	0.063408
50	0.064291	0.063394	0.063382

Pada Tabel 5.2 ini menampilkan hasil dari nilai *MSE* setiap epoch pada perhitungan manual, perhitungan tensorflowjs, dan perhitungan dari program yang di rancang dengan perbedaan hasil dari nilai *MSE* dari hasil yang didapatkan di rangkup menjadi nilai rata-rata dengan nilai toleransi perbedaan nilai *MSE* sebesar *0.001*. Hal ini masih masuk dalam kategori perbedaan nilai toleransi yang kecil.

5.2.2.2. Pengujian Perbedaan Nilai MSE Pada Evaluasi *Testing*

Pengujian nilai *MSE* pada Evaluasi *Testing* di lakukan di dapat hasil dari nilai rata-rata seluruh nilai *error* pada setiap iterasi Evaluasi *testing* dalam setiap *epoch*, nilai tersebut di bandingkan satu sama lain dengan tensorflowjs sebagai acuan nilai akurat dalam perhitungan model LSTM, seperti yang terlihat pada Tabel 5.3 berikut.

Tabel 5.3. Perbandingan Hasil Nilai Evaluasi Testing

Evaluasi (Perhitungan Manual)	Evaluasi (Tensorflow.JS)	Evaluasi (Perhitungan Sistem)
0.027642	0.032897	0.033142

Pada Tabel 5.3 menampilkan hasil nilai *MSE* pada evaluasi testing pada perhitungan manual, perhitungan tensorflowjs, dan perhitungan dari program yang di rancang di dapat perbedaan hasil rata-rata dengan perbedaan toleransi nilai sebesar 0.005. Hal ini masih masuk dalam kategori perbedaan nilai toleransi yang kecil.

5.2.2.3. Pengujian Perbedaan Nilai Hasil Prediksi

Pengujian Nilai Hasil Prediksi ini di lakukan untuk dapat melihat hasil Prediksi sesuai hasil yang di harapkan dengan hasil perbedaan yang tidak terlalu signifikan, nilai tersebut di bandingkan satu sama lain dengan tensorflowjs sebagai acuan nilai akurat dalam perhitungan model LSTM, seperti yang terlihat pada Tabel 5.4 berikut.

Tabel 5.4. Perbandingan Hasil Prediksi

Hari Ke	Prediksi (Perhitungan Manual)	Prediksi (Tensorflow.JS)	Prediksi (Perhitungan Sistem)
1	0.187837	0.199734	0.200231
2	0.171560	0.187837	0.188577
3	0.170921	0.187463	0.188280
4	0.171590	0.187753	0.188416

Pada Tabel 5.4 menampilkan nilai hasil Prediksi pada perhitungan manual, perhitungan tensorflowjs, dan perhitungan dari program yang di rancang di dapat

perbedaan hasil prediksi dengan perbedaan toleransi nilai sebesar 0.01. Hal ini masih masuk dalam kategori perbedaan nilai toleransi yang tidak besar.

5.2.2.4. Konversi Hasil Prediksi Curah Hujan Dalam Nilai Nyata

Untuk tingkatan curah hujan memiliki nilai rentang berdasarkan tingkatan jumlah curah hujan dalam satuan milimeter, Satu milimeter hujan berarti air hujan yang turun di wilayah seluas satu meter persegi akan memiliki ketinggian satu milimeter jika air hujan tidak meresap, mengalir, atau menguap, berdasarkan nilai akumulasi yang di dapatkan peneliti pada *Stasiun Klimatologi Kelas II Sicincin Padang Pariaman*. Ambang batas nilai yang digunakan untuk menentukan intensitas hujan terlihat seperti pada Tabel 5.5 berikut.

Tabel 5.5. Rentang Nilai Curah Hujan

Nilai	Keterangan	Satuan
0	Berawan	<i>mm/hari</i>
0.5 – 20	Hujan ringan	<i>mm/hari</i>
20 – 50	Hujan sedang	<i>mm/hari</i>
50 – 100	Hujan lebat	<i>mm/hari</i>
100 – 150	Hujan sangat lebat	<i>mm/hari</i>
> 150	Hujan ekstrem	<i>mm/hari</i>

Seperti yang terlihat pada Tabel 5.5 nilai curah hujan di ukur berdasarkan tingkatan curah hujan dalam 1 *milimeter*, maka dari itu perlu di lakukan konversi nilai hasil Prediksi ke nilai nyata agar nilai Prediksi tersebut dapat di implementasikan untuk Prediksi curah hujan dalam kehidupan nyata.

Berdasarkan output hasil prediksi masih berbentuk nilai normalisasi *minmaxscaller*, maka dari itu perlu di lakukan konversi nilai hasil Prediksi dari hasil Prediksi Perhitungan Sistem yang di rancang ke nilai nyata dengan di lakukan denormalisasi nilai, seperti yang terlihat pada

Tabel 5.6. Denormalisasi Nilai Hasil Prediksi Perhitungan Sistem

Hari Ke	Prediksi (Perhitungan Sistem)	Denormalisasi Prediksi (Perhitungan Sistem)	Nilai Real Hasil Prediksi (Perhitungan Sistem)
1	0.200231	19.4	Hujan ringan
2	0.188577	18.3	Hujan ringan
3	0.188280	18.3	Hujan ringan
4	0.188416	18.3	Hujan ringan

Berdasarkan Tabel 5.6 hasil denormalisasi hari ke 1 untuk Perhitungan Sistem dari nilai 0.200231 di dapat nilai real sebesar 19.4 yang memiliki arti bahwa Prediksi feature (*rr*) curah hujan untuk hari ke 1 berdasarkan perhitungan sistem di perkirakan dalam rentang nilai 0.5 – 20 mm/hari, dapat di katakan prediksi curah hujan untuk hari 1 berdasarkan nilai rentang pada Tabel 5.5 dapat di katakan akan terjadi Hujan ringan.

BAB VI

PENUTUP

6.1. Kesimpulan

Berdasarkan perancangan arsitektur dan sistem terhadap dataset yang di dapat, yang telah diuraikan pada bab sebelumnya, dengan melakukan penelitian dan penganalisaan dengan menggunakan metode-metode penelitian yang dibutuhkan untuk membangun arsitektur model yang dirancang, maka dapat diambil kesimpulan sebagai berikut.

1. Proses prediksi curah hujan dengan menggunakan pendekatan *Deep Learning* menggunakan metode *Long Short-Term Memory* dapat menghasilkan alternatif dalam pengambilan keputusan, dimana dalam pengambilan keputusan metode *Long Short-Term Memory* memberikan ketepatan hasil prediksi sesuai nilai *error* dari hasil evaluasi, yang mana besar dari nilai *error mean squared error* prediksi tersebut bisa digunakan sebagai alternatif pengambilan keputusan, dalam memprediksi curah hujan.
2. Menerapkan *Deep Learning* menggunakan metode *Long Short-Term Memory* dapat melakukan prediksi curah hujan dengan menggunakan data pada masa lampau, dimana data curah hujan pada masa lampau digunakan untuk melatih model *Long Short-Term Memory* sehingga model tersebut dapat memberikan pola gambaran data selanjutnya untuk prediksi curah hujan di masa depan.
3. Pengujian *Deep Learning* menggunakan metode *Long Short-Term Memory* diimplementasikan ke dalam sebuah sistem yang dibangun untuk memprediksi curah hujan agar proses pengujian dapat dilakukan lebih praktis dan efisien

dimana pengaturan nilai-nilai *hyperparameter* dan jangka waktu Prediksi curah hujan dapat di lakukan dengan lebih mudah sesuai kebutuhan, Riwayat Proyeksi juga di simpan ke dalam *database* setiap melakukan proyeksi, sehingga dapat menjadi perbandingan dalam melakukan pengujian di masa depan.

6.2. Saran

Berdasarkan kesimpulan yang telah diuraikan sebelumnya menggunakan metode LSTM untuk Proyeksi curah hujan, maka peneliti menyampaikan beberapa saran yang diharapkan menjadi bahan pertimbangan dengan harapan agar berguna bagi penelitian ini dan penyempurnaan penelitian selanjutnya.

1. Penelitian ini masih dapat di kembangkan dengan menggunakan fungsi optimasi yang lebih efektif untuk penanganan perubahan nilai *Learning rate* sejalan dengan perubahan nilai *MSE* setiap iterasi sehingga dapat memperoleh hasil prediksi yang lebih akurat.
2. Menambahkan metode Proyeksi lain yang seperti metode *ARIMA* maupun metode *Deep Learning* seperti *Convolution Neural Network (CNN)* untuk meningkatkan peforma dalam memproyeksi curah hujan di masa depan.

DAFTAR PUSTAKA

- Aditya, M. A., Mulyana, R. D., Eka, I. P., & Widianto, S. R. (2020, February). Penggabungan Teknologi Untuk Analisa Data Berbasis Data Science. (Mesran, Penyunt.) *Seminar Nasional Teknologi Komputer & Sains (SAINTEKS)*, 51-56. Diambil kembali dari <https://prosiding.seminar-id.com/index.php/sainteks>
- Agusta, A., Ernawati, I., & Muliawati, A. (2021, August). Prediksi Pergerakan Harga Saham Pada Sektor Farmasi Menggunakan Algoritma Long Short-Term Memory. *JURNAL INFORMATIK*, 17(2).
- Al Amin, I. H., Lusiana, V., & Hartono, B. (2018, November 14). PENCARIAN LINTASAN PADA COLLISION DETECTION MENGGUNAKAN PENDEKATAN INTERPOLASI LINIER. *Prosiding SINTAK*, 2, 57-61. Diambil kembali dari <https://unisbank.ac.id/ojs/index.php/sintak/article/view/6513>
- Aldi, M. W., Jondri, & Aditsania, A. (2018, August). Analisis dan Implementasi Long Short Term Memory Neural Network untuk Prediksi Harga Bitcoin. *e-Proceeding of Engineering*, 5, 3548-3555. Diambil kembali dari <https://openlibrarypublications.telkomuniversity.ac.id/index.php/engineering/article/view/6739>
- Alpaydin, E. (2020). *Introduction to Machine Learning, fourth edition*. United States: MIT Press. Diambil kembali dari <https://books.google.co.id/books?id=tZnSDwAAQBAJ>
- Aprian, B. A., Azhar, Y., & Nastiti, V. R. (2020, November 2). Prediksi Pendapatan Kargo Menggunakan Arsitektur Long Short Term Memory. *Jurnal Politeknik Caltex Riau*, 6, 148-157. Diambil kembali dari <https://jurnal.pcr.ac.id/index.php/jkt/>
- Arfan, A., & ETP, L. (2019, August 22). Prediksi Harga Saham Di Indonesia Menggunakan Algoritma Long Short-Term Memory. *Seminar Nasional Teknologi Informasi dan Komunikasi*, 3(1), 225-230.
- Ashari, B. S., Otniel, S. C., & Rianto. (2019). PERBANDINGAN KINERJA K-MEANS DENGAN DBSCAN UNTUK METODE CLUSTERING DATA PENJUALAN ONLINE RETAIL. *JURNAL SILIWANGI*, 5(2), 64-67.
- Azise, N., Andono, P. N., & Pramunendar, R. A. (2019, July). Prediksi Pendapatan Penjualan Obat Menggunakan Metode Backpropagation Neural Network dengan Algoritma Genetika Sebagai Seleksi Fitur. *Jurnal Teknologi Informasi-CyberKU*, 15(2), 142-154. Diambil kembali dari <http://research.pps.dinus.ac.id/index.php/Cyberku/article/view/91/82>
- Azizah, L. M., Umayah, S. F., & Fajar, F. (2018, November). Deteksi Kecacatan Permukaan Buah Manggis Menggunakan Metode Deep Learning dengan Konvolusi Multilayer. *SEMESTA TEKNIKA*, 21, 230-236. doi:10.18196/st.212229

- Boruah, A., & Barman, P. P. (2018). A RNN based Approach for next word prediction in Assamese Phonetic Transcription. *Procedia Computer Science*, 143, 117-123. doi:10.1016/j.procs.2018.10.359
- cllau, j. (2020, June 20). *Perceptron*. Diambil kembali dari Medium: <https://medium.com/@cllaujhohan/perceptron-de822b401b58>
- Deng, X., Tong, Z., Lan, Y., & Huang, Z. (2020, May 15). Detection and Location of Dead Trees with Pine Wilt Disease Based on Deep Learning and UAV Remote Sensing. *AgriEngineering*, 2, 294-307. doi:10.3390/agriengineering2020019
- Ependi, U., Panjaitan, F., & Yulianingsih, E. (2018, October 19). Pemodelan Aplikasi Mobile Sebagai Penunjang Perjalanan Wisata Menggunakan UML Diagram. *Seminar Nasional Teknologi Informasi Dan Komunikasi*, 325-330.
- Fajarsari, E. J. (2020). Studi Komparatif Prediksi Kestabilan Lereng Dengan Menggunakan Machine Learning (ML). no. Ml.
- Flywind. (2018, June 23). *Graphs of the hyperbolic sine, cosine, and tangent*. Diambil kembali dari Wikipedia: https://en.wikipedia.org/wiki/File:Sinh_cosh_tanh_graphs_JCB.jpg
- François, C. (2018). *Deep Learning with Python*. Manning. Diambil kembali dari <https://books.google.co.id/books?id=Yo3CAQAAQAAJ>
- Ghosh, A., Bose, S., Maji, G., Debnath, N. C., & Sen, S. (2019, September). Stock Price Prediction Using LSTM on Indian. *Proceedings of 32nd international conference*, 63, 101-110. doi:10.29007/qgcz
- Glorot, X., & Bagio, Y. (2010). Understanding the difficulty of training deep feedforward neural networks. *Proceedings of the thirteenth international conference on artificial intelligence and statistics*.
- Gunova, V. (2021, Juni). IMPLEMENTASI DEEP LEARNING PADA SIMULASI AUTONOMOUS DRIVE MENGGUNAKAN AIRSIM. *Journal of Software Engineering, Information and Communication Technology*, 2, 83-92. Diambil kembali dari <https://ejournal.upi.edu/index.php/SEICT/article/view/34674>
- H. M., G. E., Menon, V. K., & S. K. (2018). NSE Stock Market Prediction Using Deep-Learning Models. *Procedia Computer Science*, 132, 1351-1362. doi:10.1016/j.procs.2018.05.050
- Hasanah, F. N., & Untari, R. S. (2020). *BUKU AJAR REKAYASA PERANGKAT LUNAK*. (M. Suryawinata, M. Nashrullah, & A. Y. Prajati, Penyunt.) Sidoarjo, Jawa Timur, Indonesia: UMSIDA PRESS.
- Hinton, G., Deng, L., Yu, D., Dahl, G. E., Mohamed, A.-r., Jaitly, N., . . . Kingsbury, B. (2012, October 18). Deep Neural Networks for Acoustic Modeling in Speech Recognition: The Shared Views of Four Research

Groups. *IEEE Signal Processing Megazine*, 82-97.
doi:10.1109/MSP.2012.2205597

Hu, J., Niu, H., Carrasco, J., Lennox, B., & Arvin, F. (2020, October 29). Voronoi-Based Multi-Robot Autonomous Exploration in Unknown Environments via Deep Reinforcement Learning. *IEEE Transactions on Vehicular Technology*, 69(12), 14413-14423.
doi:10.1109/TVT.2020.3034800

Ilahiyah, S., & Nilogiri, A. (2018, August 2). Implementasi Deep Learning Pada Identifikasi Jenis Tumbuhan Berdasarkan Citra Daun Menggunakan Convolutional Neural Network. *Jurnal Sistem & Teknologi Informasi Indonesia*, 3, 49-56. doi:10.32528/justindo.v3i2.2254

Ilham, W., & Fajri, N. (2020, May). PENENTUAN JUMLAH PRODUKSI TAHU DENGAN MENGGUNAKAN METODE FUZZY TSUKAMOTO PADA UKM ABADI BERBASIS WEB. *JURNAL DIGIT*, 10(1), 71~82.
doi:<http://journaldigit.org/index.php/DIGIT/article/viewFile/158/116>

Juanda, R. A., Jondri, & Rohmawati, A. A. (2018, August 2). Prediksi Harga Bitcoin Dengan Menggunakan Recurrent Neural Network. *e-Proceeding of Engineering*, 5, 3682-3690. Diambil kembali dari <https://openlibrarypublications.telkomuniversity.ac.id/index.php/engineering/article/view/6772>

Karno, A. S., Hastomo, W., Nisfiani, E., & Lukman, S. (2020, August 6). Optimais Deep Learning untuk Prediksi Data Saham Di Era Pandemi Covid-19. *Seminar Nasional Teknik Elektro dan Informasi*, 43-54.
doi:10.26905/santei.v1i1.3098

Knowledge@Wharton. (2018, February 13). *Vishal Sikka: Why AI Needs a Broader, More Realistic Approach*. Diambil kembali dari knowledge@wharton: <https://knowledge.wharton.upenn.edu/article/ai-needs-broader-realistic-approach/>

Kumar, D. P., Amgoth, T., & Annavarapu, C. S. (2019). Machine learning algorithms for wireless sensor networks: A survey. *Information Fusion*, 49, 1-25. doi:10.1016/j.inffus.2018.09.013

Manaswi, N. K. (2018). *Deep Learning with Applications Using Python*. Bangalore, Karnataka, India. doi:10.1007/978-1-4842-3516-4

Manu. (2021, January 30). *A simple overview of RNN, LSTM and Attention Mechanism*. Diambil kembali dari Start it up: <https://medium.com/swlh/a-simple-overview-of-rnn-lstm-and-attention-mechanism-9e844763d07b>

Moghar, A., & Hamiche, M. (2020, April). Stock Market Prediction Using LSTM Recurrent Neural Network. *International Workshop on Statistical Methods and Artificial*, 170, 1168-1173. doi:10.1016/j.procs.2020.03.049

Muflih, G. Z., Sunardi, & Yudhana, A. (2019, July). JARINGAN SARAF TIRUAN BACKPROPAGATION UNTUK PREDIKSI CURAH HUJAN

DI WILAYAH KABUPATEN WONOSOBO. *MUST: Journal of Mathematics Education, Science and Technology*, 4(1), 45-46.

- Pamungkas, F. S., Prasetya, B. D., & Kharisudin, I. (2020). Perbandingan Metode Klasifikasi Supervised Learning pada Data Bank Customers Menggunakan Python. *PRISMA, Prosiding Seminar Nasional Matematika*, 689-694. Diambil kembali dari <https://journal.unnes.ac.id/sju/index.php/prisma/>
- Pandji, B. Y., Indwiarti, & Rohmawati, A. A. (2019, September). PERBANDINGAN PREDIKSI HARGA SAHAM DENGAN MODEL ARIMA DAN ARTIFICIAL NEURAL NETWORK. *Indonesia Journal on Computing (Indo-JC)*, 4(2), 189-198. doi:10.34818/INDOJC.2019.4.2.344
- Pardede, J., & Ibrahim, R. G. (2020, December 31). Implementasi Long Short-Term Memory Untuk Identifikasi Berita Hoax Berbahasa Inggris Pada Media Sosial. *J-COSINE*, 4, 179-187. doi:10.29303/jcosine.v4i2.361
- Poornima, S., & Pushpalatha, M. (2019, October 31). Prediction of Rainfall Using Intensified LSTM Based Recurrent Neural Network with Weighted Linear Units. *Atmosphere*, 10. doi:10.3390/atmos10110668
- Priyanto, D., Zarlis, M., Mawengkang, H., & Efendi, S. (2019, December). Studi Literatur Konsep Dasar Machine Learning Dan Neural Network. *Seminar Nasional Matematika dan Terapan 2019*, 1, 160-166.
- Puspaningrum, A., Bunga, M. S., & Iryanto. (2020, November). Klasifikasi Perubahan Perangkat Lunak pada Mobile App Review dengan Menggunakan Metode Long Short Term Memory (LSTM). *Jurnal IKRA-ITH Informatika*, 3, 41-46.
- Putra, J. G. (2020). *Pengenalan Konsep Pembelajaran Mesin dan Deep Learning*. Tokyo, Jepang. Diambil kembali dari <https://wiragotama.github.io/resources/ebook/intro-to-ml-secured.pdf>
- Putra, M. R., Osmond, A. B., & Ansori, A. S. (2020, April 1). ESTIMASI HARGA KEBUTUHAN POKOK DI KOTA BANDUNG DAN PROVINSI JAWA BARAT MENGGUNAKAN METODE LSTM. *e-Proceeding of Engineering*, 7, 1455-1459.
- Putro, B., Furqon, M. T., & Wijoyo, S. H. (2018, November). Prediksi Jumlah Kebutuhan Pemakaian Air Menggunakan Metode Exponential Smoothing (Studi Kasus : PDAM Kota Malang). *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 2, 4679-4686. Diambil kembali dari <http://j-ptiik.ub.ac.id>
- Qiu, J., Wang, B., & Zhou, C. (2019, December 13). Forecasting stock prices with long-short term memory neural network based on attention mechanism. (T. Song, Penyunt.) *PLoS ONE*, 1-15. doi:10.1371/journal.pone.0227222
- Ranjit, S., Shrestha, S., Subedi, S., & Shakya, S. (2018, July 01). Foreign Rate Exchange Prediction Using Neural Network and Sentiment Analysis. *Proceedings - IEEE 2018 International Conference on Advances in*

Computing, Communication Control and Networking, ICACCCN 2018, 1173–1177. doi:10.1109/ICACCCN.2018.8748819

- Revi, A., Solikhun, & Safii, M. (2018, October). JARINGAN SYARAF TIRUAN DALAM MEMPREDIKSI JUMLAH PRODUKSI DAGING SAPI BERDASARKAN PROVINSI. *KOMIK (Konferensi Nasional Teknologi Informasi dan Komputer)*, 2(1), 297-304. Diambil kembali dari <http://ejurnal.stmik-budidarma.ac.id/index.php/>
- Rinaldi, R. (2019, February 26). PENERAPAN UNIFIED MODELLING LANGUAGE (UML) DALAM ANALISIS DAN PERANCANGAN APLIKASI E-LEARNING. *Jurnal SIMTIKA*, 2, 43–50. Diambil kembali dari <http://ejournal.undhari.ac.id/index.php/simtika/article/view/15>
- Rizki, M., Basuki, S., & Azhar, Y. (2020, March). Implementasi Deep Learning Menggunakan Arsitektur Long Short Term Memory Untuk Prediksi Curah Hujan Kota Malang. *REPOSITOR*, 2(3), 331-338.
- Sadli, A. (2018, April). SIMULASI PENGENALAN KARAKTER MENGGUNAKAN NEURAL NETWORK PADA MATLAB. *JURNAL SISTEM INFORMASI DAN TEKNOLOGI INFORMASI*, 7(1), 89-97.
- Satria, B. (2018, December 15). Prediksi Volume Penggunaan Air PDAM Menggunakan Metode Jaringan Syaraf Tiruan Backpropagation. *JURNAL RESTI*, 2(3), 674-684.
- Savalia, S., & Emamian, V. (2018, April 28). Cardiac Arrhythmia Classification by Multi-Layer Perceptron and Convolution Neural Networks. *Bioengineering*, 5, 2-10. doi:10.3390/bioengineering5020035
- Schneiderman, H., & Kanade, T. (2002, August 06). A statistical method for 3D object detection applied to faces and cars. *Proceedings IEEE Conference on Computer Vision and Pattern Recognition*. doi:10.1109/CVPR.2000.855895
- Sen, S., Sugiarto, D., & Rochman, A. (2020). Komparasi Metode Multilayer Perceptron (MLP) dan Long Short Term Memory (LSTM) dalam Peramalan Harga Beras. *target*, 4(1).
- Setiyani, L. (2018). *Rekayasa Perangkat Lunak [Software Engineering]*. (L. Setiyani, Penyunt.) Karawang, Jawa Barat, Indonesia: Jatayu Catra Internusa.
- Shekar, A. K., S'a, C. R., Ferreira, H., & Soares, C. (2018, April). Building robust prediction models for defective sensor data using Artificial Neural Networks.
- Siahaan, M., Jasa, C. H., Anderson, K., Rosiana, M. V., Lim, S., & Yudianto, W. (2020, November). Penerapan Artificial Intelligence (AI) Terhadap Seorang Penyandang Disabilitas Tunanetra. *Journal of Information System and Technology*, 1, 186-193. Diambil kembali dari <https://journal.uib.ac.id/index.php/joint/article/view/4322/1122>

- Sihombing, E. N., & Syaputra, M. Y. (2020, September 23). IMPLEMENTASI PENGGUNAAN KECERDASAN BUATAN DALAM PEMBENTUKAN PERATURAN DAERAH. *JURNAL ILMIAH KEBIJAKAN HUKUM*, 4, 419-434. doi:10.30641/kebijakan.2020.V14.419-434
- Sta. Klim. Kelas II Padang Pariaman. (2021, November). Padang Pariaman, Sumatera Barat, Indonesia: BMKG Klimatologi Padang Pariaman.
- Sucipto, L., & Syaharuddin, S. (2018, September 2). Konstruksi Forecasting System Multi-Model untuk pemodelan matematika pada peramalan Indeks Pembangunan Manusia Provinsi Nusa Tenggara Barat. *Jurnal Ilmiah Teknologi Sistem Informasi*, 4, 114-123. doi:10.26594/register.v4i2.1263
- Suhermi, N., Suhartono, Dana, I. G., & Prastyo, D. D. (2018, November). Pemilihan Arsitektur Terbaik pada Model Deep Learning Melalui Pendekatan Desain Eksperimen untuk Peramalan Deret Waktu Nonlinier. *Departemen Statistika*, 18, 153 –159. doi:10.29313/jstat.v18i2.4545
- Sulistyo, A., Yudhana, A., & Sunardi, S. (2018). PERANCANGAN SISTEM INFORMASI BREEDING PLACE TERHADAP KEJADIAN DEMAM BERDARAH DENGUE (DBD) BERBASIS MOBILE TECHNOLOGY. *Prosiding SNST Fakultas Teknik*, 1(1).
- Supriyadi, E. (2019, Oktober 16). PREDIKSI PARAMETER CUACA MENGGUNAKAN DEEP LEARNING LONG-SHORT TERM MEMORY (LSTM). *JURNAL METEOROLOGI DAN GEOFISIKA*, 21, 55-67. Diambil kembali dari <https://pdfs.semanticscholar.org/f17a/634eb087b317c0e9eaf632c0ec4350725eb3.pdf>
- Surtiningsih, L., Furqon, M. T., & Adinugroho, S. (2018, August 8). Prediksi Jumlah Kunjungan Wisatawan Mancanegara Ke Bali Menggunakan Support Vector Regression dengan Algoritma Genetika. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 2, 2578-2586. Diambil kembali dari <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/1857>
- Susilawati, & Muhamathir. (2019, January 2). Analisis Pengaruh Fungsi Aktivasi, Learning Rate Dan Momentum Dalam Menentukan Mean Square Error (MSE) Pada Jaringan Saraf Restricted Boltzmann Machines (RBM). *JITE (Journal of Informatics and Telecommunication Engineering)*, 2, 77-91.
- Swarnkar, A., & Swarnkar, A. (2019). *Artificial Intelligence Based Optimization Techniques: A Review*. Singapore, Singapore, Singapore: Springer. doi:https://doi.org/10.1007/978-981-15-0214-9_12
- Tabrani, M., & Pudjiarti, E. (2021, August 2). Pembangunan Perangkat Lunak E-Learning dalam Kegiatan Belajar Mengajar Sekolah Menengah Kejuruan Angkasa Husein. *Jurnal Sains Manajemen Informatika dan Komputer*, 20(2), 130~138. Diambil kembali dari <https://ojs.trigunadharma.ac.id/>

- Tarkus, E. D., Sompie, S. R., & Jacobus, A. (2020, Juni 30). Implementasi Metode Recurrent Neural Network pada Pengklasifikasian Kualitas Telur Puyuh. *Jurnal Teknik Informatika*, 15, 137-144.
- Thohari, A. N., & Hertantyo, G. B. (2018, August 11). Implementasi Convolutional Neural Network untuk Klasifikasi Pembalap MotoGP Berbasis GPU. *Conference on Electrical Engineering, Telematics, Industrial Technology, and Creative Media (CENTIVE)*, 50-55. Diambil kembali dari <http://conferences.ittelkom-pwt.ac.id/index.php/centive/article/view/9>
- Wahyudi, A. (2018). Perancangan sistem menggunakan metode sdlc. *J. Din. Inform*, 4(2), 1-7.
- Wibisono, Y., & Khodra, M. L. (2018, April 09). Pengenalan Entitas Bernama Otomatis untuk Bahasa Indonesia dengan Pendekatan Pembelajaran Mesin. doi:<http://dx.doi.org/10.31227/osf.io/vud2p>
- Wijaya, R., Masriadi, & Ikhlas, M. (2020, July). IMPLEMENTASI MODEL WATERFALL PADA PENGEMBANGAN SISTEM INFORMASI PERHITUNGAN NILAI MATA PELAJARAN BERBASIS WEB PADA SEKOLAH DASAR AL-AZHAR SYIFA BUDI JATIBENING. *INFORMATION SYSTEM DEVELOPMENT*, 5(2).
- Winoto, A. R. (2020, September). RANCANG BANGUN APLIKASI PRESENSI DENGAN MEDIA SUARA MENGGUNAKAN MFCC DAN ANN BERBASIS ANDROID. *Jurnal Ilmiah Sainsbertek Jurnal Ilmiah Sains & Teknologi*, 1, 46--57.
- Wiranda, L., & Sadikin, M. (2019, December). PENERAPAN LONG SHORT TERM MEMORY PADA DATA TIME SERIES UNTUK MEMPREDIKSI PENJUALAN PRODUK PT. METISKA FARMA. *Jurnal Nasional Pendidikan Teknik Informatika*, 8(3), 184-196.
- Zahara, S., Sugianto, & Ilmuddafiq, M. B. (2019, December 2). Prediksi Indeks Harga Konsumen Menggunakan Metode Long Short Term Memory(LSTM) Berbasis Cloud Computing. *JURNAL RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 3, 357–363. doi:[10.29207/resti.v3i3.1086](https://doi.org/10.29207/resti.v3i3.1086)
- Zhou, V. (2019, March 6). *Machine Learning for Beginners: An Introduction to Neural Networks*. Diambil kembali dari towards data science: <https://towardsdatascience.com/machine-learning-for-beginners-an-introduction-to-neural-networks-d49f22d238f9>